



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校

参赛队号

	1.
队员姓名	2.
	3.

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目：多模态情感的时序对齐、鲁棒预测与可解释建模

摘 要：

多模态情感预测面临三重困难：文本、语音与视觉在采样频率与时间尺度上差异显著，实际采集又常出现局部时段模态不可用，而多数模型的决策依据难以复核。本文以赛题提供的 CMU-MOSEI 系列数据为唯一数据来源，围绕时序特征构建、缺失鲁棒预测与可解释分析，依次建立不确定边界锚点对齐模型、教师-学生鲁棒预测模型与模态子集训练及输入干预解释模型。

针对问题一，以原词为时间锚点、以子词为输出位置，结合 BERT 语义表示、25 维声学描述符与 16 维人脸几何及运动描述符，采用 CTC 强制对齐与时间交叠池化建立三模态对应关系，并由观测覆盖、路径置信度与边界扰动合成锚点质量分数。完成附件 1 全部 100 条样本的处理：三模态特征维度分别为 50×768 、 50×25 与 50×16 ；1932 个原词中 1920 个生成时间区间，区间生成率为 99.38%。全量清单、词级明细与帧级记录支持从特征、词区间到原始帧段的逐级追溯，典型样本给出文字、语音与视频的对应关系。

针对问题二，建立三态感知可靠补全与融合模型 TSRF-D。以内容掩码与观测掩码区分填充、观测与局部缺失三种状态，通过观测节点加权补全、可靠度门控融合与双向时序编码联合预测情感极性与连续强度，训练阶段由真实标签监督、教师任务蒸馏与重建辅助目标共同约束。验证集 Macro-F1 为 0.6012、强度 MAE 为 0.5915，附件 2 测试集分别为 0.6138 与 0.6275；8 锚点局部文本缺失时 F1 降至 0.5198，而局部语音、视觉缺失时分别为 0.6157 与 0.6100，表明文本证据对当前模型的影响最大。补全相对回退使特征 MAE 降低 0.0260，改善主要来自视觉模态，蒸馏与门控在多种缺失条件下给出可核验的对照结果。模型完成附件 3 全部 30 条样本的极性与强度预测。

针对问题三，构建 ICF-Shapley 解释模型，以模态子集训练覆盖解释输入状态，在固定参考类别下精确枚举模态联盟，并通过局部输入删除定位证据片段。验证集 Macro-F1 为 0.6170、MAE 为 0.5954，附件 2 测试集分别为 0.6054 与 0.6303；96 条验证样本中，高分片段删除相对随机删除的 AOPC 差为 0.1068，95% 区间为 [0.0887, 0.1259]。完成附件 4 全部 20 条样本的预测与解释，结合词级 CTC 区间与真实视频 PTS 输出文本、语音与关键帧证据；不同随机种子与不同解释基线下的主要参考模态一致率分别达到 82% 以上与 87% 以上，模态贡献具有较高一致性。

关键词： 多模态情感 时序对齐 局部模态缺失 教师-学生蒸馏 Shapley 解释

1 问题重述

1.1 问题背景

情感状态经由语言内容、语音韵律与面部运动三条通道同时表达：词义决定评价的正负方向，语调、语速与能量反映强调、迟疑与情绪唤醒，面部关键点的运动则补充词面之外的态度信息。三者的物理载体并不相同，分别表现为离散词元序列、等间隔采样的声学帧与带时间戳的视频帧，在采样频率、特征维度与时间尺度上存在明显差异。

真实录制条件放大了这种差异：自动转写可能识别失败，音视频轨道的起止时刻与有效时长并不一致，部分视频帧中人脸检出失败，个别模态还会在局部连续时段内整体不可用。若按序号直接拼接三路特征，同一位置上的语义、语音与视觉信息可能对应不同时刻；若直接剔除不完整样本，则会损失本就有限的建模数据。因此，多模态情感预测需要先建立从原始素材到时序特征的对应关系，再在证据不完整时稳定输出情感极性与强度，并说明判断所依据的模态与局部片段，使结果可追溯、可复核。

1.2 问题描述

本文以赛题提供的 CMU-MOSEI 系列数据为唯一数据来源，依次完成三项建模任务。

问题一（多模态情感特征提取与时序对齐）：附件 1 提供筛选自 CMU-MOSEI 的 100 条英文原始视频及其转写与标注表，视频时长介于 2.648s 与 34.567s 之间。要求以原始素材为输入，建立文本、语音、视觉三模态情感特征提取与时序对齐的数学模型，明确原始样本的处理流程、各模态情感特征的定义与提取方法、跨模态时序对齐的规则与实现逻辑，特征提取的基础处理可使用开源工具或预训练模型。自生成的特征文件需满足三项要求：一是样本覆盖完整性，样本编号、模态文件与输出特征一一对应；二是时序组织可核验性，序列位置、有效长度、填充规则及其与原始素材的对应关系均有记录；三是方法合理性与可复现性，提取工具、关键参数、处理日志与复现说明齐备。同时以表格汇总全部 100 条样本的样本编号、模态类型、原始有效时长、特征维度与对齐粒度，选取典型样本展示文本片段、语音时段、视频帧段与三类特征的对应关系，并按统一格式保存全部特征。

问题二（模态局部缺失条件下的情感预测）：附件 2 给出官方对齐与非对齐两种版本的三模态标准化特征及标签，各 4850 条样本并按训练、验证、测试划分，其中对齐版本文本、语音、视觉矩阵形状分别为 $(N, 50, 768)$ 、 $(N, 50, 74)$ 与 $(N, 50, 35)$ ；附件 3 为无标签的模态局部缺失专项测试集，缺失表现为一个或多个模态中出现特征值全为零的随机连续区间，而非整个模态完全不存在。要求建立鲁棒情感预测模型，在局部模态信息不完整的条件下稳定输出情感极性与强度，分析缺失模态类型、缺失位置与缺失时长对预测性能的影响规律。训练集用于参数学习，验证集用于选择模型结构、超参数与决策阈值，附件 3 仅用于最终推理。分类任务采用 Accuracy 与 F1 评价，回归任务采用 MAE 与 Pearson 相关系数评价，预测结果按指定 CSV 格式提交。

问题三（可解释性情感预测）：附件 4 为无标签的真实场景视频及其对应三模态特征，特征字段、张量维度与时序组织方式与附件 2 一致，且三模态信息完整。要求在输出情感极性与强度的同时，以可量化、可复核的方式说明本次判断主要依据了哪些输入信息：给出不同模态在当前样本中的作用差异、对预测起主要作用的主要参考模态，以及各模态中与判断密切相关的局部片段，关键证据需可对应至原始文本片段、语音时段或视觉关键帧。附件 4 仅用于最终推理预测，预测与解释结果按指定 CSV 格式提交。问题二与问题三均以附件 2 为训练与验证数据，各自独立建模。

1.3 研究综述

多模态情感预测的研究沿两条主线展开 [1]: 一是跨模态表示与融合, 二是缺失条件下的鲁棒建模与决策解释; 赛题所用的 CMU-MOSEI 即为面向真实场景的多模态情感基准数据 [2]。

在特征表示与融合方面, 早期工作以张量外积显式建模模态间的高阶交互 [3], 随后注意力机制被用于自动学习模态间的信息权重与跨模态对齐 [4]; 预训练语言模型 [5] 与自监督语音模型 [6] 分别提供了语义与声学层面的高质量表示, 使不同模态的特征在可比空间内参与融合。时间对齐方面, 连接主义时序分类 (CTC) 为无切分序列与词序列之间提供了可微分的对齐路径 [7], 使声学帧到词级单元的时间归属可由模型输出直接推断, 为跨模态时间对应提供了可核验的中间变量。

在缺失鲁棒性与决策解释方面, 知识蒸馏通过教师-学生结构把完整输入下的判别能力迁移到受损输入 [8], 为局部缺失场景提供了一条不依赖插补值的训练路径; 可解释性方面, Shapley 值为量化各模态对预测的贡献提供了具有公理化保证的博弈论工具 [9], 局部代理解释 [10] 与统一的加性归因框架 [11] 进一步把贡献分解推进到输入片段级别。

对本题而言, 上述方法留下三点需要专门处理的特殊性: 其一, 赛题要求以原始素材为输入自主完成特征提取与词级时间对齐, 通用融合模型并不提供可直接核验的时间对应记录; 其二, 附件 3 的缺失形态是局部连续区间不可用, 常见缺失填补方法多针对随机丢失, 缺少对连续缺口内候选证据塌缩的显式建模; 其三, 解释需在同一预测器上同时给出模态级作用程度与片段级证据, 并要求证据可回映至原始视频, 而通用解释方法通常只提供特征层面的归因。本文据此依次展开三项任务, 并在每问中给出可核验的处理记录与对照实验。

2 问题分析

2.1 总体思路

三项任务构成从时间组织到鲁棒预测、再到决策解释的递进链条。问题一处理原始素材与时间基准: 三模态采样粒度不同, 需先以词为公共时间锚点建立可核验的对应关系, 输出内容位置、观测掩码与词级时间区间。问题二处理证据不完整: 在附件 2 的官方对齐特征上区分填充、观测与局部缺失三种状态, 使预测在连续缺口存在时仍然可用。问题三处理决策可追溯: 在附件 2 上独立训练预测器, 通过固定参考类别的模态联盟分解与输入片段删除, 给出主要参考模态、模态作用程度与可回映到原始素材的关键证据。

三问的数据输入、模型节点与输出关系如图 1 所示。

图中上层汇总三问使用的四类原始数据: 附件 1 的 100 条视频与官方转写、附件 2 的官方对齐特征与标签、附件 3 与附件 4 的专项测试样本; 下层三个面板分别对应三问的处理流程与输出。问题一由文本、语音、视觉三路分别形成模态特征, 经 CTC 词级强制对齐确定词区间, 依次完成子词映射、交叠池化与质量评价, 输出 50 位定长接口。问题二在三态掩码上完成观测节点补全与可靠度门控融合, 经双向时序编码由双头输出极性与强度, 训练期由冻结教师提供分类与强度蒸馏。问题三以子集感知编码为预测器, 通过固定参考类别的模态联盟枚举分配模态贡献, 用锚点块删除定位局部证据, 并以累计删除对照、多基线与多种子分析校验解释结果。

三问并非串联流水线。问题一不向问题二、问题三传递特征, 只提供内容位置与观测掩码的三态口径以及词级时间锚点, 问题三的证据回映沿用同一时间映射方式; 问题二与问题三同源附件 2、共享输入接口与三态口径, 但各自独立训练、不共享参数。特征维度亦不混用: 问题一输出自提取的三模态接口 (768/25/16), 问题二与问题三使用附件 2 至




图 1 本文总体研究思路图。上层汇总三问使用的四类原始数据；下层三个并列面板分别给出特征提取与时序对齐、局部缺失鲁棒预测、可解释预测与证据定位的处理流程与输出。实线箭头为处理流程，虚线框为训练期与校验环节；跨面板虚线箭头标注三问间共享的时序口径与同源数据关系，问题二、三同源附件 2 但独立建模。

附件 4 的官方对齐特征 (768/74/35)。图中实线表示处理流程，虚线框表示训练期与校验环节，跨面板虚线箭头标注上述方法联系。

2.2 各问题的关键难点

问题一的核心是离散词元与连续音视频之间的时间对应。三模态采样率不同，且存在转写失败与人脸检出失败，需在词这一公共锚点上给出可核验的区间记录。拟以 CTC 词级强制对齐确定锚点，按字符偏移建立子词归属，以时间交叠权重聚合音视频特征，并通过覆盖率与边界扰动评价观测完整性与敏感性。

问题二的难点在于连续缺口内可能同时失去多模态证据，若以插补值充当观测，误差会沿融合路径继续传播。为此先区分填充、观测与局部缺失三种状态，仅从缺口外的可观测节点构造补全表示，并由门控控制其融合比例；训练阶段由完整输入学习的教师模型通过任务蒸馏约束学生，使基础性能不因鲁棒性设计而退化。实验按基础性能、缺失因素与组件作用三组对照展开，使设计选择与实测效果相互对应。

问题三的难点在于区分预测准确性与解释忠实性，并保持干预前后解释目标的一致性。拟以固定参考类别下的精确模态 Shapley 值刻画全局作用，以词元重编码后的局部删除衡量片段贡献，并将证据回映至原始转写、音频与视频帧；通过累计删除对照、多基线与多种子重复分别评价局部证据效果与解释稳定性。

3 模型假设

1. 官方转写与视频中的话语顺序一致，转写不改变话语先后。依据是该转写由赛题统一提供并与音轨逐条对应。这一条使词级强制对齐的单调路径约束成立，未通过字符目标构造的词也可按同一顺序单独记录。
2. 同一原词的子词共享父词时间区间，帧特征在其时间支撑区间内近似为分段常量。依据是词为发音的自然单位，而音频帧率远高于词长：前者使子词继承父词的音视频锚点，后者使式 (11) 的交叠积分退化为加权求和。
3. 附件 2 至附件 4 的对齐版本中，同一序列位置的三个模态共享官方给定的时间对应关系，局部缺失长度以锚点数度量。依据是这些附件按 `aligned_50` 组织，位置本身即对应单元。问题二与问题三因此只需处理观测可用性，不必重新估计时间对应。
4. 内容位置的文本 [UNK] 与全零音视频向量表示观测不可用，而非有效的特征取值。依据是附件 3 对局部缺失的定义即为特征值全为零的连续区间。填充、观测与缺失三种状态由此可由掩码唯一确定。
5. 人工遮挡只改变输入证据，不改变样本标签，既定情感目标在证据减少时仍具有可预测性。依据是遮挡由程序在训练阶段随机生成，原始标签不受其影响。问题二据此在附件 2 上构造缺失条件下的监督信号。
6. 附件 2 训练集估计的标准化统计量适用于验证集与附件 3、附件 4，推理期间模型权重与标准化统计量保持固定。依据是各附件由同一特征提取流程生成，维度与量纲一致。该约定避免推理阶段引入测试数据信息，并使跨附件指标在同一尺度下可比。

4 符号说明

表 1 列出三问共用的主要符号。上标 t, a, v 分别表示文本、语音与视觉， $m \in \{t, a, v\}$ ；原始素材的时间以秒计，对齐序列的长度以锚点数计，二者通过词级时间区间相互换算。问题一按自提取特征定义维度，问题二与问题三直接使用附件 2 至附件 4 的官方对齐特征，两套维度不混用，故符号表只给出与维度无关的通用形式。上标 t, a, v 分别表示文本、语音与视觉；原始素材时间以秒计，对齐序列长度以锚点数计。问题三沿用内容及观测掩码、预测值和原词时间区间，另以 $\mathcal{A}_i$ 、 ϕ_i^m 、 ω_i^m 、 m_i^* 和 $\Delta_i^m(E)$ 表示可用模态集合、模态 Shapley 贡献、模态作用份额、主要参考模态及局部删除效应，详细定义见第 5.3 节。

表 1 主要符号及含义

符号	含义
i, u, k, j	样本、原词、输出位置及特征帧的索引
$m \in \{t, a, v\}$	模态索引；涉及帧池化时 $m \in \{a, v\}$
$K, g_i(k)$	固定接口长度 ($K = 50$) 及第 k 个内容词元的父词编号
P_{ik}, O_{ik}^m	内容位置掩码与模态观测掩码，取值均为 0 或 1
$A_{iu} = [a_{iu}, b_{iu})$	第 i 条样本第 u 个原词的半开时间区间 (s)
$J_{ij}^m = [s_{ij}^m, e_{ij}^m)$	模态 m 中第 j 个特征帧的时间支撑区间 (s)
$\mathbf{f}_{ij}^m, r_{ij}^m$	帧级特征向量及有效性标记
$\ell_{ij}^m(A), \omega_{ij}^m(A)$	帧与锚点的有效交叠时长 (s) 及归一化池化权重
$\mathbf{x}_{iu}^m, X_i^m$	词级池化向量及固定 50 位的模态特征矩阵
c_{iu}, d_{iu}^m	CTC 路径置信度与词级模态覆盖指标，均位于 $[0, 1]$
B, s	边界扰动次数与扰动标准差，分别为 50 次和 0.04 s
V_{iu}^m, σ_{im}^2	扰动池化向量方差及样本内模态帧特征离散度
$\tilde{V}_{iu}^m$	由样本内尺度归一化的边界扰动方差
Q_{iu}^m, γ_m	综合质量分数及敏感度衰减系数， $\gamma_a = \gamma_v = 1$
T_i^a, T_i^v, Δ_i	音轨、视频轨的解码跨度及其差 $\Delta_i = T_i^a - T_i^v$ (s)
$H_{ik}^m, \tilde{O}_{ik}^m$	问题二的人工遮挡掩码及遮挡后的观测掩码
Ω_i, ρ_{ik}^m	样本内观测候选集合及补全融合权重
$y_i, r_i, \hat{y}_i, \hat{r}_i$	极性与强度真值及相应预测值
p_i^T, p_i^S, J	教师、学生类别分布及验证集联合选模指标

5 模型的建立与求解

本文按照原始素材处理与特征预测两个阶段组织数据。附件 1 的 100 条视频用于自主提取三模态特征，视频、音轨与官方转写通过样本标识关联；附件 2 的对齐版特征用于情感预测模型训练和评价，附件 3 的同版本特征用于专项推理。各阶段保留全部样本，通过内容掩码、观测掩码与截断记录描述有效范围。问题二的标准化参数仅由附件 2 训练集的观测位置估计。

5.1 问题一的模型建立与求解

5.1.1 问题分析与建模思路

附件 1 提供 100 条英文视频及对应转写文本。问题一要求从原始素材中提取文本、语音和视觉特征，并建立三类特征与原始片段之间可核验的时间对应关系。本问旨在构造具有统一时序组织、明确有效范围和完整溯源记录的多模态表示，为后续分析提供可解释的数据基础。

三种模态的时间结构存在差异：文本以离散词元组织，语音是连续采样信号，视觉则由带时间戳的视频帧组成。直接按序号拼接会混淆不同时间范围内的信息；按词数均分视频长度又会忽略语速、停顿和词长差异。此外，人脸未检出和文本接口截断均可能使部分位置缺少特征，必须与正常观测区分。

据此，本文采用**以原词为时间锚点、以子词为输出位置**的建模方案：首先利用官方转写与音频建立词级时间区间，再将子词映射到父词；在同一锚点区间内，对语音和视觉帧特征进行时间交叠加权聚合。进一步计算覆盖率与边界扰动敏感度，形成不确定边界锚点

对齐模型（Uncertain-Boundary Anchor Alignment, UBA）。图 2 给出总体流程。




图 2 三模态特征提取与时间锚点对齐流程。声学特征与强制对齐共用音频信号；视觉帧采用自身解码时间戳。

输出采用 50 位定长接口，每个内容位置通过父词索引关联实际时间区间。模型评价包括样本覆盖、区间结构、模态观测覆盖与参数敏感性四个方面。

5.1.2 数据准备

(1) 样本组织与数据特征

以视频标识与片段编号组成唯一键 `video_id$_clip_id`，连接视频文件、官方转写和输出记录。附件 1 共来自 37 个原始视频，包含 1932 个空白分隔原词和 2317 个 BERT 词元；完整文本中 283 个原词对应多个词元，占 14.65%。样本标签仅用于数据说明，不参与本问的特征提取或参数拟合。

(2) 时间基准与有效区间

音频解码、重采样和声道合并后得到信号 $x_i[n]$ ，采样率为 $f_s = 16000 \text{ Hz}$ ，其相对时间为 n/f_s 。声学描述符提取与词级强制对齐使用同一信号，避免两种音频处理链引入不同的时间原点。

视频第 j 帧的呈现时间取解码 PTS 与时间基的乘积，记为 t_{ij} 。100 条样本首帧 PTS 均为 0，23241 个解码帧的 PTS 完整且单调。根据容器编辑列表确定有效呈现范围，以音频相对秒数和视频 PTS 建立名义公共时间轴，保持两轨各自的原始时间尺度。

表 2 数据特点与相应处理方式

对象	实测特点	处理方式
文本长度	每条 5–65 词，5–82 个词元	保存全量词表，固定接口仅保留前 48 个内容词元
音频格式	源采样率 44.1 kHz，单/双声道 AAC	统一解码为 16 kHz 单声道信号
视频采样	8 种分辨率，帧间隔并非处处相同	使用逐帧 PTS，不由帧数和标称帧率反推时间
容器时间	90 条声明帧数与实解帧数不同	区分媒体样本数、有效呈现时长与解码跨度
视觉可观测性	4 条全片未检出人脸，另有局部未检出	保存有效帧掩码，缺失帧不参与池化




图 3 附件 1 的原词数、音视频解码跨度差及帧数统计。声明帧数与实解帧数的差额主要与容器编辑列表有关。

容器媒体时长、编辑列表时长和解码跨度分别描述存储范围、有效呈现范围与实际样本范围。100 条样本的有效视频、音频时长分别合计为 787.985 s 和 777.106 s。声明视频帧数为 33147，实解 23241，二者差额主要由编辑列表限定的呈现范围解释。逐样本汇总采用有效呈现时长；实际音频处理总时长为 777.0091 s。

记两轨解码跨度之差为 $\Delta_i = T_i^a - T_i^v$ 。其均值为 -92.3 ms，绝对值中位数为 91.3 ms。该量仅表示时长差，不作为同步偏移的估计。

图 3 给出样本长度与媒体时间分布。原词数具有长尾，因此在定长接口之外保留全量词级记录；音视频跨度及帧数统计存在差异，因此视觉分支采用实际解码帧与 PTS 建立时间支撑。

(3) 建模约定

以官方转写确定待对齐词序列，同一原词的子词共享其时间区间；视觉描述符取自成功检测的人脸，质量分数用于评价锚点的相对可用性。预训练模型保持冻结，分别承担特征编码和强制对齐，参数计算独立于附件 1 的情感标签。

5.1.3 模型构建

(1) 文本特征与词元归属

文本语义通过评价对象、情感词、否定与程度修饰表达情感。采用冻结的 bert-base-uncased 编码器 [5] 提取上下文词元表示，构成文本语义特征。

设原词 w_{iu} 在转写中的字符范围为 $[l_{iu}, r_{iu})$ ，分词器返回词元 z_{ik} 的字符范围 $[l_{ik}^z, r_{ik}^z)$ 。若词元范围包含于原词范围内，定义

$$g_i(k) = u \quad \text{当} \quad [l_{ik}^z, r_{ik}^z) \subseteq [l_{iu}, r_{iu}). \quad (1)$$

对非包含关系，依次按字符交叠和邻词附着确定归属；本批 100 条样本均由包含关系确定父词。词内标点继承父词的时间区间。

固定接口长度 $K = 50$ ，顺序安排 [CLS]、至多 48 个内容词元、[SEP] 及尾部 [PAD]。仅内容词元取 $P_{ik} = 1$ ，其余位置为 0。将包含特殊符号的完整接口输入 BERT 后，取最后一层隐藏向量：

$$X_{ik}^t = P_{ik} \mathbf{h}_{ik}, \quad \mathbf{h}_{ik} \in \mathbb{R}^{768}. \quad (2)$$

内容掩码 P 排除特殊符号，BERT 注意力掩码则保留 [CLS] 和 [SEP]。超过 48 个内容词元的尾部保存于全量词表，其父词继续参与音视频对齐与池化；位置级文本向量覆盖接口内的词元。

(2) 语音特征与词级时间估计

语音的响度、音高、谱形和发声质量能够表征重音、语调与发声方式，为情感分析提供区别于文字内容的线索。采用 openSMILE 的 eGeMAPSv02 低层描述符，获得 25 维帧特征 $\mathbf{f}_{ij}^a$ 。特征的时间起止点直接使用工具输出，帧移为 10 ms；保留原量纲，论文热图中的逐维标准化仅用于展示。

记第 j 个声学帧的工具输出支撑为 $J_{ij}^a = [s_{ij}^a, e_{ij}^a)$ 。池化按该支撑区间计算交叠权重，保留分析窗的交叠关系。LLD 提取与强制对齐共用 16 kHz 单声道 PCM 信号，具有一致的时间原点。

表 3 声学特征的组成与建模含义（合计 25 维）

特征组	维数	内容与作用
响度与谱形	6	响度、alpha 比、Hammarberg 指数、两个频段谱斜率、频谱通量，描述能量与频谱变化
倒谱表示	4	MFCC 1-4，描述短时谱包络
基频与发声质量	6	基频半音值、jitter、shimmer、HNR 及两项谐波相对能量，描述音高与声门发声特征
共振峰	9	第一至第三共振峰的频率、带宽与相对幅度，描述声道共振结构

词级时间估计采用预训练 wav2vec2 声学模型与 CTC 强制对齐。将原词映射为声学术典支持的大写字符，词间插入分隔符，构成目标序列 $\mathbf{y}_i$ 。无法产生目标字符的词保留为未对齐记录。设 $\pi_{it}(c)$ 为第 t 个声学输出帧对字符 c 的概率，最优路径为

$$\mathbf{z}_i^* = \arg \max_{\mathbf{z}: B(\mathbf{z}) = \mathbf{y}_i} \sum_t \log \pi_{it}(z_t), \quad (3)$$

其中 $\mathcal{B}$ 表示 CTC 的去空白与重复合并映射。对合并后的第 c 个目标字符，记其帧支撑为 $[\alpha_{ic}, \beta_{ic}]$ ；原词包含的目标字符集合记为 $\mathcal{C}_{iu}$ 。声学输出帧移 $h = 0.02 \text{ s}$ ，则

$$A_{iu} = \left[h \min_{c \in \mathcal{C}_{iu}} \alpha_{ic}, h \max_{c \in \mathcal{C}_{iu}} \beta_{ic} \right). \quad (4)$$

式 (4) 使用字符支撑的起点与终点，允许字符之间存在空白帧，不假定字符连续占据整个词区间。强制对齐在给定转写顺序下搜索最优声学路径 [7]。字符字典未覆盖的数字或符号保留为未对齐词；生成的词区间依次接受单调性、正长度和音轨边界检查。

先对字符支撑内的路径对数概率求均值，再汇总原词中的各字符，定义词级路径置信度：

$$\bar{\ell}_{ic} = \frac{1}{\beta_{ic} - \alpha_{ic}} \sum_{t=\alpha_{ic}}^{\beta_{ic}-1} \log \pi_{it}(y_{ic}), \quad c_{iu} = \exp \left(\frac{1}{|\mathcal{C}_{iu}|} \sum_{c \in \mathcal{C}_{iu}} \bar{\ell}_{ic} \right). \quad (5)$$

路径分数 c_{iu} 衡量声学模型对目标字符序列的支持程度。无法构造字符目标的词保留空区间，并单独记录可用性状态。

(3) 视觉特征与有效帧建模

视觉分支提取人脸几何与关键点位移，用于表征口型、眼眉形态及面部运动。先以 FaceDetection 定位最高分人脸，按人脸框宽高的 1.6 倍裁剪区域，再使用 FaceMesh 提取 478 个关键点；区域处理失败时尝试整帧检测。将区域内坐标映射回原图后，取二维像素坐标 $\mathbf{p}_{ijq} = (x_{ijq}, y_{ijq})$ 。

对于宽 W 、高 H 的原帧，设裁剪边界为 (x_0, y_0, x_1, y_1) ，FaceMesh 在裁剪图上返回归一化坐标 (u_{ijq}, v_{ijq}) ，则回映关系为

$$x_{ijq} = x_0 + u_{ijq}(x_1 - x_0), \quad y_{ijq} = y_0 + v_{ijq}(y_1 - y_0). \quad (6)$$

裁剪边界限制在 $[0, W] \times [0, H]$ 内，关键点回映后在统一像素坐标系中计算跨帧位移。两阶段检测用于改善小人脸与高亮背景下的人脸可观测性，未检出帧通过有效性掩码记录。

以脸宽和脸高的均值作为尺度

$$L_{ij} = \frac{|x_{ij,234} - x_{ij,454}| + |y_{ij,10} - y_{ij,152}|}{2} + 10^{-6}, \quad \delta_{ij}(p, q) = \frac{\|\mathbf{p}_{ijp} - \mathbf{p}_{ijq}\|_2}{L_{ij}}, \quad (7)$$

构造表 4 中的 14 个几何分量及 2 个运动分量，分别描述眼眉口部形态和关键点位移。

表 4 16 维视觉描述符的定义

维度	描述符	定义
1-3	嘴开合、嘴宽、开合宽比	$\delta(13, 14)$ 、 $\delta(61, 291)$ 及 $\delta(13, 14)/(\delta(61, 291) + 10^{-6})$
4-5	左右嘴角相对高度	上下唇中点纵坐标减嘴角 61 或 291 的纵坐标，再除以 L
6-7	左右眼开合	$\delta(159, 145)$ 、 $\delta(386, 374)$
8-9	左右眼宽	$\delta(33, 133)$ 、 $\delta(362, 263)$
10-11	左右眉眼距离	$\delta(105, 159)$ 、 $\delta(334, 386)$
12-13	补充眉眼距离	$\delta(70, 159)$ 、 $\delta(300, 386)$
14	脸高宽比	$ y_{10} - y_{152} /(x_{234} - x_{454} + 10^{-6})$
15-16	全脸与嘴部位移	相对前一有效检测帧的归一化关键点位移 RMS

设 j^- 为第 j 帧之前最近一次成功检测的帧。对全脸或嘴部关键点集合 $\mathcal{P}$ ，运动量定

义为

$$M_{ij}(\mathcal{P}) = \sqrt{\frac{1}{|\mathcal{P}|} \sum_{q \in \mathcal{P}} \frac{\|\mathbf{p}_{ijq} - \mathbf{p}_{ij-q}\|_2^2}{L_{ij}^2}}. \quad (8)$$

首次检测时运动分量置 0。\$M_{ij}\$ 表示当前帧相对前一有效帧的归一化位移幅度，允许两帧之间存在检测空缺。

人脸检测成功记 \$r_{ij}^v = 1\$，否则置 \$r_{ij}^v = 0\$ 并存储零向量。帧的支撑区间定义为

$$J_{ij}^v = [t_{ij}, t_{i,j+1}), \quad j < N_i^v; \quad J_{i,N_i^v}^v = [t_{i,N_i^v}, t_{i,N_i^v} + \hat{h}_i^v), \quad (9)$$

其中 \$\hat{h}_i^v\$ 为正帧间隔的中位数。这相当于将当前帧描述符保持到下一帧，在帧间隔较大时包含保持近似；因此视觉覆盖指标衡量的是该支撑约定下的人脸特征可用程度。

(4) 时间交叠池化与子词映射

不同模态无须先统一帧率。对词区间 \$A = [a, b)\$，令有效交叠长度为

$$\ell_{ij}^m(A) = r_{ij}^m \max\{0, \min(b, e_{ij}^m) - \max(a, s_{ij}^m)\}, \quad S_i^m(A) = \sum_j \ell_{ij}^m(A), \quad (10)$$

音频帧取 \$r_{ij}^a = 1\$，视觉使用检测有效性。若 \$S_i^m(A) > \varepsilon\$，则

$$\omega_{ij}^m(A) = \frac{\ell_{ij}^m(A)}{S_i^m(A)}, \quad \mathbf{x}_{iu}^m = \sum_j \omega_{ij}^m(A_{iu}) \mathbf{f}_{ij}^m, \quad d_{iu}^m = \min\left(1, \frac{S_i^m(A_{iu})}{b_{iu} - a_{iu}}\right), \quad (11)$$

其中 \$\varepsilon = 10^{-9}\$。无有效交叠时，令 \$\mathbf{x}_{iu}^m = \mathbf{0}\$、\$d_{iu}^m = 0\$。式 (11) 使部分交叠的帧按实际支撑长度贡献特征；权重归一化与覆盖指标分开计算，避免在归一化后丢失缺失程度的信息。对有重叠的声学分析窗，\$d^a\$ 为截断到 1 的支撑指标，并非窗口并集时长的无偏估计。

图 4 给出一组可手算的视觉例子。设词区间为 \$[0.08, 0.32)\$ s，四个相邻帧支撑各长 0.10 s，第三帧未检出人脸，则四帧有效交叠依次为 0.02, 0.10, 0, 0.02 s。由式 (11)，非零权重为 1/7, 5/7, 1/7，而覆盖指标为 0.14/0.24 = 0.583。即使权重和为 1，词区间仍有 41.7% 的时长缺乏有效视觉支撑；这正是单独保存 \$d^v\$ 的必要性。




图 4 交叠池化示意算例。灰色第三帧的视觉特征无效，不进入加权平均；词锚点与有效帧的交叠决定权重，覆盖指标另外记录缺失程度。图中时间和权重为说明公式的构造值，并非附件 1 样本统计。

通过父词映射，将音视频词级特征复制到对应子词位置：

$$X_{ik}^m = \begin{cases} \mathbf{x}_{i,g_i(k)}^m, & P_{ik} = 1, \\ \mathbf{0}, & P_{ik} = 0, \end{cases} \quad O_{ik}^m = P_{ik} \mathbf{1}\{d_{i,g_i(k)}^m > 0\}, \quad m \in \{a, v\}. \quad (12)$$

非内容位置的 O 定义为 0，不求值不存在的父词。三模态最终维度分别为

$$X_i^t \in \mathbb{R}^{50 \times 768}, \quad X_i^a \in \mathbb{R}^{50 \times 25}, \quad X_i^v \in \mathbb{R}^{50 \times 16}. \quad (13)$$

多个子词继承父词的完整区间，不等分原词时间； $P = 1, O^m = 0$ 表示位置存在但该模态无观测，而不是一个真实的全零特征事件。

(5) 边界扰动与质量分量

词边界变化会改变聚合帧及其权重。对区间两端加入标准差 $s = 40 \text{ ms}$ 的独立高斯扰动，采样 $B = 50$ 次并重新池化。两端先裁剪到模态时间范围；若终点不大于起点，设置 20 ms 的最小区间。池化使用修正区间与有效帧的实际交叠，完全无覆盖的扰动另行计数。

令 $\mathcal{H}_{iu}^m$ 为有覆盖的扰动集合， $B_{iu}^m = |\mathcal{H}_{iu}^m|$ 。当 $B_{iu}^m \geq 2$ 时定义

$$\bar{\mathbf{x}}_{iu}^{m,\text{pert}} = \frac{1}{B_{iu}^m} \sum_{q \in \mathcal{H}_{iu}^m} \mathbf{x}_{iu}^{m,(q)}, \quad (14)$$

$$V_{iu}^m = \frac{1}{B_{iu}^m} \sum_{q \in \mathcal{H}_{iu}^m} \left\| \mathbf{x}_{iu}^{m,(q)} - \bar{\mathbf{x}}_{iu}^{m,\text{pert}} \right\|_2^2. \quad (15)$$

原窗口无观测或有效扰动不足 2 次时，设置退化标记，方差字段以 0 占位。其余锚点的 V 衡量有观测条件下的边界敏感性，有效扰动次数 B_{iu}^m 随结果保存。

在每条样本内部，按有效帧计算模态尺度

$$\sigma_{im}^2 = \frac{1}{N_i^{m,\text{valid}}} \sum_{j:r_{ij}^m=1} \left\| \mathbf{f}_{ij}^m - \bar{\mathbf{f}}_i^m \right\|_2^2 + 10^{-12}, \quad \tilde{V}_{iu}^m = \frac{V_{iu}^m}{\max(\sigma_{im}^2, 10^{-9})}. \quad (16)$$

少于 2 个有效帧时，尺度取 1。归一化方差刻画池化变化相对于片段内特征变化的大小，各模态分别统计。

综合质量分数取

$$Q_{iu}^m = c_{iu} d_{iu}^m \exp(-\gamma_m \tilde{V}_{iu}^m), \quad \gamma_a = \gamma_v = 1. \quad (17)$$

路径置信度、观测覆盖和边界敏感性共同决定综合质量 Q 。保存 $c, d, V, \tilde{V}, Q$ 及退化标记，可按质量排序定位待复核锚点，并追溯相应影响分量。

三项分量相乘还有明确的边界行为：词对齐失败时没有可用锚点；锚点存在但人脸完全缺失时 $d^v = 0$ ，因而 $Q^v = 0$ ；仅当有覆盖且扰动能够产生至少两个有效池化结果时，边界敏感性才有可解释的估计。零覆盖与“稳定但数值小”属于不同状态，必须结合观测掩码和退化标记阅读 Q 。

5.1.4 模型求解与参数设置

(1) 求解流程

在冻结预训练模型的条件下，按以下步骤求解特征与时间映射。

1. 读取样本标识与官方转写，建立原词字符区间及词元归属，生成文本特征和 50 位内容掩码。
2. 解码音轨，提取 25 维声学帧特征；对全量原词构建字符目标，计算 CTC 路径、词区间及路径置信度。
3. 按视频 PTS 读取帧，计算 16 维人脸特征及有效帧掩码，建立各帧支撑区间。

4. 对每个已生成区间的原词执行交叠池化和边界扰动；未生成区间的词保留失败记录，不赋予人为时间。
5. 将词级特征映射到保留的子词位置，输出特征、掩码和质量分量；保存全量词表及截断尾部记录。
6. 汇总 100 条样本，核查样本键、张量形状、区间顺序和有效范围，并生成全量清单与典型对应图。

(2) 工具与关键参数

扰动随机种子由样本标识的 MD5 摘要前 8 位生成，固定 B, s, γ 后可在同一运行环境中复算。复现所需主要工具与参数见表 5。

表 5 特征提取工具与关键参数

模块	工具及版本	设置
运行环境	Python 3.12.10, CPU	NumPy 1.26.4, pandas 2.3.3
音视频解码	PyAV 18.1.0	音频 16 kHz 单声道，视觉采用解码 PTS
文本编码	transformers 4.56.0	bert-base-uncased, 推理模式, 50 位
声学描述符	openSMILE 2.6.0	eGeMAPSv02, LLD 层, 25 维
词级对齐	torch / torchaudio 2.8.0	WAV2VEC2_ASR_BASE_960H, 20 ms 帧移
人脸描述符	MediaPipe 0.10.21	FaceDetection 与 FaceMesh, 478 点, ROI 倍率 1.6
边界扰动	NumPy 随机生成器	$B = 50, s = 40 \text{ ms}, \gamma_a = \gamma_v = 1$

逐样本运行记录的累计处理耗时为 9.43 min，平均每条 5.66 s。其中视觉处理 482.20 s，占 85.3%；文本、音频及池化阶段分别为 6.95、65.16 和 11.25 s。该统计来自逐样本日志，不包含首次下载模型、论文绘图与编译，实际复现耗时随硬件和缓存状态变化。

特征张量、词级时间与帧级记录通过样本键和父词索引关联，形成表 6 所示的数据组织。文件字段、读取示例和 100 条逐项结果见附录 A。

表 6 多模态特征的层次组织与追溯关系

核验对象	输出记录与全量结果
样本对应	以唯一样本键连接媒体、转写和输出，清单保存输入哈希；100 条输入均对应特征记录
序列组织	固定 50 位，三模态维度为 768/25/16；保存内容掩码 P 、父词索引 U 及观测掩码 O^a/O^v
时间追溯	1932 条原词明细中 1920 条有区间 $[a, b)$ ；帧级文件保存音频支撑区间、视频 PTS 及有效标记
可复现性	保存工具版本、参数、逐样本耗时和随机种子规则；保留 100 份逐样本记录与 100 份帧级文件

5.1.5 实验结果与分析

(1) 全量处理结果与统计口径

100 条样本均完成处理。1932 个原词中，1920 个生成时间区间，区间生成率为 99.38%；其余 12 项包括 6 个数字词和 6 个标点或符号串，均未通过字符目标构造。已生成区间全部满足非负起点、正长度、音轨范围内终点和起点随词序单调四项条件。

表 7 以全部 1932 个原词与已生成区间的 1920 个原词为两个统计范围。音频覆盖在已生成区间上达到 1.000，视觉覆盖均值仅 0.9302，说明锚点信息的不完整主要来自人脸观测，而非声学支撑。

表 7 全量特征生成与覆盖结果

指标	结果	统计范围
样本输出 / 原词记录	100 / 1932	附件 1 全量
生成区间的原词	1920 (99.38%)	全部 1932 词
词区间时长均值 / 中位数	0.219 / 0.160 s	1920 个已生成区间
路径置信度均值 / 中位数	0.750 / 0.969	同上
音频覆盖均值	1.000 / 0.9938	已生成区间 / 全部原词
视觉覆盖均值	0.9302 / 0.9245	已生成区间 / 全部原词
视觉零覆盖词数	120 / 132	已生成区间 / 全部原词
全片未检出人脸的样本	4	100 条样本
触发截断的样本	6	100 条样本
未进入接口的词元 / 完全失位原词	70 / 52	全量文本尾部记录

12 个未生成区间的词在固定接口中仍占 22 个内容位置，其内容掩码 $P = 1$ ，观测掩码 $O^a = O^v = 0$ 。三态表示由此可以区分“有文本、无时间支撑”与“文本、时间支撑齐备”两类位置。另有 120 个已生成区间的词缺少视觉覆盖，说明时间区间是否有效与人脸观测是否有效是两个独立条件。

已生成区间的词时长中位数为 0.160 s，其中 28.1% 短于 0.10 s；若以解码音频总时长 777.0091 s 除以 1932 个原词，含词间停顿的平均间隔约为 0.402 s。两者的差异说明：按词数均分音轨会把词间停顿推入相邻词，并掩盖短词的真实边界。CTC 区间与交叠池化因此分别在声学证据与实际帧支撑上计算，而不由总时长反推每词边界。

图 5 从词元长度与词级观测状态解释接口覆盖的构成。全量 2317 个内容词元中，2247 个进入固定接口，保留比例为 96.98%；音频零覆盖的 12 词均未生成时间区间。视觉方面，除这 12 词外，还有 120 个已生成区间的词没有有效人脸特征支撑。因此，时间锚点的存在与模态观测的存在是两个独立条件，在模型中分别由内容掩码 P 与观测掩码 O^m 表达。




图 5 由样本清单和词级明细重算的接口覆盖情况。左图为 100 条样本的完整词元数，虚线表示 48 个内容词元上限；6 条样本触发截断，共 70 个词元未进入接口。右图以全部 1932 个原词为分母，区分完整、部分与零覆盖；完整覆盖按 $d \geq 1 - 10^{-6}$ 判定。

(2) 典型样本的文本、语音与视频对应

选取样本-I_e4mIh0yE\$_\$1。图 6 在统一秒轴上展示 6 个原词的音频区间、区间附近的视频帧，以及对应声学与视觉特征；表 8 给出数值关系。文本向量由这些词对应的 BERT 内容位置取得，视频帧则通过 PTS 定位，不由 50 位下标换算时间。




图 6 典型样本的原词、音频区间、视频帧和帧级特征对应。标出的 6 个原词依次关联其音频窗口和视频画面；声学热图的逐维标准化仅用于可视化。

表 8 典型样本的词区间与三模态映射。每个内容词元对应 768 维文本向量，并继承父词的 25 维语音向量与 16 维视觉向量。

原词	语音区间 (s)	内容词元数	c	d^a	d^v
States	[1.34, 1.58)	1	0.999	1.00	1.00
punish	[2.20, 2.50)	1	0.965	1.00	1.00
to	[3.52, 3.62)	1	1.000	1.00	1.00
which	[4.42, 4.62)	1	1.000	1.00	1.00
punished	[5.50, 5.86)	1	0.960	1.00	1.00
Europe.	[6.62, 6.86)	2	0.964	1.00	1.00

以 Europe. 为例，父词区间为 [6.62, 6.86) s，两个词元共享该区间，分别对应 768 维上下文文本表示，并继承相同的音视频池化向量。由此，词元语义、语音窗口和视频帧段通过父词区间建立一致的对应关系。

(3) 观测缺失与截断的处理效果

图 7 展示人脸检出率为 37.5% 的样本 -HwX2H8Z4hY\$_\$5。无有效视觉支撑的锚点取 $O^v = 0$ 、 $Q^v = 0$ ，其余位置按有效帧池化；音频与文本保留各自可用信息。该例说明位置级掩码能够刻画同一样本内部的局部模态缺失。




图 7 局部视觉观测缺失样本。上三幅以秒为横轴，下方质量条带以 50 位接口索引为横轴，二者通过父词映射和词区间关联。红带表示人脸特征无有效观测，灰色接口位置为非内容位。

文本方面，6 条样本超过 48 个内容词元，合计 70 个词元未进入接口，52 个原词完全失去接口位置。最严重样本含 65 个原词、82 个词元，其中 34 个词元与 26 个原词位于接口之外；这些词元的词级时间与音视频记录仍保留于全量输出。接口长度属于可配置参数，扩展后即可在相同记录上重新编码，无需重复特征提取。

图 8 并列展示定长接口与全量词区间。蓝色部分对应保留的 48 个内容词元，红色三格示意截断尾部；中图展示 65 个原词的时间记录，由此区分位置级输出范围与全量时间记录范围。

(4) 质量分量与参数敏感性

表 9 质量分量统计（1920 个已生成时间区间的原词）

分量	音频均值	音频中位数	视觉均值	视觉中位数
覆盖指标 d	1.0000	1.0000	0.9302	1.0000
归一化扰动方差 $\tilde{V}$	0.0931	0.0471	0.0498	0.0186
综合质量 Q	0.6848	0.8673	0.6904	0.9128

音频与视觉 $\tilde{V}$ 的 95% 分位数分别为 0.3328 和 0.1875，120 个视觉零覆盖词另记为退化状态。音视频 Q 的 Spearman 相关约为 0.765：两者共享路径置信度因子，排序差异则来自各自独立的覆盖与扰动分量。

图 9 展示质量分量及音视频 Q 的联合分布。路径置信度的差异使相同覆盖率的锚点




图 8 样本-a55Q6RWvTA\$_3 的文本接口截断。上：50 位接口的词元归属，右侧红格为截断尾部示意；中：全部原词的时间区间；下：内容掩码。实际有 34 个尾部词元未形成位置级文本特征，但词级时间记录仍保留。

具有不同质量；视觉 $Q = 0$ 对应零覆盖词。归一化扰动方差采用对数坐标展示，退化记录通过独立标记识别。

质量分数的三个参数按词区间的时间尺度与模块规模设定：衰减系数 γ 控制覆盖偏离的惩罚强度，扰动次数 B 与尺度 s 决定边界敏感性的估计精度。表 10 给出三者变化时的排序一致性，用以检验质量分量的取值是否依赖具体参数设定。

表 10 参数敏感性结果与适用范围

实验	已有结果	适用范围
γ 变化	音频 Q : 0.5 和 2 相对 1 的样本内排序相关均值 0.974、0.972	音频质量分量的排序在该参数取值范围内保持稳定
B 变化	视觉 V : 50 相对 200 的排序相关 0.995	在排序前 12 条样本各前 8 词上核算的视觉方差排序
s 变化	相对 40 ms, 20 ms 的样本内 Q 排序相关均值 0.937/0.937, 80 ms 为 0.960/0.901	音频与视觉分别计算的样本内排序一致性

在所选子集上， $B = 50$ 与 200 的视觉方差排序相关为 0.995，两种扰动次数对锚点给出的排序高度一致；22.9% 的点值平均差则来自扰动采样的随机波动。质量分量的排序结构不随扰动次数的具体取值改变，可用于锚点间的相对比较。

(5) 相对时序一致性检验

若时间映射正确，人为错位应当降低音视频之间的词级关联。据此设计单模态错位实验：保持一侧词窗口不动，仅将另一侧平移 ± 0.25 、 ± 0.5 或 ± 1.0 s，比较响度与嘴部开合、嘴部运动的词级相关。12 种非零错位条件下的两项平均相关均低于各自的样本配对基线，24 项 Wilcoxon 检验中 20 项在未校正的 5% 水平上显著，最小 p 约为 2.20×10^{-8} 。




图 9 1920 个已生成词区间的路径置信度、归一化边界扰动方差和综合质量分布。图 (d) 的音视频质量相关包含共享的路径置信度因子；零覆盖与退化记录需结合掩码判断。

各错位条件分别剔除越界与无覆盖词，相关变化同时包含时间平移与可用词集合变化的影响。在该口径下，任一非零错位都使两项相关下降，且多数差异在统计上显著，说明当前时间映射保持了音视频之间的词级关联。

在 83 条人脸检出率较高的样本上，包络相关最大值对应的延迟中位数为嘴部开合 +0.09 s、嘴部运动 +0.22 s 与全脸运动 +0.27 s，正值表示音频包络较晚。该量记为**包络最佳延迟**，用于描述词级音视频的联动强度，其取值依赖特征类型、取样方式与搜索范围。

附录 A 列出特征文件字段、读取方法及附件 1 全部 100 条样本的结果，与本节汇总统计和典型样本共同呈现特征生成、时间映射及观测覆盖情况。

(6) 结果讨论与适用范围

本模型把“三模态特征的组织”与“原始时间对应”作为两个问题分别处理，以词级区间作为可解释的中间变量：字符偏移保证子词归属可追踪，时间交叠池化使不同采样频率的特征映射到同一锚点，内容掩码与观测掩码分别刻画接口结构与模态可用性，三者共同构成该问的证据链。

本问的验证覆盖样本完整性、时间区间结构、观测覆盖与典型片段对应关系：**99.38%**的词区间生成率与典型样本的逐项对应共同支持处理流程的可追溯性，质量分量则在给定的提取与扰动规则下区分锚点的可用程度。**50** 位接口之外的词级时间与音视频记录保留于完整输出，位置级文本表示覆盖前 **48** 个内容词元。

据此获得附件 1 全部 100 条样本的三模态特征，输出维度为 50×768 、 50×25 与 50×16 ，1932 条原词记录中 1920 条生成时间区间。典型样本给出了文本、语音与视频的对应过程，全量结果及文件规范见附录 A。

5.2 问题二的模型建立与求解

5.2.1 问题分析与建模思路

实际交互中的转写失败、语音中断和画面遮挡，通常只使某一模态的局部连续片段不可用。问题二要求在此条件下，同时预测样本的情感极性与连续情感强度，并分析缺失模态、缺失位置、缺口长度及缺失率对预测性能的影响。因此，建模的关键不仅是融合三类特征，还在于区分有效观测与缺失信息，并控制不可靠补全对最终判断的影响。

针对上述问题，构建三态感知可靠补全与融合网络 TSRF-D，并采用教师-学生任务蒸馏进行训练。模型以结构填充、有效观测和局部缺失三种状态描述输入，利用样本内可用节点生成补全表示，通过可靠度门控调节补全信息与缺失嵌入的融合比例。在此基础上，采用双向时序编码器提取序列特征，实现情感极性与强度的联合预测。教师基于原始可用输入学习情感分布，学生在局部遮挡输入下同时接受标签监督和教师软监督。

问题一研究原始素材的特征提取与时间对齐，本问研究对齐特征在局部缺失条件下的情感预测。根据赛题数据安排，训练与评价采用附件 2 的对齐版特征，专项推理采用附件 3 的对应版本。两问沿用一致的时序表示思想，各自使用相应附件的特征维度与输入接口。

5.2.2 数据准备

(1) 数据划分与输入接口

附件 2 共含 4850 条样本，按题目给定划分使用 3395 条训练样本、728 条验证样本和 727 条测试样本；附件 3 包含 30 条无标签样本。每个样本存储为至多 50 个对齐序列位置，文本、语音、视觉特征维度分别为 768、74 和 35。三分类标签对应负向、中性和正向，连续强度位于 $[-3, 3]$ ；其中 0 仅属于中性类。强度标签包含非整数值，故按连续回归处理。

为统一训练与专项推理的文本输入，采用冻结的 bert-base-uncased 第 12 层，将 text_bert 中的词元编号、注意力掩码和分段编号转换为连续表示。重算特征与附件 2 自带特征的平均绝对偏差约为 6.6×10^{-7} ，最小余弦相似度约为 0.9999997，二者具有较高的数值一致性。

本文以对齐锚点为时间组织单位，假设同一锚点上的三模态特征具有附件规定的时间对应关系。由于附件 2 未提供逐词时间戳，缺口长度统一以锚点数度量。声学 & 视觉向量作为整体特征参与建模。

表 11 数据接口与处理约定

项目	附件 2	附件 3
用途与规模	训练 3395、验证 728、测试 727	最终预测 30 条，无标签
输入形状	$X^t \in \mathbb{R}^{50 \times 768}$, $X^a \in \mathbb{R}^{50 \times 74}$, $X^v \in \mathbb{R}^{50 \times 35}$	
文本入口	使用相同冻结 BERT，由 text_bert 生成连续表示	
缺失识别	文本内容位的 [UNK]；语音、视觉内容位的全零向量	
统计量估计	仅训练集观测位置估计均值与标准差	复用训练统计量
评价方式	基于真实标签计算分类与回归指标	汇总全量预测及预测概率分布

(2) 内容、观测与人工缺失掩码

记样本为 i ，锚点为 k ，模态 $m \in \{t, a, v\}$ 。内容掩码 P_{ik} 由注意力有效位排除 [CLS] 和 [SEP] 得到。自然观测掩码分别定义为

$$O_{ik}^t = P_{ik} \mathbf{1}\{\text{token}_{ik} \neq [\text{UNK}]\}, \quad (18)$$

$$O_{ik}^a = P_{ik} \mathbf{1}\{X_{ik}^a \neq \mathbf{0}\}, \quad O_{ik}^v = P_{ik} \mathbf{1}\{X_{ik}^v \neq \mathbf{0}\}. \quad (19)$$

其中 $X_{ik}^m \neq \mathbf{0}$ 表示该向量至少有一个非零分量。依据附件的缺失标记规则，文本由词元标记识别缺失，语音和视觉由全零向量识别缺失，三路观测掩码分别计算。

令人工遮挡掩码为 H_{ik}^m ，且 $H_{ik}^m \leq O_{ik}^m$ ，则最终观测掩码 $\tilde{O}_{ik}^m = O_{ik}^m(1 - H_{ik}^m)$ 。三态变量定义为

$$s_{ik}^m = \begin{cases} 0, & P_{ik} = 0, \\ 1, & P_{ik} = 1, \tilde{O}_{ik}^m = 1, \\ 2, & P_{ik} = 1, \tilde{O}_{ik}^m = 0. \end{cases} \quad (20)$$

自然缺失与人工缺失在模型输入中均为状态 2，但仅人工遮挡位置保留可用于重建评价的原始真值。对模态 m 的第 j 维，使用训练集观测位置估计 μ_j^m, σ_j^m 并计算

$$\bar{X}_{ikj}^m = \frac{X_{ikj}^m - \mu_j^m}{\tilde{\sigma}_j^m}, \quad \tilde{\sigma}_j^m = \begin{cases} 1, & \sigma_j^m < 10^{-6}, \\ \sigma_j^m, & \text{其他}. \end{cases} \quad (21)$$

结构位在标准化后置零，缺失位通过观测掩码排除于候选集合之外。人工音视频遮挡使用标准化空间中的零值；文本则先将选定词元替换为 [UNK]，再经 BERT 编码，同时保留原有序列位置。这样可以避免未遮挡位置的上下文表示提前包含已删除文本信息。

附件 3 共含 605 个内容锚点，文本、语音和视觉分别有 131、131 和 135 个缺失位置。文本与语音掩码在 30 条样本上逐位一致，文本与视觉掩码在 29 条样本上逐位一致，缺失主要表现为多模态局部同段共缺。

5.2.3 模型构建

(1) 总体结构与三态投影

图 10 给出学生网络及教师监督的关系。学生的计算顺序为投影、补全与门控、时序编码、池化和双任务预测；时序编码位于补全之后。




图 10 TSRF-D 网络结构与教师-学生监督关系。虚线表示训练阶段的辅助监督。

将三模态特征映射到公共维度 $d = 64$ 。设模型实际接收的标准化输入为 $\tilde{x}_{ik}^m$ ，则

$$z_{ik}^m = P_{ik} \left(W_m \tilde{x}_{ik}^m + b_m + e_m^{\text{mod}} + e_{s_{ik}^m}^{\text{state}} + e_k^{\text{pos}} \right). \quad (22)$$

模态嵌入描述信息来源，状态嵌入表征可观测性，位置嵌入保留序列顺序，三者共同形成缺失感知的节点表示。

(2) 观测节点加权补全

对样本 i ，以 $\Omega_i = \{(n, j) : \tilde{O}_{ij}^n = 1\}$ 为候选集。缺失位置的查询及候选键值为

$$q_{ik}^m = Q(e_k^{\text{pos}} + e_m^{\text{mod}} + e_2^{\text{state}}), \quad \kappa_{ij}^n = K_z(z_{ij}^n), \quad v_{ij}^n = V_z(z_{ij}^n), \quad (23)$$

其中 Q, K_z, V_z 为可学习仿射映射。查询由目标位置、模态与缺失状态共同确定，候选键值由有效观测生成，从而将缺失位置的结构信息与样本内容联系起来。

设 ℓ_{ij}^n 为候选位置所在连续观测段的长度，定义观测连续性先验

$$u_{ij}^n = \sigma \left(\alpha_0 + \alpha_1 \tilde{O}_{ij}^n + \alpha_2 \min(\ell_{ij}^n/10, 1) \right). \quad (24)$$

该先验利用连续观测段长度描述候选节点的局部可用性。对 $(n, j) \in \Omega_i$ ，补全代价及权重为

$$C_{i,k,j}^{m,n} = \frac{\|q_{ik}^m - \kappa_{ij}^n\|_2^2}{d} + \lambda_t \frac{|k-j|}{50} + \lambda_q (1 - u_{ij}^n), \quad (25)$$

$$\pi_{i,k,j}^{m,n} = \frac{\exp(-C_{i,k,j}^{m,n}/\tau)}{\sum_{(n',j') \in \Omega_i} \exp(-C_{i,k,j'}^{m,n'}/\tau)}, \quad \hat{z}_{ik}^m = \sum_{(n,j) \in \Omega_i} \pi_{i,k,j}^{m,n} v_{ij}^n. \quad (26)$$

上述代价综合表示距离、位置距离和观测连续性，其中时间项赋予邻近锚点较高的候选优先级。候选范围覆盖样本内全部可用模态，因而兼顾同模态时序信息与跨模态关联信息。

(3) 可靠度门控与情感预测

依据加权代价均值、加权方差、最小有效代价、候选数量占比及目标模态可用比例，构造门控输入

$$g_{ik}^m = [\bar{C}, \text{Var}_\pi(C), C_{\min}, |\Omega_i|/(3 \cdot 50), a_i^m, e_m^{\text{mod}}], \quad a_i^m = \frac{\sum_k \tilde{O}_{ik}^m}{\sum_k P_{ik}}. \quad (27)$$

两层感知机输出 $\rho_{ik}^m = \sigma(G(g_{ik}^m))$ ，并与可学习的缺失嵌入 e_m^{miss} 融合：

$$z_{ik}^{m,f} = \tilde{O}_{ik}^m z_{ik}^m + P_{ik} (1 - \tilde{O}_{ik}^m) [\rho_{ik}^m z_{ik}^m + (1 - \rho_{ik}^m) e_m^{\text{miss}}]. \quad (28)$$

门控权重 ρ 调节补全表示对融合结果的贡献。当候选集为空时，令 $\pi = 0, \rho = 0$ ，以缺失嵌入完成回退。

对每个模态独立进行单层双向 GRU 编码，双向隐状态合计 64 维。实现中按有效前缀打包序列，以避免尾部填充通过反向递归污染内容位置。随后仅在 $P = 1$ 处计算均值池化和最大池化，拼接三模态池化向量及 a_i^t, a_i^a, a_i^v ，形成 $6d + 3 = 387$ 维向量，经共享 MLP 得到 h_i 。双任务输出为

$$p_i = \text{softmax}(W_c h_i + b_c), \quad \hat{y}_i = \arg \max_c p_{ic}, \quad \hat{r}_i = 3 \tanh(w_r^\top h_i + b_r). \quad (29)$$

分类与回归采用共享表示和独立输出头，并通过下文的一致性损失建立任务间的软约束。

(4) 真实标签与任务蒸馏

教师采用相同的投影、时序编码与双任务输出结构，关闭补全和可靠度分支，在不额外加入人工遮挡的训练数据上学习；原有自然缺失仍保留。教师训练完成后冻结参数，学生接收人工缺失输入，利用任务蒸馏 [8] 学习教师的类别分布和强度输出。真实标签监督为

$$\mathcal{L}_{\text{sup}} = \text{CE}_w(y, p^S) + \lambda_r \text{Huber}_1(r, \hat{r}^S) + \lambda_c [(p_+^S - p_-^S) - \tanh(\hat{r}^S/3)]^2, \quad (30)$$

其中分类权重由训练标签频数计算，损失在批内汇总。教师与学生的分类 logits 记为 o^T, o^S ，温度为 T ，蒸馏目标为

$$\mathcal{L}_{dc} = T^2 \text{KL}(\text{sg}[\text{softmax}(o^T/T)] \parallel \text{softmax}(o^S/T)), \quad (31)$$

$$\mathcal{L}_{dr} = \text{Huber}_1(\hat{r}^S, \text{sg}[\hat{r}^T]). \quad (32)$$

sg 表示停止梯度。训练采用样本等权的蒸馏损失，并离线缓存教师在训练样本上的输出。分类蒸馏传递类别间的分布信息，强度蒸馏约束连续预测，两者共同指导学生学习的缺失条件下的情感表示。

(5) 补全与相对可靠度监督

对具有真值的人工遮挡集合 $\mathcal{H}_m$ ，使用可学习解码头 D_m 将补全表示映射回原始标准化特征空间：

$$\mathcal{L}_{rec} = \frac{1}{|\mathcal{M}_H|} \sum_{m \in \mathcal{M}_H} \frac{1}{|\mathcal{H}_m|} \sum_{(i,k) \in \mathcal{H}_m} \text{SmoothL1}_1(D_m(\hat{z}_{ik}^m), \bar{X}_{ik}^{m, \text{true}}), \quad (33)$$

其中每个向量的损失对特征维取均值， $\mathcal{M}_H$ 为当前批次存在人工遮挡的模式集合。重建目标为标准化后的原始特征，解码头与学生网络共同训练。

分别计算补全和回退表示相对真值的逐位置平均绝对误差 e_{rec}, e_{fal} ，构造

$$\rho^* = \text{sg}[\sigma((e_{fal} - e_{rec})/\tau_\rho)], \quad \mathcal{L}_{rel} = \text{BCE}(\rho, \rho^*). \quad (34)$$

可靠度损失同样先在各模式人工遮挡位平均，再在有遮挡模式间平均。该目标鼓励门控识别补全是否优于模型自身回退。自然缺失无原始真值，不参与上述两项监督。

综合目标为

$$\mathcal{L} = \mathcal{L}_{sup} + \beta_e (\lambda_{dc} \mathcal{L}_{dc} + \lambda_{dr} \mathcal{L}_{dr} + \lambda_{rec} \mathcal{L}_{rec} + \lambda_{rel} \mathcal{L}_{rel}). \quad (35)$$

首轮 $\beta_e = 0$ ，随后三轮线性升至 1，避免训练初期辅助目标主导优化。预热阶段保留分类、回归和一致性损失。

5.2.4 模型求解与参数设置

(1) 遮挡策略与训练流程

人工缺失由无新增遮挡、单模式局部缺口、多模式缺失和整模式丢弃混合构成，采样比例分别为 20%、45%、25% 和 10%。局部遮挡保留自然缺失，只作用于原可观测位置。文本通过预生成遮挡编码库轮换使用，降低 BERT 重复编码成本；音视频依据对应掩码处理。混合场景用于增强训练覆盖，整模式丢弃只承担压力训练作用。其中，含文本的 9 类遮挡模式按样本预生成并在轮次间选用；不含文本的模式按种子和轮次生成。局部缺口由参数为 0.35 的几何分布采样段长，并受目标遮挡预算、最大 32 锚点段长和样本边界限制。目标比例控制采样预算，实际遮挡量由最终掩码统计。

(2) 选模准则与关键参数

模型以验证集联合指标选择训练轮次：

$$J = 0.5 F_{\text{base}} + 0.5 \left(\frac{1}{4} \sum_{c \in \mathcal{C}} F_c \right) - 0.1 \text{MAE}_{\text{base}}, \quad \mathcal{C} = \{t, a, v, tav\} \text{的居中 8 锚点缺口}. \quad (36)$$

其中 F 为 Macro-F1，短样本按有效长度截断。“基础输入”指保留自然缺失、未增加人工遮挡的输入。准则 J 综合基础分类、局部缺失分类和基础强度回归表现，用于确定教师与学生的保存轮次。

表 12 TSRF-D 模型与训练参数

参数	取值
公共维度、Dropout	64、0.2
时序编码器	每模态单层 BiGRU；单方向隐维 32
补全参数	$\tau = 0.5, \lambda_t = 0.1, \lambda_q = 0.5$
观测连续性先验	$\alpha_0 = 0, \alpha_1 = 2, \alpha_2 = 0.5$ ；段长尺度 10
损失权重	$\lambda_r = 1, \lambda_c = 0.2, \lambda_{\text{rec}} = 0.5, \lambda_{\text{rel}} = 0.3$
蒸馏与门控目标	$\lambda_{\text{dc}} = \lambda_{\text{dr}} = 1, T = 2, \tau_\rho = 0.2$
优化器与调度	AdamW，初始学习率 0.0015，权重衰减 10^{-4} ，余弦调度
批量、轮数、早停	256、至多 32 轮、耐心值 8；梯度裁剪范数 5
随机种子与集成	学生和组件消融均使用 0、1、2；预测概率与强度分别取均值
计算环境	Python 3.12, PyTorch 2.8.0+cu128；RTX 5060 Ti；冻结 BERT 重算文本

模型参数由附件 2 训练集学习，保存轮次由验证集确定。求解分为教师训练与学生训练两个阶段：先训练并冻结教师，再在混合缺失场景下优化学生的联合目标。完成选模后，固定学生参数进行缺失干预实验及附件 3 推理。

(3) 教师-学生训练算法

算法 1 给出具体求解步骤。学生训练同时结合标签、蒸馏和重建辅助目标；预生成的文本遮挡特征按相应掩码索引，以保持输入与监督位置的一致性。

算法 1 TSRF-D 教师-学生联合训练

输入：附件 2 训练集 $\mathcal{D}_{\text{tr}}$ 、验证集 $\mathcal{D}_{\text{val}}$ ，冻结 BERT，缺失场景分布 $\mathcal{Q}$ ，损失权重，种子集合 $\{0, 1, 2\}$ 。

输出：按验证集联合准则选出的学生参数 $\{\theta_S^{*(s)}\}_{s=0}^2$ 。

- 1 构建内容掩码 P 和自然观测掩码 O ；仅用训练集观测位置拟合标准化统计量。
- 2 **对每个随机种子 $s \in \{0, 1, 2\}$ ，执行：**
- 3 初始化教师；在训练集基础输入上最小化 $\mathcal{L}_{\text{sup}}$ ，保留自然缺失。
- 4 每轮按验证集联合准则 J 选择教师；冻结最优参数，缓存其训练样本输出。
- 5 初始化学生 θ_S ；令 $J^* = -\infty$ ，最大轮数 $E = 32$ ，早停耐心值为 8。
- 6 **对 $e = 1, \dots, E$ ，执行：**
- 7 依据 $\mathcal{Q}$ 生成本轮遮挡掩码 H ，限制 $H^m \leq O^m$ ，并打乱训练样本。
- 8 设置辅助权重 $\beta_1 = 0$ ；第 2 至 4 轮依次为 1/3, 2/3, 1，此后为 1。
- 9 **对每个训练批次 $\mathcal{B}$ ，执行：**
- 10 保留遮挡前标准化真值 $\bar{X}^{\text{true}}$ ，仅供辅助损失使用。
- 11 将 $H^t = 1$ 处词元替换为 [UNK] 后编码；按掩码读取预生成文本特征。
- 12 音视频遮挡位使用标准化零值，更新 $\tilde{O} = O \odot (1 - H)$ 及三态变量。
- 13 学生前向：投影、加权补全、可靠度融合、BiGRU 与池化，得到 $p^S, \hat{r}^S$ 。
- 14 计算真实标签损失 $\mathcal{L}_{\text{sup}}$ ，读取冻结教师输出 $p^T, \hat{r}^T$ 。
- 15 计算分类与强度蒸馏损失 $\mathcal{L}_{\text{dc}}, \mathcal{L}_{\text{dr}}$ ；教师停止梯度。
- 16 仅在人工遮挡位计算 $\mathcal{L}_{\text{rec}}, \mathcal{L}_{\text{rel}}$ ；可靠度目标停止梯度。
- 17 按式 (35) 汇总损失；反向传播、梯度裁剪，使用 AdamW 更新学生。
- 18 **结束批次循环：**更新余弦学习率。
- 19 在验证集基础输入及四类固定局部缺口上计算 J ，评价时不更新模型参数。
- 20 若 $J > J^*$ ，保存学生参数并更新 J^* ；否则连续 8 轮无改善时提前停止。
- 21 **结束轮次循环，**恢复最优学生参数 $\theta_S^{*(s)}$ 。
- 22 **结束种子循环：**返回三组学生参数，用于冻结后的概率与强度集成。

说明：辅助权重为 0 时跳过对应损失；某批次没有人工遮挡时，重建与可靠度损失置零。附件 3 不进入本算法的训练和选模过程。




图 11 三个学生种子的训练过程。轮次从 1 开始；左图实线为基础输入验证 F1，虚线为四类固定局部缺口平均 F1；右图为联合选模指标，圆点标记实际保存轮次。

如图 11 所示，三个种子的分类指标在训练初期较快上升，随后进入波动区间。局部缺失条件下的 F1 整体低于基础输入，反映出信息遮挡带来的预测损失。联合准则在基础性能与缺失性能之间进行权衡，保存其最大值对应的学生参数。

5.2.5 实验结果与分析

(1) 评价指标与基础性能

分类采用 Accuracy 和 Macro-F1，回归采用 MAE 和 Pearson 相关系数。Macro-F1 对三类等权平均，以反映各类别的综合识别能力。评价时先对各随机种子的分类概率和强度预测取均值，再计算集成模型的指标。对照模型包括文本单模态、拼接 MLP 及不同缺失处理策略，种子数列于表 13；简单基线按基础 F1 选模，教师与学生按联合准则 J 选模。表 13

表 13 基础输入下各模型性能（各自种子概率与强度集成；验证 728 条，测试 727 条）

模型	种子	验证 F1	验证 MAE	测试 F1	测试 Acc	测试 MAE	测试 Pearson
仅文本	2	0.6192	0.6032	0.6077	0.6286	0.6394	0.6585
拼接 MLP	2	0.6037	0.5926	0.5882	0.6135	0.6456	0.6512
零填充	2	0.6001	0.5989	0.5877	0.6231	0.6428	0.6678
均值填充	2	0.6044	0.6063	0.5978	0.6272	0.6490	0.6647
缺失标记	2	0.6147	0.5981	0.5863	0.6176	0.6429	0.6685
模态丢弃	2	0.6089	0.6086	0.5902	0.6272	0.6380	0.6752
三态嵌入	3	0.5972	0.6076	0.6112	0.6437	0.6524	0.6653
TSRF-D	3	0.6012	0.5915	0.6138	0.6396	0.6275	0.6770
教师	3	0.6158	0.5933	0.6053	0.6300	0.6291	0.6769

给出基础输入下各模型的双任务指标。TSRF-D 在验证集上的 Accuracy、Macro-F1、MAE 与 Pearson 分别为 0.6099、0.6012、0.5915 与 0.6448，在测试集上分别为 0.6396、0.6138、0.6275 与 0.6770；相对文本单模态，其测试集 F1 高出 0.0061，两个划分的 MAE 分别降低 0.0117 与 0.0119。分类指标在两类输入下处于同一区间，而强度回归误差在两个划分上同时降低，三模态输入对连续强度的估计给出了一致改善。

样本级配对 bootstrap 检验显示，TSRF-D 相对缺失标记模型的测试集 F1 优势为 +0.0275 ($p = 0.033$)。基础输入下各模型总体处于同一性能区间，模型之间的差异更多来自局部缺失条件下的表现，下面按缺失形态分别考察。

(2) 局部缺失模态的影响

在附件 2 测试集上固定模型权重，对不同模态组合施加长度为 1、4 和 8 的连续锚点缺口。各条件均保留自然缺失，报告实际新增遮挡占比

$$\eta_H = \frac{\sum_{i,m,k} H_{ik}^m}{3 \sum_{i,k} P_{ik}}, \quad \Delta F = F_H - F_{\text{base}}, \quad \Delta E = \text{MAE}_H - \text{MAE}_{\text{base}}. \quad (37)$$

η_H 表示人工新增缺失占全部三模态内容位置的比例，总缺失率由新增缺失与自然缺失共同构成。各模态组合按同一随机数流依次采样缺口位置，比较条件保持相同的目标长度与测试样本。例如，长度 8 表示在内容序列中选取连续 8 个位置，将指定模态在这些位置上的观测遮挡；它度量对齐序列的跨度，单位为锚点。附件 3 的观测缺口长度为 1 至 4 个锚点，长度 8 用于检验较长中断下的性能。短于目标长度的样本按实际内容长度遮挡，此时可能覆盖该模态的全部内容位置。表 14 与图 12 表明，涉及文本的缺失组合对缺口长度

表 14 局部连续缺失的模态组合结果（测试 727 条，三种子集成；长度单位为锚点）

长度	遮挡模态	η_H	Macro-F1	MAE	ΔF
1	文本	0.0144	0.5929	0.6487	-0.0209
1	语音	0.0144	0.6122	0.6271	-0.0016
1	视觉	0.0134	0.6137	0.6266	-0.0001
1	文本 + 语音	0.0288	0.6068	0.6477	-0.0070
1	文本 + 视觉	0.0276	0.5969	0.6466	-0.0169
1	语音 + 视觉	0.0278	0.6114	0.6269	-0.0023
1	文本 + 语音 + 视觉	0.0420	0.6140	0.6414	+0.0002
4	文本	0.0574	0.5581	0.6912	-0.0556
4	语音	0.0574	0.6188	0.6259	+0.0050
4	视觉	0.0533	0.6050	0.6254	-0.0087
4	文本 + 语音	0.1149	0.5700	0.6790	-0.0438
4	文本 + 视觉	0.1108	0.6025	0.6839	-0.0113
4	语音 + 视觉	0.1105	0.6194	0.6228	+0.0056
4	文本 + 语音 + 视觉	0.1685	0.5806	0.6841	-0.0332
8	文本	0.1130	0.5198	0.7334	-0.0940
8	语音	0.1130	0.6157	0.6250	+0.0020
8	视觉	0.1046	0.6100	0.6206	-0.0038
8	文本 + 语音	0.2260	0.5370	0.7304	-0.0768
8	文本 + 视觉	0.2177	0.5311	0.7357	-0.0827
8	语音 + 视觉	0.2179	0.6227	0.6209	+0.0090
8	文本 + 语音 + 视觉	0.3309	0.5332	0.7406	-0.0806

最为敏感：8 锚点缺口下，仅文本缺失使 F1 由 0.6138 降至 0.5198、MAE 由 0.6275 升至 0.7334，且退化幅度随长度由 1 增至 8 逐档放大；仅语音、仅视觉缺失时 F1 分别为 0.6157 与 0.6100，与基础输入接近；三模态同段缺失时 F1 为 0.5332、MAE 为 0.7406。文本承担了较多的情感判别信息，文本缺口是局部缺失条件下的主要困难；音视频通道在文本完整时的边际贡献相对有限，却在文本失效时提供补偿。

(3) 缺失位置、长度与比例的影响

设置三组敏感性实验：位置实验分别遮挡内容首段、中段和尾段约三分之一的连续位置；长度实验随机放置 1、2、4、8、16 锚点的三模态共缺区间，短样本按有效长度截断，其实际新增遮挡量 η_H 由 4.20% 增至 60.71%，构成连续区间口径下的缺失率序列；比例实验采用随机点状遮挡，在各模态观测位置中按指定比例抽样，构成分散缺失口径下的缺失




图 12 不同模态组合与连续缺口长度下的预测性能。左：Macro-F1；右：强度 MAE。

表 15 位置、连续缺口长度与随机点状比例实验（测试 727 条，三种子集成）；前两项分析连续区间缺失，第三项分析分散缺失

条件	η_H	Macro-F1	MAE	ΔF	ΔMAE
位置：句首	0.3278	0.5638	0.6816	-0.0499	+0.0541
位置：句中	0.3276	0.5738	0.7011	-0.0400	+0.0736
位置：句尾	0.3257	0.5747	0.6904	-0.0391	+0.0629
长度：1	0.0420	0.5906	0.6438	-0.0232	+0.0163
长度：2	0.0842	0.5967	0.6619	-0.0171	+0.0344
长度：4	0.1680	0.5739	0.6967	-0.0399	+0.0692
长度：8	0.3307	0.5410	0.7412	-0.0728	+0.1136
长度：16	0.6071	0.4462	0.8026	-0.1676	+0.1751
点状比例：0.05	0.0479	0.6074	0.6352	-0.0064	+0.0077
点状比例：0.10	0.0984	0.5822	0.6662	-0.0316	+0.0387
点状比例：0.20	0.1975	0.5832	0.6761	-0.0306	+0.0486
点状比例：0.30	0.2929	0.5711	0.7141	-0.0427	+0.0865
点状比例：0.40	0.3917	0.5469	0.7316	-0.0668	+0.1041

率序列。前两组分析连续区间缺失，第三组分析分散缺失带来的影响。由表 15 和图 13 可知，句首遮挡对应最低 F1 (0.5638)，句中遮挡对应最高 MAE (0.7011)。三种位置的 F1 极差为 0.0108，位置效应小于模态类型与缺口长度的影响。缺口长度由 1 增加至 16 个锚点时，F1 总体由 0.5906 降至 0.4462，MAE 由 0.6438 升至 0.8026；其中长度 2 的 F1 略高于长度 1，表明分类变化并非逐档单调。长度 16 同时对应 60.71% 的实际新增遮挡量，故该结果体现连续跨度与信息损失数量的共同影响。

随机点状缺失比例从 5% 增加至 40% 时，F1 从 0.6074 降至 0.5469，MAE 从 0.6352 升至 0.7316。两项指标整体随缺失程度增加而退化，其中 F1 在个别相邻比例间出现小幅波动。连续缺口实验与随机点状实验共同反映了缺失几何和缺失数量对预测的影响。

两组序列的实际新增遮挡量区间相近，可在同一缺失程度坐标下比较缺失几何的影响。图 14 给出相应曲线：在实际新增遮挡量约 4%–5% 处，连续缺口与随机点状的 F1 分别为 0.5906 与 0.6074；在约 33% 处，连续缺口的 F1 为 0.5410，低于随机点状在 29.29% 与 39.17% 处的 0.5711 与 0.5469，强度 MAE 呈现同向差异 (0.7412 对 0.7141 与 0.7316)。在相近甚至更高的缺失数量下，随机点状缺失的性能仍高于连续缺口，说明除信息损失数量




图 13 缺失位置、连续缺口长度与随机点状缺失比例的敏感性。上排为 Macro-F1，下排为 MAE；灰色虚线表示基础输入性能。横轴比例为目标抽样比例，实际新增遮挡占比见表 15。

外，缺失在时间上的聚集方式同样影响预测。长度实验对短样本按有效长度整段截断，该序列同时包含整段覆盖带来的影响。




图 14 实际新增遮挡量 η_H 与预测性能的关系。左：Macro-F1；右：强度 MAE。连续缺口为长度 1–16 锚点的三模态共缺区间，随机点状为按比例分散遮挡；灰色虚线为基础输入性能。

需要说明三组实验的口径差异：模态组合实验与长度实验各自采样缺口位置，同为长度 8 的三模态共缺，两处分别得到 0.5332 与 0.5410，差别来自遮挡位置不同；位置实验则保持同样样本的目标长度不变，仅把区间移动到句首、句中与句尾，实际新增遮挡量的细微差别只源于自然缺失的分布。

整模态删除给出信息减少到极限时的参照：文本整体缺失时 F1 为 0.4088，三模态全

缺时为 0.1190。前者仍保留音视频观测，模型借此完成跨模态补偿，F1 保持在 0.40 以上；后者补全候选集为空、触发回退，性能降至 0.12 附近。两者的差值刻画了跨模态补偿在极端条件下的作用幅度。

（4）缺失条件下的消融与补全机制验证

为检验蒸馏、补全与可靠度监督各自的作用，在相同测试样本、相同固定干预掩码下比较关闭或替换相应模块后的预测性能，以排除掩码差异带来的干扰。各配置均使用三个种子，并采用与主模型一致的概率集成口径。结果列于表 16：基础输入列给出各配置在无新增缺失时的性能，用于区分模块自身的影响与缺失条件下的影响；连续段缺口列为句首、句中、句尾三种连续区间的 Macro-F1 均值，与表 15 的位置实验共用同一组掩码，对应实际新增遮挡量约 32.6%。

表 16 补充压力条件下的消融 Macro-F1（测试 727 条，各配置三种子概率集成；连续段缺口为句首、句中、句尾三种连续区间的均值）

配置	基础输入	连续段缺口	点状 20%	点状 40%	整缺文本
TSRF-D	0.6138	0.5708	0.5716	0.5490	0.4088
关闭全部蒸馏	0.6034	0.5763	0.5820	0.5467	0.4186
仅分类蒸馏	0.6096	0.5736	0.5670	0.5472	0.4166
仅强度蒸馏	0.6082	0.5802	0.5769	0.5449	0.4169
关闭补全分支	0.6087	0.5725	0.5907	0.5421	0.4155
关闭可靠度监督	0.6068	0.5783	0.5667	0.5507	0.4048
仅同模态候选	0.6122	0.5717	0.5618	0.5396	0.3815
仅跨模态候选	0.6132	0.5788	0.5788	0.5595	0.4014
关闭观测连续性项	0.6054	0.5730	0.5649	0.5544	0.4022
置信度加权蒸馏	0.6052	0.5755	0.5800	0.5400	0.4452

按组件逐项看：蒸馏的作用与缺失强度相关，随机 20% 缺失时关闭全部蒸馏使 F1 由 0.5716 升至 0.5820，而在随机 40% 缺失时由 0.5490 降至 0.5467；补全分支呈现同一方向，两种条件下分别变化 +0.0191 与 -0.0069，说明其收益随缺失强度而变。候选来源方面，40% 缺失下仅跨模态候选的 F1 为 0.5595，高于仅同模态候选的 0.5396，高缺失程度下跨模态信息的补偿作用更为明显。在相同连续区间条件下，各配置的 F1 介于 0.5708 与 0.5802 之间，极差 0.0094，小于点状缺失下的配置差异，说明共享连续缺口时组件之间的差异收敛。需要说明两组消融的口径：消融组内部共用固定掩码，但与敏感性实验采用各自独立的遮挡实现，故两表中 20% 与 40% 条件的数值分别对应其掩码；连续段缺口列与位置实验使用同一组掩码，用于在共享连续区间内比较组件作用。

为分析补全质量，在验证集设置四类居中 8 锚点缺口，以遮挡前的标准化特征为真值，比较学习补全、模型回退和均值填充的 MAE。三个种子与四类条件共形成 50388 条位置记录，结果按模态汇总于表 17。记录数包含样本在不同条件和种子下的重复评价。图 15 给

表 17 人工遮挡位的特征重建 MAE（验证集；记录数含多种子及多条件重复）

模态	记录数	补全	回退	均值填充	回退减补全
总体	50388	0.7140	0.7401	0.7407	+0.0260
文本	17142	0.7817	0.7852	0.7841	+0.0035
语音	17118	0.6618	0.6794	0.6787	+0.0176
视觉	16128	0.6975	0.7564	0.7605	+0.0589




图 15 逐模态补全效果。左：补全、回退及均值填充的特征 MAE；右：相对回退的 MAE 下降量。

出逐模态的补全效果：学习补全相对回退使总体 MAE 下降 0.0260，约 78.8% 的位置记录获得改善；分模态看，视觉、语音与文本的 MAE 分别下降 0.0589、0.0176 与 0.0035。视觉特征在标准化空间中的可重建性最好，而文本遮挡造成的预测退化最大，二者共同说明特征空间的近似误差与语义信息的丢失并不同质：数值上可重建的模态未必对预测最关键，文本缺口因而是后续优化的重点。

可靠度是否可用，取决于它与重建误差的实际关系：总体 Pearson 相关系数为 -0.0625 ，以“误差低于中位数”为正类的 AUC 为 0.6664；分模态计算时 AUC 为 0.5120、0.4392 与 0.5575，均低于混合统计，说明该判别力来自跨模态位置的误差尺度差异，而非单一模态内部的误差排序。上述指标在重复位置记录上评价绝对重建误差，与训练中相对回退的监督目标互为补充，分别刻画“特征是否被重建”与“重建是否优于回退”。门控取值干预直接检验融合权重的作用：固定 $\rho \equiv 0$ 时平均 F1 比学习门控低 0.0133，说明补全表示确实携带任务信息；固定 $\rho \equiv 1$ 与学习门控的平均 F1 相差 0.0039，两者处于同一水平。

(5) 验证集可视化与错误归因




图 16 验证集分类混淆矩阵、自然缺失分组准确率与覆盖率分析。

验证集三类 F1 分别为负向 0.6456、中性 0.4848、正向 0.6732。混淆矩阵中，206 条负向样本有 49 条判为中性；338 条正向样本有 92 条判为中性；184 条中性样本中有 34 条判为负向、46 条判为正向。共 284 条误判中，221 条涉及中性类，约占 77.8%，表明中性与正、负情感之间的混淆是主要错误类型。

中性类精确率为 0.4245，极性样本与中性样本的交界区间构成分类判别的主要着力点。结合文本缺失实验，文本证据的保留与中性边界的刻画是提高预测性能的两个重点；受控

遮挡实验给出不同缺失条件下的性能变化。

(6) 附件 3 全量预测与结果展示

冻结三个学生模型，分别输出分类概率和连续强度，再取算术平均：

$$\bar{p}_i = \frac{1}{3} \sum_{s=0}^2 p_i^{(s)}, \quad \hat{y}_i = \arg \max_c \bar{p}_{ic}, \quad \bar{r}_i = \frac{1}{3} \sum_{s=0}^2 \hat{r}_i^{(s)}.$$
 (38)

专项推理由冻结学生独立完成，以未经校准的最大类别概率 $c_i = \max_c \bar{p}_{ic}$ 衡量类别分布的集中程度，并同时记录种子间的预测标准差。

附件 3 的 30 条样本均完成预测，其中负向 7 条、中性 11 条、正向 12 条。最大类别概率均值为 0.5939，最小为 0.3694，13 条样本低于 0.5。全部样本均满足可用锚点数量规则，未触发兜底标记。附件 3 为无标签专项集，本节汇总其预测分布与逐样本结果。




图 17 附件 3 的缺失结构、三分类概率及最大类别概率。热力图表示缺失模态数量，0 也包含结构填充位置；虚线 0.5 仅作概率参照，不用于拒识。

表 18 列出全部 30 条样本的编号、内容长度、模态缺失计数、缺失率、预测极性、连续强度与最大类别概率，三类概率、种子间标准差与诊断标记一并写入预测结果文件。

表 18 附件 3 全部 30 条预测（缺失计数依次为文本/语音/视觉；最大概率未经校准）

编号	锚点数	缺失计数	缺失率	极性	连续强度	最大概率
3-01	6	0/0/0	0.0000	负向	-0.5468	0.5510
3-02	28	5/5/5	0.1786	中性	-0.0340	0.6782
3-03	32	5/5/9	0.1979	中性	+0.2972	0.5889
3-04	31	2/2/2	0.0645	正向	+0.4812	0.4923
3-05	12	0/0/0	0.0000	负向	-1.3953	0.9228
3-06	25	3/3/3	0.1200	正向	+0.9457	0.7818
3-07	21	3/3/3	0.1429	中性	+0.2034	0.3952
3-08	15	2/2/2	0.1333	正向	+0.7475	0.6083
3-09	14	2/2/2	0.1429	正向	+1.1769	0.8901
3-10	6	0/0/0	0.0000	中性	+0.0221	0.8000
3-11	14	4/4/4	0.2857	中性	+0.3927	0.4260
3-12	13	2/2/2	0.1538	正向	+1.1345	0.7688
3-13	19	2/2/2	0.1053	中性	+0.1896	0.4078

续下页

编号	锚点数	缺失计数	缺失率	极性	连续强度	最大概率
3-14	23	2/2/2	0.0870	负向	-0.5930	0.7110
3-15	27	3/3/3	0.1111	正向	+0.6544	0.6194
3-16	34	4/4/4	0.1176	正向	+1.3189	0.8447
3-17	22	8/8/8	0.3636	负向	-0.1464	0.4464
3-18	17	3/3/3	0.1765	中性	+0.4361	0.4876
3-19	24	7/7/7	0.2917	负向	-0.2082	0.4608
3-20	48	14/14/14	0.2917	中性	-0.1412	0.4622
3-21	9	3/3/3	0.3333	正向	+0.3313	0.4513
3-22	17	4/4/4	0.2353	负向	+0.0996	0.3694
3-23	13	4/4/4	0.3077	中性	+0.3399	0.5748
3-24	8	2/2/2	0.2500	负向	-0.0593	0.4709
3-25	9	2/2/2	0.2222	中性	+0.4343	0.4780
3-26	22	6/6/6	0.2727	正向	+0.7859	0.7061
3-27	21	8/8/8	0.3810	正向	+0.7377	0.7438
3-28	33	11/11/11	0.3333	正向	+0.5745	0.5556
3-29	18	8/8/8	0.4444	正向	+0.7135	0.6559
3-30	24	12/12/12	0.5000	中性	+0.3798	0.4671

两类样本给出缺失程度的对照：样本 3-05 不含人工缺失，负向概率 0.9228、强度 -1.3953，两个输出头一致给出明确的负向判断；样本 3-30 三模态各缺失 12 个锚点（缺失率 50%），仍给出中性概率 0.4671 与强度 +0.3798，极性与强度同时落在中性区间，表明中等缺失程度下双任务输出仍保持一致。

样本 3-22 的类别输出为负向，强度为 +0.0996，最大类别概率仅 0.3694。当强度接近零点时，类别判别与强度估计表现出不同的敏感度，两个输出头因此出现方向分歧；结果表保留双头的原始预测，不做一致性修正。

专项结果按附件 3 的编号顺序输出，一行对应一个样本；类别编号 0、1、2 分别为负向、中性、正向，缺失计数以内容锚点为单位，三模态缺失率的分母为三倍内容长度。输出文件同时保留三类概率、预测集中度、种子间波动与可用锚点数。

接口一致性以附件 2 与附件 3 的重合样本核验：两条加载路径下的最大概率差约为 1.55×10^{-6} ，最大强度差约为 4.95×10^{-6} ，均处于浮点误差量级，表明训练数据与专项数据经过同一套加载流程。

（7） 结果讨论与改进方向

TSRF-D 通过三态表示、观测节点补全与教师-学生训练，在局部信息缺失时完成极性与强度的联合预测。验证集 Macro-F1 为 0.6012、强度 MAE 为 0.5915，附件 2 测试集分别为 0.6138 与 0.6275。受控遮挡实验说明三个因素的作用并不等价：模态类型的影响最大，8 锚点文本缺口使 F1 由 0.6138 降至 0.5198，而同等语音、视觉缺口下 F1 分别保持在 0.6157 与 0.6100；缺口长度其次，连续缺口由 1 增至 16 个锚点时 F1 总体由 0.5906 降至 0.4462；区间位置的影响最小，句首、句中、句尾三种位置的 F1 极差仅 0.0108。

TSRF-D 在文本整体缺失时借助音视频观测完成跨模态补偿，三模态同段缺失 8 锚点时的 F1 为 0.5332；40% 点状缺失下仅跨模态候选的 F1 为 0.5595，高于仅同模态候选的 0.5396，说明高缺失程度下跨模态信息的作用更加明显。特征重建改善主要来自视觉，蒸馏与补全的作用随压力条件变化，组件对照在基础输入、相同连续区间、点状缺失与整模态删除四类条件下均可复现。后续工作可围绕缺口上下文建模、门控收益评价与缺失条件下的回归性能继续展开。

实验范围与结论的对应关系为：连续遮挡实验覆盖局部缺失的模态类型、位置与锚点

长度，其中长度序列的实际新增遮挡量由 4.20% 增至 60.71%，构成连续区间口径下的缺失率分析；点状比例序列给出分散缺失口径下的缺失率结果；整模态删除提供极端条件参照。组件对照在基础输入、相同连续区间、点状缺失与整模态删除四类条件下报告（表 16）；模态组合各自采样缺口、基线种子数与选模准则亦有差异，比较结果包含这些实验条件的影响。

标准化与梯度训练使用附件 2 训练集，参数保存依据验证集指标。附件 2 测试划分用于多组诊断；附件 3 不进入训练与选模过程，仅由冻结模型完成前向推理并汇总结果，最大类别概率用于描述输出集中程度。

5.3 问题三的模型建立与求解

5.3.1 问题分析与建模思路

问题三要求在输出情感极性与强度的同时，确定主要参考模态、量化模态作用程度，并定位可回看至原始素材的局部证据。为此，建立输入干预联盟 Shapley 解释模型（ICF-Shapley），按“情感预测、模态贡献分解、局部证据定位、原素材回映”四个步骤求解。

模型由子集感知预测器（SAP）与两级解释方法组成。预测器采用三态输入和双向时序编码，在附件 2 上独立训练；模态层精确枚举文本、语音和视觉的 8 个联盟，以 Shapley 值分配预测变化；片段层逐块删除输入，以固定类别的预测响应衡量局部作用。沿用前两问的内容掩码、观测掩码及原词时间区间记号，预测器关闭补全分支，使干预后的输入状态由观测掩码直接控制。

5.3.2 数据准备

（1）输入组织与可用模态

采用附件 2 的对齐版特征，训练、验证、测试样本分别为 3395、728、727 条，文本、语音和视觉特征形状分别为 50×768 、 50×74 和 50×35 。以 P_{ik} 表示内容掩码， O_{ik}^m 表示模态 m 的观测掩码；标准化统计量仅由训练集观测位置估计。文本使用冻结的 bert-base-uncased 编码，训练与专项推理保持同一接口。

附件 4 包含 20 条样本，共 564 个内容锚点，单条长度介于 11 与 48 之间。第 13 条视觉特征在 30 个内容位置均为零，因此将该特征分支标记为不可用。定义

$$L_i = \sum_k P_{ik}, \quad \mathcal{A}_i = \{m \in \mathcal{M} : \sum_k O_{ik}^m > 0\}, \quad \rho_i^m = \frac{\sum_k O_{ik}^m}{L_i}, \quad \mathcal{M} = \{t, a, v\}. \quad (39)$$

其中 ρ_i^m 描述观测比例。不可用模态在所有联盟中保持缺失，输出贡献记为 NA；该标记描述特征文件的可用性。

（2）片段划分与时间回映

将内容区划分为不重叠的 2 锚点块 E ，末块允许不足 2 个锚点。解释时保持序列长度和位置不变，仅改变相应输入及观测状态。文本块先替换为 [UNK]，再对整句重新编码；语音和视觉块通过观测掩码删除。

附件 4 原始转写与音轨经词级 CTC 强制对齐，得到原词区间 $A_{iu} = [a_{iu}, b_{iu}]$ 。若块 E 对应原词集合 $\mathcal{U}_i(E) = \{g_i(k) : k \in E\}$ ，则证据时间范围为

$$I_i(E) = \left[\min_{u \in \mathcal{U}_i(E)} a_{iu}, \max_{u \in \mathcal{U}_i(E)} b_{iu} \right). \quad (40)$$

包含部分子词时按所属原词完整区间回映。逐位核验分词序列后，仅对已获得有效词区间的证据输出秒数，并按真实视频 PTS 提取距区间中点最近的关键帧；其余保留锚点索引与状态标记。

5.3.3 模型构建

(1) 三态投影与时序编码

令 $s_{ik}^m \in \{0, 1, 2\}$ 分别表示结构填充、已观测和内容缺失。最终采用单层预测器，其输入表示为

$$z_{ik}^m = \text{Lin}_m(X_{ik}^m) + e_m^{\text{mod}} + e_k^{\text{pos}} + e_{s_{ik}^m}^{\text{state}}, \quad \tilde{z}_{ik}^m = O_{ik}^m z_{ik}^m + P_{ik}(1 - O_{ik}^m)e_m^{\text{miss}}. \quad (41)$$

按内容长度打包序列，分别输入逐模态双向 GRU，避免结构填充参与递归。设隐藏维度为 d ，对各模态内容位的编码结果 h_{ik}^m 分别取均值与最大值，再拼接观测比例：

$$u_i = \text{Concat}_{m \in \mathcal{M}} \left(\frac{1}{L_i} \sum_k h_{ik}^m, \max_k h_{ik}^m \right) \parallel [\rho_i^t, \rho_i^a, \rho_i^v], \quad h_i = \text{MLP}(u_i). \quad (42)$$

融合向量维度为 $6d + 3$ ，分类与回归头分别输出

$$p_i = \text{softmax}(W_c h_i + b_c), \quad \hat{r}_i = 3 \tanh(W_r h_i + b_r). \quad (43)$$

(2) 子集训练与目标函数

最终采用 C0 方案：以 0.70 的概率保留全部模态，其余 0.30 均匀分配给 7 个非完整联盟，包含空集。对采样联盟 S_i ，令 $\tilde{O}_{ik}^m = O_{ik}^m \mathbf{1}\{m \in S_i\}$ 。训练目标为

$$\mathcal{L}_3 = \text{CE}_w(y_i, p_i) + \text{Huber}_1(r_i, \hat{r}_i) + 0.2 [(p_{i,+} - p_{i,-}) - \tanh(\hat{r}_i/3)]^2. \quad (44)$$

类别权重由训练集频数确定，Huber 损失拟合连续强度，最后一项约束两类输出的方向一致性。该方案覆盖模态联盟输入；连续片段遮挡增广及更深网络作为候选变体单独比较。

(3) 模态贡献与主要参考模态

以三种子平均概率 $\bar{p}_i$ 确定原始可用输入的参考类别 $c_i^* = \arg \max_c \bar{p}_{ic}(\mathcal{A}_i)$ ，解释全过程固定该类别。对联盟 $S \subseteq \mathcal{M}$ ，定义

$$F_i^{\text{cls}}(S) = \log \frac{\bar{p}_{i,c_i^*}(S)}{1 - \bar{p}_{i,c_i^*}(S)}, \quad F_i^{\text{reg}}(S) = \bar{r}_i(S). \quad (45)$$

数值计算时将概率截断至 $[10^{-6}, 1 - 10^{-6}]$ 。对分类与强度分别计算 Shapley 贡献：

$$\phi_i^m = \sum_{S \subseteq \mathcal{M} \setminus \{m\}} \frac{|S|!(2 - |S|)!}{3!} [F_i(S \cup \{m\}) - F_i(S)], \quad \sum_{m \in \mathcal{A}_i} \phi_i^m = F_i(\mathcal{A}_i) - F_i(\emptyset). \quad (46)$$

贡献为正表示相对基线抬高价值，为负表示压低价值。以分类贡献绝对值最大的可用模态为主要参考模态，作用份额定义为

$$m_i^* = \arg \max_{m \in \mathcal{A}_i} |\phi_i^{m,\text{cls}}|, \quad \omega_i^m = \frac{|\phi_i^{m,\text{cls}}|}{\sum_{j \in \mathcal{A}_i} |\phi_i^{j,\text{cls}}|}. \quad (47)$$

当总贡献幅度小于 10^{-8} 时标记为无法区分；其余同时报告作用份额与有符号贡献，以区分作用大小和方向。

(4) 局部证据与解释评价

记 $F_i^{\text{cls,del}(m,E)}$ 为仅删除模态 m 中块 E 后的固定类别价值，定义

$$\Delta_i^m(E) = F_i^{\text{cls}}(\mathcal{A}_i) - F_i^{\text{cls,del}(m,E)}. \quad (48)$$

$\Delta_i^m(E) > 0$ 表示该片段支持参考类别，小于零表示抑制参考类别。对全部可用模态计算逐块响应，并在各模态中按响应降序选取局部证据。

在主要参考模态中，按块数的 10%、20%、30% 向上取整，分别累计删除高分块、低分块和随机块；随机顺序重复 3 次，并报告实际锚点覆盖率。以三个删除档位的平均概率下降定义 AOPC，按样本配对比较高分与随机删除，采用 2000 次 bootstrap 估计区间。条件充分性保留其他模态及主要模态的高分块，计算相对原预测的绝对概率偏差。另以训练集同位置均值（B2）和模态内顺序打乱（B3）替代缺失状态基线（B1），比较主模态一致率及贡献排序。

5.3.4 模型求解与参数设置

（1）候选比较与模型选择

以 C0 为基准，设置三个递进变体：V1 调整联盟采样并加入连续块遮挡；V2 进一步采用两层 BiGRU、逐模态 LayerNorm 和回归支路；V3 增加联盟单调一致性正则。V1 与 V2 各包含多项联合改动，因此比较反映方案组合的影响。V3 约束增补模态后的参考类别响应，其单调性不等价于贡献可加性。

选模指标为 $J = \text{Macro-F1} - 0.1\text{MAE}$ 。候选须同时满足： J 不低于 C0 减 0.002；去文本、去语音、去视觉及全缺失四种状态的平均 Macro-F1 不低于 C0 减 0.002；解释 AOPC 差不低于 C0 减 0.005。通过者按缺失状态平均 Macro-F1 排序，并列时比较 J 。训练早停与变体选择使用验证集，最终在附件 2 测试集评价预测性能，对附件 4 输出预测与解释。

表 19 最终 SAP 预测器及解释参数

项目	设置
网络	投影维度 64；单层 BiGRU，单方向 32；融合 MLP；Dropout 0.2
优化	AdamW；学习率 0.0015；权重衰减 10^{-4} ；余弦调度
训练	批量 256；至多 32 轮；早停耐心 8；梯度范数上限 5；种子 0、1、2
联盟采样	全集 0.70，其余 7 个联盟各 0.30/7；最终模型无块遮挡增广
解释	8 个联盟精确枚举；局部 2 锚点块；3 组随机删除；样本 bootstrap 2000 次
验证子集	固定种子 20260925 随机抽取 96 条，用于解释诊断和候选比较
计算环境	Python 3.12；PyTorch 2.8.0+cu128；RTX 5060 Ti

算法 2 ICF-Shapley 预测与证据定位

输入：三模态特征、掩码、原始素材、冻结预测器与标准化参数。

输出：情感极性、强度、模态贡献、主要参考模态及局部证据。

1. 计算可用集合 $\mathcal{A}_i$ 与集成预测，固定参考类别 c_i^* 。
2. 枚举 8 个模态联盟，计算分类 log-odds 与预测强度。
3. 求解两类 Shapley 值，核验效率性，输出 ω_i^m 与 m_i^* 。
4. 遍历各可用模态的 2 锚点块，实施输入删除，计算 $\Delta_i^m(E)$ 。
5. 选择各模态最高分片段，由原词 CTC 区间及视频 PTS 定位证据。
6. 保存预测、贡献与逐块响应，生成解释卡；在验证子集评价忠实性、条件充分性及稳定性。

5.3.5 实验结果与分析

（1）预测性能与候选比较

按三项门槛选择的预测器为 C0 对照（原训练分布）。三个种子分别在第 4、5、3 轮取得最优验证指标，训练轮次完全由验证集 J 决定，测试集与附件 4 只参与前向计算。验证集单种子 Macro-F1 为 0.6068、0.5941、0.6082，三种子集成后为 0.6170；测试集 Macro-F1 为 0.6054，MAE 为 0.6303。验证集负向、中性、正向 F1 依次为 0.6430、0.5114 与 0.6966，类别间的差异集中在中间类别，中性边界的刻画是提升分类表现的关键环节。图 18 给出类别间的混淆结构与各类别指标。

表 20 SAP 三种子集成的预测性能

数据集	Accuracy	Macro-F1	MAE	Pearson
验证集	0.6264	0.6170	0.5954	0.6420
测试集	0.6286	0.6054	0.6303	0.6730




图 18 验证集混淆矩阵与分类指标。

V1 未通过预测指标与缺失状态性能门槛，V2 未通过预测指标门槛，V3 未通过缺失状态性能门槛；三者的解释 AOPC 差均达到门槛。据此选择 C0 作为最终 SAP 预测器，后续贡献分解和附件 4 推理均使用该模型。内容区打包与全序列编码的各单种子 J 平均值分别为 0.542 和 0.539。表中仅完整输入对照采用单种子，其余方案采用三种子集成；种子一致率指主要参考模态的两两一致率平均值。整模态删除给出模态重要性的独立证据：C0 去文本后的 Macro-F1 为 0.4150，而去语音、去视觉后分别为 0.6092 与 0.5974，相对完整输入的 0.6170，文本删除造成的下降最大，与联盟分解中文本主导的结论一致。仅用完整输入训练的的单种子模型去文本后降至 0.2904；两者集成规模不同，该差值同时包含训练方案与集成的影响。全缺失条件仅用于输入状态诊断，其预测仍可利用保留的内容长度。

(2) 模态作用差异

空集价值为-0.687，全模态价值为 0.542，单模态联盟中文本为 0.382、语音为-0.651、视觉为-0.637；三模态平均 Shapley 贡献为文本 +1.105、语音 +0.068、视觉 +0.056，96 条子集中分类主参考模态为文本 86 条、语音 3 条、视觉 7 条。图 19 显示，文本的平均 Shapley 贡献为 +1.105，构成预测的主导信息来源；语音与视觉分别贡献 +0.068 与 +0.056，在三模态协同中提供补充信息，主参考模态分布与贡献排序一致。样本层的正负贡献与主参考

表 21 候选方案与实现对照的验证结果

方案	J	Macro-F1	MAE	AOPC 差	种子一致率
仅完整输入（单种子）	0.5470	0.6073	0.6030	—	—
无内容区打包对照	0.5468	0.6073	0.6048	—	—
C0: 子集训练	0.557	0.6170	0.5954	0.107	84.0%
V1: 采样与遮挡	0.553	0.6112	0.5869	0.130	77.8%
V2: 增加容量	0.553	0.6128	0.6010	0.112	79.2%
V3: 单调正则	0.559	0.6192	0.6011	0.124	75.7%

模态另行保留，以刻画个体差异。效率性残差不超过 8.9×10^{-16} ，满足 Shapley 效率性公理。




图 19 模态联盟的平均分类价值与三模态平均 Shapley 贡献。

(3) 局部证据与解释检验

位置级证据由输入干预直接度量：96 条验证样本共完成 3397 个局部块干预，文本、语音与视觉的平均绝对 log-odds 响应分别为 0.377、0.015 与 0.025，与模态级贡献的结论一致，均以文本为主。典型样本的逐块分布见图 22，累计删除结果见图 20。按块数 10%、20%、30% 三个目标档位累计删除时，高分块引起的参考类别概率下降分别为 0.187、0.226、0.241，随机块为 0.075、0.111、0.148，低分块为-0.014、0.006、0.038；高分块与随机块的样本级配对差为 0.1068（95% 区间 [0.0887,0.1259]），实际覆盖率为 14.41%、24.03%、35.49%。条件充分性在最高档的绝对概率偏差为 0.1608，表明主要模态中被舍弃的片段对预测仍有贡献。图 20(b) 给出解释方法的对照结果：B1/B2/B3 三种基线下的主模态一致率分别为 100.00%、90.62% 与 87.50%，绝对贡献排序的 Spearman 相关为 0.812 与 0.625，主要参考模态的判定不依赖具体基线。同一删除协议在强度回归头上给出相同的排序：删除高分块 10%、20%、30% 时强度的绝对变化为 0.399、0.468 与 0.499，删除低分块为 0.142、0.192 与 0.227，两组差距随删除比例扩大，局部证据排序对连续强度输出同样成立。在主参考模态为文本的 86 条样本中，最高分证据块完全由功能词或标点构成的比例为 17.4%，低于全部文本块基线的 30.5%，配对差为-0.130（95% 区间 [-0.212,-0.046]），最高分证据落点集中在实词上。训练随机性与解释基线分别检验解释的稳定性：三种子两两的主参考模态一




图 20 高分、随机与低分块累计删除对比、基线敏感性 & 条件充分性。

致率为 82.29%、83.33% 与 86.46%，B1/B2/B3 三种基线下的主模态一致率分别为 100.00%、90.62% 与 87.50%。输入删除能够稳定识别对当前预测作用较强的片段；上述 96 条样本同时参与候选比较，置信区间描述该验证子集上的配对差异。

(4) 错误分布与归因分析

验证集共 272 条误判，其中 214 条涉及中性，占 78.7%。按真实分组看：中性组错误率 39.1%（184 条），非中性且 $|\text{强度}| < 0.5$ 的弱情感组错误率 60.5%（147 条）， $|\text{强度}| \geq 0.5$ 的强情感组错误率 28.0%（397 条）。错误随情感强度降低而集中，说明零点附近的类别判别比强情感的方向判断更困难。

在 96 条解释样本中，低强度组与高强度组的解释不稳定率分别为 31.7% 和 23.6%，覆盖正确与错误预测两类样本，给出解释稳定性在不同强度水平上的分布。错误分析将改进重点指向中性边界与弱情感区间的表征增强。

(5) 附件 4 全量结果

附件 4 全部 20 条样本的预测分布为中性 7 条、负向 7 条、正向 6 条，分类主参考模态为文本 19 条、视觉 1 条。图 21 给出全量预测、模态份额和种子间波动，表 22 列出逐条数值。20 条样本的强度三种子标准差均值为 0.105，最大为 0.410（附件 4_10）。第 13 条的视觉分支不可用，其视觉份额标记为 NA，其余两个模态照常给出贡献；4-04 与 4-19 的预测极性与强度方向不一致，属于独立双头结构下的输出分歧，两个任务分别保留各自的预测与贡献分解。pred_附件 4.csv 保存预测及分类、强度的有符号贡献；explain_




图 21 附件 4 全部 20 条样本的情感预测、模态作用份额与种子间波动。

附件 4.csv 按样本和模态保存证据片段、时间与媒体索引，共 60 行，包含不可用状态；local_blocks_附件 4.csv 保存全部逐块响应。

(6) 典型样本与证据回映

选取附件 4 第 1 条展示完整解释链条。第 1 条预测为中性，强度 +0.362，主要参考模态为文本（份额 0.678），最高分证据片段为 *the timing*，估计时间 2.62–3.00s。图 22 同时展示预测结果、三模态作用程度、主要模态的逐块响应与原始关键帧；响应的正负分别对应支持和抑制作用。回映覆盖情况如下：20 条样本的重新分词序列均与官方词元一致，482 个原词中 478 个获得 CTC 时间区间；59 条可用模态证据中 58 条完成时间回映，时间区间由 CTC 词级对齐给出，未获得词区间的证据以锚点索引记录。第 13 条的视觉特征不可用，其解释保留文本与语音贡献，并在全量文件中标记为视觉 NA。

本模型把情感预测分解为可复核的模态贡献与局部响应，并通过词级时间区间连接到原始素材：Shapley 值度量指定模型与基线下的作用差异，删除实验检验局部证据与预测响应的一致性。两项分析在同一预测器上完成，因此解释结论可直接对应该模型的决策过程。

表 22 附件 4 全量预测与分类模态作用份额

编号	极性	强度	文本份额	语音份额	视觉份额	主模态
4-01	中性	+0.362	0.678	0.124	0.198	文本
4-02	中性	+0.034	0.518	0.254	0.229	文本
4-03	中性	-0.185	0.441	0.119	0.440	文本
4-04	负向	+0.089	0.705	0.178	0.116	文本
4-05	正向	+0.711	0.484	0.085	0.432	文本
4-06	正向	+0.660	0.699	0.014	0.287	文本
4-07	正向	+0.801	0.833	0.029	0.138	文本
4-08	中性	+0.501	0.106	0.384	0.510	视觉
4-09	负向	-1.989	0.955	0.018	0.027	文本
4-10	负向	-1.027	0.903	0.060	0.037	文本
4-11	负向	-1.112	0.820	0.020	0.160	文本
4-12	负向	-0.804	0.897	0.036	0.067	文本
4-13	中性	+0.238	0.844	0.156	NA	文本
4-14	中性	+0.409	0.654	0.031	0.315	文本
4-15	正向	+1.116	0.703	0.192	0.105	文本
4-16	负向	-2.137	0.946	0.031	0.022	文本
4-17	正向	+1.528	0.930	0.029	0.040	文本
4-18	中性	-0.055	0.679	0.021	0.300	文本
4-19	负向	+0.188	0.809	0.049	0.141	文本
4-20	正向	+1.040	0.816	0.040	0.144	文本

问题三 典型样本解释卡




图 22 附件 4 第 1 条解释卡：预测、模态份额、局部片段重要性与关键证据定位。

6 模型检验与灵敏度分析

6.1 模型检验

模型检验按“输出是否完整、约束是否满足、结论是否可复现”三项目标展开，分别对应三问的可核验要求。

问题一检验处理覆盖与时间结构。100 条样本均形成输出，1920 个已生成词区间全部满足非负起点、正长度、音轨范围内终点与起点随词序单调四项约束；典型样本给出词元、音频窗口与视频帧之间的映射，其字段与全量清单一致。区间生成率与结构约束共同刻画处理覆盖与一致性，6 条超出接口长度样本的截断位置亦被逐条记录。

问题二同时报告分类与回归指标，并以配对方式核验差异。验证集 Macro-F1 为 0.6012、强度 MAE 为 0.5915；中性类 F1 为 0.4848，低于负向与正向两类，221 条涉及中性类的误判占全部误判的 77.8%，与错误归因中“零点附近判别更困难”的判断一致。补全、可靠度门控与蒸馏的作用通过缺失条件下的同掩码对照评价，详见第 5.2 节。

问题三的检验独立于分类评价，用于确认解释是否忠实于预测行为。联盟价值分解的效率残差不超过 8.9×10^{-16} ，满足 Shapley 效率性公理；以 96 条固定验证样本比较高分、随机与低分片段的累计删除效果，高分删除相对随机删除的 AOPC 差为 0.1068，样本级 95% 区间为 [0.0887, 0.1259]。条件充分性在最高档的绝对概率偏差为 0.1608，说明主要模态中被舍弃的片段对预测仍有贡献；三种子与三种基线下的主参考模态一致率分别为 82.29%、83.33%、86.46% 与 100.00%、90.62%、87.50%。

6.2 灵敏度与稳健性分析

灵敏度分析考察关键设置变化时结论是否保持稳定，包括采样强度、缺失强度与解释配置三个方面。

问题一在 12 条样本子集上增加边界扰动次数，视觉方差的排序相关达到 0.995，质量分量的排序结构保持稳定，说明锚点间的相对比较不依赖扰动次数的具体取值。

问题二以两类干预刻画缺失强度的影响。连续缺口由 1 增至 16 个锚点时，F1 由 0.5906 降至 0.4462、MAE 由 0.6438 升至 0.8026；随机点状缺失比例由 5% 增至 40% 时，两项指标分别变化为 0.6074 至 0.5469 与 0.6352 至 0.7316。两类干预均显示信息减少伴随整体性能退化，具体幅度随缺失模态与区间位置变化；在相近的实际新增遮挡量下，连续缺口的 F1 低于随机点状缺失，说明缺失在时间上的聚集方式与缺失数量共同影响预测，模型对分散缺失的容忍度高于连续缺口。

问题三在固定评估掩码下重复多种子训练与多基线解释，主参考模态的一致率保持在 82% 以上，绝对贡献排序的 Spearman 相关为 0.812 与 0.625，解释结论对训练随机性与基线选择均保持稳定。

7 模型评价与推广

7.1 模型特点

时间锚点模型以父词区间连接不同采样粒度，兼顾子词语义与原始音视频的追溯能力，覆盖与退化标记使局部观测缺失得到显式表达，而非被填充值掩盖。TSRF-D 将观测节点补全、缺失状态编码与双任务学习结合，在保持输入接口一致条件下完成局部缺失预测与全量专项推理，使鲁棒性设计不以常规性能为代价。ICF-Shapley 模型以子集感知预测器统一分类与解释的输入状态，模态级贡献与片段级证据共享同一预测器，避免解释与预测脱节。三个模型依次解决时间组织、证据不完整与决策可追溯问题，共同构成从素材时间

组织到不完整特征预测的处理框架。

7.2 模型推广与改进

三问共享的内容掩码、观测掩码与词级时间区间构成可直接复用的接口，模型可沿以下方向继续扩展。

在时间对齐方面，质量分数用于锚点间的相对排序，后续可引入数字读法归一化、长序列编码与人工词边界评价，扩大覆盖范围并给出绝对时间误差的标定。

在缺失预测方面，改进方向包括缺口上下文建模、中性类别边界刻画与门控收益评价，并可扩展至更长缺口、更多模态与多任务联合的预测场景；基于样本及多组掩码的不确定性分析，可区分缺失因素与采样波动的影响。

在解释方面，后续可增加随机排列重复、原词级片段对照与人工时间标注，把当前解释结果与人工判断对照，提升解释的稳定性与时间精度。

8 结论

本文依次建立原始素材的特征时间组织、局部缺失预测与可解释性分析模型，三问通过统一的内容掩码与时间回映规则相互连接，形成从素材时间组织到不完整特征预测、再到决策依据复核的处理框架。

第一，建立词级时间锚点与交叠池化模型，完成附件 1 全部 100 条视频的自主特征提取与时序组织。1932 个原词中 1920 个生成时间区间，区间生成率为 99.38%。三模态特征、观测掩码、父词索引与帧级记录共同支持全量结果追溯，典型样本给出了文本片段、语音时段与视频帧段的逐项对应。

第二，基于附件 2 的官方对齐特征建立教师-学生模型 TSRF-D，完成局部缺失条件下的极性分类与强度回归，验证集 Macro-F1 为 0.6012、强度 MAE 为 0.5915。受控遮挡实验显示：文本缺口引起最大的预测退化，8 锚点文本缺口使测试集 F1 由 0.6138 降至 0.5198，而同等条件下语音、视觉缺口分别为 0.6157 与 0.6100；连续缺口跨度与缺失数量共同增加时性能总体下降，在同一实际新增遮挡量下连续缺口的退化更为明显。标准化特征的重建改善主要来自视觉模态，各组成部分的作用通过缺失条件下的对照实验给出。附件 3 全部 30 条样本均已完成预测，输出负向 7 条、中性 11 条、正向 12 条，并保存逐样本概率与强度。

第三，采用模态子集训练与固定参考类别的输入干预构建 ICF-Shapley 模型，完成附件 4 全部 20 条样本的预测与解释，输出中性 7 条、负向 7 条、正向 6 条。96 条验证样本中，高分片段累计删除引起的参考类别概率下降大于随机对照，AOPC 差为 0.1068；模态贡献在多种子与多基线下具有较高一致性。通过原词区间与视频 PTS，局部证据可回映至原始素材，形成预测、模态作用与可回看证据的对应记录。

上述结果说明：以词为公共锚点的时序组织能够同时支持特征提取、缺失建模与证据回映三项目标，三态掩码表示使局部缺失无需插补值即可参与训练，固定参考类别的联盟分解与片段删除可在同一预测器上给出可量化、可复核的解释。三问共享的时间口径与掩码约定也为后续扩展到更长缺口、更多模态与多任务联合预测提供了可直接复用的接口。

参考文献

- [1] Baltrusaitis T, Ahuja C, Morency L P. Multimodal machine learning: A survey and taxonomy[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(2): 423–443.

- [2] Zadeh A, Liang P P, Poria S, Cambria E, Morency L P. Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL), 2018: 2236–2246.
- [3] Zadeh A, Chen M, Poria S, Cambria E, Morency L P. Tensor fusion network for multimodal sentiment analysis[C]. Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2017: 1103–1114.
- [4] Tsai Y H H, Bai S, Liang P P, Kolter J Z, Morency L P, Salakhutdinov R. Multimodal transformer for unaligned multimodal language sequences[C]. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL), 2019: 6558–6569.
- [5] Devlin J, Chang M W, Lee K, Toutanova K. BERT: Pre-training of deep bidirectional transformers for language understanding[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT), 2019: 4171–4186.
- [6] Baevski A, Zhou Y, Mohamed A, Auli M. wav2vec 2.0: A framework for self-supervised learning of speech representations[C]. Advances in Neural Information Processing Systems (NeurIPS), 2020: 12449–12460.
- [7] Graves A, Fernandez S, Gomez F, Schmidhuber J. Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks[C]. Proceedings of the 23rd International Conference on Machine Learning (ICML), 2006: 369–376.
- [8] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[EB/OL]. arXiv:1503.02531, 2015.
- [9] Shapley L S. A value for n-person games[M]//Kuhn H W, Tucker A W. Contributions to the Theory of Games II. Princeton: Princeton University Press, 1953: 307–317.
- [10] Ribeiro M T, Singh S, Guestrin C. "Why should I trust you?": Explaining the predictions of any classifier[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD), 2016: 1135–1144.
- [11] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]. Advances in Neural Information Processing Systems (NeurIPS), 2017: 4765–4774.

附录 A 问题一特征文件与全量样本结果

A.1 特征文件规范与读取方法

采用“样本级清单、词级时间明细、位置级特征、帧级记录”四层组织，既满足模型输入的固定形状，也保留从接口位置回到原始素材的路径。主要文件见表 23。

表 23 问题一输出文件及内容

文件	内容与规模
E1_features.pkl	100 条位置级特征及掩码、父词映射、词级分量；8.86 MiB
E1_manifest.csv	100 行、37 列样本清单，包含标识、解码时长、帧数、覆盖统计、处理耗时和输入哈希
E1_alignment_detail.csv	1932 行、26 列词级明细，包含区间、置信度、覆盖、扰动、退化和截断信息
per_sample/*.pkl	100 份完整词表、字符偏移、词元归属、尾部记录及媒体元数据
frames/*.npz	100 份帧特征、帧起止时间及视觉有效性标记
audit_elst.csv、 run_log.json	编辑列表有效时长、工具版本、运行参数与产物索引

主特征文件顶层包含 version、n 和 features；后者以样本唯一键索引。每条记录的 Xt/Xa/Xv 分别保存三模态矩阵，P 为内容掩码，U 为父词编号，Oa/Ov 为观测掩码。Da/Dv、Va/Vv、Vta/Vtv、Qa/Qv 分别保存覆盖、方差、归一化方差和综合质量。特征矩阵采用 float16 存储，质量分量主要保留 float32；正文中的统计来自词级明细，不对重复继承的子词再次加权。

以下代码展示从主文件取得位置级特征与观测掩码的方式，文件路径由使用者指向交付目录。

```
import pickle
with open("E1_features.pkl", "rb") as f:
    data = pickle.load(f)
sid = next(iter(data["features"]))
r = data["features"][sid]
Xt, Xa, Xv = r["Xt"], r["Xa"], r["Xv"]
P, U, Oa, Ov = r["P"], r["U"], r["Oa"], r["Ov"]
# k -> U[k] -> words[u]["a"], words[u]["b"]
```

实际回溯时，先确认 $P_{ik} = 1$ ，再由 $U[k]$ 查父词记录的 a/b，最后在相应音轨和视频 PTS 序列中定位；若该词没有时间区间，则不进行伪造回映。问题一特征与附件 2 官方特征的维度和生成方式不同，本问产物不直接替代问题二的官方训练输入。问题三处理其他视频时，可复用映射方法，但需要建立相应视频自己的词级时间记录。

A.2 附件 1 全部 100 条样本的结果

表 24 逐条汇总 100 条样本。视、音时长采用编辑列表有效呈现口径，合计分别为 787.985 s 和 777.106 s；对齐粒度均为原词锚点与子词继承。

T、A、V 表示文本、语音和人脸视觉分支；V 后的星号、空心圆分别表示部分帧、全片未检出人脸。“区间/词”分母含未对齐项，“内容位”为进入 50 位接口的内容词元数，上限为 48。

表 24 附件 1 全部 100 条样本的特征提取结果。全部采用原词锚点、子词继承的对齐粒度。

序号	样本编号	模态	视/音时长 (s)	T/A/V 维度	区间/词	内容位	检出率
1	-3g5yACwYnA\$_\$2	T+A+V	9.394/9.231	768/25/16	14/14	17	100.0%
2	-3g5yACwYnA\$_\$3	T+A+V	14.389/14.328	768/25/16	29/29	40	100.0%
3	-3g5yACwYnA\$_\$9	T+A+V	8.817/8.696	768/25/16	21/21	28	100.0%
4	-3g5yACwYnA\$_\$13	T+A+V	5.514/5.399	768/25/16	15/15	18	100.0%
5	-3nNcZdcdvU\$_\$5	T+A+V*	7.868/7.788	768/25/16	18/18	22	99.6%
6	-571d8cVauQ\$_\$0	T+A+V*	5.167/4.992	768/25/16	12/12	16	96.7%
7	-571d8cVauQ\$_\$5	T+A+V	15.273/15.115	768/25/16	43/43	48	100.0%
8	-6rXp3zJ3kc\$_\$8	T+A+V	12.805/12.738	768/25/16	34/34	38	100.0%
9	-9y-fZ3swSY\$_\$0	T+A+V	6.900/6.757	768/25/16	22/22	28	100.0%
10	-9y-fZ3swSY\$_\$4	T+A+V	2.821/2.665	768/25/16	9/9	11	100.0%
11	-9y-fZ3swSY\$_\$8	T+A+V*	4.989/4.917	768/25/16	12/12	14	91.3%
12	-AUZQgSxyPQ\$_\$2	T+A+V	22.511/22.405	768/25/16	41/41	48	100.0%
13	-HeZS2-Prhc\$_\$2	T+A+V	8.262/8.151	768/25/16	16/16	17	100.0%
14	-HwX2H8Z4hY\$_\$2	T+A+V*	3.982/3.916	768/25/16	7/8	12	23.5%
15	-HwX2H8Z4hY\$_\$5	T+A+V*	5.653/5.544	768/25/16	9/10	10	37.5%
16	-HwX2H8Z4hY\$_\$6	T+A+V*	3.358/3.256	768/25/16	7/7	9	66.7%
17	-HwX2H8Z4hY\$_\$9	T+A+V*	7.734/7.637	768/25/16	22/22	24	12.9%
18	-I_e4mIh0yE\$_\$1	T+A+V	7.622/7.444	768/25/16	18/18	21	100.0%
19	-I_e4mIh0yE\$_\$3	T+A+V	9.163/8.995	768/25/16	22/22	30	100.0%
20	-MeTTeMJBNc\$_\$0	T+A+V*	9.334/9.218	768/25/16	21/21	26	99.6%
21	-MeTTeMJBNc\$_\$7	T+A+V	10.517/10.412	768/25/16	31/31	33	100.0%
22	-MeTTeMJBNc\$_\$13	T+A+V	5.430/5.255	768/25/16	14/14	16	100.0%
23	-NFrJFQijfE\$_\$1	T+A+V°	5.746/5.659	768/25/16	16/16	16	0.0%
24	-NFrJFQijfE\$_\$2	T+A+V°	6.856/6.698	768/25/16	18/18	18	0.0%
25	-RfYyzHpjk4\$_\$2	T+A+V	5.516/5.392	768/25/16	25/25	29	100.0%
26	-RfYyzHpjk4\$_\$8	T+A+V	4.589/4.532	768/25/16	17/17	21	100.0%
27	-RfYyzHpjk4\$_\$11	T+A+V	5.239/5.074	768/25/16	17/17	19	100.0%
28	-THoVjtIkeU\$_\$2	T+A+V	4.292/4.230	768/25/16	10/10	11	100.0%
29	-THoVjtIkeU\$_\$6	T+A+V*	8.097/7.983	768/25/16	30/30	32	99.6%
30	-THoVjtIkeU\$_\$12	T+A+V	14.896/14.805	768/25/16	39/39	42	100.0%
31	-UUCSKoHeMA\$_\$0	T+A+V*	7.867/7.732	768/25/16	18/18	23	99.6%
32	-UacrmKiTn4\$_\$4	T+A+V	4.741/4.681	768/25/16	14/14	15	100.0%
33	-UacrmKiTn4\$_\$10	T+A+V	7.362/7.242	768/25/16	18/18	22	100.0%
34	-UuXlxuaiiE\$_\$0	T+A+V	3.700/3.576	768/25/16	9/9	12	100.0%
35	-UuXlxuaiiE\$_\$1	T+A+V	10.350/10.267	768/25/16	27/27	33	100.0%
36	-UuXlxuaiiE\$_\$3	T+A+V	4.130/4.038	768/25/16	9/9	9	100.0%
37	-UuXlxuaiiE\$_\$6	T+A+V	8.114/7.944	768/25/16	22/22	23	100.0%
38	-a55Q6RWvTA\$_\$3	T+A+V	22.154/22.084	768/25/16	65/65	48	100.0%
39	-aNfi7CP8vM\$_\$7	T+A+V	8.695/8.538	768/25/16	18/18	23	100.0%
40	-aqamKhZ1Ec\$_\$0	T+A+V	11.000/10.890	768/25/16	13/14	16	100.0%
41	-dxftGcXJoc\$_\$0	T+A+V*	20.534/20.410	768/25/16	38/41	48	78.0%
42	-dxftGcXJoc\$_\$1	T+A+V	16.161/16.019	768/25/16	36/36	42	100.0%
43	-dxftGcXJoc\$_\$2	T+A+V	16.698/16.633	768/25/16	32/34	40	100.0%
44	-dxftGcXJoc\$_\$6	T+A+V	12.735/12.628	768/25/16	27/27	32	100.0%
45	-egA8-b7-3M\$_\$1	T+A+V	10.266/10.156	768/25/16	19/20	22	100.0%
46	-egA8-b7-3M\$_\$6	T+A+V	6.265/6.183	768/25/16	12/12	13	100.0%
47	-egA8-b7-3M\$_\$9	T+A+V	5.090/4.936	768/25/16	10/10	12	100.0%
48	-egA8-b7-3M\$_\$13	T+A+V	4.184/4.024	768/25/16	11/11	16	100.0%
49	-egA8-b7-3M\$_\$16	T+A+V	5.538/5.483	768/25/16	11/11	13	100.0%
50	-egA8-b7-3M\$_\$17	T+A+V	7.271/7.095	768/25/16	16/16	19	100.0%

表 24 附件 1 全部 100 条样本的特征提取结果（续）。全部采用原词锚点、子词继承的对齐粒度。

序号	样本编号	模态	视/音时长 (s)	T/A/V 维度	区间/词	内容位	检出率
51	-egA8-b7-3M\$_\$18	T+A+V	8.386/8.266	768/25/16	22/22	27	100.0%
52	-egA8-b7-3M\$_\$20	T+A+V	6.645/6.475	768/25/16	20/20	24	100.0%
53	-egA8-b7-3M\$_\$26	T+A+V	6.031/5.920	768/25/16	15/15	19	100.0%
54	-hnBHB8p5A\$_\$6	T+A+V*	6.401/6.333	768/25/16	13/13	14	82.3%
55	-hnBHB8p5A\$_\$7	T+A+V*	7.372/7.308	768/25/16	13/13	17	60.8%
56	-iRBcNs9oI8\$_\$3	T+A+V	5.621/5.538	768/25/16	8/8	9	100.0%
57	-iRBcNs9oI8\$_\$6	T+A+V	2.903/2.821	768/25/16	5/5	5	100.0%
58	-iRBcNs9oI8\$_\$7	T+A+V	4.104/4.006	768/25/16	9/9	15	100.0%
59	-iRBcNs9oI8\$_\$8	T+A+V	8.093/8.026	768/25/16	21/21	26	100.0%
60	-iRBcNs9oI8\$_\$9	T+A+V*	3.416/3.374	768/25/16	5/5	5	78.4%
61	-lzEya4AM_4\$_\$5	T+A+V	7.675/7.570	768/25/16	19/19	21	100.0%
62	-lzEya4AM_4\$_\$6	T+A+V	14.792/14.741	768/25/16	43/43	48	100.0%
63	-mJ2ud6oKI8\$_\$1	T+A+V ^o	6.103/6.054	768/25/16	13/13	13	0.0%
64	-mJ2ud6oKI8\$_\$2	T+A+V*	5.731/5.702	768/25/16	11/11	17	78.4%
65	-mJ2ud6oKI8\$_\$6	T+A+V	2.257/2.229	768/25/16	5/5	5	100.0%
66	-mJ2ud6oKI8\$_\$8	T+A+V	4.192/4.172	768/25/16	11/11	11	100.0%
67	-mJ2ud6oKI8\$_\$9	T+A+V	7.033/6.909	768/25/16	22/22	29	100.0%
68	-mqbVkbCndg\$_\$0	T+A+V	6.500/6.385	768/25/16	12/12	17	100.0%
69	-qDkUB0GgY\$_\$6	T+A+V	4.678/4.614	768/25/16	16/16	18	100.0%
70	-ri04z7vwnc\$_\$0	T+A+V ^o	2.807/2.763	768/25/16	8/8	8	0.0%
71	-ri04z7vwnc\$_\$2	T+A+V*	6.027/5.914	768/25/16	16/16	26	35.7%
72	-ri04z7vwnc\$_\$5	T+A+V	3.545/3.440	768/25/16	8/9	11	100.0%
73	-s9qJ7ATP7w\$_\$0	T+A+V	6.867/6.710	768/25/16	24/24	28	100.0%
74	-s9qJ7ATP7w\$_\$1	T+A+V	4.792/4.644	768/25/16	11/11	12	100.0%
75	-s9qJ7ATP7w\$_\$4	T+A+V*	4.427/4.247	768/25/16	9/9	10	71.3%
76	-s9qJ7ATP7w\$_\$5	T+A+V	8.561/8.398	768/25/16	19/19	20	100.0%
77	-s9qJ7ATP7w\$_\$6	T+A+V*	2.475/2.315	768/25/16	5/5	5	81.7%
78	-s9qJ7ATP7w\$_\$7	T+A+V*	6.966/6.839	768/25/16	28/28	38	63.3%
79	-s9qJ7ATP7w\$_\$8	T+A+V	3.295/3.184	768/25/16	12/13	17	100.0%
80	-t217m2on-s\$_\$2	T+A+V	5.686/5.630	768/25/16	12/12	16	100.0%
81	-t217m2on-s\$_\$7	T+A+V	17.183/17.026	768/25/16	45/45	48	100.0%
82	-tANM6ET1_M\$_\$3	T+A+V	6.758/6.604	768/25/16	22/22	29	100.0%
83	-tPCyztz4rww\$_\$10	T+A+V	4.789/4.678	768/25/16	12/12	15	100.0%
84	-tPCyztz4rww\$_\$11	T+A+V	5.467/5.378	768/25/16	17/17	20	100.0%
85	-tPCyztz4rww\$_\$12	T+A+V	11.864/11.736	768/25/16	26/26	28	100.0%
86	-tPCyztz4rww\$_\$16	T+A+V	7.206/7.139	768/25/16	16/16	17	100.0%
87	-tPCyztz4rww\$_\$18	T+A+V	6.645/6.569	768/25/16	16/16	22	100.0%
88	-uywlfIYOS8\$_\$4	T+A+V	6.045/5.882	768/25/16	18/18	22	100.0%
89	-vxjVxOeScU\$_\$4	T+A+V	9.127/9.037	768/25/16	21/21	27	100.0%
90	-wMB_hJL-3o\$_\$7	T+A+V*	6.044/5.976	768/25/16	22/22	23	96.7%
91	-wny00Az3g8\$_\$0	T+A+V	3.334/3.274	768/25/16	9/9	11	100.0%
92	-wny00Az3g8\$_\$1	T+A+V	6.844/6.776	768/25/16	22/23	28	100.0%
93	-wny00Az3g8\$_\$2	T+A+V	6.687/6.523	768/25/16	23/23	28	100.0%
94	-wny00Az3g8\$_\$3	T+A+V	6.146/6.100	768/25/16	20/20	20	100.0%
95	-wny00Az3g8\$_\$5	T+A+V	6.912/6.741	768/25/16	20/20	27	100.0%
96	-wny00Az3g8\$_\$7	T+A+V	8.068/7.911	768/25/16	29/29	31	100.0%
97	-wny00Az3g8\$_\$9	T+A+V	6.213/6.043	768/25/16	20/20	22	100.0%
98	-yRb-Jum7EQ\$_\$1	T+A+V	29.288/29.109	768/25/16	49/49	48	100.0%
99	-yRb-Jum7EQ\$_\$5	T+A+V	13.169/13.044	768/25/16	25/25	31	100.0%
100	-yRb-Jum7EQ\$_\$6	T+A+V	11.226/11.242	768/25/16	19/19	24	100.0%

附录 B 问题二预测文件与实验索引

附件 3 预测保存于 pred_ 附件 3.csv，按原文件序号排列，共 30 条记录。主要字段为样本编号、预测极性、类别编号、三类概率和连续强度；类别编号 0、1、2 对应负向、中性、正向。诊断字段包括内容锚点数、各模态缺失计数、缺失率及种子间输出标准差。正文表 18 列出全量结果，诊断字段中的空值表示相应统计不适用。

表 25 问题二主要实验产物与论述对应

产物	对应内容
eval_splits.json	基础输入下的验证、测试性能
missing_summary.json	缺失模态、位置、长度和比例实验
robust.json	共享干预掩码下的模型及组件比较
recon_check.json	人工遮挡位置的补全真值评价
valid_eval.json	验证集混淆矩阵与错误分组
pred_a3.json	附件 3 预测及接口一致性核查