



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 南通大学

参赛队号 26103040266

	1. 徐路尧
队员姓名	2. 陈智杰
	3. 慕蕙榕

中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

题 目： 多模态情感的时序对齐与可解释预测

摘 要：

针对多模态情感预测中的时序差异、局部信息缺失与决策依据难以追溯问题，本文基于赛题提供的 CMU-MOSEI 数据，建立词级时间锚点对齐、教师-学生鲁棒预测与输入干预解释模型，实现原始素材的特征组织、缺失条件下的情感预测及关键证据定位。

针对问题一，采用 CTC 强制对齐估计原词时间区间，以字符偏移确定子词归属，通过时间交叠加权聚合语音与视觉特征，建立不确定边界锚点对齐模型。完成全部 100 条视频的特征提取，文本、语音、视觉特征维度分别为 50×768 、 50×25 和 50×16 ；1932 个原词中 1920 个生成时间区间，生成率为 99.38%。结合覆盖率与边界扰动评价锚点质量，并以典型样本展示三模态特征与原始片段的时间对应关系。

针对问题二，建立三态感知可靠补全与融合模型 TSRF-D，以冻结 EMT-DLFR 为教师，结合逆频率类别加权与分类、强度蒸馏训练学生。验证集 Macro-F1 为 0.6163、强度 MAE 为 0.5818；测试集 Accuracy 为 0.6437、MAE 为 0.6221。在 105 种连续局部缺失条件下，平均 Macro-F1 为 0.6066、MAE 为 0.6492。通过与九类基线的统一比较及输入模态消融，分析不同缺失条件下的分类与强度预测表现，并完成附件 3 全部 30 条样本的预测。

针对问题三，构建 ICF-Shapley 解释模型，以模态子集训练适配干预输入，通过精确枚举模态联盟分解分类与回归贡献，并以局部删除响应定位关键片段。验证集 Macro-F1 为 0.6170、MAE 为 0.5954，测试集对应指标为 0.6054 与 0.6303。冻结模型后，在 96 条测试样本上确认分类与强度的高分片段删除优势分别为 0.1318 和 0.2132，原视频聚类 95% 区间均高于零。完成附件 4 全部 20 条样本的双任务解释，118 条可用证据均对应至原始文本、语音时段与视频关键帧；非文本主导归因仍对解释基线较敏感。

关键词： 多模态情感 时序对齐 局部模态缺失 教师-学生蒸馏 Shapley 解释

目录

1	问题重述	4
1.1	问题背景	4
1.2	问题描述	4
1.3	总体解题思路	4
2	模型假设	5
3	符号说明	6
4	模型的建立与求解	6
4.1	问题一的模型建立与求解	6
4.1.1	问题分析与建模思路	6
4.1.2	数据准备	7
4.1.3	模型构建	8
4.1.4	模型求解与参数设置	13
4.1.5	实验结果与分析	14
4.2	问题二的模型建立与求解	23
4.2.1	问题分析与建模思路	23
4.2.2	数据准备	23
4.2.3	模型构建	24
4.2.4	模型求解与参数设置	26
4.2.5	实验结果与分析	29
4.2.6	与基线的测试集比较	33
4.2.7	附件 3 全量预测与结果展示	35
4.3	问题三的模型建立与求解	37
4.3.1	问题分析与建模思路	37
4.3.2	数据准备	37
4.3.3	模型构建	37
4.3.4	模型求解与参数设置	39
4.3.5	实验结果与分析	40
5	模型检验与灵敏度分析	46
5.1	模型检验	46
5.2	灵敏度分析	47
6	模型评价与推广	47
6.1	模型特点	47
6.2	模型局限与改进	47
7	结论	48
	参考文献	48
	附录 A 问题二专项模型核心代码	50

附录 B 问题三专项模型核心代码	51
------------------------	----

1 问题重述

1.1 问题背景

情感分析是具身智能、自然人机交互等领域的关键支撑技术。真实交互中，人类情绪经由语言内容、语音韵律与面部运动等多通道信号协同表达：词义决定评价的正负方向，语调、语速与能量承载强调、迟疑与情绪唤醒，面部关键点的运动则补充词面之外的态度信息。三者的物理载体并不相同，分别表现为离散词元序列、等间隔采样的声学帧与带时间戳的视频帧，在采样频率、特征维度与时间尺度上差异显著。多模态联合建模因此成为突破单模态识别局限、提升复杂场景下情绪理解准确性与稳定性的核心路径。

然而，多模态情感预测在真实场景中面临三重挑战。其一，特征提取与时序对齐的质量直接决定模型性能上限：自动转写可能识别失败，音视频轨道的起止时刻与有效时长并不一致，部分视频帧中人脸检出失败，若按序号直接拼接三路特征，同一位置上的语义、语音与视觉信息可能对应不同时刻，若直接剔除不完整样本，又会损失本就有限的建模数据。其二，画面遮挡、环境噪声与转写失败常导致模态局部时段不可用，常规固定权重融合模型的性能随之急剧下降。其三，多数模型仅输出预测结果，决策依据难以追溯与复核，制约了模型的可信应用。因此，多模态情感预测需要在三个层次上开展建模：先建立从原始素材到标准化时序特征的对应关系，再在证据不完整时稳定输出情感极性与情感强度，最后量化说明判断所依据的模态与局部片段。

1.2 问题描述

本文以赛题提供的 CMU-MOSEI 系列数据为唯一数据来源，依次完成三项建模任务。

问题一：以附件 1 的原始视频为研究对象，建立文本、语音、视觉三模态情感特征提取与时序对齐的数学模型。模型须明确三类情感特征的定义与提取方法，给出跨模态时间对应规则，将采样频率与时间粒度各异的三路信号统一至同一时间基准，并规定各处理环节对原始样本的操作方式。自生成的特征文件需满足三项规范：样本编号、模态文件与输出特征一一对应；序列位置、有效长度、填充规则及其与原始素材的对应记录完整可核验；特征提取工具、关键参数、处理日志与复现实验说明齐备。最终以表格形式汇总附件 1 全部 100 条样本的特征提取结果，并以典型样本呈现文本片段、语音时段、视频帧段与三类特征的对应关系。

问题二：针对模态局部缺失的复杂场景，建立鲁棒性多模态情感预测模型。模态局部缺失指一条或多条模态在部分连续时段内信息不可用，而非整条模态缺失。模型须在模态信息不完整的条件下稳定输出情感极性与情感强度预测，并分析缺失模态类型、缺失位置、缺失时长及缺失比例对预测性能的影响规律。模型建立后须对附件 3 中的测试样本完成推理预测。

问题三：针对三模态信息完整而决策依据难以追溯的场景，建立可解释性多模态情感预测模型。模型除输出情感极性与情感强度外，还须以可量化、可复核的方式给出判断依据：量化各模态在当前样本中的作用差异，明确主要参考模态，定位各模态中与判断密切相关的局部片段。关键证据应可对应至原始文本片段、语音时段或视觉关键帧，以支持回溯核验。模型须对附件 4 中的测试样本完成预测与解释。

1.3 总体解题思路

三项任务构成从时间组织到鲁棒预测、再到决策解释的递进链条。问题一处理原始素材与时间基准：三模态采样粒度不同，需先以词为公共时间锚点建立可核验的对应关系，输出内容位置、观测掩码与词级时间区间。问题二处理证据不完整：在附件 2 的官方对齐

特征上区分填充、观测与局部缺失三种状态，使预测在连续缺口存在时仍然可用。问题三处理决策可追溯：在附件 2 上独立训练预测器，通过固定参考类别的模态联盟分解与输入片段删除，给出主要参考模态、模态作用程度与可回映到原始素材的关键证据。

三问的数据输入、模型节点与输出关系如图 1 所示。



图 1 本文总体研究思路

三问共享时间组织与掩码表示方法，各自使用相应附件的数据。问题一生成 768/25/16 维自主特征；问题二与问题三使用 768/74/35 维官方特征，分别学习预测参数。问题三沿用词级对齐方法，为附件 4 建立独立的时间记录，将特征层证据回映至原始素材。

2 模型假设

- 官方转写与视频中的话语顺序一致，转写不改变话语的先后关系。依据是该转写由赛题统一提供并与音轨逐条对应。该假设使词级强制对齐的单调路径约束成立，无法构造字符目标的词仍可按同一顺序单独记录。
- 同一原词的子词共享父词的时间区间，帧特征在其时间支撑区间内近似为分段常量。依据是词为发音的自然单位，而音频帧率远高于词长：前者使子词继承父词的音视频锚点，后者使式 (11) 的交叠积分退化为加权求和。
- 在附件 2 至附件 4 的对齐版本中，同一序列位置的三个模态共享官方给定的时间对应关系，局部缺失长度以锚点数度量。依据是这些附件按 `aligned_50` 组织，每个序列位置本身即为一个对应单元。问题二与问题三因此只需处理各位置的观测可用性，无需重新估计时间对应关系。
- 内容位置上的文本 [UNK] 与全零音视频向量表示该位置观测不可用，而非有效的特征取值。依据是附件 3 将局部缺失定义为特征值全为零的连续区间。填充、观测与局部缺失三种状态由此可由掩码唯一确定。
- 人工遮挡改变可用证据，但不改变样本标签；遮挡后仍以原片段的情感极性与情感强

度作为监督目标，以评价输入信息减少时的预测性能。问题二据此构造缺失条件下的训练样本。

6. 标准化统计量仅由附件 2 的训练集估计，并直接用于验证集与附件 3、附件 4；推理阶段模型权重与标准化统计量保持固定。依据是各附件由同一特征提取流程生成，特征维度与量纲一致。该约定避免推理阶段引入测试数据信息，并使跨附件指标在同一尺度下可比。

3 符号说明

符号	含义
i, u, k, j	样本、原词、接口位置及特征帧的索引
$m \in \{t, a, v\}$	模态索引， t, a, v 分别表示文本、语音与视觉；涉及帧池化时 $m \in \{a, v\}$
$K, g_i(k)$	固定接口长度（ $K = 50$ ）及第 k 个内容词元的父词编号
P_{ik}, O_{ik}^m	内容位置掩码与模态观测掩码，取值均为 0 或 1
$A_{iu} = [a_{iu}, b_{iu})$	第 i 条样本第 u 个原词的半开时间区间（s）
$J_{ij}^m = [s_{ij}^m, e_{ij}^m)$	模态 m 中第 j 个特征帧的时间支撑区间（s）
$\mathbf{f}_{ij}^m, r_{ij}^m$	帧级特征向量及有效性标记
$\ell_{ij}^m(A), \omega_{ij}^m(A)$	帧与锚点的有效交叠时长（s）及归一化池化权重
$\mathbf{x}_{iu}^m, X_i^m$	词级池化向量及固定 50 位的模态特征矩阵
c_{iu}, d_{iu}^m	CTC 路径置信度与词级模态覆盖指标，均位于 $[0, 1]$
B, s	边界扰动次数与扰动标准差，分别为 50 次和 0.04 s
V_{iu}^m, σ_{im}^2	扰动池化向量方差及样本内模态帧特征离散度
$\tilde{V}_{iu}^m$	由样本内尺度归一化的边界扰动方差
Q_{iu}^m, γ_m	综合质量分数及敏感度衰减系数， $\gamma_a = \gamma_v = 1$
$N_i^a, T_i^a, T_i^v, \Delta_i$	音频解码样本数、音轨与视频轨的解码跨度及其差 $\Delta_i = T_i^a - T_i^v$ (s)
$H_{ik}^m, \tilde{O}_{ik}^m$	问题二的人工遮挡掩码及遮挡后的观测掩码
Ω_i, ρ_{ik}^m	样本内观测候选集合及补全融合权重
$y_i, r_i, \hat{y}_i, \hat{r}_i$	极性与强度真值及相应预测值
p_i^T, p_i^S, J	教师、学生类别分布及验证集联合选模指标

4 模型的建立与求解

4.1 问题一的模型建立与求解

4.1.1 问题分析与建模思路

附件 1 提供 100 条英文视频及对应转写文本。问题一要求从原始素材中提取文本、语音与视觉特征，建立三类特征与原始片段之间可核验的时间对应关系。本问的目标是构造时序组织统一、有效范围明确、溯源记录完整的多模态表示。

三模态的时间结构存在本质差异：文本以离散词元组织，语音是连续采样信号，视觉由带时间戳的视频帧构成。若直接按序号拼接，不同时刻的信息会被错位对齐；若按词数均分视频长度，语速、停顿与词长的差异又被忽略。此外，人脸未检出与文本接口截断都会使部分位置缺少有效特征，必须与正常观测严格区分。

据此，本文采用以原词为时间锚点、以子词为输出位置的建模方案。先由官方转写与音频信号建立词级时间区间，并将子词映射至父词；再在同一锚点区间内对语音与视觉帧特征进行时间交叠加权聚合。为刻画对齐结果的不确定性，进一步定义覆盖率与边界扰动敏感度，二者与对齐过程共同构成不确定边界锚点对齐模型（Uncertain-Boundary Anchor Alignment, UBA）。总体流程如图 2 所示。




图 2 三模态特征提取与时间锚点对齐流程

模型输出采用 50 位定长接口，每个内容位置经父词索引关联至实际时间区间；模型评价从样本覆盖、区间结构、模态观测覆盖与参数敏感性四个方面展开。

4.1.2 数据准备

(1) 样本组织与数据特征

附件 1 的样本以视频标识与片段编号组成唯一键，用于关联视频文件、官方转写与输出记录。100 条样本来自 37 个原始视频，共含 1932 个空白分隔原词与 2317 个 BERT 词元；其中 283 个原词对应多个词元，占 14.65%。样本标签仅用于数据说明，不参与本问的特征提取与参数拟合。原始素材在文本长度、音频格式、视频采样、容器时间与可观测性上的实测特点及相应处理方式汇总于表 2。

输出按定长接口与全量记录两级组织：接口给出三模态共享的位置级输入，词级记录保留接口之外的时间对应与截断信息，两者通过父词索引相互关联。

表 2 数据特点与相应处理方式

对象	实测特点	处理方式
文本长度	每条 5–65 词, 5–82 个词元	保存全量词表, 固定接口仅保留前 48 个内容词元
音频格式	源采样率 44.1 kHz, 单/双声道 AAC	统一解码为 16 kHz 单声道信号
视频采样	8 种分辨率, 帧间隔并非处处相同	使用逐帧 PTS, 不由帧数和标称帧率反推时间
容器时间	90 条声明帧数与实解帧数不同	区分媒体样本数、有效呈现时长与解码跨度
视觉可观测性	4 条全片未检出人脸, 另有局部未检出	保存有效帧掩码, 缺失帧不参与池化

(2) 时间基准与有效区间

音频经解码、重采样与声道合并后得到信号 $x_i[n]$, 采样率 $f_s = 16000$ Hz, 其相对时间为 n/f_s ; 设解码样本数为 N_i^a , 则音频轨的解码跨度 $T_i^a = N_i^a/f_s$ 。声学描述符提取与词级强制对齐共用该信号, 以保证两条处理链具有一致的时间原点。

视频第 j 帧的呈现时间取解码 PTS 与时间基的乘积, 记为 t_{ij} 。100 条样本的首帧 PTS 均为 0, 23241 个解码帧的 PTS 完整且单调。有效呈现范围由容器编辑列表确定; 名义公共时间轴以音频相对秒数与视频 PTS 建立, 两轨各自保持原始时间尺度。视频轨的解码跨度 T_i^v 按末帧 PTS 加一个中位帧间隔计算, 与帧支撑的延展约定一致。

容器媒体时长、编辑列表时长与解码跨度分别描述存储范围、有效呈现范围与实际样本范围。100 条样本的音视频轨各含一条编辑列表且媒体时间均非零, 解码音频与编辑列表时长的中位差约为 1 ms, 实解帧数与按编辑列表预测的帧数中位差约为 1.4 帧, 解码输出落在编辑列表限定的呈现范围内。100 条样本的有效视频时长与音频时长分别合计为 787.985 s 和 777.106 s。声明视频帧数为 33147, 实解 23241, 二者差额主要来自编辑列表限定的呈现范围。逐样本汇总采用有效呈现时长, 实际音频处理总时长为 777.0091 s。

记两轨解码跨度之差为 $\Delta_i = T_i^a - T_i^v$, 其均值为 -92.3 ms, 绝对值中位数为 91.3 ms。该量刻画两轨整体时长差异, 随逐样本清单保存并用于范围核验。

图 3 给出样本长度与媒体时间分布: 原词数呈长尾分布, 故在定长接口之外保留全量词级记录; 音视频解码跨度与帧数统计存在差异, 故视觉分支采用实际解码帧与 PTS 建立时间支撑。

(3) 建模约定

本文以官方转写确定待对齐的词序列, 同一原词的子词共享其时间区间; 视觉描述符取自成功检出的人脸, 质量分数用于评价锚点的相对可用性。各模态在词锚点上完成聚合后写入统一接口, 内容掩码与观测掩码随特征一并保存; 预训练模型保持冻结, 分别承担特征编码与强制对齐, 其参数计算不涉及附件 1 的情感标签。

4.1.3 模型构建

模型构建沿三条分支展开: 文本分支确定位置级语义表示, 语音分支给出词级时间区间, 视觉分支提供帧级观测与有效性标记, 三者原词锚点上汇合为统一接口。位置、时间与观测三类信息分别由内容掩码 P 、区间 A_{iu} 与观测掩码 O_{ik}^m 表达, 使特征张量在存在局部缺失时仍保持明确的时间含义。



图3 附件1的原词数、音视频解码跨度差及帧数统计

(1) 文本特征与词元归属

文本情感通过评价对象、情感词、否定与程度修饰等语义单元表达，其时间定位依赖转写与音频的词级对应。转写以空白分词给出原词，预训练编码器以 WordPiece 为输入单位，两类单位在数量与边界上均不一致，因此先建立词元到原词的归属关系，再在同一接口内组织语义表示。

设原词 w_{iu} 在转写中的字符范围为 $[l_{iu}, r_{iu})$ ，分词器返回词元 z_{ik} 的字符范围 $[l_{ik}^z, r_{ik}^z)$ 。若词元范围包含于原词范围内，定义

$$g_i(k) = u \quad \text{当} \quad [l_{ik}^z, r_{ik}^z) \subseteq [l_{iu}, r_{iu}). \quad (1)$$

对非包含关系，依次按字符交叠和邻词附着确定归属；本批 100 条样本均由包含关系确定父词。词内标点继承父词的时间区间，与所在原词共享同一时间锚点。

固定接口长度 $K = 50$ ，顺序安排 [CLS]、至多 48 个内容词元、[SEP] 及尾部 [PAD]。仅内容词元取 $P_{ik} = 1$ ，其余位置为 0。将包含特殊符号的完整接口输入 BERT 后，取最后一层隐藏向量：

$$X_{ik}^t = P_{ik} \mathbf{h}_{ik}, \quad \mathbf{h}_{ik} \in \mathbb{R}^{768}. \quad (2)$$

内容掩码 P 排除特殊符号，BERT 注意力掩码保留 [CLS] 和 [SEP]，使内容位置的上下文表示涵盖完整句意。超过 48 个内容词元的尾部保存于全量词表，其父词继续参与音视频对齐与池化；位置级文本向量覆盖接口内的词元，接口之外的部分在词级记录中保持可追溯。编码器参数在本问中保持冻结，文本表示仅由原始转写决定。

(2) 语音特征与词级时间估计

语音的响度、音高、谱形和发声质量能够表征重音、语调与发声方式，为情感分析提供区别于文字内容的线索。采用 openSMILE 的 eGeMAPSv02 低层描述符，获得 25 维帧特征 f_{ij}^a ，其分组与建模含义如表 3 所示。帧特征的时间区间直接取自工具输出，帧移为 10 ms、窗长为 20 ms，相邻窗口存在交叠，特征数值保持原始尺度进入聚合。

记第 j 个声学帧的工具输出支撑为 $J_{ij}^a = [s_{ij}^a, e_{ij}^a]$ 。池化按该支撑区间计算交叠权重，保留分析窗的交叠关系；音频帧在整条样本内均记为有效观测。LLD 提取与强制对齐共用 16 kHz 单声道 PCM 信号，具有一致的时间原点。

表 3 声学特征的组成与建模含义（合计 25 维）

特征组	维数	内容与作用
响度与谱形	6	响度、alpha 比、Hammarberg 指数、两个频段谱斜率、频谱通量，描述能量与频谱变化
倒谱表示	4	MFCC 1-4，描述短时谱包络
基频与发声质量	6	基频半音值、jitter、shimmer、HNR 及两项谐波相对能量，描述音高与声门发声特征
共振峰	9	第一至第三共振峰的频率、带宽与相对幅度，描述声道共振结构

词级时间估计将连续语音映射为离散词区间，采用预训练 wav2vec2 声学模型与 CTC 强制对齐完成。将原词映射为声学字典支持的大写字符，词间插入分隔符，构成目标序列 y_i ；无法产生目标字符的词保留为未对齐记录。设 $\pi_{it}(c)$ 为第 t 个声学输出帧对字符 c 的概率，最优路径为

$$z_i^* = \arg \max_{z: B(z)=y_i} \sum_t \log \pi_{it}(z_t), \quad (3)$$

其中 B 表示 CTC 的去空白与重复合并映射；声学输出帧移 $h = 0.02$ s，各帧支撑按定长帧计算。对合并后的第 c 个目标字符，记其帧支撑为 $[\alpha_{ic}, \beta_{ic}]$ ；原词包含的目标字符集合记为 C_{iu} ，则词区间为

$$A_{iu} = \left[h \min_{c \in C_{iu}} \alpha_{ic}, h \max_{c \in C_{iu}} \beta_{ic} \right). \quad (4)$$

式 (4) 使用字符支撑的起点与终点，允许字符之间存在空白帧，不假定字符连续占据整个词区间。强制对齐在给定转写顺序下搜索最优声学路径 [7]。字符字典未覆盖的数字或符号保留为未对齐词；生成的词区间依次接受单调性、正长度和音轨边界检查，未通过检查的区间不计入有效锚点。

先对字符支撑内的路径对数概率求均值，再汇总原词中的各字符，定义词级路径置信度：

$$\bar{\ell}_{ic} = \frac{1}{\beta_{ic} - \alpha_{ic}} \sum_{t=\alpha_{ic}}^{\beta_{ic}-1} \log \pi_{it}(y_{ic}), \quad c_{iu} = \exp \left(\frac{1}{|C_{iu}|} \sum_{c \in C_{iu}} \bar{\ell}_{ic} \right). \quad (5)$$

路径分数 c_{iu} 衡量声学模型对目标字符序列的支持程度，作为对齐质量分量进入综合评分；无法构造字符目标的词保留空区间，并单独记录可用性状态。

(3) 视觉特征与有效帧建模

视觉分支提取人脸几何与关键点位移，用于表征口型、眼眉形态及面部运动，并以人脸尺度归一，使不同分辨率与人脸大小的样本具有可比的位移量度。先以 FaceDetection 定位最高分人脸，按人脸框宽高的 1.6 倍裁剪区域，再使用 FaceMesh 提取 478 个关键点；区

域处理失败时尝试整帧检测。同一帧出现多张人脸时取检测分数最高者，作为该帧的目标人脸。将区域内坐标映射回原图后，取二维像素坐标 $\mathbf{p}_{ijq} = (x_{ijq}, y_{ijq})$ 。对于宽 W 、高 H 的原帧，设裁剪边界为 (x_0, y_0, x_1, y_1) ，FaceMesh 在裁剪图上返回归一化坐标 (u_{ijq}, v_{ijq}) ，则回映关系为

$$x_{ijq} = x_0 + u_{ijq}(x_1 - x_0), \quad y_{ijq} = y_0 + v_{ijq}(y_1 - y_0). \quad (6)$$

裁剪边界限制在 $[0, W] \times [0, H]$ 内，关键点回映后在统一像素坐标系中计算跨帧位移。两阶段检测用于改善小人脸与高亮背景下的人脸可观测性，未检出帧通过有效性掩码记录。

以脸宽和脸高的均值作为尺度

$$L_{ij} = \frac{|x_{ij,234} - x_{ij,454}| + |y_{ij,10} - y_{ij,152}|}{2} + 10^{-6}, \quad \delta_{ij}(p, q) = \frac{\|\mathbf{p}_{ijp} - \mathbf{p}_{ijq}\|_2}{L_{ij}}, \quad (7)$$

构造表 4 中的 14 个几何分量及 2 个运动分量，分别描述眼眉口部形态和关键点位移。取相邻帧 $j-1$ 与 j ，且两帧均成功检出人脸，对全脸或嘴部关键点集合 $\mathcal{P}$ 定义运动量

$$M_{ij}(\mathcal{P}) = \sqrt{\frac{1}{|\mathcal{P}|} \sum_{q \in \mathcal{P}} \frac{\|\mathbf{p}_{ijq} - \mathbf{p}_{i,j-1,q}\|_2^2}{L_{ij}^2}}. \quad (8)$$

首帧或前一帧未检出人脸时运动不可测，该帧记无效并存储零向量，不以前一有效帧的关键点替代；不可测原因（首帧、跨检测缺口）在帧级文件与样本元数据中分别记录。

表 4 16 维视觉描述符的定义

维度	描述符	定义
1-3	嘴开合、嘴宽、开合宽比	$\delta(13, 14)$ 、 $\delta(61, 291)$ 及 $\delta(13, 14)/(\delta(61, 291) + 10^{-6})$
4-5	左右嘴角相对高度	上下唇中点纵坐标减嘴角 61 或 291 的纵坐标，再除以 L
6-7	左右眼开合	$\delta(159, 145)$ 、 $\delta(386, 374)$
8-9	左右眼宽	$\delta(33, 133)$ 、 $\delta(362, 263)$
10-11	左右眉眼距离	$\delta(105, 159)$ 、 $\delta(334, 386)$
12-13	补充眉眼距离	$\delta(70, 159)$ 、 $\delta(300, 386)$
14	脸高宽比	$ y_{10} - y_{152} /(x_{234} - x_{454} + 10^{-6})$
15-16	全脸与嘴部位移	相邻两帧均检出时的归一化关键点位移 RMS；不可测帧不进入池化

视觉帧的有效标记 $r_{ij}^v = 1$ 要求相邻两帧均检出；人脸未检出或运动不可测时置 $r_{ij}^v = 0$ 并存储零向量。帧的支撑区间定义为

$$J_{ij}^v = [t_{ij}, t_{i,j+1}), \quad j < N_i^v; \quad J_{i,N_i^v}^v = [t_{i,N_i^v}, t_{i,N_i^v} + \hat{h}_i^v), \quad (9)$$

其中 $\hat{h}_i^v$ 为正帧间隔的中位数。该约定将当前帧描述符保持到下一帧，在帧间隔较大时包含保持近似；视觉覆盖指标据此衡量有效视觉帧对锚点区间的支撑程度。

(4) 时间交叠池化与子词映射

不同模态无须先统一帧率：词锚点给出统一的时间窗口，各模态按自身帧支撑进入窗口完成聚合。对词区间 $A = [a, b)$ ，令有效交叠长度为

$$\ell_{ij}^m(A) = r_{ij}^m \max\{0, \min(b, e_{ij}^m) - \max(a, s_{ij}^m)\}, \quad S_i^m(A) = \sum_j \ell_{ij}^m(A), \quad (10)$$

音频帧取 $r_{ij}^a = 1$ ，视觉使用检测有效性。若 $S_i^m(A) > \varepsilon$ ，则

$$\omega_{ij}^m(A) = \frac{\ell_{ij}^m(A)}{S_i^m(A)}, \quad \mathbf{x}_{iu}^m = \sum_j \omega_{ij}^m(A_{iu}) \mathbf{f}_{ij}^m, \quad d_{iu}^m = \min \left(1, \frac{S_i^m(A_{iu})}{b_{iu} - a_{iu}} \right), \quad (11)$$

其中 $\varepsilon = 10^{-9}$ 。无有效交叠时，令 $\mathbf{x}_{iu}^m = \mathbf{0}$ 、 $d_{iu}^m = 0$ 。式 (11) 使部分交叠的帧按实际支撑长度贡献特征，权重归一化与覆盖指标分开计算，在归一化权重的同时保留缺失程度的信息；声学分析窗存在交叠， d^a 按有效交叠长度累计并截断到 1。

图 4 给出一组可手算的视觉例子。设词区间为 $[0.08, 0.32]$ s，四个相邻帧支撑各长 0.10 s，第三帧未检出人脸，则四帧有效交叠依次为 0.02, 0.10, 0, 0.02 s。由式 (11)，非零权重为 $1/7, 5/7, 1/7$ ，而覆盖指标为 $0.14/0.24 = 0.583$ 。即使权重和为 1，词区间仍有 41.7% 的时长缺乏有效视觉支撑；这正是单独保存 d^v 的必要性。



图 4 交叠池化示意算例

通过父词映射，将音视频词级特征复制到对应子词位置：

$$X_{ik}^m = \begin{cases} \mathbf{x}_{i,g_i(k)}^m, & P_{ik} = 1, \\ \mathbf{0}, & P_{ik} = 0, \end{cases} \quad O_{ik}^m = P_{ik} \mathbf{1}\{d_{i,g_i(k)}^m > 0\}, \quad m \in \{a, v\}. \quad (12)$$

非内容位置的 O 定义为 0，不求值不存在的父词。三模态最终维度分别为

$$X_i^t \in \mathbb{R}^{50 \times 768}, \quad X_i^a \in \mathbb{R}^{50 \times 25}, \quad X_i^v \in \mathbb{R}^{50 \times 16}. \quad (13)$$

多个子词继承父词的完整区间，不等分原词时间；同一原词的各子词共享相同的池化向量与覆盖指标，位置级输出与词级时间记录由此一一对应。 $P = 1, O^m = 0$ 表示位置存在但该模态无观测，与全零特征在模型中由内容掩码和观测掩码分别表达。

(5) 边界扰动与质量分量

词边界由强制对齐给出，边界的小幅变化会改变参与聚合的帧及其权重。为刻画这一影响，对区间两端加入标准差 $s = 40$ ms 的独立高斯扰动，采样 $B = 50$ 次并重新池化；扰动幅度小于多数词区间的时长，用于刻画小范围边界移动的影响。两端先裁剪到模态时间范围；若终点不大于起点，设置 20 ms 的最小区间。池化使用修正区间与有效帧的实际交叠，完全无覆盖的扰动另行计数。

令 $\mathcal{H}_{iu}^m$ 为有覆盖的扰动集合, $B_{iu}^m = |\mathcal{H}_{iu}^m|$ 。当 $B_{iu}^m \geq 2$ 时定义

$$\bar{\mathbf{x}}_{iu}^{m,\text{pert}} = \frac{1}{B_{iu}^m} \sum_{q \in \mathcal{H}_{iu}^m} \mathbf{x}_{iu}^{m,(q)}, \quad (14)$$

$$V_{iu}^m = \frac{1}{B_{iu}^m} \sum_{q \in \mathcal{H}_{iu}^m} \left\| \mathbf{x}_{iu}^{m,(q)} - \bar{\mathbf{x}}_{iu}^{m,\text{pert}} \right\|_2^2. \quad (15)$$

原窗口无观测或有效扰动不足 2 次时, 设置退化标记, 方差字段以 0 占位; 其余锚点的 V 衡量有观测条件下的边界敏感性, 有效扰动次数 B_{iu}^m 随结果保存。

在每条样本内部, 按有效帧计算模态尺度

$$\sigma_{im}^2 = \frac{1}{N_i^{m,\text{valid}}} \sum_{j:r_{ij}^m=1} \left\| \mathbf{f}_{ij}^m - \bar{\mathbf{f}}_i^m \right\|_2^2 + 10^{-12}, \quad \tilde{V}_{iu}^m = \frac{V_{iu}^m}{\max(\sigma_{im}^2, 10^{-9})}. \quad (16)$$

少于 2 个有效帧时, 尺度取 1。归一化方差刻画池化变化相对于片段内特征变化的大小, 各模态分别统计。

综合质量分数取

$$Q_{iu}^m = c_{iu} d_{iu}^m \exp(-\gamma_m \tilde{V}_{iu}^m), \quad \gamma_a = \gamma_v = 1. \quad (17)$$

路径置信度、观测覆盖与边界敏感性分别从对齐可信度、观测完整性和边界稳健性三个方面刻画锚点, 共同决定综合质量 Q 。保存 $c, d, V, \tilde{V}, Q$ 及退化标记, 可按质量排序定位待复核锚点, 并追溯相应影响分量。

三项分量相乘给出明确的边界行为: 词对齐失败时没有可用锚点; 锚点存在但人脸完全缺失时 $d^v = 0$, 因而 $Q^v = 0$; 有覆盖且扰动能够产生至少两个有效池化结果时, 边界敏感性有可解释的估计。零覆盖与低稳定性属于不同状态, 逐词记录中的观测掩码与退化标记用于区分二者。

4.1.4 模型求解与参数设置

(1) 求解流程

全部特征与时间映射在冻结预训练模型的条件下逐样本求解, 网络参数不参与更新, 输出由输入素材与固定参数共同决定。

1. 读取样本标识与官方转写, 建立原词字符区间及其词元归属, 生成文本特征与 50 位内容掩码。
2. 解码音轨, 提取 25 维声学帧特征; 对全量原词构建字符目标, 计算 CTC 路径、词区间与路径置信度。
3. 按视频 PTS 读取帧, 计算 16 维人脸特征与有效帧掩码, 并建立各帧的支撑区间。
4. 对每个已生成区间的原词执行交叠池化与边界扰动; 未生成区间的词保留失败记录, 不赋予人为时间。
5. 将词级特征映射到保留的子词位置, 输出特征、掩码与质量分量, 并保存全量词表及截断尾部记录。
6. 汇总 100 条样本, 核查样本键、张量形状、区间顺序与有效范围, 生成全量清单与典型对应图。

(2) 工具与关键参数

扰动随机种子由样本标识的 MD5 摘要前 8 位生成, 固定 B, s, γ 后可在同一运行环境中复算。各分支所用工具、版本与关键设置见表 5。

逐样本运行记录的累计处理耗时为 9.72 min, 平均每条 5.83 s。其中视觉处理 499.04 s, 占 85.6%; 文本、音频及池化阶段分别为 6.61、65.37 和 12.19 s。视觉分支需逐帧执行人脸

表 5 特征提取工具与关键参数

模块	工具及版本	设置
运行环境	Python 3.12.10, CPU	NumPy 1.26.4, pandas 2.3.3
音视频解码	PyAV 18.1.0	音频 16 kHz 单声道, 视觉采用解码 PTS
文本编码	transformers 4.56.0	bert-base-uncased, 推理模式, 50 位
声学描述符	openSMILE 2.6.0	eGeMAPSv02, LLD 层, 25 维
词级对齐	torch / torchaudio 2.8.0	WAV2VEC2_ASR_BASE_960H, 20 ms 帧移
人脸描述符	MediaPipe 0.10.21	FaceDetection 与 FaceMesh, 478 点, ROI 倍率 1.6
边界扰动	NumPy 随机生成器	$B = 50$, $s = 40$ ms, $\gamma_a = \gamma_v = 1$

检测与关键点回归, 构成耗时的主要部分。该统计取自逐样本日志, 不含模型首次下载、绘图与论文编译耗时。

运行环境、关键参数、逐阶段耗时与输入哈希由程序在运行时自动记录, 随支撑材料提交。

特征张量、词级时间与帧级记录以样本键关联, 自生成文件的存储组织与读取方式见表 6; 读取时由样本键定位逐样本记录, 再按内容掩码 P 与父词索引 U 将接口位置还原到词级区间。

表 6 自生成特征文件的存储组织与读取方式

文件	内容与读取方式
E1_features.pkl	全部 100 条样本的 $X^t/X^a/X^v$ 、掩码与质量分量的汇总字典, 含版本号与样本数; 按样本键索引, 用于全量读取与跨样本统计
per_sample/	逐样本记录, 含特征矩阵、内容掩码 P 、父词索引 U 、观测掩码 O^a/O^v 、词级记录与元数据; 文件名由样本键转换得到, 是逐样本核对与追溯的入口
frames/	帧级支撑, 含音频帧特征与起止区间、视频帧 PTS 与有效标记; 与逐样本记录按同一键关联, 是帧级时间与覆盖的来源
E1_alignment_detail.csv	1932 条逐词明细, 含区间 $[a, b)$ 、路径置信度与覆盖、扰动及质量分量; 用于定位单个词的时间与质量
E1_manifest.csv	样本级清单, 含文本与媒体统计、模态覆盖、逐阶段耗时与输入哈希; 用于覆盖统计与结果核验

4.1.5 实验结果与分析

(1) 全量处理结果与统计口径

100 条样本均完成处理。1932 个原词中, 1920 个生成时间区间, 区间生成率为 99.38%; 其余 12 项包括 6 个数字词和 6 个标点或符号串, 均未通过字符目标构造。已生成区间全部满足非负起点、正长度、音轨范围内终点和起点随词序单调四项条件。

表 7 以全部 1932 个原词与已生成区间的 1920 个原词为两个统计范围。音频覆盖在已生成区间上达到 1.000, 视觉覆盖均值仅 0.9276, 说明锚点信息的不完整主要来自人脸观测与运动不可测帧, 而非声学支撑。

12 个未生成区间的词在固定接口中仍占 22 个内容位置, 其内容掩码 $P = 1$, 观测掩码 $O^a = O^v = 0$ 。三态表示由此可以区分“有文本、无时间支撑”与“文本、时间支撑齐备”两类位置。另有 128 个已生成区间的词缺少视觉覆盖, 说明时间区间是否有效与人脸观测是否有效是两个独立条件。视觉有效帧要求相邻两帧均检出人脸: 100 条样本中共有 143 帧因运动不可测而记无效 (首帧 87 帧、跨检测缺口 56 帧), 这些帧不进入池化, 无效

表 7 全量特征生成与覆盖结果

指标	结果	统计范围
样本输出 / 原词记录	100 / 1932	附件 1 全量
生成区间的原词	1920 (99.38%)	全部 1932 词
词区间时长均值 / 中位数	0.219 / 0.160 s	1920 个已生成区间
路径置信度均值 / 中位数	0.750 / 0.969	同上
音频覆盖均值	1.000 / 0.9938	已生成区间 / 全部原词
视觉覆盖均值	0.9276 / 0.9218	已生成区间 / 全部原词
视觉零覆盖词数	128 / 140	已生成区间 / 全部原词
全片未检出人脸的样本	4	100 条样本
触发截断的样本	6	100 条样本
未进入接口的词元 / 完全失位原词	70 / 52	全量文本尾部记录

位置记录在帧级文件中，原因计数保存在样本清单与逐样本元数据中。

已生成区间的词时长中位数为 0.160 s，其中 28.1% 短于 0.10 s；若以解码音频总时长 777.0091 s 除以 1932 个原词，含词间停顿的平均间隔约为 0.402 s。两者的差异说明：按词数均分音轨会把词间停顿推入相邻词，并掩盖短词的真实边界。CTC 区间与交叠池化因此分别在声学证据与实际帧支撑上计算，而不由总时长反推每词边界。

图 5 从词元长度与词级观测状态解释接口覆盖的构成。全量 2317 个内容词元中，2247 个进入固定接口，保留比例为 96.98%；音频零覆盖的 12 词均未生成时间区间。视觉方面，除这 12 词外，还有 128 个已生成区间的词没有有效视觉特征支撑。因此，时间锚点的存在与模态观测的存在是两个独立条件，在模型中分别由内容掩码 P 与观测掩码 O^m 表达。




图 5 由样本清单和词级明细重算的接口覆盖情况

(2) 典型样本的文本、语音与视频对应

选取样本-yRb-Jum7EQ\$_5。该句以否定与转折改变语义走向：*not by the students of terrorism, but by those who teach terrorism*。图 6 在统一秒轴上给出 25 个原词的音频区间、关键帧与两类帧级特征，帧级特征面板按维度标准化以便同图对比，点线为否定词 *not* 的切分时刻；表 8 给出词区间、词元数、模态覆盖率以及词处的音高与能量。文本向量由这些词对应的 BERT 内容位置取得，视频帧通过 PTS 定位，不由 50 位下标换算时间。



图 6 典型样本的文本、语音与视频对应

表 8 典型样本的词区间与三模态映射

原词	语音区间 (s)	词元数	d^a	d^v	F_0 (半音)	能量
lost	[1.48, 1.68)	1	1.00	1.00	18.1	0.14
attack,	[5.42, 6.14)	2	1.00	1.00	20.3	0.21
not [†]	[6.26, 6.48)	1	1.00	1.00	21.2	0.34
but [†]	[8.78, 9.08)	1	1.00	1.00	27.9	0.76
teach	[10.10, 10.24)	1	1.00	1.00	29.3	0.36
teacher.	[12.46, 12.80)	2	1.00	1.00	23.0	0.33

以 teacher. 为例，父词区间为 [12.46, 12.80) s，两个词元共享该区间，分别对应 768 维上下文文本表示，并继承相同的音视频池化向量。否定与转折处出现局部音高与能量峰值：*not* 与 *but* 相对各自前 0.7s 参考段分别抬高 2.0 与 7.3 半音，能量抬高 0.18 与 0.60。在 100 条样本内可评估的 20 个否定/转折词上，70% 出现音高局部抬高、中位抬高 2.2 半音，全部出现能量抬升、中位抬升 0.49 (audit_prosody.json)。词元语义、语音窗口与视频帧段由此在同一时间轴上建立一致对应，否定与转折的韵律标记落在同一位置。

(3) 观测缺失与截断的处理效果

图 7 展示人脸检出率为 37.5%、视觉有效帧占比 33.9% 的样本 -HwX2H8Z4hY\$_5。无有效视觉支撑的锚点取 $O^v = 0$ 、 $Q^v = 0$ ，其余位置按有效帧池化；音频与文本保留各自可用信息。该例说明位置级掩码能够刻画同一样本内部的局部模态缺失。




图 7 局部视觉观测缺失样本

文本方面，6 条样本超过 48 个内容词元，合计 70 个词元未进入接口，52 个原词完全失去接口位置。最严重样本含 65 个原词、82 个词元，其中 34 个词元与 26 个原词位于接口之外；这些词元的词级时间与音视频记录仍保留于全量输出。接口长度属于可配置参数，扩展后即可在相同记录上重新编码，无需重复特征提取。

图 8 并列展示定长接口与全量词区间。蓝色部分对应保留的 48 个内容词元，红色三格示意截断尾部；中图展示 65 个原词的时间记录，由此区分位置级输出范围与全量时间记录范围。

(4) 质量分量与参数敏感性

音频与视觉 $\tilde{V}$ 的 95% 分位数分别为 0.3328 和 0.1875，128 个视觉零覆盖词另记为退化状态。音视频 Q 的 Spearman 相关约为 0.764：两者共享路径置信度因子，排序差异则来自各自独立的覆盖与扰动分量。




图 8 样本-a55Q6RWvTA\$_3 的文本接口截断

表 9 质量分量统计 (1920 个已生成时间区间的原词)

分量	音频均值	音频中位数	视觉均值	视觉中位数
覆盖指标 d	1.0000	1.0000	0.9276	1.0000
归一化扰动方差 $\tilde{V}$	0.0931	0.0471	0.0478	0.0192
综合质量 Q	0.6849	0.8673	0.6892	0.9124

图 9 展示质量分量及音视频 Q 的联合分布。路径置信度的差异使相同覆盖率的锚点具有不同质量；视觉 $Q = 0$ 对应零覆盖词。归一化扰动方差采用对数坐标展示，退化记录通过独立标记识别。

质量分数的三个参数按词区间的时间尺度与模块规模设定：衰减系数 γ 控制覆盖偏离的惩罚强度，扰动次数 B 与尺度 s 决定边界敏感性的估计精度。表 10 给出三者变化时的排序一致性，用以检验质量分量的取值是否依赖具体参数设定。

表 10 参数敏感性结果与适用范围

实验	已有结果	适用范围
γ 变化	音频 Q : 0.5 和 2 相对 1 的样本内排序相关均值 0.974、0.972	音频质量分量的排序在该参数取值范围内保持稳定
B 变化	视觉 V : 50 相对 200 的排序相关 0.995	在排序前 12 条样本各前 8 词上核算的视觉方差排序
s 变化	相对 40 ms, 20 ms 的样本内 Q 排序相关均值 0.915/0.937, 80 ms 为 0.960/0.901	音频与视觉分别计算的样本内排序一致性

在所选子集上， $B = 50$ 与 200 的视觉方差排序相关为 0.995，点值平均差为 22.9%。增加采样次数会改变方差估计值，但锚点排序较为一致，因此采用 $B = 50$ 进行相对质量比较。




图9 1920个已生成词区间的路径置信度、归一化边界扰动方差和综合质量分布

(5) 相对时序一致性检验

若时间映射正确，人为错位应当降低音视频之间的词级关联。据此设计单模态错位实验：保持一侧词窗口不动，仅将另一侧平移 ± 0.25 、 ± 0.5 或 ± 1.0 s，比较响度与嘴部开合、嘴部运动的词级相关。12种非零错位条件下的两项平均相关均低于各自的样本配对基线，24项 Wilcoxon 检验中 20 项在未校正的 5% 水平上显著，最小 p 约为 6.8×10^{-8} 。

各错位条件分别剔除越界与无覆盖词，相关变化同时包含时间平移与可用词集合变化的影响。在该口径下，任一非零错位都使两项相关下降，且多数差异在统计上显著，说明当前时间映射保持了音视频之间的词级关联。

在 83 条人脸检出率较高的样本上，包络相关最大值对应的延迟中位数为嘴部开合 $+0.09$ s、嘴部运动 $+0.22$ s 与全脸运动 $+0.27$ s，正值表示音频包络较晚。该量记为**包络最佳延迟**，用于描述词级音视频的联动强度，其取值依赖特征类型、取样方式与搜索范围。

表 11 汇总附件 1 全部 100 条样本的结果，特征文件字段与读取方法随支撑材料提交。

(6) 结果讨论与适用范围

词级时间区间连接了子词表示与音视频帧：字符偏移确定归属，交叠池化统一采样粒度，内容与观测掩码记录有效范围。100 条样本均完成处理，词区间生成率为 99.38%；50 位接口之外仍保留全量词级时间与音视频记录。现有结果从区间结构、观测覆盖和典型片段三个方面检验了对应关系，后续可通过人工词边界标注进一步评价绝对时间误差。

(7) 全量样本结果

表 11 逐条汇总 100 条样本。视、音时长采用编辑列表有效呈现口径，合计分别为 787.985 s 和 777.106 s；对齐粒度均为原词锚点与子词继承。

T、A、V 表示文本、语音和人脸视觉分支；V 后的星号、空心圆分别表示部分帧、全

片未检出人脸。“区间/词”分母含未对齐项，“内容位”为进入 50 位接口的内容词元数，上限为 48。

表 11 附件 1 全部 100 条样本的特征提取结果

序号	样本编号	模态	视/音时长 (s)	T/A/V 维度	区间/词	内容位	检出率
1	-3g5yACwYnA\$_\$2	T+A+V	9.394/9.231	768/25/16	14/14	17	100.0%
2	-3g5yACwYnA\$_\$3	T+A+V	14.389/14.328	768/25/16	29/29	40	100.0%
3	-3g5yACwYnA\$_\$9	T+A+V	8.817/8.696	768/25/16	21/21	28	100.0%
4	-3g5yACwYnA\$_\$13	T+A+V	5.514/5.399	768/25/16	15/15	18	100.0%
5	-3nNcZdcdvU\$_\$5	T+A+V*	7.868/7.788	768/25/16	18/18	22	99.6%
6	-571d8cVauQ\$_\$0	T+A+V*	5.167/4.992	768/25/16	12/12	16	96.7%
7	-571d8cVauQ\$_\$5	T+A+V	15.273/15.115	768/25/16	43/43	48	100.0%
8	-6rXp3zJ3kc\$_\$8	T+A+V	12.805/12.738	768/25/16	34/34	38	100.0%
9	-9y-fZ3swSY\$_\$0	T+A+V	6.900/6.757	768/25/16	22/22	28	100.0%
10	-9y-fZ3swSY\$_\$4	T+A+V	2.821/2.665	768/25/16	9/9	11	100.0%
11	-9y-fZ3swSY\$_\$8	T+A+V*	4.989/4.917	768/25/16	12/12	14	91.3%
12	-AUZQgSxyPQ\$_\$2	T+A+V	22.511/22.405	768/25/16	41/41	48	100.0%
13	-HeZS2-Prhc\$_\$2	T+A+V	8.262/8.151	768/25/16	16/16	17	100.0%
14	-HwX2H8Z4hY\$_\$2	T+A+V*	3.982/3.916	768/25/16	7/8	12	23.5%
15	-HwX2H8Z4hY\$_\$5	T+A+V*	5.653/5.544	768/25/16	9/10	10	37.5%
16	-HwX2H8Z4hY\$_\$6	T+A+V*	3.358/3.256	768/25/16	7/7	9	66.7%
17	-HwX2H8Z4hY\$_\$9	T+A+V*	7.734/7.637	768/25/16	22/22	24	12.9%
18	-I_e4mIh0yE\$_\$1	T+A+V	7.622/7.444	768/25/16	18/18	21	100.0%
19	-I_e4mIh0yE\$_\$3	T+A+V	9.163/8.995	768/25/16	22/22	30	100.0%
20	-MeTTeMJBNC\$_\$0	T+A+V*	9.334/9.218	768/25/16	21/21	26	99.6%
21	-MeTTeMJBNC\$_\$7	T+A+V	10.517/10.412	768/25/16	31/31	33	100.0%
22	-MeTTeMJBNC\$_\$13	T+A+V	5.430/5.255	768/25/16	14/14	16	100.0%
23	-NFrJFQijFE\$_\$1	T+A+V°	5.746/5.659	768/25/16	16/16	16	0.0%
24	-NFrJFQijFE\$_\$2	T+A+V°	6.856/6.698	768/25/16	18/18	18	0.0%
25	-RfYyzHpjk4\$_\$2	T+A+V	5.516/5.392	768/25/16	25/25	29	100.0%
26	-RfYyzHpjk4\$_\$8	T+A+V	4.589/4.532	768/25/16	17/17	21	100.0%
27	-RfYyzHpjk4\$_\$11	T+A+V	5.239/5.074	768/25/16	17/17	19	100.0%
28	-THoVjtIkeU\$_\$2	T+A+V	4.292/4.230	768/25/16	10/10	11	100.0%
29	-THoVjtIkeU\$_\$6	T+A+V*	8.097/7.983	768/25/16	30/30	32	99.6%
30	-THoVjtIkeU\$_\$12	T+A+V	14.896/14.805	768/25/16	39/39	42	100.0%
31	-UUCSKoHeMA\$_\$0	T+A+V*	7.867/7.732	768/25/16	18/18	23	99.6%
32	-UacrmKiTn4\$_\$4	T+A+V	4.741/4.681	768/25/16	14/14	15	100.0%
33	-UacrmKiTn4\$_\$10	T+A+V	7.362/7.242	768/25/16	18/18	22	100.0%
34	-UuXlXuaiiE\$_\$0	T+A+V	3.700/3.576	768/25/16	9/9	12	100.0%
35	-UuXlXuaiiE\$_\$1	T+A+V	10.350/10.267	768/25/16	27/27	33	100.0%
36	-UuXlXuaiiE\$_\$3	T+A+V	4.130/4.038	768/25/16	9/9	9	100.0%
37	-UuXlXuaiiE\$_\$6	T+A+V	8.114/7.944	768/25/16	22/22	23	100.0%
38	-a55Q6RWvTA\$_\$3	T+A+V	22.154/22.084	768/25/16	65/65	48	100.0%
39	-aNfi7CP8vM\$_\$7	T+A+V	8.695/8.538	768/25/16	18/18	23	100.0%
40	-aqamKhZ1Ec\$_\$0	T+A+V	11.000/10.890	768/25/16	13/14	16	100.0%
41	-dxftGcXJoc\$_\$0	T+A+V*	20.534/20.410	768/25/16	38/41	48	78.0%
42	-dxftGcXJoc\$_\$1	T+A+V	16.161/16.019	768/25/16	36/36	42	100.0%
43	-dxftGcXJoc\$_\$2	T+A+V	16.698/16.633	768/25/16	32/34	40	100.0%
44	-dxftGcXJoc\$_\$6	T+A+V	12.735/12.628	768/25/16	27/27	32	100.0%
45	-egA8-b7-3M\$_\$1	T+A+V	10.266/10.156	768/25/16	19/20	22	100.0%
46	-egA8-b7-3M\$_\$6	T+A+V	6.265/6.183	768/25/16	12/12	13	100.0%
47	-egA8-b7-3M\$_\$9	T+A+V	5.090/4.936	768/25/16	10/10	12	100.0%
48	-egA8-b7-3M\$_\$13	T+A+V	4.184/4.024	768/25/16	11/11	16	100.0%
49	-egA8-b7-3M\$_\$16	T+A+V	5.538/5.483	768/25/16	11/11	13	100.0%
50	-egA8-b7-3M\$_\$17	T+A+V	7.271/7.095	768/25/16	16/16	19	100.0%

表 11 附件 1 全部 100 条样本的特征提取结果（续）

序号	样本编号	模态	视/音时长 (s)	T/A/V 维度	区间/词	内容位	检出率
51	-egA8-b7-3M\$_\$18	T+A+V	8.386/8.266	768/25/16	22/22	27	100.0%
52	-egA8-b7-3M\$_\$20	T+A+V	6.645/6.475	768/25/16	20/20	24	100.0%
53	-egA8-b7-3M\$_\$26	T+A+V	6.031/5.920	768/25/16	15/15	19	100.0%
54	-hnBHBn8p5A\$_\$6	T+A+V*	6.401/6.333	768/25/16	13/13	14	82.3%
55	-hnBHBn8p5A\$_\$7	T+A+V*	7.372/7.308	768/25/16	13/13	17	60.8%
56	-iRbcNs9oI8\$_\$3	T+A+V	5.621/5.538	768/25/16	8/8	9	100.0%
57	-iRbcNs9oI8\$_\$6	T+A+V	2.903/2.821	768/25/16	5/5	5	100.0%
58	-iRbcNs9oI8\$_\$7	T+A+V	4.104/4.006	768/25/16	9/9	15	100.0%
59	-iRbcNs9oI8\$_\$8	T+A+V	8.093/8.026	768/25/16	21/21	26	100.0%
60	-iRbcNs9oI8\$_\$9	T+A+V*	3.416/3.374	768/25/16	5/5	5	78.4%
61	-lZEya4AM_4\$_\$5	T+A+V	7.675/7.570	768/25/16	19/19	21	100.0%
62	-lZEya4AM_4\$_\$6	T+A+V	14.792/14.741	768/25/16	43/43	48	100.0%
63	-mJ2ud6oKI8\$_\$1	T+A+V ^o	6.103/6.054	768/25/16	13/13	13	0.0%
64	-mJ2ud6oKI8\$_\$2	T+A+V*	5.731/5.702	768/25/16	11/11	17	78.4%
65	-mJ2ud6oKI8\$_\$6	T+A+V	2.257/2.229	768/25/16	5/5	5	100.0%
66	-mJ2ud6oKI8\$_\$8	T+A+V	4.192/4.172	768/25/16	11/11	11	100.0%
67	-mJ2ud6oKI8\$_\$9	T+A+V	7.033/6.909	768/25/16	22/22	29	100.0%
68	-mqbVkbCndg\$_\$0	T+A+V	6.500/6.385	768/25/16	12/12	17	100.0%
69	-qDkUB0GgYY\$_\$6	T+A+V	4.678/4.614	768/25/16	16/16	18	100.0%
70	-ri04Z7vwnc\$_\$0	T+A+V ^o	2.807/2.763	768/25/16	8/8	8	0.0%
71	-ri04Z7vwnc\$_\$2	T+A+V*	6.027/5.914	768/25/16	16/16	26	35.7%
72	-ri04Z7vwnc\$_\$5	T+A+V	3.545/3.440	768/25/16	8/9	11	100.0%
73	-s9qJ7ATP7w\$_\$0	T+A+V	6.867/6.710	768/25/16	24/24	28	100.0%
74	-s9qJ7ATP7w\$_\$1	T+A+V	4.792/4.644	768/25/16	11/11	12	100.0%
75	-s9qJ7ATP7w\$_\$4	T+A+V*	4.427/4.247	768/25/16	9/9	10	71.3%
76	-s9qJ7ATP7w\$_\$5	T+A+V	8.561/8.398	768/25/16	19/19	20	100.0%
77	-s9qJ7ATP7w\$_\$6	T+A+V*	2.475/2.315	768/25/16	5/5	5	81.7%
78	-s9qJ7ATP7w\$_\$7	T+A+V*	6.966/6.839	768/25/16	28/28	38	63.3%
79	-s9qJ7ATP7w\$_\$8	T+A+V	3.295/3.184	768/25/16	12/13	17	100.0%
80	-t217m2on-s\$_\$2	T+A+V	5.686/5.630	768/25/16	12/12	16	100.0%
81	-t217m2on-s\$_\$7	T+A+V	17.183/17.026	768/25/16	45/45	48	100.0%
82	-tANM6ET1_M\$_\$3	T+A+V	6.758/6.604	768/25/16	22/22	29	100.0%
83	-tPCytz4rww\$_\$10	T+A+V	4.789/4.678	768/25/16	12/12	15	100.0%
84	-tPCytz4rww\$_\$11	T+A+V	5.467/5.378	768/25/16	17/17	20	100.0%
85	-tPCytz4rww\$_\$12	T+A+V	11.864/11.736	768/25/16	26/26	28	100.0%
86	-tPCytz4rww\$_\$16	T+A+V	7.206/7.139	768/25/16	16/16	17	100.0%
87	-tPCytz4rww\$_\$18	T+A+V	6.645/6.569	768/25/16	16/16	22	100.0%
88	-uywlfIYOS8\$_\$4	T+A+V	6.045/5.882	768/25/16	18/18	22	100.0%
89	-vxjVxOeScU\$_\$4	T+A+V	9.127/9.037	768/25/16	21/21	27	100.0%
90	-wMB_hJL-3o\$_\$7	T+A+V*	6.044/5.976	768/25/16	22/22	23	96.7%
91	-wny00Az3g8\$_\$0	T+A+V	3.334/3.274	768/25/16	9/9	11	100.0%
92	-wny00Az3g8\$_\$1	T+A+V	6.844/6.776	768/25/16	22/23	28	100.0%
93	-wny00Az3g8\$_\$2	T+A+V	6.687/6.523	768/25/16	23/23	28	100.0%
94	-wny00Az3g8\$_\$3	T+A+V	6.146/6.100	768/25/16	20/20	20	100.0%
95	-wny00Az3g8\$_\$5	T+A+V	6.912/6.741	768/25/16	20/20	27	100.0%
96	-wny00Az3g8\$_\$7	T+A+V	8.068/7.911	768/25/16	29/29	31	100.0%
97	-wny00Az3g8\$_\$9	T+A+V	6.213/6.043	768/25/16	20/20	22	100.0%
98	-yRb-Jum7EQ\$_\$1	T+A+V	29.288/29.109	768/25/16	49/49	48	100.0%
99	-yRb-Jum7EQ\$_\$5	T+A+V	13.169/13.044	768/25/16	25/25	31	100.0%
100	-yRb-Jum7EQ\$_\$6	T+A+V	11.226/11.242	768/25/16	19/19	24	100.0%

4.2 问题二的模型建立与求解

4.2.1 问题分析与建模思路

实际交互中的转写失败、语音中断和画面遮挡，通常只使某一模态的局部连续片段不可用。问题二要求在此条件下，同时预测样本的情感极性与连续情感强度，并分析缺失模态、缺失位置、缺口长度及缺失率对预测性能的影响。因此，建模的关键不仅是融合三类特征，还在于区分有效观测与缺失信息，并控制不可靠补全对最终判断的影响。

针对上述问题，构建三态感知可靠补全与融合网络 TSRF-D，以 EMT-DLFR 作为异构教师进行任务蒸馏。学生以结构填充、有效观测和局部缺失三种状态描述输入，利用样本内可用节点生成补全表示，通过可靠度门控调节补全信息与缺失嵌入的融合比例，再经双向时序编码实现极性与强度联合预测。冻结教师在不额外遮挡的输入上产生软目标，学生在局部缺失输入下同时接受类别平衡的标签监督与教师监督。

问题一研究原始素材的特征提取与时间对齐，本问研究对齐特征在局部缺失条件下的情感预测。根据赛题数据安排，训练与评价采用附件 2 的对齐版特征，专项推理采用附件 3 的对应版本。两问沿用一致的时序表示思想，各自使用相应附件的特征维度与输入接口。

4.2.2 数据准备

(1) 数据划分与输入接口

附件 2 共含 4850 条样本，按题目给定划分使用 3395 条训练样本、728 条验证样本和 727 条测试样本；附件 3 包含 30 条无标签样本。每个样本存储为至多 50 个对齐序列位置，文本、语音、视觉特征维度分别为 768、74 和 35。三分类标签对应负向、中性和正向，连续强度位于 $[-3, 3]$ ；其中 0 仅属于中性类。强度标签包含非整数值，故按连续回归处理。

为统一训练与专项推理的文本输入，采用冻结的 bert-base-uncased 第 12 层，将 text_bert 中的词元编号、注意力掩码和分段编号转换为连续表示。重算特征与附件 2 自带特征的平均绝对偏差约为 6.6×10^{-7} ，最小余弦相似度约为 0.9999997，二者具有较高的数值一致性。

本文以对齐锚点为时间组织单位，假设同一锚点上的三模态特征具有附件规定的时间对应关系。由于附件 2 未提供逐词时间戳，缺口长度统一以锚点数度量。声学 & 视觉向量作为整体特征参与建模。

表 12 数据接口与处理约定

项目	附件 2	附件 3
用途与规模	训练 3395、验证 728、测试 727	最终预测 30 条，无标签
输入形状	$X^t \in \mathbb{R}^{50 \times 768}$, $X^a \in \mathbb{R}^{50 \times 74}$, $X^v \in \mathbb{R}^{50 \times 35}$	
文本入口	使用相同冻结 BERT，由 text_bert 生成连续表示	
缺失识别	文本内容位的 [UNK]；语音、视觉内容位的全零向量	
统计量估计	仅训练集观测位置估计均值与标准差	复用训练统计量
评价方式	基于真实标签计算分类与回归指标	汇总全量预测及预测概率分布

(2) 内容、观测与人工缺失掩码

记样本为 i ，锚点为 k ，模态 $m \in \{t, a, v\}$ 。内容掩码 P_{ik} 由注意力有效位排除 [CLS] 和 [SEP] 得到。自然观测掩码分别定义为

$$O_{ik}^t = P_{ik} \mathbf{1}\{\text{token}_{ik} \neq [\text{UNK}]\}, \quad (18)$$

$$O_{ik}^a = P_{ik} \mathbf{1}\{X_{ik}^a \neq \mathbf{0}\}, \quad O_{ik}^v = P_{ik} \mathbf{1}\{X_{ik}^v \neq \mathbf{0}\}. \quad (19)$$

其中 $X_{ik}^m \neq \mathbf{0}$ 表示该向量至少有一个非零分量。依据附件的缺失标记规则，文本由词元标记识别缺失，语音和视觉由全零向量识别缺失，三路观测掩码分别计算。

令人工遮挡掩码为 H_{ik}^m ，且 $H_{ik}^m \leq O_{ik}^m$ ，则最终观测掩码 $\tilde{O}_{ik}^m = O_{ik}^m(1 - H_{ik}^m)$ 。三态变量定义为

$$s_{ik}^m = \begin{cases} 0, & P_{ik} = 0, \\ 1, & P_{ik} = 1, \tilde{O}_{ik}^m = 1, \\ 2, & P_{ik} = 1, \tilde{O}_{ik}^m = 0. \end{cases} \quad (20)$$

自然缺失与人工缺失在模型输入中均为状态 2，但仅人工遮挡位置保留可用于重建评价的原始真值。对模态 m 的第 j 维，使用训练集观测位置估计 μ_j^m, σ_j^m 并计算

$$\bar{X}_{ikj}^m = \frac{X_{ikj}^m - \mu_j^m}{\tilde{\sigma}_j^m}, \quad \tilde{\sigma}_j^m = \begin{cases} 1, & \sigma_j^m < 10^{-6}, \\ \sigma_j^m, & \text{其他}. \end{cases} \quad (21)$$

结构位在标准化后置零，缺失位通过观测掩码排除于候选集合之外。人工音视频遮挡使用标准化空间中的零值；文本则先将选定词元替换为 [UNK]，再经 BERT 编码，同时保留原有序列位置。这样可以避免未遮挡位置的上下文表示提前包含已删除文本信息。

附件 3 共含 605 个内容锚点，文本、语音和视觉分别有 131、131 和 135 个缺失位置。文本与语音掩码在 30 条样本上逐位一致，文本与视觉掩码在 29 条样本上逐位一致，缺失主要表现为多模态局部同段共缺。

4.2.3 模型构建

(1) 总体结构与三态投影

图 10 给出学生网络及教师监督的关系。学生的计算顺序为投影、补全与门控、时序编码、池化和双任务预测；时序编码位于补全之后。



图 10 TSRF-D 网络结构与教师-学生监督关系

将三模态特征映射到公共维度 $d = 64$ 。设模型实际接收的标准化输入为 $\tilde{x}_{ik}^m$ ，则

$$z_{ik}^m = P_{ik} \left(W_m \tilde{x}_{ik}^m + b_m + e_m^{\text{mod}} + e_{s_{ik}^m}^{\text{state}} + e_k^{\text{pos}} \right). \quad (22)$$

模态嵌入描述信息来源，状态嵌入表征可观测性，位置嵌入保留序列顺序，三者共同形成缺失感知的节点表示。

(2) 观测节点加权补全

对样本 i ，以 $\Omega_i = \{(n, j) : \tilde{O}_{ij}^n = 1\}$ 为候选集。缺失位置的查询及候选键值为

$$q_{ik}^m = Q(e_k^{\text{pos}} + e_m^{\text{mod}} + e_2^{\text{state}}), \quad \kappa_{ij}^n = K_z(z_{ij}^n), \quad v_{ij}^n = V_z(z_{ij}^n), \quad (23)$$

其中 Q, K_z, V_z 为可学习仿射映射。查询由目标位置、模态与缺失状态共同确定，候选键值由有效观测生成，从而将缺失位置的结构信息与样本内容联系起来。

设 ℓ_{ij}^n 为候选位置所在连续观测段的长度，定义观测连续性先验

$$u_{ij}^n = \sigma \left(\alpha_0 + \alpha_1 \tilde{O}_{ij}^n + \alpha_2 \min(\ell_{ij}^n/10, 1) \right). \quad (24)$$

该先验利用连续观测段长度描述候选节点的局部可用性。对 $(n, j) \in \Omega_i$ ，补全代价及权重为

$$C_{i,k,j}^{m,n} = \frac{\|q_{ik}^m - \kappa_{ij}^n\|_2^2}{d} + \lambda_t \frac{|k-j|}{50} + \lambda_q (1 - u_{ij}^n), \quad (25)$$

$$\pi_{i,k,j}^{m,n} = \frac{\exp(-C_{i,k,j}^{m,n}/\tau)}{\sum_{(n',j') \in \Omega_i} \exp(-C_{i,k,j'}^{m,n'}/\tau)}, \quad \hat{z}_{ik}^m = \sum_{(n,j) \in \Omega_i} \pi_{i,k,j}^{m,n} v_{ij}^n. \quad (26)$$

上述代价综合表示距离、位置距离和观测连续性，其中时间项赋予邻近锚点较高的候选优先级。候选范围覆盖样本内全部可用模态，因而兼顾同模态时序信息与跨模态关联信息。

(3) 可靠度门控与情感预测

依据加权代价均值、加权方差、最小有效代价、候选数量占比及目标模态可用比例，构造门控输入

$$g_{ik}^m = [\bar{C}, \text{Var}_\pi(C), C_{\min}, |\Omega_i|/(3 \cdot 50), a_i^m, e_m^{\text{mod}}], \quad a_i^m = \frac{\sum_k \tilde{O}_{ik}^m}{\sum_k P_{ik}^m}. \quad (27)$$

两层感知机输出 $\rho_{ik}^m = \sigma(G(g_{ik}^m))$ ，并与可学习的缺失嵌入 e_m^{miss} 融合：

$$z_{ik}^{m,f} = \tilde{O}_{ik}^m z_{ik}^m + P_{ik} (1 - \tilde{O}_{ik}^m) [\rho_{ik}^m z_{ik}^m + (1 - \rho_{ik}^m) e_m^{\text{miss}}]. \quad (28)$$

门控权重 ρ 调节补全表示对融合结果的贡献。当候选集为空时，令 $\pi = 0, \rho = 0$ ，以缺失嵌入完成回退。

对每个模态独立进行单层双向 GRU 编码，双向隐状态合计 64 维。实现中按有效前缀打包序列，以避免尾部填充通过反向递归污染内容位置。随后仅在 $P = 1$ 处计算均值池化和最大池化，拼接三模态池化向量及 a_i^t, a_i^a, a_i^v ，形成 $6d + 3 = 387$ 维向量，经共享 MLP 得到 h_i 。双任务输出为

$$p_i = \text{softmax}(W_c h_i + b_c), \quad \hat{y}_i = \arg \max_c p_{ic}, \quad \hat{r}_i = 3 \tanh(w_r^\top h_i + b_r). \quad (29)$$

分类与回归采用共享表示和独立输出头，并通过下文的一致性损失建立任务间的软约束。

(4) 真实标签与任务蒸馏

教师采用 EMT-DLFR 的任务适配结构 [9]。文本经线性投影，语音和视觉经单向 LSTM 编码到 64 维；两层、四头的高效多模态 Transformer 在全局模态表示与局部序列之间交互，融合表示经双任务头输出三类 logits 和连续强度。教师训练同时使用基础与遮挡输入的标签监督，并结合高层表示吸引和低层特征重建目标；参数仅在附件 2 训练集上学习，保存轮次由验证集联合指标确定。

教师完成训练后冻结参数，为每个学生种子提供对应教师的训练样本输出。生成软目标时不增加人工遮挡，已有自然缺失仍保留；学生接收人工缺失输入，利用任务蒸馏 [8] 学习教师的类别分布和强度输出。学生真实标签监督为

$$\mathcal{L}_{\text{sup}} = \text{CE}_w(y, p^S) + \lambda_r \text{Huber}_1(r, \hat{r}^S) + \lambda_c [(p_+^S - p_-^S) - \tanh(\hat{r}^S/3)]^2, \quad (30)$$

设训练集样本量为 N ，类别 c 的样本量为 N_c ，取 $w_c = N/(3N_c)$ 。对训练批次 $\mathcal{B}$ ，分类损失按实际样本权重归一化：

$$\text{CE}_w(y, p^S) = -\frac{\sum_{i \in \mathcal{B}} w_{y_i} \log p_{i, y_i}^S}{\sum_{i \in \mathcal{B}} w_{y_i}}. \quad (31)$$

回归与一致性损失仍按样本平均。类别权重仅作用于真实标签的分类损失，以平衡不同类别对监督目标的贡献；不改变训练采样频率和预测时的最大概率决策规则。教师与学生的分类 logits 记为 o^T, o^S ，温度为 T ，蒸馏目标为

$$\mathcal{L}_{\text{dc}} = T^2 \text{KL}(\text{sg}[\text{softmax}(o^T/T)] \parallel \text{softmax}(o^S/T)), \quad (32)$$

$$\mathcal{L}_{\text{dr}} = \text{Huber}_1(\hat{r}^S, \text{sg}[\hat{r}^T]). \quad (33)$$

sg 表示停止梯度。训练采用样本等权的蒸馏损失，并离线缓存教师在训练样本上的输出。分类蒸馏传递类别间的分布信息，强度蒸馏约束连续预测，两者共同指导学生在学习缺失条件下的情感表示。

(5) 补全与相对可靠度监督

对具有真值的人工遮挡集合 $\mathcal{H}_m$ ，使用可学习解码头 D_m 将补全表示映射回原始标准化特征空间：

$$\mathcal{L}_{\text{rec}} = \frac{1}{|\mathcal{M}_H|} \sum_{m \in \mathcal{M}_H} \frac{1}{|\mathcal{H}_m|} \sum_{(i,k) \in \mathcal{H}_m} \text{SmoothL1}_1(D_m(\hat{z}_{ik}^m), \bar{X}_{ik}^{m, \text{true}}), \quad (34)$$

其中每个向量的损失对特征维取均值， $\mathcal{M}_H$ 为当前批次存在人工遮挡的模式集合。重建目标为标准化后的原始特征，解码头与学生网络共同训练。

分别计算补全和回退表示相对真值的逐位置平均绝对误差 $e_{\text{rec}}, e_{\text{fal}}$ ，构造

$$\rho^* = \text{sg}[\sigma((e_{\text{fal}} - e_{\text{rec}})/\tau_\rho)], \quad \mathcal{L}_{\text{rel}} = \text{BCE}(\rho, \rho^*). \quad (35)$$

可靠度损失同样先在各模式人工遮挡位平均，再在有遮挡模式间平均。该目标鼓励门控识别补全是否优于模型自身回退。自然缺失无原始真值，不参与上述两项监督。

综合目标为

$$\mathcal{L} = \mathcal{L}_{\text{sup}} + \beta_e (\lambda_{\text{dc}} \mathcal{L}_{\text{dc}} + \lambda_{\text{dr}} \mathcal{L}_{\text{dr}} + \lambda_{\text{rec}} \mathcal{L}_{\text{rec}} + \lambda_{\text{rel}} \mathcal{L}_{\text{rel}}). \quad (36)$$

首轮 $\beta_e = 0$ ，随后三轮线性升至 1，避免训练初期辅助目标主导优化。预热阶段保留分类、回归和一致性损失。

4.2.4 模型求解与参数设置

(1) 遮挡策略与训练流程

人工缺失由无新增遮挡、单模式局部缺口、多模式缺失和整模式丢弃混合构成，采样比例分别为 20%、45%、25% 和 10%。局部遮挡保留自然缺失，只作用于原可观测位置。文本通过预生成遮挡编码库轮换使用，降低 BERT 重复编码成本；音视频依据对应掩码处理。混合场景用于增强训练覆盖，整模式丢弃只承担压力训练作用。其中，含文本的 9 类遮挡模式按样本预生成并在轮次间选用；不含文本的模式按种子和轮次生成。局部缺口由参数为 0.35 的几何分布采样段长，并受目标遮挡预算、最大 32 锚点段长和样本边界限制；

整模态丢弃类覆盖对应模态的全部内容位。目标比例控制采样预算，实际遮挡量由最终掩码统计：局部与多模态类平均覆盖约 10% 内容锚点，缺口段长以 1–4 个锚点为主。

(2) 选模准则与关键参数

模型以验证集联合指标选择训练轮次：

$$J = 0.5F_{\text{base}} + 0.5 \left(\frac{1}{4} \sum_{c \in \mathcal{C}} F_c \right) - 0.1 \text{MAE}_{\text{base}}, \quad \mathcal{C} = \{t, a, v, tav\} \text{ 的居中 8 锚点缺口. } \quad (37)$$

其中 F 为 Macro-F1，“基础输入”保留自然缺失而不增加人工遮挡。选模中的固定 8 锚点缺口对短样本按有效长度截断，属于包含短样本整段遮挡的压力条件。下文主要评价另以 $L_i - 1$ 限制连续区间长度，区分选模压力条件与局部缺失评价。教师与学生均按验证集 J 保存参数。

表 13 TSRF-D 模型与训练参数

参数	取值
公共维度、Dropout	64、0.2
时序编码器	每模态单层 BiGRU；单方向隐维 32
补全参数	$\tau = 0.5, \lambda_t = 0.1, \lambda_q = 0.5$
观测连续性先验	$\alpha_0 = 0, \alpha_1 = 2, \alpha_2 = 0.5$ ；段长尺度 10
损失权重	$\lambda_r = 1, \lambda_c = 0.2, \lambda_{\text{rec}} = 0.5, \lambda_{\text{rel}} = 0.3$
蒸馏与门控目标	$\lambda_{\text{dc}} = \lambda_{\text{dr}} = 1, T = 2, \tau_\rho = 0.2$
优化器与调度	AdamW，初始学习率 0.0015，权重衰减 10^{-4} ，余弦调度
批量、轮数、早停	256、至多 32 轮、耐心值 8；梯度裁剪范数 5
教师与分类权重	EMT-DLFR 任务适配版； $w_c = N/(3N_c)$ ，按训练标签计算
随机种子与集成	教师、学生均使用 0、1、2；学生预测概率与强度分别取均值
计算环境	Python 3.12, PyTorch 2.8.0+cu128; RTX 5060 Ti; 冻结 BERT 重算文本

模型参数由附件 2 训练集学习，保存轮次由验证集确定。求解分为教师训练与学生训练两个阶段：先训练并冻结教师，再在混合缺失场景下优化学生的联合目标。完成选模后，固定学生参数进行缺失干预实验及附件 3 推理。

(3) 配置依据与类别平衡

训练集中正向样本占比为 49.19%，中性样本占比为 22.33%。若对所有样本赋予相同分类权重，正向类别在经验损失中具有更大的总权重。本文采用式 (31)，使各类别满足 $N_c w_c = N/3$ ，从训练目标上均衡三类样本的贡献，与 Macro-F1 逐类等权评价的出发点相一致。具体频数和权重见表 14。

表 14 由训练集类别频数确定的分类权重

类别	样本数 N_c	样本占比/%	权重 w_c
负向	967	28.48	1.1703
中性	758	22.33	1.4930
正向	1670	49.19	0.6776

求解过程中还考察了温和平衡规则 $w_c = [N/(3N_c)]^{1/4}$ 。该规则在既有验证集上取得小幅分类增益，但在训练集内部按来源视频分组的两组留出检查中，相对等权重的局部平均 F1 分别下降 0.0123 和 0.0106；检查覆盖 20% 连续缺口的七种模态组合及三个位置。由于收益未跨划分复现，后续不再围绕该指数搜索，最终采用由训练频数直接确定的逆频率规

则。该选择依据类别平衡目标，性能由下文完整实验评价；上述小规模检查未直接检验逆频率权重的最优性。

其余配置围绕信息缺失与双任务学习确定：冻结 EMT-DLFR 提供未追加遮挡时的任务分布，学生由真实标签和软目标共同训练；三态编码区分无效填充与内容缺失，门控使补全信息以可调比例参与融合。取 64 维公共空间以压缩高维输入，首轮标签预热和三轮辅助损失升温用于平缓多目标优化。验证准则同时包含基础分类、局部缺失分类和强度误差，避免仅按完整输入分类表现保存模型。这些配置共同构成本轮固定求解方案。

(4) 教师-学生训练算法

算法 1 给出具体求解步骤。学生训练同时结合标签、蒸馏和重建辅助目标；预生成的文本遮挡特征按相应掩码索引，以保持输入与监督位置的一致性。

算法 1 TSRF-D 教师-学生联合训练

输入：附件 2 训练集 $\mathcal{D}_{tr}$ 、验证集 $\mathcal{D}_{val}$ ，冻结 BERT，缺失场景分布 $\mathcal{Q}$ ，损失权重，种子集合 $\{0, 1, 2\}$ 。

输出：按验证集联合准则选出的学生参数 $\{\theta_S^{*(s)}\}_{s=0}^2$ 。

- 1 构建 P, O ；仅用训练集拟合标准化统计量，并由类别频数计算 $w_c = N/(3N_c)$ 。
- 2 **对每个**随机种子 $s \in \{0, 1, 2\}$ ，**执行：**
- 3 用训练集学习 EMT-DLFR 教师，结合基础/遮挡标签监督及双层恢复目标。
- 4 按验证集 J 保存教师并冻结；仅缓存训练样本在无新增遮挡输入上的输出。
- 5 初始化学生 θ_S ；令 $J^* = -\infty$ ，最大轮数 $E = 32$ ，早停耐心值为 8。
- 6 **对** $e = 1, \dots, E$ ，**执行：**
- 7 依据 $\mathcal{Q}$ 生成本轮遮挡掩码 H ，限制 $H^m \leq O^m$ ，并打乱训练样本。
- 8 设置辅助权重 $\beta_1 = 0$ ；第 2 至 4 轮依次为 1/3, 2/3, 1，此后为 1。
- 9 **对每个**训练批次 $\mathcal{B}$ ，**执行：**
- 10 保留遮挡前标准化真值 $\bar{X}^{true}$ ，仅供辅助损失使用。
- 11 将 $H^t = 1$ 处词元替换为 [UNK] 后编码；按掩码读取预生成文本特征。
- 12 音视频遮挡位使用标准化零值，更新 $\tilde{O} = O \odot (1 - H)$ 及三态变量。
- 13 学生前向：投影、加权补全、可靠度融合、BiGRU 与池化，得到 $p^S, \hat{r}^S$ 。
- 14 以逆频率类别权重计算 $\mathcal{L}_{sup}$ ，读取教师输出 $p^T, \hat{r}^T$ 。
- 15 计算分类与强度蒸馏损失 $\mathcal{L}_{dc}, \mathcal{L}_{dr}$ ；教师停止梯度。
- 16 仅在人工遮挡位计算 $\mathcal{L}_{rec}, \mathcal{L}_{rel}$ ；可靠度目标停止梯度。
- 17 按式 (36) 汇总损失；反向传播、梯度裁剪，使用 AdamW 更新学生。
- 18 **结束批次循环**；更新余弦学习率。
- 19 在验证集基础输入及四类固定局部缺口上计算 J ，评价时不更新模型参数。
- 20 若 $J > J^*$ ，保存学生参数并更新 J^* ；否则连续 8 轮无改善时提前停止。
- 21 **结束轮次循环**，恢复最优学生参数 $\theta_S^{*(s)}$ 。
- 22 **结束种子循环**；返回三组学生参数，用于冻结后的概率与强度集成。

说明：辅助权重为 0 时跳过对应损失；某批次没有人工遮挡时，重建与可靠度损失置零。附件 3 不进入本算法的训练和选模过程。

如图 11 所示，三个种子的分类指标在训练初期较快上升，随后进入波动区间。局部缺失条件下的 F1 整体低于基础输入，反映出信息遮挡带来的预测损失。联合准则在基础性能与缺失性能之间进行权衡，保存其最大值对应的学生参数。




图 11 三个学生种子的训练过程

4.2.5 实验结果与分析

(1) 评价协议与基础性能

分类采用 Accuracy 和 Macro-F1，强度预测采用 MAE 和 Pearson 相关系数。三个种子的分类概率与回归输出分别取均值后计算集成指标。基础输入保留自然缺失，不额外添加人工遮挡。附件 2 的有标签测试划分用于性能评价，附件 3 仅用于无标签专项推理。

表 15 TSRF-D 基础输入性能

划分	样本数	Accuracy	Macro-F1	MAE	Pearson
验证集	728	0.6250	0.6163	0.5818	0.6606
测试集	727	0.6437	0.6189	0.6221	0.6824

验证集 Macro-F1 为 0.6163，强度 MAE 为 0.5818；测试集对应指标为 0.6189 和 0.6221。下面在冻结参数的条件下，从缺失模态、比例、位置和长度四个方面评价预测变化。

(2) 类别权重的求解检验

为观察类别平衡对预测分布的影响，将本轮结果与已有等权重学生的验证集预测比较。两者使用相同 EMT-DLFR 教师、学生结构与三个种子，训练轮次分别由各自验证轨迹确定。

表 16 验证集类别权重与识别结果

标签权重	Macro-F1	MAE	负向召回	中性召回	正向召回
等权重	0.6191	0.5831	0.6650	0.4891	0.7041
逆频率权重	0.6163	0.5818	0.6359	0.5978	0.6331

逆频率加权后的验证集 Macro-F1 变化为-0.0028，105 种局部条件平均 F1 由 0.6019 变为 0.6012。中性召回率由 0.4891 变为 0.5978，正向召回率由 0.7041 变为 0.6331，体现了增加少数类权重后的识别取舍。本文采用训练频数确定类别权重，并同时报告总体性能与分类型表现。

(3) 连续局部缺失与输入模态消融

取模态集合 $\{t, a, v, ta, tv, av, tav\}$ 、目标区间比例 $\{5\%, 10\%, 20\%, 30\%, 40\%\}$ 以及句首、句中、句尾三个位置，形成 105 种连续缺失条件。对内容长度 $L_i \geq 2$ ，区间长度为

$$n_i = \min\{L_i - 1, \max[1, \lfloor qL_i + 0.5 \rfloor]\}, \quad H_{ik}^m = \mathbf{1}\{m \in \mathcal{M}_H, k \in I_i\} O_{ik}^m. \quad (38)$$

同一样本的所选模态共用连续区间 I_i ；自然缺失位置不重复计为人工删除。长度不足 2 的样本不追加遮挡。目标比例 q 以内容锚点为分母，实际新增观测删除率定义为 $\sum_{imk} H_{ik}^m / \sum_{imk} O_{ik}^m$ 。本文分别保存区间长度比例与实际删除率，避免将目标比例直接视为实现比例。

逐项移除单模态或模态组合的局部信息，构成输入模态消融。表中每种组合对五个比例、三个位置等权平均；全局局部指标对 105 种条件等权平均，不将同一样本的不同遮挡版本视为独立样本。

表 17 测试集局部输入模态消融结果

移除的局部模态	Macro-F1	MAE	$\Delta F1$
文本	0.5923	0.6688	-0.0267
语音	0.6233	0.6226	+0.0043
视觉	0.6224	0.6228	+0.0035
文本 + 语音	0.5926	0.6692	-0.0264
文本 + 视觉	0.5970	0.6685	-0.0220
语音 + 视觉	0.6222	0.6235	+0.0033
三模态	0.5963	0.6690	-0.0226

仅文本局部缺失时，平均 F1 为 0.5923、MAE 为 0.6688；仅语音和仅视觉局部缺失时，F1 分别为 0.6233 和 0.6224。三模态同段缺失时 F1 为 0.5963。这些结果描述各输入干预下的敏感程度，不等同于补全或蒸馏组件的独立贡献。

(4) 缺失比例、位置与长度的影响

表 18 连续缺失比例与位置的测试结果

条件	实际观测删除率	Macro-F1	MAE
区间比例 5%	0.0312	0.6151	0.6351
区间比例 10%	0.0589	0.6138	0.6389
区间比例 20%	0.1153	0.6096	0.6477
区间比例 30%	0.1718	0.6034	0.6553
区间比例 40%	0.2286	0.5911	0.6691
句首	0.1214	0.6111	0.6423
句中	0.1214	0.6021	0.6518
句尾	0.1206	0.6065	0.6535

比例实验对七种模态组合及三个位置平均，位置实验对七种组合及五个比例平均。因未选模态仍然可用，表中的三模态合计观测删除率通常低于目标区间比例。短样本的取整与自然缺失还会使实际比例偏离名义值。

目标区间比例由 5% 增至 40% 时，平均 F1 由 0.6151 降至 0.5911，MAE 由 0.6351 增至 0.6691，Pearson 相关系数由 0.6659 降至 0.6233，连续信息损失同时削弱分类判别与强度排序（图 12）。分模态看，文本与三模态共缺两条曲线在四个指标上均随比例单调退化，文本的 Pearson 相关系数由 0.6532 降至 0.5795，语音与视觉单模态缺口在 1.5 个点以内波动（0.6824 至 0.6817），退化主要由文本通道贡献。

表 19 三模态同段居中缺口的长度实验

目标长度	截短样本数	实际观测删除率	Macro-F1	MAE
1	0	0.0431	0.6047	0.6496
2	2	0.0859	0.6046	0.6584
4	7	0.1714	0.6009	0.6665
8	62	0.3345	0.5485	0.7309
16	236	0.6060	0.4632	0.7981




图 12 不同缺失模态与目标区间比例下四项指标的退化曲线




图 13 缺失位置、缺口长度与基线比较

位置实验中，句首缺失的平均 F1 最高 (0.6111)，句中最低 (0.6021)，差值为 0.0090；同一位置内部不同模态组合与比例造成的 Macro-F1 跨度达 0.0743，逐样本配对比较中 22.0% 的样本在句首缺口下判断更准、21.9% 更差、56.1% 不变 (图 13(a))。位置对预测的影响远小于缺失比例与缺失模态，模型对缺口出现的位置不敏感。

目标缺口由 1 增至 16 个锚点时，F1 由 0.6047 变为 0.4632，MAE 由 0.6496 变为 0.7981。长度以附件提供的对齐锚点度量，不换算为秒；短样本将缺口截为 $L_i - 1$ 。对所选模态实际发生删除且仍保留至少一个观测的样本进一步取 105 条件交集，得到 648 条严格局部样本。

表 20 严格局部共同子集的敏感性核验

模型	样本数	局部平均 F1	局部平均 MAE
LMF	648	0.5680	0.7073
MuT	648	0.5961	0.6987
TSRF-D	648	0.6007	0.6614

(5) 受控缺口下的逐样本错误转移

把完整输入下的判断与受控缺口下的判断逐样本比较，727 条测试样本在同一条件下可分为四类：两侧均正确、翻转（由正确变为错误）、修复（由错误变为正确）与两侧均错误。三模态共缺 20%（句中）时四类样本依次为 408、60、48 和 211 条，缺口扩大到 40% 时翻转升至 102 条、修复 60 条；缺口长度为 16 个锚点时翻转 193 条、修复 65 条。该长度下缺失时的分类错误共 387 条，其中 50.1% 在完整输入下本已错误，说明误差中包含相当比例的样本固有难度，而不是全部由遮挡造成。翻转率随实际观测删除率单调上升，文本单模态缺口与三模态共缺接近，语音与视觉单模态缺口几乎不产生翻转（图 14）。




图 14 受控缺口下的逐样本错误转移

(6) 验证集可视化与错误归因

验证集负向、中性、正向 F1 分别为 0.6517、0.5081 和 0.6892。273 条分类错误中，213 条涉及中性类，占 78.0%。其中真实正向判为中性的样本有 89 条，真实负向判为中性的样本有 50 条。类别边界混淆是当前分类误差的重要组成，强度散点图同时展示连续预测与标签之间的偏离。




图 15 验证集类别混淆与强度回归结果

4.2.6 与基线的测试集比较

(1) 对照设置

在同一训练划分、同一课程遮挡、同一冻结 BERT 遮挡编码、同一训练集标准化统计量与同样三个种子的条件下，重跑七类输入处理与结构基线：仅文本、拼接 MLP、零填充、均值填充、缺失标记、模态丢弃和三态嵌入。零填充按自身训练口径使用原始零值标准化输入，其余模型在自然缺失位置使用训练集均值填充；公开融合基线 LMF[10] 与 MulT[4] 按本题三分类与连续回归任务适配，保留各自训练配置。十类模型共用 727 条测试样本、相同人工掩码和三个种子，按基础输入与 105 种连续局部缺失条件比较，分类概率与强度输出分别取种子集成。

LMF、MulT 与内部基线不使用教师监督，TSRF-D 的训练还包含 EMT-DLFR 教师的软监督，因此本节比较完整方法的预测表现，训练计算成本应计入教师学习。

表 21 测试集统一口径的基线比较

模型	基础 Acc	基础 F1	基础 MAE	基础 r	局部 F1	局部 MAE
仅文本	0.6410	0.6192	0.6396	0.6613	0.6028	0.6700
拼接 MLP	0.6039	0.5805	0.6386	0.6602	0.5852	0.6636
零填充	0.6231	0.5894	0.6417	0.6703	0.5851	0.6653
均值填充	0.6410	0.6073	0.6539	0.6659	0.5979	0.6786
缺失标记	0.6217	0.5945	0.6337	0.6732	0.5900	0.6610
模态丢弃	0.6190	0.5855	0.6314	0.6765	0.5782	0.6559
三态嵌入	0.6424	0.6078	0.6412	0.6726	0.5976	0.6676
LMF	0.6259	0.5932	0.6729	0.6292	0.5669	0.7028
MulT	0.6437	0.6155	0.6740	0.6509	0.5984	0.6907
TSRF-D	0.6437	0.6189	0.6221	0.6824	0.6066	0.6492

(2) 基础输入与局部缺失下的表现

基础输入下，TSRF-D 的 Accuracy 为 0.6437，与 MulT 并列最高；强度 MAE 为 0.6221、Pearson 相关系数为 0.6824，两项均为十类模型最优；Macro-F1 为 0.6189，与仅文本的 0.6192 相差 0.0003，配对区间跨零。十类模型的基础分类指标集中，自然缺失条件下的分类差异有限，方法差异主要体现在局部缺口出现之后。

局部缺失条件下，TSRF-D 的局部 F1 为 0.6066、局部 MAE 为 0.6492，两项均为十类

模型最优，且相对全部九类基线的点估计方向一致：F1 均为正差、MAE 均为负差。相对模态丢弃的局部 F1 改善 +0.0284 经多重比较校正后显著（校正 $p = 0.018$ ）；相对 LMF 的局部 F1 改善 +0.0397，区间 [+0.0152, +0.0633]（校正 $p = 0.056$ ）。强度回归上的区分更清楚：相对均值填充、三态嵌入、LMF 和 MulT 的局部 MAE 改善分别为 -0.0294、-0.0184、-0.0536 和 -0.0414，经校正后均达到 5% 显著性水平。相对仅文本、均值填充、三态嵌入与 MulT 的局部 F1 差异区间跨零；仅文本在局部条件下仍保有 0.6028 的 F1，与训练样本以文本为主要判别证据的情形一致。




图 16 十类模型在测试集上的比较

为量化差异的不确定性，将测试集按来源视频分为 381 组，进行 2000 次配对 bootstrap；同一视频的所有片段及全部缺失条件共用重采样权重。表中差值为本文模型减去基线，F1 正值和 MAE 负值分别表示改善；对九类基线的局部 F1 与局部 MAE 共 18 项比较采用 Holm 校正。区间反映固定模型的评价样本不确定性，种子间波动见表 23。

表 22 测试集上本文模型相对各基线的局部配对差异及 95% 区间

基线	指标	差值	95% 区间	校正 p
仅文本	局部 F1	+0.0038	[-0.0166, +0.0232]	1.000
仅文本	局部 MAE	-0.0208	[-0.0412, -0.0014]	0.697
拼接 MLP	局部 F1	+0.0214	[+0.0029, +0.0406]	0.513
拼接 MLP	局部 MAE	-0.0144	[-0.0291, +0.0001]	0.856
零填充	局部 F1	+0.0215	[+0.0075, +0.0362]	0.091
零填充	局部 MAE	-0.0161	[-0.0270, -0.0054]	0.100
均值填充	局部 F1	+0.0086	[-0.0038, +0.0213]	1.000
均值填充	局部 MAE	-0.0294	[-0.0413, -0.0177]	0.018
缺失标记	局部 F1	+0.0166	[+0.0019, +0.0325]	0.684
缺失标记	局部 MAE	-0.0118	[-0.0222, -0.0017]	0.480
模态丢弃	局部 F1	+0.0284	[+0.0143, +0.0421]	0.018
模态丢弃	局部 MAE	-0.0067	[-0.0194, +0.0061]	1.000
三态嵌入	局部 F1	+0.0090	[-0.0031, +0.0209]	1.000
三态嵌入	局部 MAE	-0.0184	[-0.0275, -0.0090]	0.018
LMF	局部 F1	+0.0397	[+0.0152, +0.0633]	0.056
LMF	局部 MAE	-0.0536	[-0.0783, -0.0276]	0.018
MulT	局部 F1	+0.0082	[-0.0080, +0.0254]	1.000
MulT	局部 MAE	-0.0414	[-0.0598, -0.0235]	0.018

(3) 输入处理策略的比较

零填充与均值填充代表两种最简缺失处理，前者保留原始零值标准化，后者以训练均值替代；两者的局部 F1 分别为 0.5851 与 0.5979，局部 MAE 分别为 0.6653 与 0.6786，均低于 TSRF-D。可学习缺失标记与训练期模态丢弃的局部 F1 分别为 0.5900 与 0.5782。固定填充与缺失标记不区分缺口的上下文位置，连续局部缺口下判别证据的损失难以由单一填充常量补偿，缺口上下文编码与门控补全在局部条件下的作用由此体现。

与公开基线的比较中，MulT 的局部 F1 与 TSRF-D 接近（差 +0.0082），但局部 MAE 高 0.0414；LMF 的局部 F1 低 0.0397、局部 MAE 高 0.0536，两项差异方向一致。三态嵌入以模态状态与位置嵌入区分结构填充与有效观测，局部 F1 为 0.5976，是内部基线中最接近本文模型的配置。

经多重比较校正，相对模态丢弃的局部 F1 改善以及相对均值填充、三态嵌入、LMF、MulT 的局部 MAE 改善得到统计支持。分类与回归反映不同预测目标，因而分别依据对应差异和区间评价方法效果。

表 23 局部条件下的随机种子波动

模型	单种子局部 F1 均值	种子标准差
仅文本	0.5951	0.0036
拼接 MLP	0.5823	0.0035
零填充	0.5843	0.0181
均值填充	0.5943	0.0081
缺失标记	0.5863	0.0143
模态丢弃	0.5722	0.0151
三态嵌入	0.5929	0.0063
LMF	0.5465	0.0061
MulT	0.5891	0.0063
TSRF-D	0.5997	0.0038

TSRF-D 的单种子局部 F1 波动为 0.0038，在十类模型中最小；零填充与模态丢弃的单种子波动分别为 0.0181 与 0.0151，其局部表现对初始化更敏感。

4.2.7 附件 3 全量预测与结果展示

冻结模型后，对附件 3 全部 30 条样本完成推理。预测分布为负向 7 条、中性 9 条、正向 14 条；平均最大预测概率为 0.5876，低于 0.5 的样本为 11 条。附件 3 没有真实标签，分类概率用于描述模型输出，不作为准确率或经过校准的置信保证。

双任务输出中有 1 条非中性预测的类别方向与回归符号不同。例如样本 3-22 预测为负向，强度为 +0.0834，体现了分类与回归在软一致性约束下仍存在的边界差异。




图 17 附件 3 全量样本的分类概率与强度预测

表 24 附件 3 全部 30 条样本的预测

样本	锚点数	缺失 $t/a/v$	极性	强度	最大概率
3-01	6	0/0/0	负向	-0.7926	0.6790
3-02	28	5/5/5	中性	+0.0170	0.6927
3-03	32	5/5/9	中性	+0.3507	0.5615
3-04	31	2/2/2	正向	+0.5548	0.5655
3-05	12	0/0/0	负向	-1.3149	0.8804
3-06	25	3/3/3	正向	+0.9528	0.7760
3-07	21	3/3/3	中性	+0.1607	0.4278
3-08	15	2/2/2	正向	+0.5953	0.4915
3-09	14	2/2/2	正向	+1.1710	0.8556
3-10	6	0/0/0	中性	-0.0066	0.8054
3-11	14	4/4/4	正向	+0.3761	0.4166
3-12	13	2/2/2	正向	+0.7533	0.5491
3-13	19	2/2/2	中性	+0.0642	0.4059
3-14	23	2/2/2	负向	-0.4828	0.6079
3-15	27	3/3/3	正向	+0.7277	0.6803
3-16	34	4/4/4	正向	+1.5138	0.8705
3-17	22	8/8/8	负向	-0.1494	0.4290
3-18	17	3/3/3	中性	+0.3571	0.4949
3-19	24	7/7/7	负向	-0.2043	0.4454
3-20	48	14/14/14	中性	+0.0810	0.5071
3-21	9	3/3/3	正向	+0.4352	0.4968
3-22	17	4/4/4	负向	+0.0834	0.3645
3-23	13	4/4/4	中性	+0.3641	0.5916
3-24	8	2/2/2	负向	-0.1855	0.5218
3-25	9	2/2/2	中性	+0.4876	0.4757
3-26	22	6/6/6	正向	+0.7644	0.6848
3-27	21	8/8/8	正向	+0.7554	0.6965
3-28	33	11/11/11	正向	+0.5554	0.5326
3-29	18	8/8/8	正向	+0.7940	0.6596
3-30	24	12/12/12	正向	+0.4701	0.4629

提交文件 pred_ 附件 3.csv 按原始顺序保存样本编号、极性、强度与三类概率，另附观测缺失计数及种子间波动；完整实验指标、掩码核验和模型哈希与模型参数共同保存。

4.3 问题三的模型建立与求解

4.3.1 问题分析与建模思路

问题三要求在输出情感极性与强度的同时，确定主要参考模态、量化模态作用程度，并定位可回看至原始素材的局部证据。为此，建立输入干预联盟 Shapley 解释模型（ICF-Shapley），按“情感预测、模态贡献分解、局部证据定位、原素材回映”四个步骤求解。

模型由子集感知预测器（SAP）与两级解释方法组成。预测器采用三态输入和双向时序编码，在附件 2 上独立训练；模态层精确枚举文本、语音和视觉的 8 个联盟，以 Shapley 值分配预测变化；片段层逐块删除输入，以固定类别的预测响应衡量局部作用。沿用前两问的内容掩码、观测掩码及原词时间区间记号，预测器关闭补全分支，使干预后的输入状态由观测掩码直接控制。

4.3.2 数据准备

（1）输入组织与可用模态

采用附件 2 的对齐版特征，训练、验证、测试样本分别为 3395、728、727 条，文本、语音和视觉特征形状分别为 50×768 、 50×74 和 50×35 。以 P_{ik} 表示内容掩码， O_{ik}^m 表示模态 m 的观测掩码；标准化统计量仅由训练集观测位置估计。文本使用冻结的 bert-base-uncased 编码，训练与专项推理保持同一接口。

附件 4 包含 20 条样本，共 564 个内容锚点，单条长度介于 11 与 48 之间。第 13 条视觉特征在 30 个内容位置均为零，因此将该特征分支标记为不可用。定义

$$L_i = \sum_k P_{ik}, \quad \mathcal{A}_i = \{m \in \mathcal{M} : \sum_k O_{ik}^m > 0\}, \quad \rho_i^m = \frac{\sum_k O_{ik}^m}{L_i}, \quad \mathcal{M} = \{t, a, v\}. \quad (39)$$

其中 ρ_i^m 描述观测比例。不可用模态在所有联盟中保持缺失，输出贡献记为 NA；该标记描述特征文件的可用性。

（2）片段划分与时间回映

将内容区划分为不重叠的 2 锚点块 E ，末块允许不足 2 个锚点。解释时保持序列长度和位置不变，仅改变相应输入及观测状态。文本块先替换为 [UNK]，再对整句重新编码；语音和视觉块通过观测掩码删除。

附件 4 原始转写与音轨经词级 CTC 强制对齐，得到原词区间 $A_{iu} = [a_{iu}, b_{iu}]$ 。若块 E 对应原词集合 $\mathcal{U}_i(E) = \{g_i(k) : k \in E\}$ ，则证据时间范围为

$$I_i(E) = \left[\min_{u \in \mathcal{U}_i(E)} a_{iu}, \max_{u \in \mathcal{U}_i(E)} b_{iu} \right]. \quad (40)$$

包含部分子词时按所属原词完整区间回映。逐位核验分词序列后，以块内已对齐实词区间的包络定位证据；标点保留在文本与锚点索引中，不单独赋予发音时间。若含有未对齐实词，则保留锚点并标记未映射。按真实视频 PTS 提取距区间中点最近的关键帧，同时导出对应音轨。CTC 区间为自动估计，回映覆盖率度量证据可追溯性。

4.3.3 模型构建

（1）总体结构与解释接口

图 18 给出问题三的预测器与解释层结构。模型先以三态观测输入完成情感预测，再在同一冻结预测器上分别进行模态联盟干预和局部片段干预；前者输出模态贡献与主要参考模态，后者输出关键证据位置，最后通过词级时间区间和视频 PTS 回映至原始素材。解

释层不另行训练预测器，因而解释结果与预测结果来自同一模型输出。




图 18 问题三 ICF-Shapley 预测器与解释层结构

(2) 三态投影与时序编码

令 $s_{ik}^m \in \{0, 1, 2\}$ 分别表示结构填充、已观测和内容缺失。最终采用单层预测器，其输入表示为

$$z_{ik}^m = \text{Lin}_m(X_{ik}^m) + e_m^{\text{mod}} + e_k^{\text{pos}} + e_{s_{ik}^m}^{\text{state}}, \quad \tilde{z}_{ik}^m = O_{ik}^m z_{ik}^m + P_{ik}(1 - O_{ik}^m)e_m^{\text{miss}}. \quad (41)$$

按内容长度打包序列，分别输入逐模态双向 GRU，避免结构填充参与递归。设隐藏维度为 d ，对各模态内容位的编码结果 h_{ik}^m 分别取均值与最大值，再拼接观测比例：

$$u_i = \text{Concat}_{m \in \mathcal{M}} \left(\frac{1}{L_i} \sum_k h_{ik}^m, \max_k h_{ik}^m \right) \parallel [\rho_i^t, \rho_i^a, \rho_i^v], \quad h_i = \text{MLP}(u_i). \quad (42)$$

融合向量维度为 $6d + 3$ ，分类与回归头分别输出

$$p_i = \text{softmax}(W_c h_i + b_c), \quad \hat{r}_i = 3 \tanh(W_r h_i + b_r). \quad (43)$$

(3) 子集训练与目标函数

最终采用 C0 方案：以 0.70 的概率保留全部模态，其余 0.30 均匀分配给 7 个非完整联盟，包含空集。对采样联盟 S_i ，令 $\tilde{O}_{ik}^m = O_{ik}^m \mathbf{1}\{m \in S_i\}$ 。训练目标为

$$\mathcal{L}_3 = \text{CE}_w(y_i, p_i) + \text{Huber}_1(r_i, \hat{r}_i) + 0.2 [(p_{i,+} - p_{i,-}) - \tanh(\hat{r}_i/3)]^2. \quad (44)$$

类别权重由训练集频数确定，Huber 损失拟合连续强度，最后一项约束两类输出的方向一致性。该方案覆盖模态联盟输入；连续片段遮挡增广及更深网络作为候选变体单独比较。

(4) 模态贡献与主要参考模态

以三种子平均概率 $\bar{p}_i$ 确定原始可用输入的参考类别 $c_i^* = \arg \max_c \bar{p}_{ic}(\mathcal{A}_i)$ ，解释全过程固定该类别。对联盟 $S \subseteq \mathcal{M}$ ，定义

$$F_i^{\text{cls}}(S) = \log \frac{\bar{p}_{i,c_i^*}(S)}{1 - \bar{p}_{i,c_i^*}(S)}, \quad F_i^{\text{reg}}(S) = \bar{r}_i(S). \quad (45)$$

数值计算时将概率截断至 $[10^{-6}, 1 - 10^{-6}]$ 。对分类与强度分别计算 Shapley 贡献：

$$\phi_i^m = \sum_{S \subseteq \mathcal{M} \setminus \{m\}} \frac{|S|!(2 - |S|)!}{3!} [F_i(S \cup \{m\}) - F_i(S)], \quad \sum_{m \in \mathcal{A}_i} \phi_i^m = F_i(\mathcal{A}_i) - F_i(\emptyset). \quad (46)$$

贡献为正表示相对基线抬高价值，为负表示压低价值。以分类贡献绝对值最大的可用模态为主要参考模态，作用份额定义为

$$m_i^* = \arg \max_{m \in \mathcal{A}_i} |\phi_i^{m, \text{cls}}|, \quad \omega_i^m = \frac{|\phi_i^{m, \text{cls}}|}{\sum_{j \in \mathcal{A}_i} |\phi_i^{j, \text{cls}}|}. \quad (47)$$

当总贡献幅度小于 10^{-8} 时标记为无法区分；其余同时报告作用份额与有符号贡献，以区分作用大小和方向。

(5) 局部证据与解释评价

记 $F_i^{\text{cls}, \text{del}(m, E)}$ 为仅删除模态 m 中块 E 后的固定类别价值，定义

$$\Delta_i^m(E) = F_i^{\text{cls}}(\mathcal{A}_i) - F_i^{\text{cls}, \text{del}(m, E)}. \quad (48)$$

$\Delta_i^m(E) > 0$ 表示该片段支持参考类别，小于零表示抑制参考类别。另定义强度响应 $\Delta_i^{m, \text{reg}}(E) = \hat{r}_i - \hat{r}_i^{\text{del}(m, E)}$ ，正、负值分别表示该片段抬高、降低预测强度。两个任务分别以贡献绝对值确定主要模态，并在各可用模态中选择绝对局部响应最大的片段作为关键证据，保留符号方向。分类删除检验仍按有符号响应降序，强度删除检验按绝对强度响应排序。

在主要参考模态中，按块数的 10%、20%、30% 向上取整，分别累计删除高分块、低分块和随机块；随机顺序重复 3 次，并报告实际锚点覆盖率。以三个删除档位的平均概率下降定义 AOPC，按样本配对比较高分与随机删除，采用 2000 次 bootstrap 估计区间。条件充分性保留其他模态及主要模态的高分块，计算相对原预测的绝对概率偏差。另以训练集同位置均值 (B2) 和模态内顺序打乱 (B3) 替代缺失状态基线 (B1)，比较主模态一致率及贡献排序。

4.3.4 模型求解与参数设置

(1) 候选比较与模型选择

以 C0 为基准，设置三个递进变体：V1 调整联盟采样并加入连续块遮挡；V2 进一步采用两层 BiGRU、逐模态 LayerNorm 和回归支路；V3 增加联盟单调一致性正则。V1 与 V2 各包含多项联合改动，因此比较反映方案组合的影响。V3 约束增补模态后的参考类别响应，其单调性不等价于贡献可加性。

选模指标为 $J = \text{Macro-F1} - 0.1\text{MAE}$ 。候选须同时满足： J 不低于 C0 减 0.002；去文本、去语音、去视觉及全缺失四种状态的平均 Macro-F1 不低于 C0 减 0.002；解释 AOPC 差不低于 C0 减 0.005。通过者按缺失状态平均 Macro-F1 排序，并列时比较 J 。训练早停与变体选择使用验证集，最终在附件 2 测试集评价预测性能，对附件 4 输出预测与解释。

最终预测器的网络规模、训练配置及解释采样参数汇总于表 25。全集与非完整联盟联合采样，使同一预测器同时学习常规预测和模态删除后的输入状态；解释阶段冻结全部参数，以保持不同干预之间的可比性。

表 25 最终 SAP 预测器及解释参数

项目	设置
网络	投影维度 64；单层 BiGRU，单方向 32；融合 MLP；Dropout 0.2
优化	AdamW；学习率 0.0015；权重衰减 10^{-4} ；余弦调度
训练	批量 256；至多 32 轮；早停耐心 8；梯度范数上限 5；种子 0、1、2
联盟采样	全集 0.70，其余 7 个联盟各 0.30/7；最终模型无块遮挡增广
解释	8 个联盟精确枚举；局部 2 锚点块；3 组随机删除；bootstrap 2000 次
验证子集	固定种子 20260925 随机抽取 96 条，用于解释诊断和候选比较
确认子集	固定种子 20261001 抽取 96 条测试样本；区间按原视频聚类估计
计算环境	Python 3.12；PyTorch 2.8.0+cu128；RTX 5060 Ti

完整求解过程见算法 2。先固定参考类别并计算模态贡献，再定位分类与强度各自的关键片段，最后将片段锚点转换为原始素材的时间区间。

算法 2 ICF-Shapley 预测与证据定位

输入：	三模态特征、掩码、原始素材、冻结预测器与标准化参数。
输出：	情感极性、强度、模态贡献、主要参考模态及局部证据。
1.	计算可用集合 $\mathcal{A}_i$ 与集成预测，固定参考类别 c_i^* 。
2.	枚举 8 个模态联盟，计算分类 log-odds 与预测强度。
3.	求解两类 Shapley 值，核验效率性，输出 ω_i^m 与 m_i^* 。
4.	遍历各可用模态的 2 锚点块，实施输入删除，计算 $\Delta_i^m(E)$ 。
5.	分别选择各模态分类与强度绝对响应最大的片段，保留作用方向，由原词 CTC 区间及视频 PTS 定位证据。
6.	保存预测、贡献与逐块响应；在验证子集进行方法比较，冻结模型后在测试子集确认双任务删除响应与稳定性。

4.3.5 实验结果与分析

(1) 预测性能与候选比较

按三项门槛选择的预测器为 C0 对照（原训练分布）。三个种子分别在第 4、5、3 轮取得最优验证指标，训练轮次完全由验证集 J 决定，测试集与附件 4 只参与前向计算。验证集单种子 Macro-F1 为 0.6068、0.5941、0.6082。表 26 汇总三种子集成的基础性能：验证集 Macro-F1 为 0.6170，测试集为 0.6054；测试集 MAE 为 0.6303，高于验证集的 0.5954，反映强度预测在测试样本上的误差有所增加。

表 26 SAP 三种子集成的预测性能

数据集	Accuracy	Macro-F1	MAE	Pearson
验证集	0.6264	0.6170	0.5954	0.6420
测试集	0.6286	0.6054	0.6303	0.6730

验证集负向、中性、正向 F1 依次为 0.6430、0.5114 与 0.6966，类别间的差异集中在中间类别，中性边界的刻画是提升分类表现的关键环节。图 19 给出类别间的混淆结构与各类别指标。




图 19 验证集混淆矩阵与分类指标

表 27 进一步比较子集训练、网络容量及一致性约束的影响。评价同时考虑预测指标、局部解释响应与种子间主模态一致性，以观察不同方案的收益与代价。

表 27 候选方案与实现对照的验证结果

方案	J	Macro-F1	MAE	AOPC 差	种子一致率
仅完整输入（单种子）	0.5470	0.6073	0.6030	—	—
无内容区打包对照	0.5468	0.6073	0.6048	—	—
C0: 子集训练	0.557	0.6170	0.5954	0.107	84.0%
V1: 采样与遮挡	0.553	0.6112	0.5869	0.130	77.8%
V2: 增加容量	0.553	0.6128	0.6010	0.112	79.2%
V3: 单调正则	0.559	0.6192	0.6011	0.124	75.7%

由表 27 可见，V3 的 J 略高于 C0，但种子一致率由 84.0% 降至 75.7%，预测与解释指标并未同步改善。结合预设门槛，V1 未通过预测指标与缺失状态性能门槛，V2 未通过预测指标门槛，V3 未通过缺失状态性能门槛；三者的解释 AOPC 差均达到门槛。据此选择 C0 作为最终 SAP 预测器，后续贡献分解和附件 4 推理均使用该模型。内容区打包与全序列编码的各单种子 J 平均值分别为 0.542 和 0.539。表中仅完整输入对照采用单种子，其余方案采用三种子集成；种子一致率指主要参考模态的两两一致率平均值。整模态删除给出模态重要性的独立证据：C0 去文本后的 Macro-F1 为 0.4150，而去语音、去视觉后分别为 0.6092 与 0.5974，相对完整输入的 0.6170，文本删除造成的下降最大，与联盟分解中文本主导的结论一致。仅用完整输入训练的单种子模型去文本后降至 0.2904；两者集成规模不同，该差值同时包含训练方案与集成的影响。全缺失条件仅用于输入状态诊断，其预测仍可利用保留的内容长度。

(2) 时序汇聚改进实验

为增强不同位置的区分能力，在同一 C0 训练方案下，将均值汇聚替换为可学习的时序加权汇聚，保留最大池化，评分层零初始化。三个种子集成后，验证集 Macro-F1 为 0.6112，MAE 为 0.5846， J 为 0.5527；相对 C0，MAE 降低 0.0107，但 Macro-F1 下降 0.0059。实验前规定 J 至少增加 0.002、F1 下降不超过 0.002、MAE 增加不超过 0.005，且至少两个种子的 J 改善；预测条件满足后再比较开发子集解释指标。候选未通过前两项条件，故最终预测器保持 C0，时序权重不用于替代干预解释。

(3) 模态作用差异

空集价值为-0.687，全模态价值为 0.542，单模态联盟中文本为 0.382、语音为-0.651、视觉为-0.637；三模态平均 Shapley 贡献为文本 +1.105、语音 +0.068、视觉 +0.056，96 条子集中分类主参考模态为文本 86 条、语音 3 条、视觉 7 条。图 20 显示，文本的平均 Shapley 贡献为 +1.105，构成预测的主导信息来源；语音与视觉分别贡献 +0.068 与 +0.056，在三模态协同中提供补充信息，主参考模态分布与贡献排序一致。样本层的正负贡献与主参考模态另行保留，以刻画个体差异。效率性残差不超过 8.9×10^{-16} ，满足 Shapley 效率性公理。




图 20 模态联盟的平均分类价值与三模态平均 Shapley 贡献

(4) 局部证据与解释检验

位置级证据由输入干预直接度量：96 条验证样本共完成 3397 个局部块干预，文本、语音与视觉的平均绝对 log-odds 响应分别为 0.377、0.015 与 0.025，与模态级贡献的结论一致，均以文本为主。典型样本的逐块分布见图 23。本段统计对应开发阶段的验证子集，冻结测试子集的双任务结果在下文单独分析。按块数 10%、20%、30% 三个目标档位累计删除时，高分块引起的参考类别概率下降分别为 0.187、0.226 和 0.241，随机块为 0.075、0.111 和 0.148，低分块为 -0.014、0.006 和 0.038。高分块相对随机块的 AOPC 配对差为 0.1068，95% 区间为 [0.0887, 0.1259]；实际锚点覆盖率为 14.41%、24.03% 和 35.49%。这些结果表明，按局部响应排序能够筛选出对当前分类判断影响较大的片段。96 条样本同时用于候选比较，区间描述该验证子集上的配对差异。

在最高删除档位，条件充分性的绝对概率偏差为 0.1608，说明主要模态中剩余片段仍影响预测。沿用分类证据排序观察回归响应，删除高分块时强度的绝对变化分别为 0.399、0.468 和 0.499，删除低分块时为 0.142、0.192 和 0.227，表明分类关键片段也会影响连续强度输出。分类与回归的模态贡献分别计算，附件 4 有 5 条样本的两个任务主模态不同。

在主模态为文本的 86 条样本中，按自定义词表判定，最高分证据块完全由功能词或标点构成的比例为 17.4%，全部文本块中的相应比例为 30.5%。这一描述性比较表明，最高分块较少由纯功能词或标点构成。

(5) 冻结模型后的双任务确认

选模完成后，以固定随机种子 20261001 从附件 2 测试集抽取 96 条样本，覆盖 85 个原视频。模型与解释规则保持冻结；按原视频聚类进行 2000 次配对 bootstrap，保留同源片段之间的相关性。该子集未参与本次候选选择，但历史测试集已有评估记录。

如图 21 左、中两幅所示，分类与强度任务的高分块曲线在三个删除档位均高于随机块曲线，说明各自的排序均能定位影响输出的片段。分类高分块相对随机块的平均概率降

幅差为 0.1318，95% 区间为 [0.1091,0.1550]。强度任务单独确定主模态与片段排序，其绝对预测变化差为 0.2132，95% 区间为 [0.1636,0.2713]。分类三个目标删除档位的实际锚点覆盖率为 15.65%、24.96% 和 35.85%；两类曲线分别衡量参考类别概率与连续强度的响应，不等同于相对真实标签的误差变化。强度条件充分性偏差分别为 0.5879、0.5428 和 0.4595，说明少量关键片段尚不能完整复现原预测。

图 21 右图同时比较总体一致率与 Cohen κ 。在该确认子集上，B1 与 B2 的主模态一致率为 90.63%， $\kappa = 0.4364$ ；B1 与 B3 的一致率为 92.71%， $\kappa = -0.0136$ 。因此，局部片段删除具有稳定的平均响应优势，而主模态归因仍依赖解释基线，尤其是少数非文本主导样本。




图 21 冻结测试子集上的分类与强度删除验证及解释基线敏感性

(6) 解释稳定性

表 28 同时报告主模态一致率与 Cohen κ ，以区分总体一致程度和主模态分布偏斜的影响。验证子集中 B1 与 B2 的一致率为 90.62%， $\kappa = 0.5686$ ；B1 与 B3 的一致率为 87.50%，但 $\kappa = -0.0231$ 。B1 下 10 条非文本主导样本在 B3 下均转为文本，说明总体上的文本主导结论较一致，少数非文本归因则对基线选择更敏感。两种基线下的绝对贡献排序 Spearman 相关分别为 0.812 和 0.625。

表 28 主参考模态在不同种子与解释基线下的一致性

样本范围	比较对象	一致率 (%)	Cohen κ
验证子集 96 条	种子 0 与 1	82.29	0.2402
验证子集 96 条	种子 0 与 2	83.33	0.1768
验证子集 96 条	种子 1 与 2	86.46	0.2244
验证子集 96 条	B1 与 B2	90.62	0.5686
验证子集 96 条	B1 与 B3	87.50	-0.0231
附件 4 全部 20 条	B1 与 B2	75.00	-0.0753

三个训练种子的两两一致率介于 82.29% 与 86.46%，对应 κ 为 0.1768–0.2402。附件 4 在 B1 与 B2 下有 5 条样本改变主模态，其解释应结合具体基线与局部片段共同阅读。

(7) 错误分布与归因分析

验证集共 272 条误判，其中 214 条涉及中性，占 78.7%。按真实分组看：中性组错误率 39.1%（184 条），非中性且 | 强度 | < 0.5 的弱情感组错误率 60.5%（147 条），| 强度 | ≥ 0.5 的强情感组错误率 28.0%（397 条）。错误随情感强度降低而集中，说明零点附近的类别判别比强情感的方向判断更困难。

在 96 条解释样本中，低强度组与高强度组的解释不稳定率分别为 31.7% 和 23.6%，覆盖正确与错误预测两类样本，给出解释稳定性在不同强度水平上的分布。错误分析将改进

重点指向中性边界与弱情感区间的表征增强。

(8) 附件 4 全量结果

附件 4 全部 20 条样本的预测分布为中性 7 条、负向 7 条、正向 6 条，分类主参考模态为文本 19 条、视觉 1 条。图 22 从强度分布、分类模态份额和种子间波动三个角度展示全量结果。中图多数样本的文本份额较高，与文本主导的总体归因一致；第 8 条以视觉为主，体现个体差异。20 条样本的强度三种子标准差均值为 0.105，最大为 0.410（附件 4_10）。第 13 条的视觉分支不可用，其视觉份额标记为 NA，其余两个模态照常给出贡献；4-04 与 4-19 的预测极性与强度方向不一致，属于独立双头结构下的输出分歧，两个任务分别保留各自的预测与贡献分解。跨模态核查中，17 条样本的全部可用模态最高分证据均指向预测类别；4-06、4-14 与 4-16 各有一个模态的最高分证据方向相反，反向项均为视觉分支的最高分块，响应幅度在 -0.069 至 -0.012 之间，而三条样本的文本主证据幅度分别为 0.404、0.467 和 2.661，视觉分歧项不足其两成，判别主体仍落在文本证据上。按与验证集相同的 10%、20%、30% 三档删除协议，20 条样本上高分块相对随机块的平均概率下降差为 0.1316，95% 区间为 $[0.0857, 0.1858]$ ，逐块响应在无标签样本上同样稳定区分证据块与随机块。




图 22 附件 4 全部 20 条样本的情感预测、模态作用份额与种子间波动

表 29 列出逐条预测及作用份额，便于与图 22 核对。其中 NA 表示输入特征不可用，不能解释为该模态贡献为零；分类极性与连续强度分别来自两个输出头。

表 29 附件 4 全量预测与分类模态作用份额

编号	极性	强度	文本份额	语音份额	视觉份额	主模态
4-01	中性	+0.362	0.678	0.124	0.198	文本
4-02	中性	+0.034	0.518	0.254	0.229	文本
4-03	中性	-0.185	0.441	0.119	0.440	文本
4-04	负向	+0.089	0.705	0.178	0.116	文本
4-05	正向	+0.711	0.484	0.085	0.432	文本
4-06	正向	+0.660	0.699	0.014	0.287	文本
4-07	正向	+0.801	0.833	0.029	0.138	文本
4-08	中性	+0.501	0.106	0.384	0.510	视觉
4-09	负向	-1.989	0.955	0.018	0.027	文本
4-10	负向	-1.027	0.903	0.060	0.037	文本
4-11	负向	-1.112	0.820	0.020	0.160	文本
4-12	负向	-0.804	0.897	0.036	0.067	文本
4-13	中性	+0.238	0.844	0.156	NA	文本

续下页

表 29 附件 4 全量预测与分类模态作用份额（续）

编号	极性	强度	文本份额	语音份额	视觉份额	主模态
4-14	中性	+0.409	0.654	0.031	0.315	文本
4-15	正向	+1.116	0.703	0.192	0.105	文本
4-16	负向	-2.137	0.946	0.031	0.022	文本
4-17	正向	+1.528	0.930	0.029	0.040	文本
4-18	中性	-0.055	0.679	0.021	0.300	文本
4-19	负向	+0.188	0.809	0.049	0.141	文本
4-20	正向	+1.040	0.816	0.040	0.144	文本

新增交付目录优化实验/输出中，pred_附件 4.csv 保存全量预测及双任务有符号贡献，evidence_dual_task.csv 按样本、模态和任务保存证据，共 120 行；a4_local_all.json 保存全部逐块响应。解释卡按统一模板生成，同时保留有符号最高分片段、逐块响应与跨模态一致性核查，20 张卡片与 cards_summary.csv 随附件提交。

（9）典型样本与证据回映

解释卡把预测结论、模态份额、证据词时间与原始素材组织在同一视图中，用于检验模型响应与可观察线索的对应关系。附件 4 第 12 条的预测为负向（最大类概率 0.76，强度 -0.804），主要参考模态为文本（份额 0.897）：原文前段为 *previously had good credit*，转折词 *but*（3.88 s）之后转入信用下滑的负面叙述，最高分证据片段为 *sag*（9.94–10.30 s），同时是语音的最高分证据块，两个模态的证据落在同一词上。沿用问题一的韵律度量，*but* 处音高相对前段抬高 2.3 半音、能量抬升 0.88，证据词处音高抬高 2.3 半音、能量抬升 0.52，构成样本内两处局部韵律突起点；卡片中的全段韵律轨迹给出能量与音高随时间的走向。图 23 中黄底标记主要模态的最高分证据词，蓝底标记其他模态的最高分证据词；三个可用模态的最高分证据方向一致，未见跨模态冲突。跨模态分歧样本、视觉主模态样本与缺模态降级样本的完整解释卡及全部 20 条索引随支撑材料提交。




图 23 附件 4 第 12 条 (转折样本) 解释卡

20 条样本的重新分词序列均与官方词元一致, 482 个原词中 478 个获得 CTC 时间区间; 该回映与问题一共用同一套对齐实现, 词表构建与 CTC 强制对齐直接调用问题一的模块, 问题一建立的词元—锚点—时间对应关系由此成为后两问共享的时序基础。新增双任务证据共 120 条, 其中 118 条可用记录均完成时间回映并导出音频与关键帧; 其余 2 条为第 13 条样本的视觉特征不可用, 在分类与强度任务中分别标记 NA。每条记录保存原素材哈希、词元锚点、作用方向、时间区间及真实帧 PTS, 构成从模型响应到原素材的可追溯链条。

本模型把情感预测分解为可复核的模态贡献与局部响应, 并通过词级时间区间连接到原始素材: Shapley 值度量指定模型与基线下的作用差异, 删除实验检验局部证据与预测响应的一致性。两项分析在同一预测器上完成, 因此解释结论可直接对应该模型的决策过程。

5 模型检验与灵敏度分析

5.1 模型检验

模型检验分别围绕时间对应、缺失预测与解释忠实性展开。

问题一中, 100 条样本均形成输出, 1920 个已生成词区间全部满足非负起点、正长度、音轨范围内终点与起点随词序单调四项约束。典型样本展示了词元、声学窗口与视频帧的

对应关系，6 条超长样本保留完整词级记录，定长接口截断不影响样本覆盖。

问题二中，验证集 Macro-F1 为 0.6163、强度 MAE 为 0.5818。273 条分类错误中，213 条涉及中性类，占 78.0%。测试集使用共用掩码，将七类输入处理与结构基线和两个公开基线与本文模型置于同一协议下比较。经来源视频分组配对 bootstrap 及 Holm 校正，18 项局部比较中，相对模态丢弃的局部 F1 差异以及相对均值填充、三态嵌入、LMF、MulT 的局部 MAE 差异达到 5% 显著性水平。

问题三中，模态 Shapley 分解的效率残差不超过 8.9×10^{-16} ，满足效率性公理。在 96 条验证子集上，高分片段删除相对随机删除的 AOPC 差为 0.1068，95% 区间为 [0.0887, 0.1259]，说明局部响应排序与预测变化相符。该检验评价解释对当前模型的忠实性，主模态对基线与随机种子的敏感性另见表 28。

5.2 灵敏度分析

时间对齐模型的灵敏度主要来自词边界与聚合参数。所选 12 条样本子集中，扰动次数由 50 增至 200 后，视觉方差的排序相关为 0.995，锚点相对排序较为稳定。边界扰动尺度由 40 ms 改为 20 或 80 ms 时，音视频质量分数的排序相关均在 0.90 以上，说明该质量评价在所测范围内具有较好的排序一致性。

局部缺失预测的灵敏度从模态组合、连续区间比例、位置和长度四个方面检验。三模态居中缺口的目标长度由 1 增至 16 个锚点时，F1 由 0.6047 变为 0.4632，MAE 由 0.6496 变为 0.7981。逐样本对照显示，三模态共缺 20%（居中缺口）时 60 条样本由正确变为错误、48 条由错误变为正确，16 个锚点缺口下缺失时的分类错误中有 50.1% 在完整输入下本已错误。短样本按 $L_i - 1$ 截断，并另报告各条件均满足局部删除与保留观测要求的共同子集，区分缺失程度变化与样本边界效应。

解释模型的灵敏度表现为少数样本的主模态变化。B1 与 B2 在验证子集上的 κ 为 0.5686，B1 与 B3 为 -0.0231；B3 下原有 10 条非文本主导样本均转为文本。文本在总体上占主导，而非文本贡献需要结合解释基线考察。

6 模型评价与推广

6.1 模型特点

时间组织明确。以原词区间连接子词表示与音视频帧，用交叠权重统一不同采样粒度，并以观测掩码保留缺失状态，形成从定长特征到原始素材的对应关系。

缺失处理与任务学习相结合。三态输入区分结构填充、有效观测和局部缺失，补全表示通过门控参与融合，EMT-DLFR 教师提供分类与强度软监督。局部输入模态消融及连续缺口实验分别刻画模态敏感性与缺失程度的影响。

解释对应同一预测器。模态联盟分解与局部删除共享预测模型，分别给出模态贡献和片段响应，再通过词级时间映射定位原始证据，使预测数值与解释结果相互对应。

6.2 模型局限与改进

时间对齐采用自动估计的词区间，当前验证侧重覆盖、结构与相对时序一致性。可进一步加入人工词边界标注，评价起止点误差，并改善数字读法与长序列处理。

缺失预测的分类误差集中于中性与非中性类别之间，逆频率加权均衡了训练目标中的类别贡献，但类别识别仍取决于样本的有效证据。后续可加强缺口上下文与弱情感样本的区分，通过组件消融和独立数据进一步检验补全、蒸馏的作用。

解释结果随基线和训练种子变化，非文本主导样本尤为明显。新增冻结测试子集分别

确认了分类与强度片段的删除响应，双任务证据均已回映至原素材；进一步改进可结合独立数据与人工时间标注，检验解释迁移性及定位误差。

在应用推广中，词级锚点与掩码表示可用于其他具有转写文本的音视频分析任务；模型结构和参数需结合新任务的特征维度、缺失模式与标签分布重新确定。

7 结论

本文围绕多模态情感预测的时间组织、局部缺失与决策解释，建立三个相互关联的模型，得到以下结论。

第一，以原词为公共时间锚点，通过 CTC 强制对齐、子词归属与时间交叠池化，完成附件 1 全部 100 条样本的三模态特征提取。1932 个原词中 1920 个生成时间区间，生成率为 99.38%；全量结果表、观测掩码与典型片段共同呈现了特征与原始素材的对应关系。

第二，采用 EMT-DLFR 教师和逆频率类别加权的三态感知模型，在验证集上取得 0.6163 的 Macro-F1 和 0.5818 的强度 MAE，并完成附件 3 全部 30 条预测。测试集基础 Macro-F1 为 0.6189、MAE 为 0.6221，105 种连续局部缺失条件下的平均 Macro-F1 为 0.6066、MAE 为 0.6492。输入模态消融及比例、位置、长度实验给出了缺失条件下的性能变化，九类基线的统一比较进一步刻画了分类与强度预测的差异。

第三，模态子集训练与输入干预相结合的解释模型完成附件 4 全部 20 条预测与解释，输出中性 7 条、负向 7 条、正向 6 条。冻结测试子集上的分类与强度删除优势分别为 0.1318 和 0.2132，说明双任务局部排序均能识别影响当前输出的片段。118 条可用证据均完成时间与媒体回映；文本贡献总体占主导，少数非文本归因仍对解释基线较敏感。

上述方法分别提供了统一的时间表示、面向局部缺失的预测方式和对应模型决策的解释结果，为多模态情感分析中的特征组织与证据追溯提供了可实现的建模方案。

参考文献

- [1] Baltrusaitis T, Ahuja C, Morency L P. Multimodal machine learning: A survey and taxonomy[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(2): 423–443.
- [2] Zadeh A, Liang P P, Poria S, Cambria E, Morency L P. Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL), 2018: 2236–2246.
- [3] Zadeh A, Chen M, Poria S, Cambria E, Morency L P. Tensor fusion network for multimodal sentiment analysis[C]. Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2017: 1103–1114.
- [4] Tsai Y H H, Bai S, Liang P P, Kolter J Z, Morency L P, Salakhutdinov R. Multimodal transformer for unaligned multimodal language sequences[C]. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL), 2019: 6558–6569.
- [5] Devlin J, Chang M W, Lee K, Toutanova K. BERT: Pre-training of deep bidirectional transformers for language understanding[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT), 2019: 4171–4186.
- [6] Baevski A, Zhou Y, Mohamed A, Auli M. wav2vec 2.0: A framework for self-supervised

- learning of speech representations[C]. Advances in Neural Information Processing Systems (NeurIPS), 2020: 12449–12460.
- [7] Graves A, Fernandez S, Gomez F, Schmidhuber J. Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks[C]. Proceedings of the 23rd International Conference on Machine Learning (ICML), 2006: 369–376.
 - [8] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[EB/OL]. arXiv:1503.02531, 2015.
 - [9] Sun L, Lian Z, Liu B, Tao J. Efficient multimodal transformer with dual-level feature restoration for robust multimodal sentiment analysis[J]. IEEE Transactions on Affective Computing, 2023.
 - [10] Liu Z, Shen Y, Lakshminarasimhan V B, Liang P P, Zadeh A, Morency L P. Efficient low-rank multimodal fusion with modality-specific factors[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, 2018: 2247–2256.
 - [11] Shapley L S. A value for n-person games[M]//Kuhn H W, Tucker A W. Contributions to the Theory of Games II. Princeton: Princeton University Press, 1953: 307–317.
 - [12] Ribeiro M T, Singh S, Guestrin C. "Why should I trust you?": Explaining the predictions of any classifier[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD), 2016: 1135–1144.
 - [13] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]. Advances in Neural Information Processing Systems (NeurIPS), 2017: 4765–4774.

附录 A 问题二专项模型核心代码

问题二局部缺失情感预测专项模型（TSRF-D）的完整实现与训练脚本随支撑材料提交（问题二实现目录）。以下按三态投影、门控补全和联合损失节选核心代码，与正文式 (36) 及相应结构对应；节选保留源文件中的循环与省略位置，便于与支撑材料逐行核对。

```
# q2_model.py: tri-state projection (content / observed / missing)
def _states(self, P, O):
    s = torch.where(P, torch.full_like(P, 2, dtype=torch.long),
                    torch.zeros_like(P, dtype=torch.long))
    s = torch.where(P & O, torch.ones_like(s), s)
    return s

def _project(self, X, P, O, true_target=False):
    z = {}
    for mi, m in enumerate(MODS):
        st = torch.ones_like(P, dtype=torch.long) if true_target else self._states(P, O[m])
        base = self.e_mod[mi] + self.e_pos[: P.shape[1]]
        zz = self.proj[m](X[m]) + (self.e_state[st] if self.cfg.use_state_emb else 0.0) + base
        z[m] = zz if true_target else zz * P[..., None]
    return z
```

```
# q2_model.py: gated completion with distance, position and continuity prior
def _complete(self, z, P, O):
    cfg = self.cfg
    B, K = P.shape
    dev = P.device
    d = cfg.d
    known = {m: (P & O[m]) for m in MODS}
    run = {m: _run_length(known[m]) for m in MODS}
    cand_mask = torch.stack([known[m] for m in MODS], dim=1) # (B, 3, K)
    cmat = cand_mask[:, None].expand(B, 3, 3, K).reshape(B, 3, 3 * K)
    n_cand = cmat.sum(dim=-1)
    empty = (n_cand == 0)
    key = torch.stack([self.k_proj(z[m]) for m in MODS], dim=1)
    val = torch.stack([self.v_proj(z[m]) for m in MODS], dim=1)
    kmat = key.reshape(B, 3 * K, d)
    vmat = val.reshape(B, 3 * K, d)
    q_base = self.e_pos[:K][None, None, :, :] + self.e_state[2][None, None, None, :]
    q = self.q_proj(q_base.expand(B, 3, K, d) + self.e_mod[None, :, None, :])
    qf = q.reshape(B, 3 * K, d)
    d2 = (qf.pow(2).sum(-1)[:, :, None] + kmat.pow(2).sum(-1)[:, None, :]
          - 2.0 * torch.bmm(qf, kmat.transpose(1, 2))) / d
    d2 = d2.clamp(min=0.0).reshape(B, 3, K, 3 * K)
    cost = d2 + cfg.lam_t * self.dt[None, None, :, :]
    cost = cost + (1.0 - cmat.float())[:, :, None, :] * 1e4
    if cfg.use_u_score:
        u = torch.stack([torch.sigmoid(cfg.alpha0 + cfg.alpha1 * known[m].float()
                                         + cfg.alpha2 * (run[m] / cfg.run_scale).clamp(
(0.0, 1.0)))
                        for m in MODS], dim=1)
    else:
        u = torch.ones(B, 3, K, device=dev)
    cost = cost + cfg.lam_q * (1.0 - u.reshape(B, 3 * K))[:, None, None, :]
    cost = torch.where(empty[:, :, None, None], torch.zeros_like(cost), cost)
    pi = torch.softmax(-cost / cfg.temperature, dim=-1) * cmat.float()[:, :, None, :]
    pi = pi / pi.sum(-1, keepdim=True).clamp(min=1e-6)
    pi = torch.where(empty[:, :, None, None], torch.zeros_like(pi), pi)
    z_hat = torch.bmm(pi.reshape(B, 3 * K, 3 * K), vmat).reshape(B, 3, K, d)
```

```

cost_rho = torch.where(cmat.bool()[ :, :, None, :],
                      torch.clamp(cost, max=1e3),
                      torch.full_like(cost, 1e4))
cbar = (pi * cost_rho).sum(-1)
cvar = (pi * (cost_rho - cbar[ ..., None]).pow(2)).sum(-1)
cmin = cost_rho.min(-1).values
nsrsc = (n_cand.float() / (3.0 * K))[ :, :, None].expand(B, 3, K)
aratio = torch.stack([known[m].float().sum(-1) / P.float().sum(-1).clamp(min=1)
                      for m in MODS], dim=1)[ ..., None].expand(B, 3, K)
gin = torch.stack([cbar, cvar, cmin, nsrsc, aratio], -1) # (B,3,K,5)
if cfg.use_target_mod_gate:
    gin = torch.cat([gin, self.e_mod[None, :, None, :].expand(B, 3, K, -1)], -1)
rho = torch.sigmoid(self.g_rho(gin)).squeeze(-1)
rho = torch.where(empty[ :, :, None], torch.zeros_like(rho), rho)
return z_hat, rho, dict(n_cand=n_cand, run=run)

```

```

# q2_train.py: compute_loss (excerpt; num/cnt averaging kept from source)
l_cls = F.cross_entropy(logits, y, weight=batch["class_w"])
l_reg = F.huber_loss(r_hat, r, delta=1.0)
p = torch.softmax(logits, dim=-1)
l_cons = ((p[ :, 2] - p[ :, 0]) - torch.tanh(r_hat / 3.0)).pow(2).mean()
# ...
if cfg["use_rec"] and rec:
    num, cnt = 0.0, 0
    for m, d in rec.items():
        tgt = x_true[m][batch["hard"][m]]
        num = num + F.smooth_l1_loss(d["pred"], tgt, beta=1.0, reduction="mean")
        cnt += 1
    if cnt:
        l_rec = num / cnt
# ...
if cfg["use_kd_cls"] and batch.get("t_logits") is not None:
    T = float(cfg.get("T_kd", 2.0))
    tlog = batch["t_logits"].detach()
    pT = torch.softmax(tlog / T, dim=-1)
    logq = torch.log_softmax(logits / T, dim=-1)
    l_dc = F.kl_div(logq, pT, reduction="batchmean") * (T * T)
if cfg["use_kd_reg"] and batch.get("t_reg") is not None:
    l_dr = F.huber_loss(r_hat, batch["t_reg"].detach(), delta=1.0)
l = (l_cls + cfg["lam_r"] * l_reg + cfg["lam_c"] * l_cons
    + cfg["lam_dc"] * l_dc + cfg["lam_dr"] * l_dr
    + cfg["lam_rec"] * l_rec + cfg["lam_rel"] * l_rel)

```

附录 B 问题三专项模型核心代码

问题三子集感知可解释预测专项模型的完整实现随支撑材料提交（问题三实现目录）。以下按联盟采样、目标函数、精确 Shapley、逐块删除与忠实性评价节选核心代码。

```

# q3_train.py: coalition sampling for C0 (0.70 full set, 0.30 uniform over 7 subsets)
def sample_bits(self, n, rng):
    if self.variant['sampling'] == 'full':
        return np.full(n, 7)
    if self.variant['sampling'] == 'uniform':
        bits = np.full(n, 7)
        ch = rng.random(n) < .3
        bits[ch] = rng.integers(0, 7, int(ch.sum()))
        return bits
    return rng.choice(8, n, p=WEIGHTS)

```

```
# q3_train.py: subset-aware objective (CE + Huber + direction consistency, weight 0.2)
loss = (F.cross_entropy(z['logits'], y[blk], weight=cw)
        + F.huber_loss(z['r_hat'], r[blk])
        + BASE['cons'] * ((pr[:, 2] - pr[:, 0]) - torch.tanh(z['r_hat'] / 3)).square()
        .mean())
```

```
# q3_explain.py: exact Shapley values for three players
def shapley(values):
    values = np.asarray(values, dtype='float64')
    out = np.zeros((len(values), 3), dtype='float64')
    for j in range(3):
        for s in range(8):
            if s & (1 << j):
                continue
            k = s.bit_count()
            w = math.factorial(k) * math.factorial(2 - k) / 6
            out[:, j] += w * (values[:, s | (1 << j)] - values[:, s])
    return out

# q3_explain.py: enumerate the 8 coalitions (B1 baseline) and verify efficiency
for s in range(8):
    X = {m: d['X'][m].copy() for m in Q.MODS}
    O = {m: d['O'][m].copy() for m in Q.MODS}
    for j, m in enumerate(Q.MODS):
        if not s & (1 << j):
            X[m][:] = 0
            O[m][:] = False
    p, r = Q.predict(ms, X, d['P'], O, per_seed=True)
    probs.append(p)
    regs.append(r)
# ...
value = np.stack([logodds(p[:, s], ref) for s in range(8)], 1)
phi = shapley(value)
residual = np.abs(phi.sum(1) - (value[:, 7] - value[:, 0]))
assert residual.max() < 1e-8
```

```
# q3_explain.py: block-wise deletion, AOPC and sufficiency (excerpt)
def blocks_of(d, i):
    pos = np.flatnonzero(d['P'][i])
    return [pos[j:j + 2].tolist() for j in range(0, len(pos), 2)], pos

orders = {'top': np.argsort(-scores[i], kind='stable'),
          'low': np.argsort(scores[i], kind='stable')}
orders.update({f'random{k}': rng.permutation(len(bb)) for k in range(3)})
for kind, order in orders.items():
    for f in fractions:
        nb = min(len(bb), max(1, int(np.ceil(f * len(bb)))))
        kk = sorted(k for j in order[:nb] for k in bb[j])
        requests.append((i, m, kk))
        if kind == 'top':
            other = np.setdiff1d(pos, kk).tolist()
            requests.append((i, m, other))
            keys.append((i, 'sufficiency', f))
# ...
boot = diffs[rng.integers(0, len(diffs), (2000, len(diffs)))].mean(1)
summary = dict(curves=curves, fractions=fractions, n=len(diffs),
               aopc_top_minus_random=float(diffs.mean()),
               ci95=np.quantile(boot, [.025, .975]).tolist())
```