



中国研究生创新实践系列大赛  
“华为杯”第二十三届中国研究生  
数学建模竞赛

学 校 南通大学

---

参赛队号 26103040266

---

|      |        |
|------|--------|
|      | 1. 徐路尧 |
| 队员姓名 | 2. 陈智杰 |
|      | 3. 慕蕙榕 |

---

**中国研究生创新实践系列大赛**  
**“华为杯”第二十三届中国研究生**  
**数学建模竞赛**

**题 目：** 多模态情感的时序对齐与可解释预测

**摘 要：**

针对多模态情感预测中的时序差异、局部信息缺失与决策依据难以追溯问题，本文基于赛题提供的 CMU-MOSEI 数据，建立词级时间锚点对齐、教师-学生鲁棒预测与输入干预解释模型，实现原始素材的特征组织、缺失条件下的情感预测及关键证据定位。

针对问题一，采用 CTC 强制对齐估计原词时间区间，以字符偏移确定子词归属，通过时间交叠加权聚合语音与视觉特征，建立不确定边界锚点对齐模型。完成全部 100 条视频的特征提取，文本、语音、视觉特征维度分别为  $50 \times 768$ 、 $50 \times 25$  和  $50 \times 16$ ；1932 个原词中 1920 个生成时间区间，生成率为 99.38%。结合覆盖率与边界扰动评价锚点质量，并以典型样本展示三模态特征与原始片段的时间对应关系。

针对问题二，建立三态感知可靠补全与融合模型 TSRF-D，以冻结 EMT-DLFR 为教师，结合逆频率类别加权与分类、强度蒸馏训练学生。验证集 Macro-F1 为 0.6163、强度 MAE 为 0.5818；测试集 Accuracy 为 0.6437、MAE 为 0.6221。在 105 种连续局部缺失条件下，平均 Macro-F1 为 0.6066、MAE 为 0.6492。通过与九类基线的统一比较及输入模态消融，分析不同缺失条件下的分类与强度预测表现，并完成附件 3 全部 30 条样本的预测。

针对问题三，构建 ICF-Shapley 解释模型，以模态子集训练适配干预输入，通过精确枚举模态联盟分解分类与回归贡献，并以局部删除响应定位关键片段。验证集 Macro-F1 为 0.6170、MAE 为 0.5954，测试集对应指标为 0.6054 与 0.6303。冻结模型后，在 96 条测试样本上确认分类与强度的高分片段删除优势分别为 0.1318 和 0.2132，原视频聚类 95% 区间均高于零。完成附件 4 全部 20 条样本的双任务解释，118 条可用证据均对应至原始文本、语音时段与视频关键帧；非文本主导归因仍对解释基线较敏感。

**关键词：** 多模态情感 时序对齐 局部模态缺失 教师-学生蒸馏 Shapley 解释

## 目录

|                             |           |
|-----------------------------|-----------|
| <b>1 问题重述</b>               | <b>4</b>  |
| 1.1 问题背景                    | 4         |
| 1.2 问题描述                    | 4         |
| 1.3 总体解题思路                  | 4         |
| <b>2 模型假设</b>               | <b>5</b>  |
| <b>3 符号说明</b>               | <b>6</b>  |
| <b>4 模型的建立与求解</b>           | <b>7</b>  |
| 4.1 问题一的模型建立与求解             | 7         |
| 4.1.1 问题分析与建模思路             | 7         |
| 4.1.2 数据准备                  | 8         |
| 4.1.3 模型构建                  | 9         |
| 4.1.4 模型求解与参数设置             | 13        |
| 4.1.5 实验结果与分析               | 14        |
| 4.2 问题二的模型建立与求解             | 21        |
| 4.2.1 问题分析与建模思路             | 21        |
| 4.2.2 数据准备                  | 22        |
| 4.2.3 模型构建                  | 23        |
| 4.2.4 模型求解与参数设置             | 26        |
| 4.2.5 实验结果与分析               | 29        |
| 4.2.6 与基线的测试集比较             | 33        |
| 4.2.7 附件 3 全量预测与结果展示        | 35        |
| 4.3 问题三的模型建立与求解             | 37        |
| 4.3.1 问题分析与建模思路             | 37        |
| 4.3.2 数据准备                  | 38        |
| 4.3.3 模型构建                  | 38        |
| 4.3.4 模型求解与参数设置             | 41        |
| 4.3.5 实验结果与分析               | 42        |
| <b>5 模型评价与改进</b>            | <b>48</b> |
| 5.1 模型的优点                   | 49        |
| 5.2 模型的不足                   | 49        |
| 5.3 模型的改进方向                 | 50        |
| <b>参考文献</b>                 | <b>50</b> |
| <b>附录 A 问题一自生成特征文件的存储组织</b> | <b>52</b> |
| <b>附录 B 问题二结果文件与交付说明</b>    | <b>52</b> |
| <b>附录 C 问题二专项模型核心代码</b>     | <b>52</b> |

|                             |    |
|-----------------------------|----|
| 附录 D 问题三结果文件与交付说明 . . . . . | 54 |
| 附录 E 问题三专项模型核心代码 . . . . .  | 54 |

# 1 问题重述

## 1.1 问题背景

情感分析是具身智能、自然人机交互等领域的关键支撑技术。真实交互中，人类情绪经由语言内容、语音韵律与面部运动等多通道信号协同表达：词义决定评价的正负方向，语调、语速与能量承载强调、迟疑与情绪唤醒，面部关键点的运动则补充词面之外的态度信息。三者的物理载体并不相同，分别表现为离散词元序列、等间隔采样的声学帧与带时间戳的视频帧，在采样频率、特征维度与时间尺度上差异显著。多模态联合建模因此成为突破单模态识别局限、提升复杂场景下情绪理解准确性与稳定性的核心路径。

然而，多模态情感预测在真实场景中面临三重挑战。其一，特征提取与时序对齐的质量直接决定模型性能上限：自动转写可能识别失败，音视频轨道的起止时刻与有效时长并不一致，部分视频帧中人脸检出失败，若按序号直接拼接三路特征，同一位置上的语义、语音与视觉信息可能对应不同时刻，若直接剔除不完整样本，又会损失本就有限的建模数据。其二，画面遮挡、环境噪声与转写失败常导致模态局部时段不可用，常规固定权重融合模型的性能随之急剧下降。其三，多数模型仅输出预测结果，决策依据难以追溯与复核，制约了模型的可信应用。因此，多模态情感预测需要在三个层次上开展建模：先建立从原始素材到标准化时序特征的对应关系，再在证据不完整时稳定输出情感极性与情感强度，最后量化说明判断所依据的模态与局部片段。

## 1.2 问题描述

本文以赛题提供的 CMU-MOSEI 系列数据为唯一数据来源，依次完成三项建模任务。

**问题一：**以附件 1 的原始视频为研究对象，建立文本、语音、视觉三模态情感特征提取与时序对齐的数学模型。模型须明确三类情感特征的定义与提取方法，给出跨模态时间对应规则，将采样频率与时间粒度各异的三路信号统一至同一时间基准，并规定各处理环节对原始样本的操作方式。自生成的特征文件需满足三项规范：样本编号、模态文件与输出特征一一对应；序列位置、有效长度、填充规则及其与原始素材的对应记录完整可核验；特征提取工具、关键参数、处理日志与复现实验说明齐备。最终以表格形式汇总附件 1 全部 100 条样本的特征提取结果，并以典型样本呈现文本片段、语音时段、视频帧段与三类特征的对应关系。

**问题二：**针对模态局部缺失的复杂场景，建立鲁棒性多模态情感预测模型。模态局部缺失指一条或多条模态在部分连续时段内信息不可用，而非整条模态缺失。模型须在模态信息不完整的条件下稳定输出情感极性与情感强度预测，并分析缺失模态类型、缺失位置、缺失时长及缺失比例对预测性能的影响规律。模型建立后须对附件 3 中的测试样本完成推理预测。

**问题三：**针对三模态信息完整而决策依据难以追溯的场景，建立可解释性多模态情感预测模型。模型除输出情感极性与情感强度外，还须以可量化、可复核的方式给出判断依据：量化各模态在当前样本中的作用差异，明确主要参考模态，定位各模态中与判断密切相关的局部片段。关键证据应可对应至原始文本片段、语音时段或视觉关键帧，以支持回溯核验。模型须对附件 4 中的测试样本完成预测与解释。

## 1.3 总体解题思路

三项任务构成从时间组织到鲁棒预测、再到决策解释的递进链条。问题一处理原始素材与时间基准：三模态采样粒度不同，需先以词为公共时间锚点建立可核验的对应关系，输出内容位置、观测掩码与词级时间区间。问题二处理证据不完整：在附件 2 的官方对齐

特征上区分填充、观测与局部缺失三种状态，使预测在连续缺口存在时仍然可用。问题三处理决策可追溯：在附件 2 上独立训练预测器，通过固定参考类别的模态联盟分解与输入片段删除，给出主要参考模态、模态作用程度与可回映到原始素材的关键证据。

三问的数据输入、模型节点与输出关系如图 1 所示。



图 1 本文总体研究思路

三问共享时间组织与掩码表示方法，各自使用相应附件的数据。问题一生成 768/25/16 维自主特征；问题二与问题三使用 768/74/35 维官方特征，分别学习预测参数。问题三沿用词级对齐方法，为附件 4 建立独立的时间记录，将特征层证据回映至原始素材。

## 2 模型假设

1. 官方转写与视频中的话语顺序一致，转写不改变话语的先后关系。依据是该转写由赛题统一提供并与音轨逐条对应。该假设使词级强制对齐的单调路径约束成立，无法构造字符目标的词仍可按同一顺序单独记录。
2. 同一原词的子词共享父词的时间区间，帧特征在其时间支撑区间内近似为分段常量。依据是词为发音的自然单位，而音频帧率远高于词长：前者使子词继承父词的音视频锚点，后者使式 (11) 的交叠积分退化为加权求和。
3. 在附件 2 至附件 4 的对齐版本中，同一序列位置的三个模态共享官方给定的时间对应关系，局部缺失长度以锚点数度量。依据是这些附件按 `aligned_50` 组织，每个序列位置本身即为一个对应单元。问题二与问题三因此只需处理各位置的观测可用性，无需重新估计时间对应关系。
4. 内容位置上的文本 [UNK] 与全零音视频向量表示该位置观测不可用，而非有效的特征取值。依据是附件 3 将局部缺失定义为特征值全为零的连续区间。填充、观测与局部缺失三种状态由此可由掩码唯一确定。
5. 人工遮挡改变可用证据，但不改变样本标签；遮挡后仍以原片段的情感极性与情感强

度作为监督目标，以评价输入信息减少时的预测性能。问题二据此构造缺失条件下的训练样本。

6. 标准化统计量仅由附件 2 的训练集估计，并直接用于验证集与附件 3、附件 4；推理阶段模型权重与标准化统计量保持固定。依据是各附件由同一特征提取流程生成，特征维度与量纲一致。该约定避免推理阶段引入测试数据信息，并使跨附件指标在同一尺度下可比。

### 3 符号说明

| 符号                                                                           | 含义                                        |
|------------------------------------------------------------------------------|-------------------------------------------|
| $i, u, k, j$                                                                 | 样本、原词、接口位置及特征帧的索引                         |
| $m \in \{t, a, v\}$                                                          | 模态索引，依次为文本、语音与视觉；帧池化时 $m \in \{a, v\}$    |
| $K, g_i(k)$                                                                  | 固定接口长度 ( $K = 50$ ) 及第 $k$ 个内容词元的父词编号     |
| $P_{ik}, O_{ik}^m$                                                           | 内容位置掩码与模态观测掩码，取值均为 0 或 1                  |
| $A_{iu} = [a_{iu}, b_{iu})$                                                  | 第 $i$ 条样本第 $u$ 个原词的半开时间区间 (s)             |
| $J_{ij}^m = [s_{ij}^m, e_{ij}^m)$                                            | 模态 $m$ 中第 $j$ 个特征帧的时间支撑区间 (s)             |
| $\mathbf{f}_{ij}^m, r_{ij}^m$                                                | 帧级特征向量及有效性标记                              |
| $\ell_{ij}^m(A), \omega_{ij}^m(A)$                                           | 帧与锚点的有效交叠时长 (s) 及归一化池化权重                  |
| $\mathbf{x}_{iu}^m, X_i^m$                                                   | 词级池化向量及固定 50 位的模态特征矩阵                     |
| $c_{iu}, d_{iu}^m$                                                           | CTC 路径置信度与词级模态覆盖指标，均位于 $[0, 1]$           |
| $B, s$                                                                       | 边界扰动次数与扰动标准差，分别为 50 次和 0.04 s             |
| $V_{iu}^m, \sigma_{im}^2$                                                    | 扰动池化向量方差及样本内模态帧特征离散度                      |
| $\tilde{V}_{iu}^m$                                                           | 由样本内尺度归一化的边界扰动方差                          |
| $Q_{iu}^m, \gamma_m$                                                         | 综合质量分数及敏感度衰减系数， $\gamma_a = \gamma_v = 1$ |
| $N_i^a, T_i^a, T_i^v, \Delta_i$                                              | 音频解码样本数、两轨解码跨度及其差 $\Delta_i$ (s)          |
| $s_{ik}^m$                                                                   | 问题二三态变量：0 为结构位、1 为可观测位、2 为缺失位             |
| $H_{ik}^m, \tilde{O}_{ik}^m$                                                 | 人工遮挡掩码及遮挡后的观测掩码                           |
| $\tilde{x}_{ik}^m, \tilde{X}_{ik}^{m, \text{true}}$                          | 标准化输入及人工遮挡前的标准化特征                         |
| $e_m^{\text{mod}}, e_s^{\text{state}}, e_k^{\text{pos}}$                     | 模态嵌入、状态嵌入与位置嵌入                            |
| $e_m^{\text{miss}}, D_m$                                                     | 模态缺失嵌入与模态解码头                              |
| $z_{ik}^m, \hat{z}_{ik}^m, z_{ik}^{m, f}$                                    | 节点表示、加权补全表示与门控融合表示                        |
| $\Omega_i, C_{i, k, j}^{m, n}, \pi_{i, k, j}^{m, n}$                         | 样本内观测候选集合、补全代价与补全权重                       |
| $\rho_{ik}^m, a_i^m$                                                         | 可靠度门控权重 (取值于 $(0, 1)$ ) 与模态可用比例           |
| $h_{ik}^m, h_i$                                                              | 时序编码隐状态与样本级表示                             |
| $y_i, r_i, \hat{y}_i, \hat{r}_i$                                             | 极性与强度真值及相应预测值                             |
| $p_i^T, p_i^S, J$                                                            | 教师、学生类别分布及验证集联合选模指标                       |
| $\mathcal{L}_{\text{sup}}, \mathcal{L}_{\text{dc}}, \mathcal{L}_{\text{dr}}$ | 标签监督、分类蒸馏与强度蒸馏损失                          |
| $\mathcal{L}_{\text{rec}}, \mathcal{L}_{\text{rel}}, \beta_e$                | 重建损失、可靠度损失与辅助损失权重                         |
| $w_c, N_c, N$                                                                | 类别权重、类别样本数与训练集样本量                         |
| $T, \tau, \tau_\rho$                                                         | 蒸馏温度、补全温度与可靠度温度                           |
| $\mathcal{M}_H$                                                              | 批次内存在人工遮挡的模态集合                            |

## 4 模型的建立与求解

### 4.1 问题一的模型建立与求解

#### 4.1.1 问题分析与建模思路

附件 1 提供 100 条英文视频及对应转写文本。问题一要求从原始素材中提取文本、语音与视觉特征，建立三类特征与原始片段之间可核验的时间对应关系。本问的目标是构造时序组织统一、有效范围明确、溯源记录完整的多模态表示。

三模态的时间结构存在本质差异：文本以离散词元组织，语音是连续采样信号，视觉由带时间戳的视频帧构成。若直接按序号拼接，不同时刻的信息会被错位对齐；若按词数均分视频长度，语速、停顿与词长的差异又被忽略。此外，人脸未检出与文本接口截断都会使部分位置缺少有效特征，必须与正常观测严格区分。

据此，本文采用**以原词为时间锚点、以子词为输出位置**的建模方案。先由官方转写与音频信号建立词级时间区间，并将子词映射至父词；再在同一锚点区间内对语音与视觉帧特征进行时间交叠加权聚合。为刻画对齐结果的不确定性，进一步定义覆盖率与边界扰动敏感度，二者与对齐过程共同构成不确定边界锚点对齐模型（Uncertain-Boundary Anchor Alignment, UBA）。总体流程如图 2 所示。




图 2 三模态特征提取与时间锚点对齐流程

模型输出采用 50 位定长接口，每个内容位置经父词索引关联至实际时间区间；模型评价从样本覆盖、区间结构、模态观测覆盖与参数敏感性四个方面展开。

#### 4.1.2 数据准备

##### (1) 样本组织与数据特征

附件 1 的样本以视频标识与片段编号组成唯一键，用于关联视频文件、官方转写与输出记录。100 条样本来自 37 个原始视频，共含 1932 个空白分隔原词与 2317 个 BERT 词元；其中 283 个原词对应多个词元，占 14.65%。样本标签仅用于数据说明，不参与本问的特征提取与参数拟合。原始素材在文本长度、音频格式、视频采样、容器时间与可观测性上的实测特点及相应处理方式汇总于表 2。

输出按定长接口与全量记录两级组织：接口给出三模态共享的位置级输入，词级记录保留接口之外的时间对应与截断信息，两者通过父词索引相互关联。

表 2 数据特点与相应处理方式

| 对象     | 实测特点                    | 处理方式                     |
|--------|-------------------------|--------------------------|
| 文本长度   | 每条 5–65 词，5–82 个词元      | 保存全量词表，固定接口仅保留前 48 个内容词元 |
| 音频格式   | 源采样率 44.1 kHz，单/双声道 AAC | 统一解码为 16 kHz 单声道信号       |
| 视频采样   | 8 种分辨率，帧间隔并非处处相同        | 使用逐帧 PTS，不由帧数和标称帧率反推时间   |
| 容器时间   | 90 条声明帧数与实解帧数不同         | 区分媒体样本数、有效呈现时长与解码跨度      |
| 视觉可观测性 | 4 条全片未检出人脸，另有局部未检出      | 保存有效帧掩码，缺失帧不参与池化         |

##### (2) 时间基准与有效区间

音频经解码、重采样与声道合并后得到信号  $x_i[n]$ ，采样率  $f_s = 16000$  Hz，其相对时间为  $n/f_s$ ；设解码样本数为  $N_i^a$ ，则音频轨的解码跨度  $T_i^a = N_i^a/f_s$ 。声学描述符提取与词级强制对齐共用该信号，以保证两条处理链具有一致的时间原点。

视频第  $j$  帧的呈现时间取解码 PTS 与时间基的乘积，记为  $t_{ij}$ 。100 条样本的首帧 PTS 均为 0，23241 个解码帧的 PTS 完整且单调。有效呈现范围由容器编辑列表确定；名义公共时间轴以音频相对秒数与视频 PTS 建立，两轨各自保持原始时间尺度。视频轨的解码跨度  $T_i^v$  按末帧 PTS 加一个中位帧间隔计算，与帧支撑的延展约定一致。

容器媒体时长、编辑列表时长与解码跨度分别描述存储范围、有效呈现范围与实际样本范围。100 条样本的音视频轨各含一条编辑列表且媒体时间均非零，解码音频与编辑列表时长的中位差约为 1 ms，实解帧数与按编辑列表预测的帧数中位差约为 1.4 帧，解码输出落在编辑列表限定的呈现范围内。100 条样本的有效视频时长与音频时长分别合计为 787.985 s 和 777.106 s。声明视频帧数为 33147，实解 23241，二者差额主要来自编辑列表限定的呈现范围。逐样本汇总采用有效呈现时长，实际音频处理总时长为 777.0091 s。

记两轨解码跨度之差为  $\Delta_i = T_i^a - T_i^v$ ，其均值为  $-92.3$  ms，绝对值中位数为 91.3 ms。该量刻画两轨整体时长差异，随逐样本清单保存并用于范围核验。

图 3 给出样本长度与媒体时间分布：原词数呈长尾分布，故在定长接口之外保留全量词级记录；音视频解码跨度与帧数统计存在差异，故视觉分支采用实际解码帧与 PTS 建立时间支撑。



图3 附件1的原词数、音视频解码跨度差及帧数统计

### (3) 建模约定

本文以官方转写确定待对齐的词序列，同一原词的子词共享其时间区间；视觉描述取自成功检出的人脸，质量分数用于评价锚点的相对可用性。各模态在词锚点上完成聚合后写入统一接口，内容掩码与观测掩码随特征一并保存；预训练模型保持冻结，分别承担特征编码与强制对齐，其参数计算不涉及附件1的情感标签。

#### 4.1.3 模型构建

模型构建沿三条分支展开：文本分支确定位置级语义表示，语音分支给出词级时间区间，视觉分支提供帧级观测与有效性标记，三者在原词锚点上汇合为统一接口。位置、时间与观测三类信息分别由内容掩码  $P$ 、区间  $A_{iu}$  与观测掩码  $O_{ik}^m$  表达，使特征张量在存在局部缺失时仍保持明确的时间含义。

##### (1) 文本特征与词元归属

文本情感通过评价对象、情感词、否定与程度修饰等语义单元表达，其时间定位依赖转写与音频的词级对应。转写以空白分词给出原词，预训练编码器以 WordPiece 为输入单位，两类单位在数量与边界上均不一致，因此先建立词元到原词的归属关系，再在同一接口内组织语义表示。

设原词  $w_{iu}$  在转写中的字符范围为  $[l_{iu}, r_{iu})$ ，分词器返回词元  $z_{ik}$  的字符范围  $[l_{ik}^z, r_{ik}^z)$ 。若词元范围包含于原词范围内，定义

$$g_i(k) = u \quad \text{当} \quad [l_{ik}^z, r_{ik}^z) \subseteq [l_{iu}, r_{iu}). \quad (1)$$

对非包含关系，依次按字符交叠和邻词附着确定归属；本批 100 条样本均由包含关系确定父词。词内标点继承父词的时间区间，与所在原词共享同一时间锚点。

固定接口长度  $K = 50$ ，顺序安排 [CLS]、至多 48 个内容词元、[SEP] 及尾部 [PAD]。仅内容词元取  $P_{ik} = 1$ ，其余位置为 0。将包含特殊符号的完整接口输入 BERT 后，取最后一层隐藏向量：

$$X_{ik}^t = P_{ik} \mathbf{h}_{ik}, \quad \mathbf{h}_{ik} \in \mathbb{R}^{768}. \quad (2)$$

内容掩码  $P$  排除特殊符号，BERT 注意力掩码保留 [CLS] 和 [SEP]，使内容位置的上下文表示涵盖完整句意。超过 48 个内容词元的尾部保存于全量词表，其父词继续参与音视频对齐与池化；位置级文本向量覆盖接口内的词元，接口之外的部分在词级记录中保持可追溯。编码器参数在本问中保持冻结，文本表示仅由原始转写决定。

## (2) 语音特征与词级时间估计

语音的响度、音高、谱形和发声质量能够表征重音、语调与发声方式，为情感分析提供区别于文字内容的线索。采用 openSMILE 的 eGeMAPSv02 低层描述符，获得 25 维帧特征  $\mathbf{f}_{ij}^a$ ，其分组与建模含义如表 3 所示。帧特征的时间区间直接取自工具输出，帧移为 10 ms、窗长为 20 ms，相邻窗口存在交叠，特征数值保持原始尺度进入聚合。

记第  $j$  个声学帧的工具输出支撑为  $J_{ij}^a = [s_{ij}^a, e_{ij}^a]$ 。池化按该支撑区间计算交叠权重，保留分析窗的交叠关系；音频帧在整条样本内均记为有效观测。LLD 提取与强制对齐共用 16 kHz 单声道 PCM 信号，具有一致的时间原点。

表 3 声学特征的组成与建模含义（合计 25 维）

| 特征组     | 维数 | 内容与作用                                           |
|---------|----|-------------------------------------------------|
| 响度与谱形   | 6  | 响度、alpha 比、Hammarberg 指数、两个频段谱斜率、频谱通量，描述能量与频谱变化 |
| 倒谱表示    | 4  | MFCC 1–4，描述短时谱包络                                |
| 基频与发声质量 | 6  | 基频半音值、jitter、shimmer、HNR 及两项谐波相对能量，描述音高与声门发声特征  |
| 共振峰     | 9  | 第一至第三共振峰的频率、带宽与相对幅度，描述声道共振结构                    |

词级时间估计将连续语音映射为离散词区间，采用预训练 wav2vec2 声学模型与 CTC 强制对齐完成。将原词映射为声学字典支持的大写字母，词间插入分隔符，构成目标序列  $\mathbf{y}_i$ ；无法产生目标字符的词保留为未对齐记录。设  $\pi_{it}(c)$  为第  $t$  个声学输出帧对字符  $c$  的概率，最优路径为

$$\mathbf{z}_i^* = \arg \max_{\mathbf{z}: \mathcal{B}(\mathbf{z}) = \mathbf{y}_i} \sum_t \log \pi_{it}(z_t), \quad (3)$$

其中  $\mathcal{B}$  表示 CTC 的去空白与重复合并映射；声学输出帧移  $h = 0.02$  s，各帧支撑按定长帧计算。对合并后的第  $c$  个目标字符，记其帧支撑为  $[\alpha_{ic}, \beta_{ic}]$ ；原词包含的目标字符集合记为  $\mathcal{C}_{iu}$ ，则词区间为

$$A_{iu} = \left[ h \min_{c \in \mathcal{C}_{iu}} \alpha_{ic}, h \max_{c \in \mathcal{C}_{iu}} \beta_{ic} \right). \quad (4)$$

式 (4) 使用字符支撑的起点与终点，允许字符之间存在空白帧，不假定字符连续占据整个词区间。强制对齐在给定转写顺序下搜索最优声学路径 [7]。字符字典未覆盖的数字或符号保留为未对齐词；生成的词区间依次接受单调性、正长度和音轨边界检查，未通过检查的区间不计入有效锚点。

先对字符支撑内的路径对数概率求均值，再汇总原词中的各字符，定义词级路径置信

度:

$$\bar{\ell}_{ic} = \frac{1}{\beta_{ic} - \alpha_{ic}} \sum_{t=\alpha_{ic}}^{\beta_{ic}-1} \log \pi_{it}(y_{ic}), \quad c_{iu} = \exp \left( \frac{1}{|\mathcal{C}_{iu}|} \sum_{c \in \mathcal{C}_{iu}} \bar{\ell}_{ic} \right). \quad (5)$$

路径分数  $c_{iu}$  衡量声学模型对目标字符序列的支持程度，作为对齐质量分量进入综合评分；无法构造字符目标的词保留空区间，并单独记录可用性状态。

### (3) 视觉特征与有效帧建模

视觉分支提取人脸几何与关键点位移，用于表征口型、眼眉形态及面部运动，并以人脸尺度归一，使不同分辨率与人脸大小的样本具有可比的位移量度。先以 FaceDetection 定位最高分人脸，按人脸框宽高的 1.6 倍裁剪区域，再使用 FaceMesh 提取 478 个关键点；区域处理失败时尝试整帧检测。同一帧出现多张人脸时取检测分数最高者，作为该帧的目标人脸。将区域内坐标映射回原图后，取二维像素坐标  $\mathbf{p}_{ijq} = (x_{ijq}, y_{ijq})$ 。对于宽  $W$ 、高  $H$  的原帧，设裁剪边界为  $(x_0, y_0, x_1, y_1)$ ，FaceMesh 在裁剪图上返回归一化坐标  $(u_{ijq}, v_{ijq})$ ，则回映关系为

$$x_{ijq} = x_0 + u_{ijq}(x_1 - x_0), \quad y_{ijq} = y_0 + v_{ijq}(y_1 - y_0). \quad (6)$$

裁剪边界限制在  $[0, W] \times [0, H]$  内，关键点回映后在统一像素坐标系中计算跨帧位移。两阶段检测用于改善小人脸与高亮背景下的人脸可观测性，未检出帧通过有效性掩码记录。

以脸宽和脸高的均值作为尺度

$$L_{ij} = \frac{|x_{ij,234} - x_{ij,454}| + |y_{ij,10} - y_{ij,152}|}{2} + 10^{-6}, \quad \delta_{ij}(p, q) = \frac{\|\mathbf{p}_{ijp} - \mathbf{p}_{ijq}\|_2}{L_{ij}}, \quad (7)$$

构造表 4 中的 14 个几何分量及 2 个运动分量，分别描述眼眉口部形态和关键点位移。取相邻帧  $j-1$  与  $j$ ，且两帧均成功检出人脸，对全脸或嘴部关键点集合  $\mathcal{P}$  定义运动量

$$M_{ij}(\mathcal{P}) = \sqrt{\frac{1}{|\mathcal{P}|} \sum_{q \in \mathcal{P}} \frac{\|\mathbf{p}_{ijq} - \mathbf{p}_{i,j-1,q}\|_2^2}{L_{ij}^2}}. \quad (8)$$

首帧或前一帧未检出人脸时运动不可测，该帧记无效并存储零向量，不以前一有效帧的关键点替代；不可测原因（首帧、跨检测缺口）在帧级文件与样本元数据中分别记录。

表 4 16 维视觉描述符的定义

| 维度    | 描述符         | 定义                                                                                  |
|-------|-------------|-------------------------------------------------------------------------------------|
| 1-3   | 嘴开合、嘴宽、开合宽比 | $\delta(13, 14)$ 、 $\delta(61, 291)$ 及 $\delta(13, 14)/(\delta(61, 291) + 10^{-6})$ |
| 4-5   | 左右嘴角相对高度    | 上下唇中点纵坐标减嘴角 61 或 291 的纵坐标，再除以 $L$                                                   |
| 6-7   | 左右眼开合       | $\delta(159, 145)$ 、 $\delta(386, 374)$                                             |
| 8-9   | 左右眼宽        | $\delta(33, 133)$ 、 $\delta(362, 263)$                                              |
| 10-11 | 左右眉眼距离      | $\delta(105, 159)$ 、 $\delta(334, 386)$                                             |
| 12-13 | 补充眉眼距离      | $\delta(70, 159)$ 、 $\delta(300, 386)$                                              |
| 14    | 脸高宽比        | $ y_{10} - y_{152} /( x_{234} - x_{454}  + 10^{-6})$                                |
| 15-16 | 全脸与嘴部位移     | 相邻两帧均检出时的归一化关键点位移 RMS；不可测帧不进入池化                                                     |

视觉帧的有效标记  $r_{ij}^v = 1$  要求相邻两帧均检出；人脸未检出或运动不可测时置  $r_{ij}^v = 0$  并存储零向量。帧的支撑区间定义为

$$J_{ij}^v = [t_{ij}, t_{i,j+1}), \quad j < N_i^v; \quad J_{i,N_i^v}^v = [t_{i,N_i^v}, t_{i,N_i^v} + \hat{h}_i^v), \quad (9)$$

其中  $\hat{h}_i^v$  为正帧间隔的中位数。该约定将当前帧描述符保持到下一帧，在帧间隔较大时包含保持近似；视觉覆盖指标据此衡量有效视觉帧对锚点区间的支撑程度。

#### (4) 时间交叠池化与子词映射

不同模态无须先统一帧率：词锚点给出统一的时间窗口，各模态按自身帧支撑进入窗口完成聚合。对词区间  $A = [a, b)$ ，令有效交叠长度为

$$\ell_{ij}^m(A) = r_{ij}^m \max\{0, \min(b, e_{ij}^m) - \max(a, s_{ij}^m)\}, \quad S_i^m(A) = \sum_j \ell_{ij}^m(A), \quad (10)$$

音频帧取  $r_{ij}^a = 1$ ，视觉使用检测有效性。若  $S_i^m(A) > \varepsilon$ ，则

$$\omega_{ij}^m(A) = \frac{\ell_{ij}^m(A)}{S_i^m(A)}, \quad \mathbf{x}_{iu}^m = \sum_j \omega_{ij}^m(A_{iu}) \mathbf{f}_{ij}^m, \quad d_{iu}^m = \min\left(1, \frac{S_i^m(A_{iu})}{b_{iu} - a_{iu}}\right), \quad (11)$$

其中  $\varepsilon = 10^{-9}$ 。无有效交叠时，令  $\mathbf{x}_{iu}^m = \mathbf{0}$ 、 $d_{iu}^m = 0$ 。式 (11) 使部分交叠的帧按实际支撑长度贡献特征，权重归一化与覆盖指标分开计算，在归一化权重的同时保留缺失程度的信息；声学分析窗存在交叠， $d^a$  按有效交叠长度累计并截断到 1。

图 4 给出一组可手算的视觉例子。设词区间为  $[0.08, 0.32)$  s，四个相邻帧支撑各长 0.10 s，第三帧未检出人脸，则四帧有效交叠依次为 0.02, 0.10, 0, 0.02 s。由式 (11)，非零权重为  $1/7, 5/7, 1/7$ ，而覆盖指标为  $0.14/0.24 = 0.583$ 。即使权重和为 1，词区间仍有 41.7% 的时长缺乏有效视觉支撑；这正是单独保存  $d^v$  的必要性。



图 4 交叠池化示意算例

通过父词映射，将音视频词级特征复制到对应子词位置：

$$X_{ik}^m = \begin{cases} \mathbf{x}_{i, g_i(k)}^m, & P_{ik} = 1, \\ \mathbf{0}, & P_{ik} = 0, \end{cases} \quad O_{ik}^m = P_{ik} \mathbf{1}\{d_{i, g_i(k)}^m > 0\}, \quad m \in \{a, v\}. \quad (12)$$

非内容位置的  $O$  定义为 0，不求值不存在的父词。三模态最终维度分别为

$$X_i^t \in \mathbb{R}^{50 \times 768}, \quad X_i^a \in \mathbb{R}^{50 \times 25}, \quad X_i^v \in \mathbb{R}^{50 \times 16}. \quad (13)$$

多个子词继承父词的完整区间，不等分原词时间；同一原词的各子词共享相同的池化向量、覆盖指标与质量分量，记  $Q_{ik}^m = Q_{i, g_i(k)}^m$ ，非内容位置不定义；位置级输出与词级时间记录由此一一对应。 $P = 1, O^m = 0$  表示位置存在但该模态无观测，与全零特征在模型中由内容掩码和观测掩码分别表达。

### (5) 边界扰动与质量分量

词边界由强制对齐给出，边界的小幅变化会改变参与聚合的帧及其权重。为刻画这一影响，对区间两端加入标准差  $s = 40 \text{ ms}$  的独立高斯扰动，采样  $B = 50$  次并重新池化；扰动幅度小于多数词区间的时长，用于刻画小范围边界移动的影响。两端先裁剪到模态时间范围；若终点不大于起点，设置  $20 \text{ ms}$  的最小时间。池化使用修正区间与有效帧的实际交叠，完全无覆盖的扰动另行计数。

令  $\mathcal{H}_{iu}^m$  为有覆盖的扰动集合， $B_{iu}^m = |\mathcal{H}_{iu}^m|$ 。当  $B_{iu}^m \geq 2$  时定义

$$\bar{\mathbf{x}}_{iu}^{m,\text{pert}} = \frac{1}{B_{iu}^m} \sum_{q \in \mathcal{H}_{iu}^m} \mathbf{x}_{iu}^{m,(q)}, \quad (14)$$

$$V_{iu}^m = \frac{1}{B_{iu}^m} \sum_{q \in \mathcal{H}_{iu}^m} \left\| \mathbf{x}_{iu}^{m,(q)} - \bar{\mathbf{x}}_{iu}^{m,\text{pert}} \right\|_2^2. \quad (15)$$

原窗口无观测或有效扰动不足 2 次时，设置退化标记，方差字段以 0 占位；其余锚点的  $V$  衡量有观测条件下的边界敏感性，有效扰动次数  $B_{iu}^m$  随结果保存。

在每条样本内部，按有效帧计算模态尺度

$$\sigma_{im}^2 = \frac{1}{N_i^{m,\text{valid}}} \sum_{j:r_{ij}^m=1} \left\| \mathbf{f}_{ij}^m - \bar{\mathbf{f}}_i^m \right\|_2^2 + 10^{-12}, \quad \tilde{V}_{iu}^m = \frac{V_{iu}^m}{\max(\sigma_{im}^2, 10^{-9})}. \quad (16)$$

少于 2 个有效帧时，尺度取 1。归一化方差刻画池化变化相对于片段内特征变化的大小，各模态分别统计。

综合质量分数取

$$Q_{iu}^m = c_{iu} d_{iu}^m \exp(-\gamma_m \tilde{V}_{iu}^m), \quad \gamma_a = \gamma_v = 1. \quad (17)$$

路径置信度、观测覆盖与边界敏感性分别从对齐可信度、观测完整性和边界稳健性三个方面刻画锚点，共同决定综合质量  $Q$ 。保存  $c, d, V, \tilde{V}, Q$  及退化标记，可按质量排序定位待复核锚点，并追溯相应影响分量。

三项分量相乘给出明确的边界行为：词对齐失败时没有可用锚点；锚点存在但人脸完全缺失时  $d^v = 0$ ，因而  $Q^v = 0$ ；有覆盖且扰动能够产生至少两个有效池化结果时，边界敏感性有可解释的估计。零覆盖与低稳定性属于不同状态，逐词记录中的观测掩码与退化标记用于区分二者。

#### 4.1.4 模型求解与参数设置

##### (1) 求解流程

全部特征与时间映射在冻结预训练模型的条件下逐样本求解，网络参数不参与更新，输出由输入素材与固定参数共同决定。

1. 读取样本标识与官方转写，建立原词字符区间及其词元归属，生成文本特征与 50 位内容掩码。
2. 解码音轨，提取 25 维声学帧特征；对全量原词构建字符目标，计算 CTC 路径、词区间与路径置信度。
3. 按视频 PTS 读取帧，计算 16 维人脸特征与有效帧掩码，并建立各帧的支撑区间。
4. 对每个已生成区间的原词执行交叠池化与边界扰动；未生成区间的词保留失败记录，不赋予人为时间。
5. 将词级特征映射到保留的子词位置，输出特征、掩码与质量分量，并保存全量词表及截断尾部记录。

6. 汇总 100 条样本，核查样本键、张量形状、区间顺序与有效范围，生成全量清单与典型对应图。

## (2) 工具与关键参数

扰动随机种子由样本标识的 MD5 摘要前 8 位生成，固定  $B, s, \gamma$  后可在同一运行环境中复算。各分支所用工具、版本与关键设置见表 5。

表 5 特征提取工具与关键参数

| 模块    | 工具及版本                    | 设置                                                   |
|-------|--------------------------|------------------------------------------------------|
| 运行环境  | Python 3.12.10, CPU      | NumPy 1.26.4, pandas 2.3.3                           |
| 音视频解码 | PyAV 18.1.0              | 音频 16 kHz 单声道，视觉采用解码 PTS                             |
| 文本编码  | transformers 4.56.0      | bert-base-uncased, 推理模式, 50 位                        |
| 声学描述符 | openSMILE 2.6.0          | eGeMAPSv02, LLD 层, 25 维                              |
| 词级对齐  | torch / torchaudio 2.8.0 | WAV2VEC2_ASR_BASE_960H, 20 ms 帧移                     |
| 人脸描述符 | MediaPipe 0.10.21        | FaceDetection 与 FaceMesh, 478 点, ROI 倍率 1.6          |
| 边界扰动  | NumPy 随机生成器              | $B = 50, s = 40 \text{ ms}, \gamma_a = \gamma_v = 1$ |

逐样本运行记录的累计处理耗时为 9.72 min，平均每条 5.83 s。其中视觉处理 499.04 s，占 85.6%；文本、音频及池化阶段分别为 6.61、65.37 和 12.19 s。视觉分支需逐帧执行人脸检测与关键点回归，构成耗时的主要部分。该统计取自逐样本日志，不含模型首次下载、绘图与论文编译耗时。自生成特征文件的存储格式、组织结构与读取方式见附录 A。

### 4.1.5 实验结果与分析

#### (1) 全量处理结果与统计口径

100 条样本均完成处理。1932 个原词中，1920 个生成时间区间，区间生成率为 99.38%；未生成的 12 项由 6 个数字词与 6 个标点或符号串构成，均未通过字符目标构造。已生成区间全部满足非负起点、正长度、音轨范围内终点和起点随词序单调四项结构条件，在时间轴上构成随词序单调递增的分段覆盖。

音频覆盖在已生成区间上达到 1.000、在全部原词口径上为 0.9938，即声学支路为每个已生成锚点提供了完整观测。视觉覆盖均值为 0.9276、全量口径 0.9218；该均值低于 1.000 的部分来自人脸未检出与运动不可测帧，两口径之差 0.0058 则由 12 个未对齐词按零覆盖计入造成。路径置信度的均值 0.750 低于中位数 0.969；67.3% 的锚点不低于 0.9，而 20.8% 的锚点低于 0.3，均值受这部分低支持锚点拉低；低置信组的区间时长均值 0.266 s 高于高置信组的 0.203 s，字符数则相近。

12 个未生成区间的词在固定接口中仍占 22 个内容位置，其内容掩码  $P = 1$ ，观测掩码  $O^a = O^v = 0$ ，即文本语义在模型中保留、但不产生时间支撑。三态表示由此可以区分“有文本、无时间支撑”与“文本、时间支撑齐备”两类位置。另有 128 个已生成区间的词（全量口径 140 个）缺少视觉覆盖，4 条样本全片未检出人脸，说明时间区间是否有效与人脸观测是否有效是两个独立条件。视觉有效帧要求相邻两帧均检出人脸：100 条样本中共有 143 帧因运动不可测而记无效（首帧 87 帧、跨检测缺口 56 帧），这些帧不进入池化，其位置与原因计数分别保存在帧级文件和样本清单中。

已生成区间的词时长均值 0.219 s、中位数 0.160 s，其中 28.1% 短于 0.10 s；若以解码音频总时长 777.0091 s 除以 1932 个原词，含词间停顿的平均间隔约为 0.402 s，约为中位数的 2.5 倍。这说明按词数均分音轨会把词间停顿摊入相邻词，并掩盖短词的真实边界。词级区间因此取自 CTC 对齐的声学证据，交叠池化在该区间上按实际帧支撑计算，两者都不由总时长反推。

图 5 从词元保留与词级观测状态两个角度分解接口覆盖的构成。全量 2317 个内容词元中，2247 个进入固定接口，保留比例为 96.98%；音频零覆盖的 12 词均未生成时间区间。视觉方面，除这 12 词外，另有 128 个已生成区间的词没有有效视觉特征支撑。时间锚点的存在与模态观测的存在因此是两个独立条件，在模型中分别由内容掩码  $P$  与观测掩码  $O^m$  表达。



图 5 接口覆盖情况

## (2) 典型样本的文本、语音与视频对应

选取样本-yRb-Jum7EQ\$\_\$5。该句以否定与转折改变语义走向：*not by the students of terrorism, but by those who teach terrorism*；三类模态在该片段内均有观测，语义转折处伴随可核验的韵律变化，适合用于展示跨模态对应关系。图 6 在统一秒轴上按五个面板给出对应关系。面板 (a) 为语音波形与 25 个原词的词级区间，红色窗标记否定与转折词，点线为切分词 *not* 的 6.37 s 时刻；面板 (b) 给出基频与能量曲线，切分点前后的中位数相差 1.2 半音，否定与转折词处出现局部峰；面板 (c) 为五个关键帧，按解码 PTS 定位，其中一帧落在切分时刻；面板 (d) 与面板 (e) 分别为 25 维声学帧特征与 16 维视觉帧特征，按维度标准化后与前三个面板共用同一时间轴，视觉热图中的空白对应无效视觉帧。

表 6 给出所选词的语音区间、词元数以及词处的音高与能量，这些词的音频与视觉覆盖均为 1.00。以 *teacher*. 为例，父词区间为 [12.46, 12.80) s，两个词元共享该区间，分别对应 768 维上下文文本表示，并继承相同的音视频池化向量。否定与转折处出现局部音高与能量峰值：*not* 与 *but* 相对各自前 0.7 s 参考段分别抬高 2.0 与 7.3 半音，能量抬高 0.18 与 0.60。在 100 条样本内可评估的 20 个否定/转折词上（所在样本人脸检出率不低于 0.95 且对齐词数不少于 8），70% 出现音高局部抬高、中位抬高 2.2 半音，全部出现能量抬升、中位抬升 0.49。词元语义、语音窗口与视频帧段由此在同一时间轴上建立一致对应，否定与转折的韵律标记落在同一位置。同一父词的多个词元共享音视频池化结果、同时保留各自的上下文文本表示，时间对齐定义在词与音频、视频之间，语义编码定义在子词位置，两种粒度在接口中互不干扰。文本向量由这些词对应的内容位置取得，视频帧通过 PTS 定位，不由 50 位下标换算时间。

## (3) 观测缺失与截断的处理效果

图 7 展示人脸检出率为 37.5%、视觉有效帧占比 33.9% 的样本-HwX2H8Z4hY\$\_\$5。该片为近景人物与字幕图形叠加的镜头，未检出区间的人脸呈侧转姿态并与字幕重叠；视觉有效帧集中在 0.03–1.60 s，末段恢复检出的 0.37 s 已位于最后一个词区间之后。9 个已对齐



图 6 典型样本的文本、语音与视频对应

表 6 典型样本的词区间与三模态映射

| 原词               | 语音区间 (s)       | 词元数 | $F_0$ (半音) | 能量   |
|------------------|----------------|-----|------------|------|
| lost             | [1.48, 1.68)   | 1   | 18.1       | 0.14 |
| attack,          | [5.42, 6.14)   | 2   | 20.3       | 0.21 |
| not <sup>†</sup> | [6.26, 6.48)   | 1   | 21.2       | 0.34 |
| but <sup>†</sup> | [8.78, 9.08)   | 1   | 27.9       | 0.76 |
| teach            | [10.10, 10.24) | 1   | 29.3       | 0.36 |
| teacher.         | [12.46, 12.80) | 2   | 23.0       | 0.33 |

词中只有前两个保有视觉支撑 ( $Q^v$  为 0.994 与 0.871)，其余锚点取  $O^v = 0$ 、 $Q^v = 0$ 。这些位置的音频分量仍由声学帧独立给出，9 个已对齐词的  $Q^a$  中位数为 0.934，文本表示保持完整。该例说明位置级掩码把缺失限定在发生缺口的词与模态上：视觉观测的缺口不改动其余锚点的时间对应，也不向音频与文本扩散。



图 7 局部视觉观测缺失样本

文本方面，6 条样本的内容词元超过 48 个，合计 70 个词元未进入接口，52 个原词完全失去接口位置。最严重样本含 65 个原词、82 个词元，其中前 39 个原词贡献的 48 个词元依次占用接口的全部内容位，其余 34 个词元属于第 40 至 65 个原词，在接口中没有对应位置。截断只改变进入接口的词元数量，未进入接口的词元仍保留词级区间与音视频池化记录。

#### (4) 质量分量与参数敏感性

质量分量在 1920 个已生成区间上的统计如下：覆盖指标  $d$  的音频均值与中位数均为 1.000，视觉为 0.9276 与 1.000；归一化扰动方差  $\tilde{V}$  的音频均值为 0.0931、中位数为 0.0471，视觉为 0.0478 与 0.0192；综合质量  $Q$  的音频均值为 0.6849、中位数为 0.8673，视觉为 0.6892 与 0.9124。 $Q$  的均值明显低于中位数，低值部分由零覆盖锚点的  $Q = 0$  贡献，中位数更能代表多数锚点的质量水平。音频与视觉  $\tilde{V}$  的 95% 分位数分别为 0.3328 和 0.1875，视觉边界的相对波动低于音频，128 个视觉零覆盖词另记为退化状态。音视频  $Q$  的 Spearman 相关约为 0.764：两者共享路径置信度因子，因而保持一致的排序趋势；排序差异来自各自独立的覆盖与扰动分量。

图 8 展示质量分量及音视频  $Q$  的联合分布。路径置信度的差异使相同覆盖率的锚点具有不同质量；视觉  $Q = 0$  对应零覆盖词，归一化扰动方差采用对数坐标展示。质量分量按模态可比的口径给出锚点的相对可用性，可用于定位待复核锚点并追溯影响分量。



图 8 1920 个已生成词区间的路径置信度、归一化边界扰动方差和综合质量分布

质量分数的三个参数按词区间的时间尺度与模块规模设定：衰减系数  $\gamma$  控制覆盖偏差的惩罚强度，扰动次数  $B$  与尺度  $s$  共同决定边界敏感性的估计精度。表 7 给出三者变化时的排序一致性，用于检验锚点质量排序是否依赖具体参数设定。

表 7 参数敏感性结果与适用范围

| 实验          | 排序一致性                                                            | 说明                          |
|-------------|------------------------------------------------------------------|-----------------------------|
| $\gamma$ 变化 | 音频 $Q$ : 0.5 和 2 相对 1 的样本内排序相关均值 0.974、0.972                     | 音频质量分量的排序在该参数取值范围内保持稳定      |
| $B$ 变化      | 视觉 $V$ : 50 相对 200 的排序相关 0.995                                   | 在排序前 12 条样本各前 8 词上核算的视觉方差排序 |
| $s$ 变化      | 相对 40 ms, 20 ms 的样本内 $Q$ 排序相关均值 0.915/0.937, 80 ms 为 0.960/0.901 | 音频与视觉分别计算的样本内排序一致性          |

在所选子集上， $B = 50$  与 200 的视觉方差排序相关为 0.995，点值平均差为 22.9%。采样次数改变方差估计的数值，但锚点之间的排序保持一致，因此取  $B = 50$  用于相对质量比较。

### (5) 时间对齐准确性与时序一致性验证

时间对齐的验证从有效性、稳健性与一致性三个层面展开：有效性由词界与声学段落的对照及区间结构约束给出，稳健性由边界扰动对特征聚合的影响刻画，一致性由人为错位后的跨模态关联变化检验。

(1) **边界位置核验**。以 10 ms 步长的 RMS 包络（25 ms 窗）检测低能量停顿段，阈值

取包络 95 分位的 6%、最短 60 ms，在词界  $\pm 250$  ms 邻域内度量边界与停顿段的距离，并以词内随机时刻作对照。100 条样本共检出 479 个停顿段；邻近存在停顿的 1125 个词界中，25.1% 落在停顿段内或距其不超过 10 ms，39.2% 不超过 50 ms，同口径的随机对照分别为 7.1% 与 19.5%。词界落在声学停顿附近的比例约为随机位置的两倍，起点一侧高于终点一侧（45.6% 对 33.1%），词界落在有声段落的交界附近而非与语音段落脱节。区间结构方面，1920 个已生成区间在起点非负、长度为正、终点落在音轨有效时长之内与起点随词序单调四项约束上均无违例，词界没有越出所属词序或超出音轨范围。

（2）边界扰动实验。边界扰动改变池化权重与质量分量，其影响以排序一致性衡量。扰动次数由 50 增至 200 时视觉边界方差的排序相关为 0.995；扰动尺度取 20 ms 与 80 ms 时，音视频质量分数相对 40 ms 设定的平均排序相关均在 0.90 以上（表 7）。小幅边界变化不改变锚点之间的相对次序与相对质量判断，锚点的时间支撑对边界估计误差保持稳健。

（3）模态错位实验。时间映射的正确性可由错位后的关联下降来检验：若词级对应成立，人为破坏对应关系应使音视频之间的词级关联减弱。据此设计单模态错位实验，保持一侧词窗口不动，仅将另一侧平移  $\pm 0.25$ 、 $\pm 0.5$  或  $\pm 1.0$  s，比较响度与嘴部开合、嘴部运动的词级相关，共得到 12 种非零错位条件。所有条件的平均相关均低于各自的样本配对基线，24 项 Wilcoxon 检验中 20 项在未校正的 5% 水平上显著，最小  $p$  约为  $6.8 \times 10^{-8}$ 。

在该口径下，任一非零错位都使两项相关下降，且多数差异在统计上显著，表明当前时间映射保持了音视频之间的词级关联，最小错位幅度 0.25 s 已足以被该检验分辨。

在 83 条人脸检出率不低于 0.9 的样本上，包络相关最大值对应的延迟中位数为嘴部开合 +0.09 s、嘴部运动 +0.22 s 与全脸运动 +0.27 s，正值表示音频包络较晚。三项延迟均为正值且不超过 0.3 s，与词区间时长中位数 0.160 s 处于同一时间尺度，说明音视频包络在词级尺度上保持同步。该量记为**包络最佳延迟**，用于描述词级音视频的联动强度。边界位置核验与错位实验分别从有效性与一致性两端评价时间锚点：词界落在声学停顿附近的比例约为随机位置的两倍，人为破坏时间对应使跨模态词级关联显著减弱，所构造的词级时间锚点与有声段落交界及音视频之间的局部时序对应关系保持一致。

（6）全量样本结果

表 8 逐条汇总 100 条样本。视、音时长采用编辑列表的有效呈现口径，合计分别为 787.985 s 和 777.106 s；对齐粒度均为原词锚点与子词继承。

T、A、V 表示文本、语音和人脸视觉分支；V 后的星号、空心圆分别表示部分帧、全片未检出人脸；“检出率”为成功检出人脸的解码帧占该样本解码帧总数的比例。“区间/词”分母含未对齐项，“内容位”为进入 50 位接口的内容词元数，上限为 48。

表 8 附件 1 全部 100 条样本的特征提取结果

| 序号 | 样本编号                | 模态     | 视/音时长 (s)     | T/A/V 维度  | 对齐粒度     | 区间/词  | 内容位 | 检出率    |
|----|---------------------|--------|---------------|-----------|----------|-------|-----|--------|
| 1  | -3g5yACwYnA\$ _\$2  | T+A+V  | 9.394/9.231   | 768/25/16 | 词级 .50 位 | 14/14 | 17  | 100.0% |
| 2  | -3g5yACwYnA\$ _\$3  | T+A+V  | 14.389/14.328 | 768/25/16 | 词级 .50 位 | 29/29 | 40  | 100.0% |
| 3  | -3g5yACwYnA\$ _\$9  | T+A+V  | 8.817/8.696   | 768/25/16 | 词级 .50 位 | 21/21 | 28  | 100.0% |
| 4  | -3g5yACwYnA\$ _\$13 | T+A+V  | 5.514/5.399   | 768/25/16 | 词级 .50 位 | 15/15 | 18  | 100.0% |
| 5  | -3nNcZdcdvU\$ _\$5  | T+A+V* | 7.868/7.788   | 768/25/16 | 词级 .50 位 | 18/18 | 22  | 99.6%  |
| 6  | -571d8cVauQ\$ _\$0  | T+A+V* | 5.167/4.992   | 768/25/16 | 词级 .50 位 | 12/12 | 16  | 96.7%  |
| 7  | -571d8cVauQ\$ _\$5  | T+A+V  | 15.273/15.115 | 768/25/16 | 词级 .50 位 | 43/43 | 48  | 100.0% |
| 8  | -6rXp3zJ3kc\$ _\$8  | T+A+V  | 12.805/12.738 | 768/25/16 | 词级 .50 位 | 34/34 | 38  | 100.0% |
| 9  | -9y-fZ3swSY\$ _\$0  | T+A+V  | 6.900/6.757   | 768/25/16 | 词级 .50 位 | 22/22 | 28  | 100.0% |
| 10 | -9y-fZ3swSY\$ _\$4  | T+A+V  | 2.821/2.665   | 768/25/16 | 词级 .50 位 | 9/9   | 11  | 100.0% |
| 11 | -9y-fZ3swSY\$ _\$8  | T+A+V* | 4.989/4.917   | 768/25/16 | 词级 .50 位 | 12/12 | 14  | 91.3%  |
| 12 | -AUZQgSxyPQ\$ _\$2  | T+A+V  | 22.511/22.405 | 768/25/16 | 词级 .50 位 | 41/41 | 48  | 100.0% |
| 13 | -HeZS2-Prhc\$ _\$2  | T+A+V  | 8.262/8.151   | 768/25/16 | 词级 .50 位 | 16/16 | 17  | 100.0% |
| 14 | -HwX2H8Z4hY\$ _\$2  | T+A+V* | 3.982/3.916   | 768/25/16 | 词级 .50 位 | 7/8   | 12  | 23.5%  |

续表 8

| 序号 | 样本编号                | 模态     | 视/音时长 (s)     | T/A/V 维度  | 对齐粒度     | 区间/词  | 内容位 | 检出率    |
|----|---------------------|--------|---------------|-----------|----------|-------|-----|--------|
| 15 | -HwX2H8Z4hY\$ _\$5  | T+A+V* | 5.653/5.544   | 768/25/16 | 词级 .50 位 | 9/10  | 10  | 37.5%  |
| 16 | -HwX2H8Z4hY\$ _\$6  | T+A+V* | 3.358/3.256   | 768/25/16 | 词级 .50 位 | 7/7   | 9   | 66.7%  |
| 17 | -HwX2H8Z4hY\$ _\$9  | T+A+V* | 7.734/7.637   | 768/25/16 | 词级 .50 位 | 22/22 | 24  | 12.9%  |
| 18 | -I_e4mIh0yE\$ _\$1  | T+A+V  | 7.622/7.444   | 768/25/16 | 词级 .50 位 | 18/18 | 21  | 100.0% |
| 19 | -I_e4mIh0yE\$ _\$3  | T+A+V  | 9.163/8.995   | 768/25/16 | 词级 .50 位 | 22/22 | 30  | 100.0% |
| 20 | -MeTTeMJBNC\$ _\$0  | T+A+V* | 9.334/9.218   | 768/25/16 | 词级 .50 位 | 21/21 | 26  | 99.6%  |
| 21 | -MeTTeMJBNC\$ _\$7  | T+A+V  | 10.517/10.412 | 768/25/16 | 词级 .50 位 | 31/31 | 33  | 100.0% |
| 22 | -MeTTeMJBNC\$ _\$13 | T+A+V  | 5.430/5.255   | 768/25/16 | 词级 .50 位 | 14/14 | 16  | 100.0% |
| 23 | -NFrJFQi jFE\$ _\$1 | T+A+V° | 5.746/5.659   | 768/25/16 | 词级 .50 位 | 16/16 | 16  | 0.0%   |
| 24 | -NFrJFQi jFE\$ _\$2 | T+A+V° | 6.856/6.698   | 768/25/16 | 词级 .50 位 | 18/18 | 18  | 0.0%   |
| 25 | -RfYyzHpjk4\$ _\$2  | T+A+V  | 5.516/5.392   | 768/25/16 | 词级 .50 位 | 25/25 | 29  | 100.0% |
| 26 | -RfYyzHpjk4\$ _\$8  | T+A+V  | 4.589/4.532   | 768/25/16 | 词级 .50 位 | 17/17 | 21  | 100.0% |
| 27 | -RfYyzHpjk4\$ _\$11 | T+A+V  | 5.239/5.074   | 768/25/16 | 词级 .50 位 | 17/17 | 19  | 100.0% |
| 28 | -THoVjtIkeU\$ _\$2  | T+A+V  | 4.292/4.230   | 768/25/16 | 词级 .50 位 | 10/10 | 11  | 100.0% |
| 29 | -THoVjtIkeU\$ _\$6  | T+A+V* | 8.097/7.983   | 768/25/16 | 词级 .50 位 | 30/30 | 32  | 99.6%  |
| 30 | -THoVjtIkeU\$ _\$12 | T+A+V  | 14.896/14.805 | 768/25/16 | 词级 .50 位 | 39/39 | 42  | 100.0% |
| 31 | -UUCSKoHeMA\$ _\$0  | T+A+V* | 7.867/7.732   | 768/25/16 | 词级 .50 位 | 18/18 | 23  | 99.6%  |
| 32 | -UacrmKiTn4\$ _\$4  | T+A+V  | 4.741/4.681   | 768/25/16 | 词级 .50 位 | 14/14 | 15  | 100.0% |
| 33 | -UacrmKiTn4\$ _\$10 | T+A+V  | 7.362/7.242   | 768/25/16 | 词级 .50 位 | 18/18 | 22  | 100.0% |
| 34 | -UuXlxuiaiE\$ _\$0  | T+A+V  | 3.700/3.576   | 768/25/16 | 词级 .50 位 | 9/9   | 12  | 100.0% |
| 35 | -UuXlxuiaiE\$ _\$1  | T+A+V  | 10.350/10.267 | 768/25/16 | 词级 .50 位 | 27/27 | 33  | 100.0% |
| 36 | -UuXlxuiaiE\$ _\$3  | T+A+V  | 4.130/4.038   | 768/25/16 | 词级 .50 位 | 9/9   | 9   | 100.0% |
| 37 | -UuXlxuiaiE\$ _\$6  | T+A+V  | 8.114/7.944   | 768/25/16 | 词级 .50 位 | 22/22 | 23  | 100.0% |
| 38 | -a55Q6RWvTA\$ _\$3  | T+A+V  | 22.154/22.084 | 768/25/16 | 词级 .50 位 | 65/65 | 48  | 100.0% |
| 39 | -aNfi7CP8vM\$ _\$7  | T+A+V  | 8.695/8.538   | 768/25/16 | 词级 .50 位 | 18/18 | 23  | 100.0% |
| 40 | -aqamKhZ1Ec\$ _\$0  | T+A+V  | 11.000/10.890 | 768/25/16 | 词级 .50 位 | 13/14 | 16  | 100.0% |
| 41 | -dxftGcXJoc\$ _\$0  | T+A+V* | 20.534/20.410 | 768/25/16 | 词级 .50 位 | 38/41 | 48  | 78.0%  |
| 42 | -dxftGcXJoc\$ _\$1  | T+A+V  | 16.161/16.019 | 768/25/16 | 词级 .50 位 | 36/36 | 42  | 100.0% |
| 43 | -dxftGcXJoc\$ _\$2  | T+A+V  | 16.698/16.633 | 768/25/16 | 词级 .50 位 | 32/34 | 40  | 100.0% |
| 44 | -dxftGcXJoc\$ _\$6  | T+A+V  | 12.735/12.628 | 768/25/16 | 词级 .50 位 | 27/27 | 32  | 100.0% |
| 45 | -egA8-b7-3M\$ _\$1  | T+A+V  | 10.266/10.156 | 768/25/16 | 词级 .50 位 | 19/20 | 22  | 100.0% |
| 46 | -egA8-b7-3M\$ _\$6  | T+A+V  | 6.265/6.183   | 768/25/16 | 词级 .50 位 | 12/12 | 13  | 100.0% |
| 47 | -egA8-b7-3M\$ _\$9  | T+A+V  | 5.090/4.936   | 768/25/16 | 词级 .50 位 | 10/10 | 12  | 100.0% |
| 48 | -egA8-b7-3M\$ _\$13 | T+A+V  | 4.184/4.024   | 768/25/16 | 词级 .50 位 | 11/11 | 16  | 100.0% |
| 49 | -egA8-b7-3M\$ _\$16 | T+A+V  | 5.538/5.483   | 768/25/16 | 词级 .50 位 | 11/11 | 13  | 100.0% |
| 50 | -egA8-b7-3M\$ _\$17 | T+A+V  | 7.271/7.095   | 768/25/16 | 词级 .50 位 | 16/16 | 19  | 100.0% |
| 51 | -egA8-b7-3M\$ _\$18 | T+A+V  | 8.386/8.266   | 768/25/16 | 词级 .50 位 | 22/22 | 27  | 100.0% |
| 52 | -egA8-b7-3M\$ _\$20 | T+A+V  | 6.645/6.475   | 768/25/16 | 词级 .50 位 | 20/20 | 24  | 100.0% |
| 53 | -egA8-b7-3M\$ _\$26 | T+A+V  | 6.031/5.920   | 768/25/16 | 词级 .50 位 | 15/15 | 19  | 100.0% |
| 54 | -hnBHBn8p5A\$ _\$6  | T+A+V* | 6.401/6.333   | 768/25/16 | 词级 .50 位 | 13/13 | 14  | 82.3%  |
| 55 | -hnBHBn8p5A\$ _\$7  | T+A+V* | 7.372/7.308   | 768/25/16 | 词级 .50 位 | 13/13 | 17  | 60.8%  |
| 56 | -iRBcNs9oI8\$ _\$3  | T+A+V  | 5.621/5.538   | 768/25/16 | 词级 .50 位 | 8/8   | 9   | 100.0% |
| 57 | -iRBcNs9oI8\$ _\$6  | T+A+V  | 2.903/2.821   | 768/25/16 | 词级 .50 位 | 5/5   | 5   | 100.0% |
| 58 | -iRBcNs9oI8\$ _\$7  | T+A+V  | 4.104/4.006   | 768/25/16 | 词级 .50 位 | 9/9   | 15  | 100.0% |
| 59 | -iRBcNs9oI8\$ _\$8  | T+A+V  | 8.093/8.026   | 768/25/16 | 词级 .50 位 | 21/21 | 26  | 100.0% |
| 60 | -iRBcNs9oI8\$ _\$9  | T+A+V* | 3.416/3.374   | 768/25/16 | 词级 .50 位 | 5/5   | 5   | 78.4%  |
| 61 | -lzEya4AM_4\$ _\$5  | T+A+V  | 7.675/7.570   | 768/25/16 | 词级 .50 位 | 19/19 | 21  | 100.0% |
| 62 | -lzEya4AM_4\$ _\$6  | T+A+V  | 14.792/14.741 | 768/25/16 | 词级 .50 位 | 43/43 | 48  | 100.0% |
| 63 | -mJ2ud6oKI8\$ _\$1  | T+A+V° | 6.103/6.054   | 768/25/16 | 词级 .50 位 | 13/13 | 13  | 0.0%   |
| 64 | -mJ2ud6oKI8\$ _\$2  | T+A+V* | 5.731/5.702   | 768/25/16 | 词级 .50 位 | 11/11 | 17  | 78.4%  |
| 65 | -mJ2ud6oKI8\$ _\$6  | T+A+V  | 2.257/2.229   | 768/25/16 | 词级 .50 位 | 5/5   | 5   | 100.0% |
| 66 | -mJ2ud6oKI8\$ _\$8  | T+A+V  | 4.192/4.172   | 768/25/16 | 词级 .50 位 | 11/11 | 11  | 100.0% |
| 67 | -mJ2ud6oKI8\$ _\$9  | T+A+V  | 7.033/6.909   | 768/25/16 | 词级 .50 位 | 22/22 | 29  | 100.0% |
| 68 | -mqbVkbCndg\$ _\$0  | T+A+V  | 6.500/6.385   | 768/25/16 | 词级 .50 位 | 12/12 | 17  | 100.0% |
| 69 | -qDkUB0GgYY\$ _\$6  | T+A+V  | 4.678/4.614   | 768/25/16 | 词级 .50 位 | 16/16 | 18  | 100.0% |
| 70 | -ri04Z7vwnc\$ _\$0  | T+A+V° | 2.807/2.763   | 768/25/16 | 词级 .50 位 | 8/8   | 8   | 0.0%   |
| 71 | -ri04Z7vwnc\$ _\$2  | T+A+V* | 6.027/5.914   | 768/25/16 | 词级 .50 位 | 16/16 | 26  | 35.7%  |
| 72 | -ri04Z7vwnc\$ _\$5  | T+A+V  | 3.545/3.440   | 768/25/16 | 词级 .50 位 | 8/9   | 11  | 100.0% |
| 73 | -s9qJ7ATP7w\$ _\$0  | T+A+V  | 6.867/6.710   | 768/25/16 | 词级 .50 位 | 24/24 | 28  | 100.0% |
| 74 | -s9qJ7ATP7w\$ _\$1  | T+A+V  | 4.792/4.644   | 768/25/16 | 词级 .50 位 | 11/11 | 12  | 100.0% |
| 75 | -s9qJ7ATP7w\$ _\$4  | T+A+V* | 4.427/4.247   | 768/25/16 | 词级 .50 位 | 9/9   | 10  | 71.3%  |

续表 8

| 序号  | 样本编号                | 模态     | 视/音时长 (s)     | T/A/V 维度  | 对齐粒度     | 区间/词  | 内容位 | 检出率    |
|-----|---------------------|--------|---------------|-----------|----------|-------|-----|--------|
| 76  | -s9qJ7ATP7w\$ _\$5  | T+A+V  | 8.561/8.398   | 768/25/16 | 词级 .50 位 | 19/19 | 20  | 100.0% |
| 77  | -s9qJ7ATP7w\$ _\$6  | T+A+V* | 2.475/2.315   | 768/25/16 | 词级 .50 位 | 5/5   | 5   | 81.7%  |
| 78  | -s9qJ7ATP7w\$ _\$7  | T+A+V* | 6.966/6.839   | 768/25/16 | 词级 .50 位 | 28/28 | 38  | 63.3%  |
| 79  | -s9qJ7ATP7w\$ _\$8  | T+A+V  | 3.295/3.184   | 768/25/16 | 词级 .50 位 | 12/13 | 17  | 100.0% |
| 80  | -t217m2on-s\$ _\$2  | T+A+V  | 5.686/5.630   | 768/25/16 | 词级 .50 位 | 12/12 | 16  | 100.0% |
| 81  | -t217m2on-s\$ _\$7  | T+A+V  | 17.183/17.026 | 768/25/16 | 词级 .50 位 | 45/45 | 48  | 100.0% |
| 82  | -tANM6ET1_M\$ _\$3  | T+A+V  | 6.758/6.604   | 768/25/16 | 词级 .50 位 | 22/22 | 29  | 100.0% |
| 83  | -tPCytz4rww\$ _\$10 | T+A+V  | 4.789/4.678   | 768/25/16 | 词级 .50 位 | 12/12 | 15  | 100.0% |
| 84  | -tPCytz4rww\$ _\$11 | T+A+V  | 5.467/5.378   | 768/25/16 | 词级 .50 位 | 17/17 | 20  | 100.0% |
| 85  | -tPCytz4rww\$ _\$12 | T+A+V  | 11.864/11.736 | 768/25/16 | 词级 .50 位 | 26/26 | 28  | 100.0% |
| 86  | -tPCytz4rww\$ _\$16 | T+A+V  | 7.206/7.139   | 768/25/16 | 词级 .50 位 | 16/16 | 17  | 100.0% |
| 87  | -tPCytz4rww\$ _\$18 | T+A+V  | 6.645/6.569   | 768/25/16 | 词级 .50 位 | 16/16 | 22  | 100.0% |
| 88  | -uywlfIYOS8\$ _\$4  | T+A+V  | 6.045/5.882   | 768/25/16 | 词级 .50 位 | 18/18 | 22  | 100.0% |
| 89  | -vxjVxOeScU\$ _\$4  | T+A+V  | 9.127/9.037   | 768/25/16 | 词级 .50 位 | 21/21 | 27  | 100.0% |
| 90  | -wMB_hJL-3o\$ _\$7  | T+A+V* | 6.044/5.976   | 768/25/16 | 词级 .50 位 | 22/22 | 23  | 96.7%  |
| 91  | -wny00Az3g8\$ _\$0  | T+A+V  | 3.334/3.274   | 768/25/16 | 词级 .50 位 | 9/9   | 11  | 100.0% |
| 92  | -wny00Az3g8\$ _\$1  | T+A+V  | 6.844/6.776   | 768/25/16 | 词级 .50 位 | 22/23 | 28  | 100.0% |
| 93  | -wny00Az3g8\$ _\$2  | T+A+V  | 6.687/6.523   | 768/25/16 | 词级 .50 位 | 23/23 | 28  | 100.0% |
| 94  | -wny00Az3g8\$ _\$3  | T+A+V  | 6.146/6.100   | 768/25/16 | 词级 .50 位 | 20/20 | 20  | 100.0% |
| 95  | -wny00Az3g8\$ _\$5  | T+A+V  | 6.912/6.741   | 768/25/16 | 词级 .50 位 | 20/20 | 27  | 100.0% |
| 96  | -wny00Az3g8\$ _\$7  | T+A+V  | 8.068/7.911   | 768/25/16 | 词级 .50 位 | 29/29 | 31  | 100.0% |
| 97  | -wny00Az3g8\$ _\$9  | T+A+V  | 6.213/6.043   | 768/25/16 | 词级 .50 位 | 20/20 | 22  | 100.0% |
| 98  | -yRb-Jum7EQ\$ _\$1  | T+A+V  | 29.288/29.109 | 768/25/16 | 词级 .50 位 | 49/49 | 48  | 100.0% |
| 99  | -yRb-Jum7EQ\$ _\$5  | T+A+V  | 13.169/13.044 | 768/25/16 | 词级 .50 位 | 25/25 | 31  | 100.0% |
| 100 | -yRb-Jum7EQ\$ _\$6  | T+A+V  | 11.226/11.242 | 768/25/16 | 词级 .50 位 | 19/19 | 24  | 100.0% |

## 4.2 问题二的模型建立与求解

### 4.2.1 问题分析与建模思路

问题二使用附件 2 提供的对齐版三模态特征，训练、验证与测试样本分别为 3395、728 和 727 条；附件 3 提供 30 条无标签样本，用于局部缺失条件下的专项推理检验。按赛题定义，模态局部缺失指文本、语音或视觉中某一模态的连续若干位置取值全部为零，并不表示整条模态不存在。本问需在局部信息不完整的条件下同时输出情感极性与连续情感强度，并给出缺失模态类型、缺失率、缺失位置与缺口长度对预测性能的影响规律。

三类模态的缺失形式各不相同：文本缺失由词元标记识别，语音与视觉缺失由全零向量识别，三路观测需分别判定；缺口连续分布并横跨多个锚点，以常量填充会把填充值当作观测，直接丢弃受损位置则使信息损失随缺口长度扩大。附件 3 的缺失在同一时段上跨模态重合，缺口处的三路证据同时弱化，难以依靠单模态冗余补偿。更关键的是补全结果本身可能不可靠：由样本内可用节点估计的替代表示，其质量取决于缺口周围的上下文，本文认为不应与真实观测同等对待。此外，自然缺失的分布由采集过程决定，仅按自然缺失训练难以覆盖各类缺口形态，且类别分布不平衡，需要配合受控遮挡与类别平衡处理。

据此，本文采用以三态状态区分观测与缺损、以可靠度控制补全参与度的建模方案，构造三态感知可靠补全与融合网络 TSRF-D。有效观测、结构填充与局部缺失三种状态随输入一并进入模型；缺损位置由样本内可用节点检索生成补全表示，可靠度门控决定其与回退表示的融合比例，再经双向时序编码与双任务头输出极性概率与连续强度。训练以 EMT-DLFR[9] 作为异构教师：教师在原始可用输入上产生软目标并保持冻结，学生在局部缺失输入下同时接受类别平衡的真实标签监督、任务蒸馏以及补全与门控的辅助监督。三类信号分工不同：教师保留判别能力，补全分支处理表示缺口，门控判断补全是否可信。总体结构如图 9 所示。

模型在 50 个对齐位置上统一输出极性与强度；模型评价从基础性能、缺失条件（模

态类型、缺失率、位置与缺口长度)、组件消融与基线对照以及附件 3 全量推理四个方面展开, 全部使用同一特征版本与同一输入接口。

#### 4.2.2 数据准备

##### (1) 数据划分与输入接口

附件 2 提供 4850 条样本, 按题目给定划分使用 3395 条训练样本、728 条验证样本和 727 条测试样本; 附件 3 为 30 条无标签样本, 仅参与专项预测, 其输出以全量预测与预测概率分布的形式汇总。两批数据均采用对齐版本: 附件 2 为 aligned\_50, 每个样本至多 50 个对齐位置; 附件 3 为对齐版本目录下的同名样本, 字段组织与张量形状与附件 2 一致。输入张量分别为  $X^t \in \mathbb{R}^{50 \times 768}$ 、 $X^a \in \mathbb{R}^{50 \times 74}$ 、 $X^v \in \mathbb{R}^{50 \times 35}$ 。三分类标签依次对应负向、中性和正向, 其中 0 仅属于中性类; 训练集三类样本数依次为 967、758 和 1670, 正向样本约占一半, 类别分布并不均衡。连续强度标签位于  $[-3, 3]$ , 取值包含非整数值, 因此按连续回归处理。

为统一训练与专项推理的文本输入, 采用冻结的 bert-base-uncased 第 12 层, 由 text\_bert 中的词元编号、注意力掩码和分段编号重算连续表示。重算特征与附件 2 自带文本特征的平均绝对偏差约为  $6.6 \times 10^{-7}$ , 最小余弦相似度约为 0.9999997, 二者数值一致。由于文本遮挡需要在编码前替换词元, 保留词元编号并据此重算, 可使遮挡条件正确作用于上下文表示。

三模态特征在同一组对齐锚点上组织, 同一锚点的文本、语音与视觉向量视为同一时段的观测; 语音与视觉向量按锚点整体给出, 模型不再细分锚点内部的帧。

##### (2) 缺失分布与缺口形态

附件 2 的自然缺失在各模态间并不均衡: 视觉缺失约占内容位的 5.5%, 分布在 421 条样本中, 缺口平均跨越 7.5 个锚点、最长 48 个; 音频缺失约占 0.08%, 仅见于 4 条样本; 文本不含缺失标记。附件 3 为赛题构造的模态缺失样本, 文本、语音和视觉分别缺失 131、131 和 135 个内容位, 合计 95 段, 其中 71 段长度为 1, 平均每条样本 3.17 段; 其文本与语音的缺失位置在全部 30 条样本上逐位重合, 文本与视觉在 29 条样本上重合, 缺失呈多模态局部同段共缺的形态, 另有 3 条样本不含缺失。两批数据的缺口均以连续段而非孤立点的形式跨越若干锚点, 因此遮挡实验的缺口以连续区间为基本单位构造。

##### (3) 内容、观测与人工缺失掩码

记样本为  $i$ , 锚点为  $k$ , 模态  $m \in \{t, a, v\}$ 。内容掩码  $P_{ik}$  由注意力有效位排除 [CLS] 和 [SEP] 得到。自然观测掩码分别定义为

$$O_{ik}^t = P_{ik} \mathbf{1}\{\text{token}_{ik} \neq [\text{UNK}]\}, \quad (18)$$

$$O_{ik}^a = P_{ik} \mathbf{1}\{X_{ik}^a \neq \mathbf{0}\}, \quad O_{ik}^v = P_{ik} \mathbf{1}\{X_{ik}^v \neq \mathbf{0}\}. \quad (19)$$

其中  $X_{ik}^m \neq \mathbf{0}$  表示该向量至少有一个非零分量。依据附件的缺失标记规则, 文本由词元标记识别缺失, 语音和视觉由全零向量识别缺失, 三路观测掩码分别计算。

令人工遮挡掩码为  $H_{ik}^m$ , 且  $H_{ik}^m \leq O_{ik}^m$ , 则最终观测掩码  $\tilde{O}_{ik}^m = O_{ik}^m(1 - H_{ik}^m)$ 。三态变量定义为

$$s_{ik}^m = \begin{cases} 0, & P_{ik} = 0, \\ 1, & P_{ik} = 1, \tilde{O}_{ik}^m = 1, \\ 2, & P_{ik} = 1, \tilde{O}_{ik}^m = 0. \end{cases} \quad (20)$$

自然缺失与人工缺失在模型输入中均为状态 2, 但仅人工遮挡位置保留可用于重建评价的

原始真值。对模态  $m$  的第  $j$  维，使用训练集观测位置估计  $\mu_j^m, \sigma_j^m$  并计算

$$\bar{X}_{ikj}^m = \frac{X_{ikj}^m - \mu_j^m}{\tilde{\sigma}_j^m}, \quad \tilde{\sigma}_j^m = \begin{cases} 1, & \sigma_j^m < 10^{-6}, \\ \sigma_j^m, & \text{其他}. \end{cases} \quad (21)$$

结构位在标准化后置零，缺失位通过观测掩码排除于候选集合之外。人工音视频遮挡使用标准化空间中的零值；文本则先将选定词元替换为 **[UNK]**，再经 **BERT** 编码，同时保留原有序列位置，使未遮挡位置的上下文表示不含已删除词元的信息。

#### 4.2.3 模型构建

##### (1) 总体结构与三态投影

图 9 给出学生网络及教师监督的关系。学生的计算顺序为投影、补全与门控、时序编码、池化和双任务预测：三态投影先给出区分位置的节点表示，补全分支在样本内检索有效观测，为缺失位生成替代表示，门控决定其参与比例，随后由时序编码与池化得到样本级表示。补全位于时序编码之前，使递归编码面对的是完整序列，缺口通过检索结果而不是零值进入后续计算。



图 9 TSRF-D 网络结构与教师-学生监督关系

将三模态特征映射到公共维度  $d = 64$ 。设模型实际接收的标准化输入为  $\tilde{x}_{ik}^m$ ，则

$$z_{ik}^m = P_{ik} \left( W_m \tilde{x}_{ik}^m + b_m + e_m^{\text{mod}} + e_{s_{ik}^m}^{\text{state}} + e_k^{\text{pos}} \right). \quad (22)$$

模态嵌入描述信息来源，状态嵌入表征可观测性，位置嵌入保留序列顺序，三者共同形成缺失感知的节点表示。三个模态经各自的仿射映射进入同一  $d = 64$  维空间，使补全检索可以在跨模态候选之间比较表示距离；结构位在投影后置零，不参与检索与池化。

##### (2) 观测节点加权补全

对样本  $i$ ，以  $\Omega_i = \{(n, j) : \tilde{O}_{ij}^n = 1\}$  为候选集。缺失位置的查询及候选键值为

$$q_{ik}^m = Q(e_k^{\text{pos}} + e_m^{\text{mod}} + e_2^{\text{state}}), \quad \kappa_{ij}^n = K_z(z_{ij}^n), \quad v_{ij}^n = V_z(z_{ij}^n), \quad (23)$$

其中  $Q, K_z, V_z$  为可学习仿射映射。缺失位置没有自身观测，其表示只能由样本内其他有效节点估计；查询由目标位置、模态与缺失状态 ( $s_{ik}^m = 2$ ) 共同确定，不包含目标位的内容

信息，候选键值由有效观测生成，从而把待补位置的结构信息与候选节点的样本内容分开处理。

设  $\ell_{ij}^n$  为候选位置所在连续观测段的长度，定义观测连续性先验

$$u_{ij}^n = \sigma \left( \alpha_0 + \alpha_1 \tilde{O}_{ij}^n + \alpha_2 \min(\ell_{ij}^n/10, 1) \right). \quad (24)$$

该先验利用连续观测段长度描述候选节点的局部可用性：位于较长连续观测段上的候选更贴近缺口的上下文，孤立观测的参考价值较低。对  $(n, j) \in \Omega_i$ ，补全代价及权重为

$$C_{i,k,j}^{m,n} = \frac{\|q_{ik}^m - \kappa_{ij}^n\|_2^2}{d} + \lambda_t \frac{|k-j|}{K} + \lambda_q (1 - u_{ij}^n), \quad (25)$$

$$\pi_{i,k,j}^{m,n} = \frac{\exp(-C_{i,k,j}^{m,n}/\tau)}{\sum_{(n',j') \in \Omega_i} \exp(-C_{i,k,j'}^{m,n'}/\tau)}, \quad \hat{z}_{ik}^m = \sum_{(n,j) \in \Omega_i} \pi_{i,k,j}^{m,n} v_{ij}^n. \quad (26)$$

上述代价综合表示距离、位置距离和观测连续性，其中位置距离以接口长度  $K$  归一，时间项赋予邻近锚点较高的候选优先级，连续性项抑制孤立观测的权重；温度  $\tau$  控制权重在候选间的集中程度，取值较小时结果接近最近候选，取值较大时趋于候选均值。候选范围覆盖样本内全部可用模式，因而兼顾同模式时序信息与跨模式关联信息。

### (3) 可靠度门控与情感预测

对候选代价按补全权重聚合，得到门控所需的三个统计量：

$$\begin{aligned} \bar{C}_{ik}^m &= \sum_{(n,j) \in \Omega_i} \pi_{i,k,j}^{m,n} C_{i,k,j}^{m,n}, & C_{\min} &= \min_{(n,j) \in \Omega_i} C_{i,k,j}^{m,n}, \\ \text{Var}_{\pi}(C) &= \sum_{(n,j) \in \Omega_i} \pi_{i,k,j}^{m,n} (C_{i,k,j}^{m,n} - \bar{C}_{ik}^m)^2. \end{aligned} \quad (27)$$

以三者与候选数量占比、目标模式可用比例构造门控输入

$$g_{ik}^m = [\bar{C}, \text{Var}_{\pi}(C), C_{\min}, |\Omega_i|/(3K), a_i^m, e_m^{\text{mod}}], \quad a_i^m = \frac{\sum_k \tilde{O}_{ik}^m}{\sum_k P_{ik}}. \quad (28)$$

两层感知机输出  $\rho_{ik}^m = \sigma(G(g_{ik}^m))$ ，并与可学习的缺失嵌入  $e_m^{\text{miss}}$  融合：

$$z_{ik}^{m,f} = \tilde{O}_{ik}^m z_{ik}^m + P_{ik} (1 - \tilde{O}_{ik}^m) [\rho_{ik}^m \hat{z}_{ik}^m + (1 - \rho_{ik}^m) e_m^{\text{miss}}]. \quad (29)$$

门控输入同时刻画补全的质量与可用证据：加权代价均值与最小代价反映候选的匹配程度，加权方差反映候选之间的分歧，候选数量占比与模式可用比例反映可检索证据与模式自身的完整度。其中  $e_m^{\text{miss}}$  为模式  $m$  的可学习缺失嵌入， $\rho_{ik}^m \in (0, 1)$  由两层感知机给出，调节补全表示对融合结果的贡献。观测位置的表示保持不变，缺失位置在补全与缺失嵌入之间按  $\rho$  加权；当候选集为空时，令  $\pi = 0, \rho = 0$ ，以缺失嵌入完成回退。

锚点顺序承载情感的时序演变，因此对每个模式独立进行单层双向 GRU 编码，记输出隐状态为  $h_{ik}^m \in \mathbb{R}^{64}$ ；缺失位置经融合后已有表示，递归过程面对的是完整序列。实现中按有效前缀打包序列，避免尾部填充通过反向递归污染内容位置。池化只在内容位进行，取内容位的均值与最大值：

$$\bar{h}_i^m = \frac{\sum_k P_{ik} h_{ik}^m}{\sum_k P_{ik}}, \quad \check{h}_i^m = \max_{k: P_{ik}=1} h_{ik}^m, \quad h_i = \text{MLP}([\bar{h}_i^t, \check{h}_i^t, \bar{h}_i^a, \check{h}_i^a, \bar{h}_i^v, \check{h}_i^v, a_i^t, a_i^a, a_i^v]), \quad (30)$$

使结构化填充不参与统计，拼接维度为  $6d + 3 = 387$ 。双任务输出为

$$p_i = \text{softmax}(W_c h_i + b_c), \quad \hat{y}_i = \arg \max_c p_{ic}, \quad \hat{r}_i = 3 \tanh(w_r^\top h_i + b_r). \quad (31)$$

分类与回归采用共享表示和独立输出头，强度以  $3 \tanh(\cdot)$  输出，与标签区间  $[-3, 3]$  一致；两个任务通过下文的一致性损失建立软约束。

#### (4) 真实标签与任务蒸馏

教师采用 EMT-DLFR 的任务适配结构 [9]。文本经线性投影，语音和视觉经单向 LSTM 编码到 64 维；两层、四头的高效多模态 Transformer 在全局模态表示与局部序列之间交互，融合表示经双任务头输出三类 logits 和连续强度。教师训练同时使用基础与遮挡输入的标签监督，并结合高层表示吸引和低层特征重建目标；参数仅在附件 2 训练集上学习，保存轮次由验证集联合指标确定。

教师在同一批样本上使用未追加人工遮挡的输入，其输出反映较完整观测下的情感倾向。教师完成训练后冻结参数，为每个学生种子提供对应教师在训练样本上的输出；学生接收含人工遮挡的输入，通过任务蒸馏 [8] 学习教师的类别分布与强度输出，以软目标的形式继承这部分判别信息。蒸馏只在输出层进行，不在隐藏层施加额外对齐约束，以免与补全重建、门控监督叠加后各目标相互牵制。学生真实标签监督为

$$\mathcal{L}_{\text{sup}} = \text{CE}_w(y, p^S) + \lambda_r \text{Huber}_1(r, \hat{r}^S) + \lambda_c [(p_+^S - p_-^S) - \tanh(\hat{r}^S/3)]^2, \quad (32)$$

其中  $p_+^S$  与  $p_-^S$  分别为正、负类别的预测概率， $\lambda_r$  与  $\lambda_c$  为回归项与一致性项权重， $\text{Huber}_\delta$  表示  $\delta$  尺度的 Huber 损失， $\delta = 1$  时与  $\beta = 1$  的平滑 L1 损失一致。设训练集样本量为  $N$ ，类别  $c$  的样本量为  $N_c$ ，取  $w_c = N/(3N_c)$ 。对训练批次  $\mathcal{B}$ ，分类损失按实际样本权重归一化：

$$\text{CE}_w(y, p^S) = - \frac{\sum_{i \in \mathcal{B}} w_{y_i} \log p_{i, y_i}^S}{\sum_{i \in \mathcal{B}} w_{y_i}}. \quad (33)$$

回归与一致性损失仍按样本平均。类别权重仅作用于真实标签的分类损失，以平衡不同类别对监督目标的贡献；不改变训练采样频率和预测时的最大概率决策规则。教师与学生的分类 logits 记为  $o^T, o^S$ ，温度为  $T$ ，蒸馏目标为

$$\mathcal{L}_{\text{dc}} = T^2 \text{KL}(\text{sg}[\text{softmax}(o^T/T)] \parallel \text{softmax}(o^S/T)), \quad (34)$$

$$\mathcal{L}_{\text{dr}} = \text{Huber}_1(\hat{r}^S, \text{sg}[\hat{r}^T]). \quad (35)$$

sg 表示停止梯度。训练采用样本等权的蒸馏损失，并离线缓存教师在训练样本上的输出，使蒸馏不引入在线前向开销。分类蒸馏传递类别间的分布信息，强度蒸馏约束连续预测，两者共同指导学生缺失条件下的情感表示。

#### (5) 补全与相对可靠度监督

对具有真值的人工遮挡集合  $\mathcal{H}_m$ ，使用可学习解码头  $D_m$  将补全表示映射回原始标准化特征空间：

$$\mathcal{L}_{\text{rec}} = \frac{1}{|\mathcal{M}_H|} \sum_{m \in \mathcal{M}_H} \frac{1}{|\mathcal{H}_m|} \sum_{(i,k) \in \mathcal{H}_m} \text{Huber}_1(D_m(\hat{z}_{ik}^m), \bar{X}_{ik}^{m, \text{true}}), \quad (36)$$

其中  $\bar{X}_{ik}^{m, \text{true}}$  为人工遮挡前的标准化特征， $\mathcal{M}_H$  为当前批次存在人工遮挡的模态集合，每个向量的损失对特征维取均值。重建只在人工遮挡位置计算：这些位置同时具备缺口输入与被遮挡前的真值，自然缺失位置没有可比的原始观测。重建目标为标准化后的原始特征，解码头与学生网络共同训练。

补全表示与回退表示经同一解码头映射回特征空间，二者相对真值的逐位置平均绝对

误差为

$$\begin{aligned} e_{\text{rec}} &= \frac{1}{|\mathcal{H}_m|} \sum_{(i,k) \in \mathcal{H}_m} \frac{1}{d} \|D_m(\hat{z}_{ik}^m) - \bar{X}_{ik}^{m,\text{true}}\|_1, \\ e_{\text{fal}} &= \frac{1}{|\mathcal{H}_m|} \sum_{(i,k) \in \mathcal{H}_m} \frac{1}{d} \|D_m(e_m^{\text{miss}}) - \bar{X}_{ik}^{m,\text{true}}\|_1, \end{aligned} \quad (37)$$

据此构造门控监督目标

$$\rho^* = \text{sg}[\sigma((e_{\text{fal}} - e_{\text{rec}})/\tau_\rho)], \quad \mathcal{L}_{\text{rel}} = \text{BCE}(\rho, \rho^*). \quad (38)$$

可靠度损失同样先在各模态人工遮挡位平均，再在有遮挡模态间平均。该目标以补全与回退的相对误差为标签，使门控判断补全是否优于回退，而不依赖误差绝对水平的标定。自然缺失位置没有可用真值，不参与上述两项监督，其门控取值由这些监督训练得到的映射外推给出。

综合目标为

$$\mathcal{L} = \mathcal{L}_{\text{sup}} + \beta_e (\lambda_{\text{dc}} \mathcal{L}_{\text{dc}} + \lambda_{\text{dr}} \mathcal{L}_{\text{dr}} + \lambda_{\text{rec}} \mathcal{L}_{\text{rec}} + \lambda_{\text{rel}} \mathcal{L}_{\text{rel}}). \quad (39)$$

首轮  $\beta_e = 0$ ，学生先以真实标签建立基础预测能力；随后三轮线性升至 1，使补全、门控与蒸馏目标逐步加入，避免辅助目标在训练初期主导优化。预热阶段保留分类、回归和一致性损失。

#### 4.2.4 模型求解与参数设置

##### (1) 遮挡策略与训练流程

附件 3 的缺失多为局部的连续片段，且可同时落在多个模态上，程度随样本而异。人工缺失若只用单一形态生成，模型容易被固定模式牵着走，因此训练中的遮挡由无新增遮挡、单模态局部缺口、多模态缺失与整模态丢弃四类场景混合而成，采样比例依次为 20%、45%、25% 与 10%。占比最高的单模态局部缺口对应附件 3 的主要形态；多模态缺失描述跨模态证据同时衰减，其中三模态组合按各模态独立的位置生成缺口，使缺口部分交叠而非整齐重合；整模态丢弃把所选模态的内容位全部抹去，观测缺失达到极端，仅以 10% 的比例作为压力场景；无新增遮挡保留自然缺失，使模型在训练全程都能接触未追加遮挡的样本，基础判别能力不随缺失场景占比上升而退化。

单模态缺口的比例围绕附件 3 的实际缺失水平展开：文本给出 10%、25% 与 40% 三档，把附件 3 的水平包在中间，语音与视觉固定取 20%，与附件 3 两路约两成的缺失程度相当。文本的分档更细，因为极性判断对文本证据的依赖最强，同等比例下文本损失对判别的影响也最直接。多模态缺失覆盖双模态与三模态组合，比例取 15% 至 30%。

所有人工遮挡都嵌套在自然观测之内，即  $H^m \leq O^m$ ，只改变原本可观测内容位的取值，自然缺失与人工缺失在掩码上始终可区分。生成方式按代价分开处理：文本遮挡必须在编码前替换词元，逐轮重算上下文的开销过高，因此含文本的 9 类遮挡模式按样本预生成编码结果，在轮次间轮换；语音与视觉直接在特征位图上置零，不含文本的模式按种子与轮次在线生成，同一随机流下课程可复现。

局部缺口的段长由参数 0.35 的几何分布采样，短缺口占多数并保留较长尾部，同时受目标遮挡预算、单段 32 锚点的长度上界与样本边界约束：预算只规定该样本的遮挡总量，缺口按预算逐段铺开，触及样本末端即截断。按最终掩码统计，局部与多模态场景中的遮挡平均覆盖约 10% 的内容锚点，段长以 1 至 4 个锚点为主，与附件 3 以短缺口为主的形态同向；训练中保留的较长缺口，使评测中加长缺口的条件仍落在训练分布附近。

## (2) 选模准则与关键参数

模型以验证集联合指标选择训练轮次：

$$J = 0.5F_{\text{base}} + 0.5 \left( \frac{1}{4} \sum_{c \in \mathcal{C}} F_c \right) - 0.1 \text{MAE}_{\text{base}}, \quad \mathcal{C} = \{t, a, v, tav\} \text{的居中 8 锚点缺口.} \quad (40)$$

其中  $F$  为 Macro-F1，基础项与强度项均在保留自然缺失、不追加人工遮挡的输入上计算。基础性能与缺失性能各占一半权重，强度误差以 0.1 的系数扣除，使选模同时关注分类与回归：只按基础输入选模会偏向完整观测下的表现，只按缺失条件选模则可能牺牲基础判别能力。选模中的固定 8 锚点缺口对短样本按有效长度截断，短样本因此出现整段遮挡的压力条件。下文主要评价另以  $L_i - 1$  限制连续区间长度，把选模压力条件与局部缺失评价区分开。教师与学生均按验证集  $J$  保存参数。

表 9 TSRF-D 模型与训练参数

| 参数           | 取值                                                                                       |
|--------------|------------------------------------------------------------------------------------------|
| 公共维度、Dropout | 64、0.2                                                                                   |
| 时序编码器        | 每模态单层 BiGRU；单方向隐维 32                                                                     |
| 补全参数         | $\tau = 0.5, \lambda_t = 0.1, \lambda_q = 0.5$                                           |
| 观测连续性先验      | $\alpha_0 = 0, \alpha_1 = 2, \alpha_2 = 0.5$ ；段长尺度 10                                    |
| 损失权重         | $\lambda_r = 1, \lambda_c = 0.2, \lambda_{\text{rec}} = 0.5, \lambda_{\text{rel}} = 0.3$ |
| 蒸馏与门控目标      | $\lambda_{\text{dc}} = \lambda_{\text{dr}} = 1, T = 2, \tau_\rho = 0.2$                  |
| 优化器与调度       | AdamW，初始学习率 0.0015，权重衰减 $10^{-4}$ ，余弦调度                                                  |
| 批量、轮数、早停     | 256、至多 32 轮、耐心值 8；梯度裁剪范数 5                                                               |
| 教师与分类权重      | EMT-DLFR 任务适配版； $w_c = N/(3N_c)$ ，按训练标签计算                                                |
| 随机种子与集成      | 教师、学生均使用 0、1、2；学生预测概率与强度分别取均值                                                            |
| 计算环境         | Python 3.12, PyTorch 2.8.0+cu128; RTX 5060 Ti; 冻结 BERT 重算文本                              |

模型参数由附件 2 训练集学习，保存轮次由验证集确定。求解分为教师训练与学生训练两个阶段：先训练并冻结教师，再在混合缺失场景下优化学生的联合目标。完成选模后，固定学生参数进行缺失干预实验及附件 3 推理。主要参数的取值见表 9。

关键参数按以下依据确定。公共维度取  $d = 64$ ，在压缩三路高维输入的同时控制参数量，学生网络含约 22 万参数；补全温度  $\tau = 0.5$  使权重集中在代价较小的候选上；观测连续性先验的段长尺度取 10，与常见连续观测的长度量级相当。损失项中真实标签、分类蒸馏与强度蒸馏取同量级权重（ $\lambda_r = \lambda_{\text{dc}} = \lambda_{\text{dr}} = 1$ ），重建与门控监督取较小权重（0.5 与 0.3），使辅助目标不主导优化；一致性项以  $\lambda_c = 0.2$  约束极性与强度的方向一致。优化采用 AdamW 与余弦学习率调度，初始学习率 0.0015、权重衰减  $10^{-4}$ 、梯度裁剪范数 5；批量取 256，最多训练 32 轮，验证指标连续 8 轮无改善即停止并恢复最优参数。三个种子独立训练，预测概率与强度分别取均值集成。在本轮设置下，三个学生种子分别在第 7、第 8 和第 22 轮取得最优验证指标，训练在第 15、16 和 30 轮触发早停，单种子学生训练耗时约 40 至 80 s。

## (3) 配置依据与类别平衡

训练集中正向样本占比为 49.19%，中性样本占比为 22.33%。若对所有样本赋予相同分类权重，正向类别在经验损失中具有更大的总权重。本文采用式 (33)，使各类别满足  $N_c w_c = N/3$ ，从训练目标上均衡三类样本的贡献，与 Macro-F1 逐类等权评价的出发点相一致。具体频数和权重见表 10。

权重规则另与温和平衡方案  $w_c = [N/(3N_c)]^{1/4}$  作过比较：后者在验证集上取得小幅分

表 10 由训练集类别频数确定的分类权重

| 类别 | 样本数 $N_c$ | 样本占比/% | 权重 $w_c$ |
|----|-----------|--------|----------|
| 负向 | 967       | 28.48  | 1.1703   |
| 中性 | 758       | 22.33  | 1.4930   |
| 正向 | 1670      | 49.19  | 0.6776   |

类增益，但在训练集内部按来源视频分组的两组留出检查中，其局部平均 F1 相对等权重分别下降 0.0123 和 0.0106，检查覆盖 20% 连续缺口的七种模态组合及三个位置。增益未跨划分复现，因此采用由训练频数直接确定的逆频率权重，不再对权重指数作额外搜索。

#### (4) 教师-学生训练算法

算法 1 给出完整求解步骤，按教师训练、学生训练与集成的顺序展开：每轮重新采样遮挡场景并重建三态变量，损失权重按轮次升温。学生训练同时结合真实标签、蒸馏与重建辅助目标，预生成的文本遮挡特征按相应掩码索引，以保持输入与监督位置的一致性。

##### 算法 1 TSRF-D 教师-学生联合训练

**输入：**附件 2 训练集  $\mathcal{D}_{tr}$ 、验证集  $\mathcal{D}_{val}$ ，冻结 BERT，缺失场景分布  $\mathcal{Q}$ ，损失权重，种子集合  $\{0, 1, 2\}$ 。

**输出：**按验证集联合准则选出的学生参数  $\{\theta_S^{*(s)}\}_{s=0}^2$ 。

- 1 构建  $P, O$ ；仅用训练集拟合标准化统计量，由类别频数计算  $w_c = N/(3N_c)$ ，并预生成含文本类的遮挡编码库。
- 2 **对每个随机种子  $s \in \{0, 1, 2\}$ ，执行：**
- 3 用训练集学习 EMT-DLFR 教师，结合基础/遮挡标签监督及双层恢复目标。
- 4 按验证集  $J$  保存教师并冻结；仅缓存训练样本在无新增遮挡输入上的输出。
- 5 初始化学生  $\theta_S$ ；令  $J^* = -\infty$ ，最大轮数  $E = 32$ ，早停耐心值为 8。
- 6 **对  $e = 1, \dots, E$ ，执行：**
- 7 依据  $\mathcal{Q}$  生成本轮遮挡掩码  $H$ ，限制  $H^m \leq O^m$ ，并打乱训练样本。
- 8 设置辅助权重  $\beta_1 = 0$ ；第 2 至 4 轮依次为 1/3, 2/3, 1，此后为 1。
- 9 **对每个训练批次  $\mathcal{B}$ ，执行：**
- 10 保留遮挡前标准化真值  $\bar{X}^{true}$ ，仅供辅助损失使用。
- 11 将  $H^t = 1$  处词元替换为 [UNK] 后编码；按掩码读取预生成文本特征。
- 12 音视频遮挡位使用标准化零值，更新  $\tilde{O} = O \odot (1 - H)$  及三态变量。
- 13 学生前向：投影、加权补全、可靠度融合、BiGRU 与池化，得到  $p^S, \hat{r}^S$ 。
- 14 以逆频率类别权重计算  $\mathcal{L}_{sup}$ ，读取教师输出  $p^T, \hat{r}^T$ 。
- 15 计算分类与强度蒸馏损失  $\mathcal{L}_{dc}, \mathcal{L}_{dr}$ ；教师停止梯度。
- 16 仅在人工遮挡位计算  $\mathcal{L}_{rec}, \mathcal{L}_{rel}$ ；可靠度目标停止梯度。
- 17 按式 (39) 汇总损失；反向传播、梯度裁剪，使用 AdamW 更新学生。
- 18 **结束批次循环：**更新余弦学习率。
- 19 在验证集基础输入及  $t/a/v/tav$  居中 8 锚点缺口上按式 (40) 计算  $J$ ，评价时不更新模型参数。
- 20 若  $J > J^*$ ，保存学生参数并更新  $J^*$ ；否则连续 8 轮无改善时提前停止。
- 21 **结束轮次循环，恢复最优学生参数  $\theta_S^{*(s)}$ 。**
- 22 **结束种子循环：**返回三组学生参数，用于冻结后的概率与强度集成。

如图 10 所示，三个种子的分类指标在训练初期较快上升，随后进入波动区间：每轮的遮挡场景按课程重新采样，场景难度差异会直接反映在验证指标上，因此波动主要来自训练分布的变化，而不是优化过程的不稳定。局部缺失条件下的 F1 整体低于基础输入，反映出信息遮挡带来的预测损失。联合准则在基础性能与缺失性能之间权衡，保存其最大值对应的学生参数。




图 10 三个学生种子的训练过程

#### 4.2.5 实验结果与分析

##### (1) 评价协议与基础性能

评价围绕分类与回归两条线展开。极性是三分类问题，训练集三类样本的比例约为 28%、22% 与 49%，因此以逐类等权的 Macro-F1 作为主要指标，Accuracy 只作为总体正确率的参照；强度是连续量，用 MAE 衡量误差幅度，用 Pearson 相关系数衡量预测与标签在排序上的一致程度。三个种子分别独立训练与选模，分类概率与强度输出取均值形成集成结果，以降低初始化差异带来的波动。所有评价都在冻结参数的条件下进行，基础输入保留自然缺失、不追加人工遮挡，作为后面各类缺失干预的共同参照。附件 2 的有标签测试划分用于性能评价，附件 3 没有标签，只作专项推理。

基础输入下，验证集 Macro-F1 为 0.6163、强度 MAE 为 0.5818、Pearson 相关系数为 0.6606，测试集对应指标为 0.6189、0.6221 与 0.6824，两个划分的结果接近，说明选模没有把参数拉向验证集特有的分布。以此为参照，下面依次考察缺失模态、缺失比例、缺口位置与缺口长度四个因素引起的预测变化。

##### (2) 类别权重的求解检验

类别分布不均会直接影响决策边界：不加权时模型倾向于把边界样本推向样本量大的类别。为观察这一影响，在相同教师、相同学生结构与相同三个种子的条件下，把逆频率权重的结果与等权重学生的验证集预测作对比，两者各自按自身的验证轨迹确定训练轮次。

逆频率加权后，验证集 Macro-F1 由 0.6191 变为 0.6163、强度 MAE 由 0.5831 变为 0.5818，105 种局部条件的平均 F1 由 0.6019 变为 0.6012，变化都在种子波动的量级之内，说明平衡权重没有削弱缺失条件下的判别能力。分类型看，中性类召回率由 0.4891 升至 0.5978，正向类召回率由 0.7041 降至 0.6331，负向类召回率由 0.6650 降至 0.6359，预测分布由偏向多数类转向三类相对均衡。本文据此采用由训练频数直接确定的类别权重，并在结果中同时报告总体指标与分类型表现。

##### (3) 连续局部缺失与输入模态消融

局部缺失的评价在模态组合、缺口比例与缺口位置三个维度上交叉展开，取模态集合  $\{t, a, v, ta, tv, av, tav\}$ 、目标区间比例  $\{5\%, 10\%, 20\%, 30\%, 40\%\}$  以及句首、句中、句尾三个位置，形成 105 种连续缺失条件。每次干预把所选模态在同一段连续区间内的观测整体移除，对内容长度  $L_i \geq 2$ ，区间长度为

$$n_i = \min\{L_i - 1, \max[1, \lfloor qL_i + 0.5 \rfloor]\}, \quad H_{ik}^m = \mathbf{1}\{m \in \mathcal{M}_H, k \in I_i\} O_{ik}^m. \quad (41)$$

同一段缺口同时落在所选的全部模态上，对应附件 3 中多路证据在同一时段失效的情

形；自然缺失的位置不重复计入人工删除，内容长度不足 2 的样本不追加遮挡。目标比例以内容锚点为分母，实际新增观测删除率定义为  $\sum_{imk} H_{ik}^m / \sum_{imk} O_{ik}^m$ ，两个量分别保存：未选模态在缺口区间内仍然可用，短样本的区间又会因取整偏离名义比例，目标比例与实现比例并不相等。

按上述规则逐项移除单模态或模态组合的局部信息，构成输入模态消融。表中每种组合对五个比例与三个位置等权平均；全局局部指标对 105 种条件等权平均，同一视频的不同遮挡版本共用重采样权重，不按独立样本累计，各组合的平均结果见表 11。

表 11 测试集局部输入模态消融结果

| 移除的局部模态 | Macro-F1 | MAE    | $\Delta F1$ |
|---------|----------|--------|-------------|
| 文本      | 0.5923   | 0.6688 | -0.0267     |
| 语音      | 0.6233   | 0.6226 | +0.0043     |
| 视觉      | 0.6224   | 0.6228 | +0.0035     |
| 文本 + 语音 | 0.5926   | 0.6692 | -0.0264     |
| 文本 + 视觉 | 0.5970   | 0.6685 | -0.0220     |
| 语音 + 视觉 | 0.6222   | 0.6235 | +0.0033     |
| 三模态     | 0.5963   | 0.6690 | -0.0226     |

文本缺口的影响明显大于另外两路：仅文本局部缺失时平均 F1 降至 0.5923、MAE 升至 0.6688；仅语音和仅视觉局部缺失时 F1 分别为 0.6233 与 0.6224，与基础输入的 0.6189 相当。三模态同段缺失的 F1 为 0.5963，与仅文本缺失相差 0.0040，语音与视觉之间也只差 0.0009。局部判别证据主要由文本通道承载，音视频缺口的影响大多来自与文本缺口重叠的时段。表中数值描述各输入干预下的敏感程度，不等同于补全或蒸馏组件的独立贡献。

#### (4) 缺失比例、位置与长度的影响

缺失比例实验覆盖七种模态组合与三个位置，表 12 按目标区间比例给出三者等权平均后的结果。比例每提高一档，缺口覆盖的内容锚点随之增多，识别指标的变化如下。

表 12 连续缺失比例的测试结果

| 目标区间比例 | Macro-F1 | MAE    |
|--------|----------|--------|
| 5%     | 0.6151   | 0.6351 |
| 10%    | 0.6138   | 0.6389 |
| 20%    | 0.6096   | 0.6477 |
| 30%    | 0.6034   | 0.6553 |
| 40%    | 0.5911   | 0.6691 |

目标区间比例由 5% 增至 40% 时，平均 F1 由 0.6151 降至 0.5911，MAE 由 0.6351 增至 0.6691，Pearson 相关系数由 0.6659 降至 0.6233，信息损失同时削弱分类判别与强度排序（图 11）。分模态看，文本缺口与三模态共缺两条曲线在四项指标上都随比例单调退化，文本的 Pearson 相关系数由 0.6532 降至 0.5795；语音与视觉单模态缺口的曲线几乎水平，整段比例的波动不足 0.001，退化几乎全部来自文本通道。文本与三模态共缺的曲线在各比例上高度接近，说明重叠区段的音视频缺失没有带来额外损失，与模态消融的结论一致。

位置实验中，句首缺失的平均 F1 最高（0.6111），句中最低（0.6021），两者相差 0.0090，MAE 依次为 0.6423、0.6518 与 0.6535，与 F1 给出的排序一致；同一位置内部不同模态组合与比例造成的 F1 跨度则达到 0.0743。逐样本配对比较中，22.0% 的样本在句首缺口下判




图 11 不同缺失模态与目标区间比例下四项指标的退化曲线

断更准、21.9% 更差、56.1% 不变（图 12(a)）。缺口出现的位置只带来量级很小的平均差异，也没有系统性偏向：模型主要依据缺口周边仍然存在的证据作判断，而不依赖缺口在序列中的位置。




图 12 缺失位置、缺口长度与基线比较

图 12(b) 给出三模态同段居中缺口的长度效应：F1 由长度 1 锚点的 0.6047 降至长度 16 锚点的 0.4632，MAE 由 0.6496 升至 0.7981。长度以附件提供的对齐锚点度量，不折算为时间；短样本的缺口被截为  $L_i - 1$ ，保证至少保留一个观测，长度 8 与 16 的条件分别有 62 条与 236 条样本受此限制。缺口由短到长，分类与回归的退化都随之加深，长度 4 以内的条件仍保持 0.60 以上的 F1。对所选模态实际发生删除且仍保留至少一个观测的样本，取 105 种条件的交集，得到 648 条严格局部样本；在该子集上，LMF、MulT 与 TSFR-D 的局部平均 F1 分别为 0.5680、0.5961 与 0.6007，局部平均 MAE 分别为 0.7073、0.6987 与 0.6614，子集口径与全集口径给出的排序一致。

图 12(c) 在三模态同段共缺下给出与两种公开融合基线的对比：缺口越重，方法差距越大。目标区间比例由 5% 增至 40% 时，LMF 的 Macro-F1 由 0.5868 降至 0.4936，与 TSFR-D

的差距由 0.0243 扩大到 0.0738；MulT 全程与 TSRF-D 接近，两者差值不超过 0.013。

(5) 受控缺口下的逐样本错误转移

把完整输入与受控缺口下的判断逐样本对照，727 条测试样本可分为两侧均正确、翻转、修复与两侧均错误四类。三模态共缺 20%（句中）时四类样本依次为 408、60、48 与 211 条，缺口扩大到 40% 时翻转增至 102 条、修复 60 条；缺口长度为 16 个锚点时翻转 193 条、修复 65 条。该长度下分类错误共 387 条，其中 50.1% 在完整输入下本已判错，遮挡加剧了原本就困难的样本。翻转样本随缺口比例与缺口长度的增加而单调上升，文本单模态缺口与三模态共缺接近，语音与视觉单模态缺口几乎不产生翻转（图 13），与模态消融的趋势一致。




图 13 受控缺口下的逐样本错误转移

(6) 验证集可视化与错误归因

图 14 给出验证集类别混淆与强度回归结果。验证集的负向、中性、正向 F1 分别为 0.6517、0.5081 与 0.6892，中性类明显偏低。273 条分类错误中有 213 条涉及中性类，占 78.0%，其中真实正向判为中性 89 条、真实负向判为中性 50 条。中性样本的强度标签集中在 0 附近，与相邻极性的表达差别较小，边界样本的极性区分本身较难，类别边界因此成为分类误差的主要来源；强度散点显示连续预测与标签同样在中性附近偏离最大。




图 14 验证集类别混淆与强度回归结果

#### 4.2.6 与基线的测试集比较

##### (1) 对照设置

基线对照在同一训练划分、同一遮挡课程、同一冻结文本编码、同一训练集标准化统计量与同样三个种子的条件下重跑，覆盖七类输入处理与结构方案：仅文本、拼接 MLP、零填充、均值填充、缺失标记、模态丢弃和三态嵌入。这七类方案对缺失的处理可分为两组：零填充、均值填充、缺失标记与模态丢弃决定缺口位置取什么值或留什么标记，仅文本、拼接 MLP 与三态嵌入决定模态证据以何种形式进入判别模型。公开融合基线 LMF 与 MulT 按本题的三分类与连续回归任务适配，保留各自原有的模型配置，给出通用融合框架在同一缺失结构下的参照。自然缺失位置的填充按各模型自身的训练口径执行，零填充直接使用原始零值标准化输入，其余模型以训练集均值替代。十类模型共用 727 条测试样本、同一套人工掩码与三个种子，在基础输入与 105 种连续局部缺失条件下比较，分类概率与强度输出分别取种子集成；样本、掩码与集成口径完全对齐，指标差异只来自各模型处理同一缺失结构的方式。

LMF、MulT 与内部基线只接受自身监督信号，TSRF-D 在此基础上还使用了 EMT-DLFR 教师的软监督，因此本节比较的是含蒸馏的完整方法与各类基线之间的差距，其训练代价相应包含教师的学习过程。

表 13 测试集统一口径的基线比较

| 模型     | 基础 Acc | 基础 F1  | 基础 MAE | 基础 $r$ | 局部 F1  | 局部 MAE |
|--------|--------|--------|--------|--------|--------|--------|
| 仅文本    | 0.6410 | 0.6192 | 0.6396 | 0.6613 | 0.6028 | 0.6700 |
| 拼接 MLP | 0.6039 | 0.5805 | 0.6386 | 0.6602 | 0.5852 | 0.6636 |
| 零填充    | 0.6231 | 0.5894 | 0.6417 | 0.6703 | 0.5851 | 0.6653 |
| 均值填充   | 0.6410 | 0.6073 | 0.6539 | 0.6659 | 0.5979 | 0.6786 |
| 缺失标记   | 0.6217 | 0.5945 | 0.6337 | 0.6732 | 0.5900 | 0.6610 |
| 模态丢弃   | 0.6190 | 0.5855 | 0.6314 | 0.6765 | 0.5782 | 0.6559 |
| 三态嵌入   | 0.6424 | 0.6078 | 0.6412 | 0.6726 | 0.5976 | 0.6676 |
| LMF    | 0.6259 | 0.5932 | 0.6729 | 0.6292 | 0.5669 | 0.7028 |
| MulT   | 0.6437 | 0.6155 | 0.6740 | 0.6509 | 0.5984 | 0.6907 |
| TSRF-D | 0.6437 | 0.6189 | 0.6221 | 0.6824 | 0.6066 | 0.6492 |

##### (2) 基础输入与局部缺失下的表现

表 13 给出十类模型在基础输入与局部缺失条件下的分类与回归指标。基础输入保留自然缺失、不追加人工遮挡，各模型看到的观测位置相同，判别证据基本完整。TSRF-D 的 Accuracy 为 0.6437，与 MulT 并列最高；强度 MAE 为 0.6221、Pearson 相关系数为 0.6824，两项都优于其余模型；Macro-F1 为 0.6189，与仅文本的 0.6192 相差 0.0003，配对区间跨零。分类差异在基础输入下本身有限，强度回归的区分相对清楚，连续量的预测同时依赖三路通道的完整程度。方法的差别更多体现在人工缺口出现之后。

局部缺失条件下，TSRF-D 的局部 F1 为 0.6066、局部 MAE 为 0.6492，两项在十类模型中均为最优，且相对九类基线的点估计方向一致：F1 全为正差、MAE 全为负差。把基础输入与局部缺失两个水平放在一起，可以看出起点相近的模型对缺口并不等价：MulT 的基础 F1 为 0.6155，缺口下退到 0.5984，与 TSRF-D 的差距由 0.0034 扩大到 0.0082；均值填充与三态嵌入的基础 F1 分别为 0.6073 与 0.6078，缺口下退到 0.5979 与 0.5976；LMF 的基础 F1 低于 TSRF-D 0.0257，局部条件下差距扩大到 0.0397。缺口造成的信息损失能否被补偿，是这一组比较要回答的问题。相对模态丢弃的局部 F1 改善 +0.0284 经多重比较校正后显著（校正  $p = 0.018$ ）；相对 LMF 的改善 +0.0397，区间 [+0.0152, +0.0633]（校正

$p = 0.056$ )。强度回归上的区分更清楚，相对均值填充、三态嵌入、LMF 与 MulT 的局部 MAE 改善分别为-0.0294、-0.0184、-0.0536 与-0.0414，校正后均达到 5% 显著性水平。分类方面，相对仅文本、均值填充、三态嵌入与 MulT 的局部 F1 差异区间跨零；仅文本在局部条件下仍保有 0.6028 的 F1，与文本通道承载主要判别证据的情形一致。强度是连续量，对观测丢失的反应比离散判决更直接，配对差异因此在回归指标上更为一致。

表 14 测试集上本文模型相对各基线的局部配对差异及 95% 区间

| 基线     | 指标     | 差值      | 95% 区间             | 校正 $p$ |
|--------|--------|---------|--------------------|--------|
| 模态丢弃   | 局部 F1  | +0.0284 | [+0.0143, +0.0421] | 0.018  |
| 模态丢弃   | 局部 MAE | -0.0067 | [-0.0194, +0.0061] | 1.000  |
| 缺失标记   | 局部 F1  | +0.0166 | [+0.0019, +0.0325] | 0.684  |
| 缺失标记   | 局部 MAE | -0.0118 | [-0.0222, -0.0017] | 0.480  |
| 拼接 MLP | 局部 F1  | +0.0214 | [+0.0029, +0.0406] | 0.513  |
| 拼接 MLP | 局部 MAE | -0.0144 | [-0.0291, +0.0001] | 0.856  |
| 零填充    | 局部 F1  | +0.0215 | [+0.0075, +0.0362] | 0.091  |
| 零填充    | 局部 MAE | -0.0161 | [-0.0270, -0.0054] | 0.100  |
| 三态嵌入   | 局部 F1  | +0.0090 | [-0.0031, +0.0209] | 1.000  |
| 三态嵌入   | 局部 MAE | -0.0184 | [-0.0275, -0.0090] | 0.018  |
| 仅文本    | 局部 F1  | +0.0038 | [-0.0166, +0.0232] | 1.000  |
| 仅文本    | 局部 MAE | -0.0208 | [-0.0412, -0.0014] | 0.697  |
| 均值填充   | 局部 F1  | +0.0086 | [-0.0038, +0.0213] | 1.000  |
| 均值填充   | 局部 MAE | -0.0294 | [-0.0413, -0.0177] | 0.018  |
| MulT   | 局部 F1  | +0.0082 | [-0.0080, +0.0254] | 1.000  |
| MulT   | 局部 MAE | -0.0414 | [-0.0598, -0.0235] | 0.018  |
| LMF    | 局部 F1  | +0.0397 | [+0.0152, +0.0633] | 0.056  |
| LMF    | 局部 MAE | -0.0536 | [-0.0783, -0.0276] | 0.018  |

为量化差异的不确定性，将测试集按来源视频分为 381 组，进行 2000 次配对 bootstrap；同一视频的不同片段、同一片段的不同缺失条件共用重采样权重，避免相关内容被重复计入。表中差值为本文模型减去基线，F1 正值和 MAE 负值分别表示改善；对九类基线的局部 F1 与局部 MAE 共 18 项比较采用 Holm 校正，逐项差值、区间与校正  $p$  值见表 14，行序按局部 MAE 差距由小到大排列。九类基线中，分类方向以仅文本与 MulT 最接近本文模型，回归方向以模态丢弃最接近，这三处的区间都跨过零线；LMF 在两项上的差距都是最大。区间反映固定模型下的评价样本不确定性。

### (3) 输入处理策略的比较

零填充与均值填充代表两种最简缺失处理，前者保留原始零值标准化，后者以训练均值替代，两者的局部 F1 分别为 0.5851 与 0.5979，局部 MAE 为 0.6653 与 0.6786。两种做法都以与位置无关的常量替代观测：零填充把缺口推向标准化空间的原点，均值填充使其回到训练集中心，缺口的位置、长度与周边可用证据都不会因此改变。可学习缺失标记把缺失状态交给模型自行编码，训练期模态丢弃直接移除整路模态，两者的局部 F1 分别为 0.5900 与 0.5782；缺失标记提供了缺口处不可信的开关，却不回答该处应当依据什么判断，模态丢弃学到的是在缺口处降低依赖的退让策略，同样不生成替代证据。三态嵌入在此基础上区分结构填充、自然缺失与人工缺口，局部 F1 升至 0.5976，是内部基线中最接近本文模型的配置；其作用仍停留在状态层面，无法补偿连续缺口丢失的证据。缺口上下文编码与门控补全正对应这一环节：模型由缺口两侧的可用观测生成补全查询，再按可靠度门控在补全结果与上下文回退表示之间取舍。

与公开基线的比较中，MulT 的局部 F1 与 TSRF-D 接近（差 +0.0082），局部 MAE 高 0.0414；LMF 在两项上均落后，局部 F1 低 0.0397、局部 MAE 高 0.0536。两种融合框架都建立在模态间逐位置对应的联合表示上，缺口使这段对应关系断开，LMF 的低秩分解与 MulT 的跨模态注意力都缺少可用的输入；TSRF-D 先在缺口处重建替代证据再作融合，缺口越重，差距越明显。强度回归上的差距比分类更清楚，与连续量对缺失观测的依赖更强有关。

经 Holm 校正后，相对模态丢弃的局部 F1 改善，以及相对均值填充、三态嵌入、LMF 与 MulT 的局部 MAE 改善，都得到统计支持；其余比较的区间跨零，差异落在评价样本的不确定性范围内。分类上的差异幅度整体小于回归：点估计最大的三项依次为模态丢弃的 +0.0284、零填充的 +0.0215 与拼接 MLP 的 +0.0214，校正后仅相对模态丢弃的改善达到显著；回归指标的改善覆盖范围更广。分类与回归考察的目标不同，结论按各自指标分别给出。

TSRF-D 的单种子局部 F1 标准差为 0.0038，与拼接 MLP（0.0035）和仅文本（0.0036）同处最低区间；零填充与模态丢弃的波动分别为 0.0181 与 0.0151，恰好也是局部 F1 最低的两种方案，均值与稳定性同时落后。种子集成降低了初始化差异带来的波动，但不同缺失处理方式之间的稳定性差别仍然保留，缺口处是否有可用的替代表示，同时关系到预测水平与训练的可复现程度。

#### （4） 缺失条件下的鲁棒性概括

把四组实验合起来看，模型在局部缺失下保持稳定输出。105 种连续局部缺失条件等权平均，Macro-F1 为 0.6066、MAE 为 0.6492，两项在十类模型中均为最优；经来源视频分组配对检验与 Holm 校正，相对模态丢弃的分类改善以及相对均值填充、三态嵌入、LMF 与 MulT 的强度改善成立。退化随缺失程度单调但幅度有限：目标区间比例由 5% 增至 40% 时，F1 累计下降 0.0240、MAE 上升 0.0340，Pearson 相关系数由 0.6659 降至 0.6233；缺口位置带来的平均差异为 0.0090，逐样本比较中 56.1% 的判断不变，变好与变差的比例接近，没有方向性偏置。缺口越重，相对通用融合框架的优势越大：三模态同段共缺下，与 LMF 的 F1 差距由 5% 的 0.0243 扩大到 40% 的 0.0738，MulT 全程差值不超过 0.013。稳定性同样体现在种子层面，单种子局部 F1 标准差 0.0038，低于零填充的 0.0181 与模态丢弃的 0.0151。退化的来源是缺口承载的语义量：语音与视觉单模态缺口的曲线在各比例上几乎水平，波动不足 0.001；三模态同段居中缺口在长度 4 以内仍保持 0.60 以上的 F1，长度达到 16 个锚点时 F1 降至 0.4632、MAE 升至 0.7981。在题目定义的局部缺失范围内，模型对缺失类型、位置与比例的变化保持稳定输出，性能损失集中在连续覆盖样本主体的文本长缺口上。

#### 4.2.7 附件 3 全量预测与结果展示

冻结模型后对附件 3 全部 30 条样本完成推理，预测分布为负向 7 条、中性 9 条、正向 14 条，平均最大预测概率为 0.5876，低于 0.5 的样本 11 条，各样本的分类概率、强度预测与种子间波动见图 15，逐条数值见表 15。附件 3 的缺失在同一时段跨模态重合：文本与语音各有 131 个内容位置缺失、视觉 135 个，30 条样本中有 29 条的三路缺失计数完全一致，与训练中多模态同段缺失的形态相符。附件 3 没有真实标签，分类概率只反映模型输出分布，不用于计算准确率。

图 15 左栏为 30 条样本的三类概率热图，行按样本编号排列、颜色越深表示该类别的概率越高；右栏给出强度预测与种子间标准差。缺失位置的数量与预测的集中程度相关：三路合计缺失不超过 4 个位置的 3 条样本，平均最大类别概率为 0.7883、强度预测的平均绝对值为 0.7047；缺失超过 8 个位置的 19 条样本，两项分别降至 0.5680 与 0.4796；低于

0.5 的 11 条低置信样本全部落在缺失位置不少于 6 条的范围内。可用观测减少时，类别分布更平坦，强度取值也更靠近零。

30 条样本中有 1 条的类别方向与强度符号不一致：3-22 判为负向而强度为 +0.0834。该强度离零很近，样本处于中性边界附近，软一致性约束下两个头在边界样本上仍保留各自的判断。其余 29 条的极性方向与强度符号一致，强度绝对值较大的样本（3-16 的 +1.5138、3-05 的 -1.3149、3-09 的 +1.1710）最大类别概率同样在 0.85 以上，两个输出头给出的判断相互印证。




图 15 附件 3 全量样本的分类概率与强度预测

表 15 逐条列出全部 30 条样本的可用锚点数、三路缺失位置计数、预测极性、连续强度与最大类别概率；锚点数与缺失计数共同刻画每条样本的可用证据规模，最大概率给出类别判断的集中程度。

表 15 附件 3 全部 30 条样本的预测

| 样本   | 锚点数 | 缺失 $t/a/v$ | 极性 | 强度      | 最大概率   |
|------|-----|------------|----|---------|--------|
| 3-01 | 6   | 0/0/0      | 负向 | -0.7926 | 0.6790 |
| 3-02 | 28  | 5/5/5      | 中性 | +0.0170 | 0.6927 |
| 3-03 | 32  | 5/5/9      | 中性 | +0.3507 | 0.5615 |
| 3-04 | 31  | 2/2/2      | 正向 | +0.5548 | 0.5655 |
| 3-05 | 12  | 0/0/0      | 负向 | -1.3149 | 0.8804 |
| 3-06 | 25  | 3/3/3      | 正向 | +0.9528 | 0.7760 |
| 3-07 | 21  | 3/3/3      | 中性 | +0.1607 | 0.4278 |
| 3-08 | 15  | 2/2/2      | 正向 | +0.5953 | 0.4915 |
| 3-09 | 14  | 2/2/2      | 正向 | +1.1710 | 0.8556 |
| 3-10 | 6   | 0/0/0      | 中性 | -0.0066 | 0.8054 |
| 3-11 | 14  | 4/4/4      | 正向 | +0.3761 | 0.4166 |
| 3-12 | 13  | 2/2/2      | 正向 | +0.7533 | 0.5491 |
| 3-13 | 19  | 2/2/2      | 中性 | +0.0642 | 0.4059 |
| 3-14 | 23  | 2/2/2      | 负向 | -0.4828 | 0.6079 |
| 3-15 | 27  | 3/3/3      | 正向 | +0.7277 | 0.6803 |
| 3-16 | 34  | 4/4/4      | 正向 | +1.5138 | 0.8705 |
| 3-17 | 22  | 8/8/8      | 负向 | -0.1494 | 0.4290 |

续表 15

| 样本   | 锚点数 | 缺失 $t/a/v$ | 极性 | 强度      | 最大概率   |
|------|-----|------------|----|---------|--------|
| 3-18 | 17  | 3/3/3      | 中性 | +0.3571 | 0.4949 |
| 3-19 | 24  | 7/7/7      | 负向 | -0.2043 | 0.4454 |
| 3-20 | 48  | 14/14/14   | 中性 | +0.0810 | 0.5071 |
| 3-21 | 9   | 3/3/3      | 正向 | +0.4352 | 0.4968 |
| 3-22 | 17  | 4/4/4      | 负向 | +0.0834 | 0.3645 |
| 3-23 | 13  | 4/4/4      | 中性 | +0.3641 | 0.5916 |
| 3-24 | 8   | 2/2/2      | 负向 | -0.1855 | 0.5218 |
| 3-25 | 9   | 2/2/2      | 中性 | +0.4876 | 0.4757 |
| 3-26 | 22  | 6/6/6      | 正向 | +0.7644 | 0.6848 |
| 3-27 | 21  | 8/8/8      | 正向 | +0.7554 | 0.6965 |
| 3-28 | 33  | 11/11/11   | 正向 | +0.5554 | 0.5326 |
| 3-29 | 18  | 8/8/8      | 正向 | +0.7940 | 0.6596 |
| 3-30 | 24  | 12/12/12   | 正向 | +0.4701 | 0.4629 |

### 4.3 问题三的模型建立与求解

#### 4.3.1 问题分析与建模思路

问题三针对三模态信息完整而决策依据难以追溯的场景，要求在输出情感极性与连续强度的同时，以可量化、可复核的方式给出判断依据：量化各模态在当前样本中的作用差异，明确主要参考模态，定位各模态中与判断密切相关的局部片段，并使关键证据能够对应至原始文本片段、语音时段或视觉关键帧。本问使用附件 2 提供的对齐版特征训练预测器，训练、验证与测试样本分别为 3395、728 与 727 条，并对附件 4 的全部 20 条无标签样本完成预测与解释。

与问题二处理证据不完整不同，本问的难点在于把“判断依据”转化为可计算的量。模态作用差异是整体量，局部证据是片段量，两者粒度不同，需要在不同层级分别定义；删除输入会改变模型看到的样本，若预测器只在完整输入上训练，删除后的输出变化将同时包含证据缺失与输入分布变化两种效应，难以单独归因。此外，显眼的片段与真正改变输出的片段并不一致，解释结果需要经过删除型检验才能确认其与模型决策的对应关系。证据还必须能够回到原始素材，这要求解释结果沿词级时间区间与视频时间戳逐级映射，而不是停留在特征下标。

据此，本文采用以同一预测器支撑预测与解释、以两级输入干预定义判断依据的建模方案，建立输入干预联盟 Shapley 解释模型（ICF-Shapley），按“情感预测、模态贡献分解、局部证据定位、原素材回映”四个步骤求解。预测器采用子集感知结构（SAP），以三态输入与逐模态双向时序编码输出极性与强度，训练时按模态联盟采样：以 0.70 的概率保留全部模态，其余概率均匀分配给 7 个非完整联盟，使模型在任意可用子集下都保持有效输出。模型关闭补全分支，被删除位置不再获得替代表示，干预后的输入状态完全由观测掩码决定，删除响应因此对应“证据不可用”本身。模态层对文本、语音和视觉的 8 个联盟精确枚举，以 Shapley 值分配预测变化并核验效率性，由贡献确定作用份额与主要参考模态；片段层将内容区划分为互不重叠的 2 锚点块，逐块删除并以固定参考类别的输出变化作为局部响应，符号区分支持与抑制。沿用前两问的内容掩码、观测掩码与词级时间区间记号，两级解释在同一冻结预测器上完成。总体结构如图 16 所示。

模型在 50 个对齐锚点上统一输出；解释评价从分解性质、忠实性与稳定性三个方面展开：Shapley 分解检验效率性，局部证据以高分块与随机块、低分块的累计删除曲线差（AOPC）与条件充分性度量，稳定性由多种子主模态一致率与替代基线对照检验。最后按

块内原词的 CTC 时间区间回映证据时段，提取对应音轨与最近 PTS 关键帧，完成附件 4 全量样本的预测、解释与回映核验。

#### 4.3.2 数据准备

##### (1) 输入组织与可用模态

采用附件 2 的对齐版特征，共 4850 条样本，按官方划分使用 3395 条训练样本、728 条验证样本与 727 条测试样本。三模态输入张量分别为  $X^t \in \mathbb{R}^{50 \times 768}$ 、 $X^a \in \mathbb{R}^{50 \times 74}$ 、 $X^v \in \mathbb{R}^{50 \times 35}$ ，标签包含三分类极性与连续情感强度，分类与回归在同一输入上联合求解。文本输入由附件 2 的词元编号经冻结的 bert-base-uncased 重算得到，训练与解释干预共用同一编码接口；语音与视觉特征按锚点整体给出，模型不再细分锚点内部的帧。

以  $P_{ik}$  表示内容掩码， $O_{ik}^m$  表示模态  $m$  的观测掩码；标准化统计量仅由训练集观测位置估计，附件 4 沿用同一组统计量。附件 4 包含 20 条无标签样本，共 564 个内容锚点，单条长度介于 11 与 48 之间，只参与前向预测与解释，不用于训练、选模与阈值确定。第 13 条视觉特征在 30 个内容位置均为零，因此将该特征分支标记为不可用。定义

$$L_i = \sum_k P_{ik}, \quad \mathcal{A}_i = \{m \in \mathcal{M} : \sum_k O_{ik}^m > 0\}, \quad \rho_i^m = \frac{\sum_k O_{ik}^m}{L_i}, \quad \mathcal{M} = \{t, a, v\}. \quad (42)$$

其中  $L_i$  为内容长度， $\mathcal{A}_i$  为可用模态集合， $\rho_i^m$  描述观测比例。不可用模态在所有联盟中保持缺失，输出贡献记为 NA；该标记描述特征文件的可用性，不能解释为贡献为零。

##### (2) 片段划分与时间回映

局部解释以内容区内的连续锚点块为单位：将内容区划分为不重叠的 2 锚点块  $E$ ，末块允许不足 2 个锚点。块长度取 2 个锚点，在保持证据定位粒度的同时避免单个位置带来的响应波动。解释时保持序列长度与位置不变，仅改变相应位置的输入与观测状态，删除不引起时间轴错位。文本块先替换为 [UNK]，再对整句重新编码，使被删词的信息不再通过上下文表示残留；语音和视觉块通过观测掩码删除，被删位置的状态转为缺失，其表示由缺失嵌入替代，原始观测值不再进入后续计算。

附件 4 原始转写与音轨经词级 CTC 强制对齐，得到原词区间  $A_{iu} = [a_{iu}, b_{iu}]$ ；词表构建与对齐直接调用问题一的模块，使解释证据与前问的时序基准一致。若块  $E$  对应原词集合  $\mathcal{U}_i(E) = \{g_i(k) : k \in E\}$ ，则证据时间范围为

$$I_i(E) = \left[ \min_{u \in \mathcal{U}_i(E)} a_{iu}, \max_{u \in \mathcal{U}_i(E)} b_{iu} \right]. \quad (43)$$

包含部分子词时按所属原词完整区间回映；逐位核验分词序列后，以块内已对齐实词区间的包络定位证据。标点保留在文本与锚点索引中，不单独赋予发音时间；若块内含有未对齐实词，则保留锚点并标记未映射。按真实视频 PTS 提取距区间中点最近的关键帧，同时导出对应音轨，使每条证据都能回看至原始素材。CTC 区间为自动估计，回映覆盖率度量证据的可追溯性。

#### 4.3.3 模型构建

##### (1) 总体结构与解释接口

图 16 给出问题三的预测器与解释层结构。模型先以三态观测输入完成情感预测，再在同一冻结预测器上分别进行模态联盟干预和局部片段干预；前者输出模态贡献与主要参考模态，后者输出关键证据位置，最后通过词级时间区间和视频 PTS 回映至原始素材。解释层不另行训练预测器，因而解释结果与预测结果来自同一模型输出。

预测器只保留三态投影、时序编码、模态池化与双任务头，不含补全、门控与蒸馏分支，被删除的信息在后续计算中保持缺失，不会被重建路径补回，删除响应因此对应输入

证据本身的变化。两级干预面向两种解释粒度：模态层回答当前判断主要依赖哪一路信息，片段层回答该路信息中的哪些词或时段起了作用；二者的干预对象与价值函数分别定义，整体贡献与局部证据不相互混入。




图 16 问题三 ICF-Shapley 预测器与解释层结构

## (2) 三态投影与时序编码

令  $s_{ik}^m \in \{0, 1, 2\}$  分别表示结构填充、已观测和内容缺失。三种状态各有一套嵌入，使模型能够区分“该位置不存在”与“该位置存在但观测不可用”。最终采用单层预测器，其输入表示为

$$z_{ik}^m = \text{Lin}_m(X_{ik}^m) + e_m^{\text{mod}} + e_k^{\text{pos}} + e_{s_{ik}^m}^{\text{state}}, \quad \tilde{z}_{ik}^m = O_{ik}^m z_{ik}^m + P_{ik}(1 - O_{ik}^m)e_m^{\text{miss}}. \quad (44)$$

缺失位置由模态相关的缺失嵌入  $e_m^{\text{miss}}$  替代：序列长度与位置索引保持不变，删除只在输入取值层面生效，不改变时间轴。按内容长度打包序列，分别输入逐模态双向 GRU，避免结构填充参与递归。设隐藏维度为  $d$ ，对各模态内容位的编码结果  $h_{ik}^m$  分别取均值与最大值，再拼接观测比例：

$$u_i = \text{Concat}_{m \in \mathcal{M}} \left( \frac{1}{L_i} \sum_k h_{ik}^m, \max_k h_{ik}^m \right) \parallel [\rho_i^t, \rho_i^a, \rho_i^v], \quad h_i = \text{MLP}(u_i). \quad (45)$$

均值概括模态内部的总体倾向，最大值捕捉局部显著响应，观测比例  $\rho_i^m$  给出该模态证据的可用程度，三者共同形成样本级表示。融合向量维度为  $6d + 3$ ，分类与回归头分别输出

$$p_i = \text{softmax}(W_c h_i + b_c), \quad \hat{r}_i = 3 \tanh(W_r h_i + b_r). \quad (46)$$

强度输出经  $3 \tanh$  限幅至  $[-3, 3]$ ，与标签取值范围一致。

## (3) 子集训练与目标函数

解释层需要对任意模态联盟求值：Shapley 贡献要在全部 8 个子集上计算输出，片段删除也要求模型在部分观测缺失时仍然有效。若只在完整输入上训练，联盟输入会成为分布外样本，输出变化将混入分布外效应。为此按原训练分布设置对照配置 C0：以 0.70 的

概率保留全部模态，其余 0.30 均匀分配给 7 个非完整联盟，包含空集；完整输入保持为主要训练分布，非完整组合同时进入训练。对采样联盟  $S_i$ ，令  $\tilde{O}_{ik}^m = O_{ik}^m \mathbf{1}\{m \in S_i\}$ 。训练目标为

$$\mathcal{L}_3 = \text{CE}_w(y_i, p_i) + \text{Huber}_1(r_i, \hat{r}_i) + 0.2 [(p_{i,+} - p_{i,-}) - \tanh(\hat{r}_i/3)]^2. \quad (47)$$

类别权重由训练集频数确定，缓解三类样本不均衡；Huber 损失拟合连续强度，对大偏差样本保持稳健；最后一项约束正向与负向概率之差同强度符号的方向一致性，使两个输出头在同一表示上协同。该方案覆盖模态联盟输入；连续片段遮挡增广及更深网络作为候选变体单独比较。

#### (4) 模态贡献与主要参考模态

以三种子平均概率  $\bar{p}_i$  确定原始可用输入的参考类别  $c_i^* = \arg \max_c \bar{p}_{ic}(\mathcal{A}_i)$ ，解释全过程固定该类别，使所有干预以同一决策为比较对象，避免类别切换混入贡献。对联盟  $S \subseteq \mathcal{M}$ ，定义

$$F_i^{\text{cls}}(S) = \log \frac{\bar{p}_{i,c_i^*}(S)}{1 - \bar{p}_{i,c_i^*}(S)}, \quad F_i^{\text{reg}}(S) = \bar{r}_i(S). \quad (48)$$

概率经 log-odds 变换到无界尺度，价值差可以直接相减；数值计算时将概率截断至  $[10^{-6}, 1 - 10^{-6}]$  以保证稳定。对分类与强度分别计算 Shapley 贡献：

$$\phi_i^m = \sum_{S \subseteq \mathcal{M} \setminus \{m\}} \frac{|S|!(2 - |S|)!}{3!} [F_i(S \cup \{m\}) - F_i(S)], \quad \sum_{m \in \mathcal{A}_i} \phi_i^m = F_i(\mathcal{A}_i) - F_i(\emptyset). \quad (49)$$

三个模态只构成 8 个联盟，可以精确枚举，不需要蒙特卡洛近似；效率性等式同时作为实现的数值核验。贡献为正表示相对基线抬高价值，为负表示压低价值。以分类贡献绝对值最大的可用模态为主要参考模态，作用份额定义为

$$m_i^* = \arg \max_{m \in \mathcal{A}_i} |\phi_i^{m,\text{cls}}|, \quad \omega_i^m = \frac{|\phi_i^{m,\text{cls}}|}{\sum_{j \in \mathcal{A}_i} |\phi_i^{j,\text{cls}}|}. \quad (50)$$

有符号贡献描述作用方向，作用份额描述作用大小，两者分别报告。当总贡献幅度小于  $10^{-8}$  时标记为无法区分。

#### (5) 局部证据与解释评价

记  $F_i^{\text{cls,del}(m,E)}$  为仅删除模态  $m$  中块  $E$  后的固定类别价值，定义

$$\Delta_i^m(E) = F_i^{\text{cls}}(\mathcal{A}_i) - F_i^{\text{cls,del}(m,E)}. \quad (51)$$

$\Delta_i^m(E) > 0$  表示该片段支持参考类别，小于零表示抑制参考类别。另定义强度响应  $\Delta_i^{m,\text{reg}}(E) = \hat{r}_i - \hat{r}_i^{\text{del}(m,E)}$ ，正、负值分别表示该片段抬高、降低预测强度。两个任务分别以贡献绝对值确定主要模态，并在各可用模态中选择绝对局部响应最大的片段作为关键证据，保留符号方向。分类删除检验仍按有符号响应降序，强度删除检验按绝对强度响应排序。

解释评价检验的是证据排序与模型响应是否一致。在主要参考模态中，按块数的 10%、20%、30% 向上取整，分别累计删除高分块、低分块和随机块；随机顺序重复 3 次，并报告实际锚点覆盖率。以三个删除档位的平均概率下降定义 AOPC，按样本配对比较高分与随机删除，采用 2000 次 bootstrap 估计区间：若高分块确实承载判断依据，删除它们造成的参考类别概率下降应大于随机删除。条件充分性保留其他模态及主要模态的高分块，计算相对原预测的绝对概率偏差，考察高分块在多大程度上替代完整输入。另以训练集同位置均值 (B2) 和模态内顺序打乱 (B3) 替代缺失状态基线 (B1)，比较主模态一致率及贡献排序，检验解释结论对基线取法的敏感性。

#### 4.3.4 模型求解与参数设置

##### (1) 求解流程

求解分为训练、选模与解释三个阶段。训练阶段在附件 2 训练集上按联盟采样学习三种子预测器，标准化统计量由训练集观测位置估计，训练轮次由验证集联合指标早停确定；选模阶段在验证子集上按联合指标与三项门槛比较候选配置，确定最终结构并冻结参数；解释阶段在同一冻结模型上依次完成模态联盟枚举、逐块删除与证据回映，最后对附件 4 的 20 条样本输出预测与解释。解释阶段不更新任何参数，不同干预之间的输出差异只来自输入本身的变化。

##### (2) 候选比较与模型选择

以对照配置 C0 为基准，设置三个递进变体：V1 调整联盟采样并加入连续块遮挡；V2 进一步采用两层 BiGRU、逐模态 LayerNorm 和回归支路；V3 增加联盟单调一致性正则。V1 与 V2 各包含多项联合改动，因此比较反映方案组合的影响；V3 约束增补模态后的参考类别响应，其单调性不等价于贡献可加性。

选模指标为  $J = \text{Macro-F1} - 0.1\text{MAE}$ ，同时考察分类与回归：Macro-F1 按逐类等权计算，强度误差以 0.1 的系数扣除，避免选模偏向单一任务。候选须同时满足三项门槛： $J$  不低于 C0 减 0.002；去文本、去语音、去视觉及全缺失四种状态的平均 Macro-F1 不低于 C0 减 0.002；解释 AOPC 差不低于 C0 减 0.005。前两项约束联盟输入下的预测能力，联盟枚举与片段删除都要求模型在子集输入上保持有效；第三项约束解释忠实性，避免预测指标改善而证据排序退化。通过者按缺失状态平均 Macro-F1 排序，并列时比较  $J$ 。训练早停与变体选择使用验证集，最终在附件 2 测试集评价预测性能，对附件 4 输出预测与解释。

##### (3) 训练与解释参数

最终预测器的网络规模、训练配置及解释采样参数汇总于表 16。全集与非完整联盟联合采样，使同一预测器同时学习常规预测和模态删除后的输入状态；训练中三个种子相互独立，各自按验证集  $J$  保存最优轮次，预测概率与强度输出取均值形成集成。解释阶段冻结全部参数，随机删除顺序与 bootstrap 重采样均固定种子，使不同干预之间保持可比。解释采样与统计口径在验证子集上确定，测试集与附件 4 只参与冻结后的前向计算。

表 16 最终 SAP 预测器与解释参数

| 类别   | 项目                              | 设置                                                                                                                                          |
|------|---------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------|
| 模型结构 | 投影与融合<br>时序编码<br>输出             | 公共维度 $d = 64$ ; 融合 MLP; Dropout 0.2<br>逐模态单层 BiGRU, 单方向隐维 32<br>分类 softmax; 强度 3 tanh, 两任务共享融合表示                                            |
| 训练设置 | 目标函数<br>优化器与调度<br>批量与轮次<br>随机种子 | 逆频率类别权重; Huber 阈值 1; 方向一致性系数 0.2<br>AdamW; 学习率 0.0015; 权重衰减 $10^{-4}$ ; 余弦调度<br>批量 256; 至多 32 轮; 早停耐心 8; 梯度范数上限 5<br>独立训练 0、1、2, 三种子输出取均值集成 |
| 联盟采样 | 训练分布                            | 全集 0.70; 其余 7 个联盟各 0.30/7; 无块遮挡增广                                                                                                           |
| 解释设置 | 模态层<br>片段层<br>统计口径<br>对照基线      | 8 个联盟精确枚举, 逐样本核验效率性<br>2 锚点块逐块删除; 随机顺序重复 3 次<br>删除档位 10%、20%、30%; bootstrap 2000 次<br>B1 缺失状态; B2 训练集同位置均值; B3 模态内打乱                        |
| 评价数据 | 验证子集<br>确认子集<br>计算环境            | 固定种子 20260925 抽取 96 条, 用于解释诊断与选模<br>固定种子 20261001 抽取 96 条测试样本; 区间接原视频聚类<br>Python 3.12; PyTorch 2.8.0+cu128; RTX 5060 Ti                    |

算法 2 给出从训练到证据回映的完整流程: 先在训练集上完成子集感知预测器的学习与选模, 再固定参考类别完成模态层分解, 随后逐块删除得到局部响应, 最后把证据映射回原始素材。

#### 算法 2 ICF-Shapley 预测与证据定位

**输入:** 附件 2 训练、验证与测试集, 附件 4 样本, 三模态特征与掩码, 标准化参数, 种子集合  $\{0, 1, 2\}$ 。  
**输出:** 情感极性与强度、模态贡献  $\phi_i^m$ 、作用份额  $\omega_i^m$ 、主要参考模态  $m_i^*$  及局部证据。

- 1 仅用训练集观测位置拟合标准化统计量, 构建内容掩码  $P$  与观测掩码  $O$ 。
- 2 **对每个种子**  $s \in \{0, 1, 2\}$ , **执行:** 按 C0 联盟采样训练预测器 (全集 0.70, 其余 7 个联盟各 0.30/7), 按验证集  $J$  保存最优轮次。
- 3 在验证子集上按  $J$  与三项门槛比较候选配置, 确定最终结构并冻结参数。
- 4 **对每个样本**  $i$ , 计算可用集合  $\mathcal{A}_i$  与三种子集成预测, 固定参考类别  $c_i^*$ 。
- 5 枚举 8 个模态联盟 (不可用模态保持缺失), 计算分类 log-odds  $F_i^{\text{cls}}(S)$  与预测强度  $F_i^{\text{reg}}(S)$ 。
- 6 求解两类 Shapley 值, 核验效率性残差, 输出  $\phi_i^m$ 、 $\omega_i^m$  与主要参考模态  $m_i^*$ 。
- 7 遍历各可用模态的 2 锚点块, 逐块删除并计算分类响应  $\Delta_i^m(E)$  与强度响应  $\Delta_i^{m, \text{reg}}(E)$ 。
- 8 依绝对响应选择各模态分类与强度的关键证据, 保留作用方向。
- 9 在主要参考模态按 10%、20%、30% 累计删除高分块、低分块与随机块, 按样本配对计算 AOPC 与条件充分性。
- 10 由原词 CTC 区间与视频 PTS 定位证据时段与关键帧, 导出对应音轨与解释卡。
- 11 保存预测、贡献与逐块响应; 在验证子集比较 B1/B2/B3 基线, 冻结后在确认子集核验双任务删除响应与稳定性。

#### 4.3.5 实验结果与分析

##### (1) 预测性能与候选比较

按三项门槛选择的预测器为 C0 对照 (原训练分布)。三个种子分别在第 4、5、3 轮取得最优验证指标, 训练轮次完全由验证集  $J$  决定, 测试集与附件 4 只参与前向计算。验证集单种子 Macro-F1 为 0.6068、0.5941、0.6082。表 17 汇总三种子集成的基础性能: 验证集 Macro-F1 为 0.6170, 测试集为 0.6054; 测试集 MAE 为 0.6303, 高于验证集的 0.5954, 反映

强度预测在测试样本上的误差有所增加。强度 RMSE 为 0.8053 与 0.8627，CCC 为 0.6067 与 0.6432，两个划分在分类与回归上的表现接近。

表 17 SAP 三种子集成的预测性能

| 数据集 | 样本数 | Accuracy | Macro-F1 | MAE    | RMSE   | Pearson | CCC    |
|-----|-----|----------|----------|--------|--------|---------|--------|
| 验证集 | 728 | 0.6264   | 0.6170   | 0.5954 | 0.8053 | 0.6420  | 0.6067 |
| 测试集 | 727 | 0.6286   | 0.6054   | 0.6303 | 0.8627 | 0.6730  | 0.6432 |

验证集负向、中性、正向 F1 依次为 0.6430、0.5114 与 0.6966，类别间的差异集中在中间类别，中性边界的刻画是提升分类表现的关键环节。图 17 给出类别间的混淆结构与各类别指标。




图 17 验证集混淆矩阵与分类指标

表 18 进一步比较子集训练、网络容量及一致性约束的影响。评价同时考虑预测指标、局部解释响应与种子间主模态一致性，以观察不同方案的收益与代价。

表 18 候选方案与实现对照的验证结果

| 方案              | 预测指标          |               |               |               | 解释指标          |              |
|-----------------|---------------|---------------|---------------|---------------|---------------|--------------|
|                 | $J$           | Macro-F1      | MAE           | 缺失平均 F1       | AOPC 差        | 种子一致率        |
| 仅完整输入（单种子）      | 0.5470        | 0.6073        | 0.6030        | —             | —             | —            |
| 无内容区打包对照        | 0.5468        | 0.6073        | 0.6048        | —             | —             | —            |
| <b>C0: 子集训练</b> | <b>0.5575</b> | <b>0.6170</b> | <b>0.5954</b> | <b>0.4622</b> | <b>0.1068</b> | <b>84.0%</b> |
| V1: 采样与遮挡       | 0.5525        | 0.6112        | 0.5869        | 0.4368        | 0.1300        | 77.8%        |
| V2: 增加容量        | 0.5527        | 0.6128        | 0.6010        | 0.4835        | 0.1119        | 79.2%        |
| V3: 单调正则        | 0.5591        | 0.6192        | 0.6011        | 0.4421        | 0.1241        | 75.7%        |

由表 18 可见，V3 的  $J$  为 0.5591、略高于 C0 的 0.5575，但其缺失平均 F1 为 0.4421，低于 C0 的 0.4622 并超出 0.002 容差，种子一致率也由 84.0% 降至 75.7%，预测与解释指标并未同步改善。V2 的缺失平均 F1 为 0.4835、在四个方案中最高，但  $J$  为 0.5527，低于容差下界  $0.5575 - 0.002$ ，未通过预测指标门槛；V1 的两项预测指标同时低于门槛。三者的解释 AOPC 差均达到门槛。据此选择 C0 作为最终 SAP 预测器，后续贡献分解和附件 4 推理均使用该模型。表中加粗行为最终选用配置，缺失平均 F1 为去文本、去语音、去视觉

与全缺失四种状态下 Macro-F1 的平均值；仅完整输入对照采用单种子，其余方案采用三种子集成，种子一致率指主要参考模态的两两一致率平均值。内容区打包与全序列编码的各单种子  $J$  平均值分别为 0.542 和 0.539。整模态删除给出模态重要性的独立证据：C0 去文本后的 Macro-F1 为 0.4150，而去语音、去视觉后分别为 0.6092 与 0.5974，相对完整输入的 0.6170，文本删除造成的下降最大，与联盟分解中文本主导的结论一致。仅用完整输入训练的单种子模型去文本后降至 0.2904；两者集成规模不同，该差值同时包含训练方案与集成的影响。全缺失条件仅用于输入状态诊断，其预测仍可利用保留的内容长度。

## (2) 时序汇聚改进实验

为增强不同位置的区分能力，在同一 C0 训练方案下，将均值汇聚替换为可学习的时序加权汇聚，保留最大池化，评分层零初始化。三个种子集成后，验证集 Macro-F1 为 0.6112，MAE 为 0.5846， $J$  为 0.5527；相对 C0，MAE 降低 0.0107，但 Macro-F1 下降 0.0059。实验前规定  $J$  至少增加 0.002、F1 下降不超过 0.002、MAE 增加不超过 0.005，且至少两个种子的  $J$  改善；预测条件满足后再比较开发子集解释指标。候选未通过前两项条件，故最终预测器保持 C0，时序权重不用于替代干预解释。

## (3) 模态作用差异

空集价值为-0.687，全模态价值为 0.542，单模态联盟中文本为 0.382、语音为-0.651、视觉为-0.637；三模态平均 Shapley 贡献为文本 +1.105、语音 +0.068、视觉 +0.056，96 条子集中分类主参考模态为文本 86 条、语音 3 条、视觉 7 条。图 18 显示，文本的平均 Shapley 贡献为 +1.105，构成预测的主导信息来源；语音与视觉分别贡献 +0.068 与 +0.056，在三模态协同中提供补充信息，主参考模态分布与贡献排序一致。样本层的正负贡献与主参考模态另行保留，以刻画个体差异。效率性残差不超过  $8.9 \times 10^{-16}$ ，满足 Shapley 效率性公理。




图 18 模态联盟的平均分类价值与三模态平均 Shapley 贡献

## (4) 局部证据与解释检验

位置级证据由输入干预直接度量：96 条验证样本共完成 3397 个局部块干预，文本、语音与视觉分别占 1136、1136 与 1125 个，平均绝对 log-odds 响应分别为 0.377、0.015 与 0.025，与模态级贡献的结论一致，均以文本为主。方向构成上，文本块支持参考类别的比例为 64.6%、抑制为 35.4%，语音为 59.2% 与 40.8%，视觉为 46.3% 与 52.4%；按句首、句中、句尾分段，文本的平均响应依次为 0.243、0.233 与 0.246，三段量级接近，局部证据没有集中在序列的固定位置。典型样本的逐块分布见图 21。本段统计对应开发阶段的验证子集，冻结测试子集的双任务结果在下文单独分析。按块数 10%、20%、30% 三个目标档位累计删除时，高分块引起的参考类别概率下降分别为 0.187、0.226 和 0.241，随机块为

0.075、0.111 和 0.148，低分块为  $-0.014$ 、0.006 和 0.038。高分块相对随机块的 AOPC 配对差为 0.1068，95% 区间为  $[0.0887, 0.1259]$ ；实际锚点覆盖率为 14.41%、24.03% 和 35.49%。这些结果表明，按局部响应排序能够筛选出对当前分类判断影响较大的片段。96 条样本同时用于候选比较，区间描述该验证子集上的配对差异。

在最高删除档位，条件充分性的绝对概率偏差为 0.1608，说明主要模态中剩余片段仍影响预测。沿用**分类证据排序**观察回归响应，删除高分块时强度的绝对变化分别为 0.399、0.468 和 0.499，删除低分块时为 0.142、0.192 和 0.227，表明分类关键片段也会影响连续强度输出。分类与回归的模态贡献分别计算，附件 4 有 5 条样本的两个任务主模态不同。

在主模态为文本的 86 条样本中，按自定义词表判定，最高分证据块完全由功能词或标点构成的比例为 17.4%，全部文本块中的相应比例为 30.5%。这一描述性比较表明，最高分块较少由纯功能词或标点构成。

### (5) 冻结模型后的双任务确认

选模完成后，以固定随机种子 20261001 从附件 2 测试集抽取 96 条样本，覆盖 85 个原视频。模型与解释规则保持冻结；按原视频聚类进行 2000 次配对 bootstrap，保留同源片段之间的相关性。该子集未参与本次候选选择，但历史测试集已有评估记录。

如图 19 左、中两幅所示，分类与强度任务的高分块曲线在三个删除档位均高于随机块曲线，说明各自的排序均能定位影响输出的片段。分类高分块相对随机块的平均概率降幅为 0.1318，95% 区间为  $[0.1091, 0.1550]$ 。强度任务单独确定主模态与片段排序，其绝对预测变化差为 0.2132，95% 区间为  $[0.1636, 0.2713]$ 。分类三个目标删除档位的实际锚点覆盖率为 15.65%、24.96% 和 35.85%；两类曲线分别衡量参考类别概率与连续强度的响应，不等同于相对真实标签的误差变化。强度条件充分性偏差分别为 0.5879、0.5428 和 0.4595，说明少量关键片段尚不能完整复现原预测。

图 19 右图同时比较总体一致率与 Cohen  $\kappa$ 。在该确认子集上，B1 与 B2 的主模态一致率为 90.63%， $\kappa = 0.4364$ ；B1 与 B3 的一致率为 92.71%， $\kappa = -0.0136$ 。因此，局部片段删除具有稳定的平均响应优势，而主模态归因仍依赖解释基线，尤其是少数非文本主导样本。




图 19 冻结测试子集上的分类与强度删除验证及解释基线敏感性

### (6) 解释稳定性

表 19 同时报告主模态一致率与 Cohen  $\kappa$ ，以区分总体一致程度和主模态分布偏斜的影响。验证子集中 B1 与 B2 的一致率为 90.62%， $\kappa = 0.5686$ ；B1 与 B3 的一致率为 87.50%，但  $\kappa = -0.0231$ 。B1 下 10 条非文本主导样本在 B3 下均转为文本，说明总体上的文本主导结论较一致，少数非文本归因则对基线选择更敏感。两种基线下的绝对贡献排序 Spearman 相关分别为 0.812 和 0.625。

表 19 主参考模态与贡献排序在不同种子和解释基线下的一致性

| 样本范围         | 比较对象     | 一致率 (%) | Cohen $\kappa$ | 贡献排序相关 |
|--------------|----------|---------|----------------|--------|
| 验证子集 96 条    | 种子 0 与 1 | 82.29   | 0.2402         | —      |
| 验证子集 96 条    | 种子 0 与 2 | 83.33   | 0.1768         | —      |
| 验证子集 96 条    | 种子 1 与 2 | 86.46   | 0.2244         | —      |
| 验证子集 96 条    | B1 与 B2  | 90.62   | 0.5686         | 0.812  |
| 验证子集 96 条    | B1 与 B3  | 87.50   | -0.0231        | 0.625  |
| 附件 4 全部 20 条 | B1 与 B2  | 75.00   | -0.0753        | 0.725  |

三个训练种子的两两一致率介于 82.29% 与 86.46%，对应  $\kappa$  为 0.1768–0.2402。附件 4 在 B1 与 B2 下有 5 条样本改变主模态，贡献排序相关为 0.725，其解释应结合具体基线与局部片段共同阅读。表中贡献排序相关为绝对贡献排序的 Spearman 相关系数，种子之间只统计主模态一致率。

### (7) 错误分布与归因分析

验证集共 272 条误判，其中 214 条涉及中性，占 78.7%。按真实分组看：中性组错误率 39.1%（184 条），非中性且 | 强度 | < 0.5 的弱情感组错误率 60.5%（147 条），| 强度 | ≥ 0.5 的强情感组错误率 28.0%（397 条）。错误随情感强度降低而集中，说明零点附近的类别判别比强情感的方向判断更困难。

在 96 条解释样本中，低强度组与高强度组的解释不稳定率分别为 31.7% 和 23.6%，覆盖正确与错误预测两类样本，给出解释稳定性在不同强度水平上的分布。三种子最大类概率标准差的整体均值为 0.0487，低强度组与高强度组分别为 0.0467 与 0.0503，两组差异不显著（Welch  $p = 0.1271$ ），预测不确定性未随强度幅值系统变化。错误分析将改进重点指向中性边界与弱情感区间的表征增强。

### (8) 附件 4 全量结果

附件 4 全部 20 条样本的预测分布为中性 7 条、负向 7 条、正向 6 条，分类主参考模态为文本 19 条、视觉 1 条。图 20 从强度分布、分类模态份额和种子间波动三个角度展示全量结果。中图多数样本的文本份额较高，与文本主导的总体归因一致；第 8 条以视觉为主，体现个体差异。20 条样本的强度三种子标准差均值为 0.105，最大为 0.410（附件 4\_10）。第 13 条的视觉分支不可用，其视觉份额标记为 NA，其余两个模态照常给出贡献；4-04 与 4-19 的预测极性与强度方向不一致，属于独立双头结构下的输出分歧，两个任务分别保留各自的预测与贡献分解。跨模态核查中，17 条样本的全部可用模态最高分证据均指向预测类别；4-06、4-14 与 4-16 各有一个模态的最高分证据方向相反，反向项均为视觉分支的最高分块，响应幅度在 -0.069 至 -0.012 之间，而三条样本的文本主证据幅度分别为 0.404、0.467 和 2.661，视觉分歧项不足其两成，判别主体仍落在文本证据上。按与验证集相同的 10%、20%、30% 三档删除协议，20 条样本上高分块相对随机块的平均概率下降差为 0.1316，95% 区间为 [0.0857, 0.1858]，逐块响应在无标签样本上同样稳定区分证据块与随机块。




图 20 附件 4 全部 20 条样本的情感预测、模态作用份额与种子间波动

表 20 列出逐条预测及作用份额，便于与图 20 核对。其中 NA 表示输入特征不可用，不能解释为该模态贡献为零；分类极性与连续强度分别来自两个输出头。

表 20 附件 4 全量预测与分类模态作用份额

| 编号   | 极性 | 强度     | 文本份额  | 语音份额  | 视觉份额  | 主模态 |
|------|----|--------|-------|-------|-------|-----|
| 4-01 | 中性 | +0.362 | 0.678 | 0.124 | 0.198 | 文本  |
| 4-02 | 中性 | +0.034 | 0.518 | 0.254 | 0.229 | 文本  |
| 4-03 | 中性 | -0.185 | 0.441 | 0.119 | 0.440 | 文本  |
| 4-04 | 负向 | +0.089 | 0.705 | 0.178 | 0.116 | 文本  |
| 4-05 | 正向 | +0.711 | 0.484 | 0.085 | 0.432 | 文本  |
| 4-06 | 正向 | +0.660 | 0.699 | 0.014 | 0.287 | 文本  |
| 4-07 | 正向 | +0.801 | 0.833 | 0.029 | 0.138 | 文本  |
| 4-08 | 中性 | +0.501 | 0.106 | 0.384 | 0.510 | 视觉  |
| 4-09 | 负向 | -1.989 | 0.955 | 0.018 | 0.027 | 文本  |
| 4-10 | 负向 | -1.027 | 0.903 | 0.060 | 0.037 | 文本  |
| 4-11 | 负向 | -1.112 | 0.820 | 0.020 | 0.160 | 文本  |
| 4-12 | 负向 | -0.804 | 0.897 | 0.036 | 0.067 | 文本  |
| 4-13 | 中性 | +0.238 | 0.844 | 0.156 | NA    | 文本  |
| 4-14 | 中性 | +0.409 | 0.654 | 0.031 | 0.315 | 文本  |
| 4-15 | 正向 | +1.116 | 0.703 | 0.192 | 0.105 | 文本  |
| 4-16 | 负向 | -2.137 | 0.946 | 0.031 | 0.022 | 文本  |
| 4-17 | 正向 | +1.528 | 0.930 | 0.029 | 0.040 | 文本  |
| 4-18 | 中性 | -0.055 | 0.679 | 0.021 | 0.300 | 文本  |
| 4-19 | 负向 | +0.188 | 0.809 | 0.049 | 0.141 | 文本  |
| 4-20 | 正向 | +1.040 | 0.816 | 0.040 | 0.144 | 文本  |

### (9) 典型样本与证据回映

解释卡把预测结论、模态份额、证据词时间与原始素材组织在同一视图中，用于检验模型响应与可观察线索的对应关系。附件 4 第 12 条的预测为负向（最大类概率 0.76，强度 -0.804），主要参考模态为文本（份额 0.897）：原文前段为 *previously had good credit*，转折词 *but* (3.88 s) 之后转入信用下滑的负面叙述，最高分证据片段为 *sag*, (9.94–10.30 s)，同时是语音的最高分证据块，两个模态的证据落在同一词上。沿用问题一的韵律度量，*but* 处音高相对前段抬高 2.3 半音、能量抬升 0.88，证据词处音高抬高 2.3 半音、能量抬升 0.52，构成样本内两处局部韵律突起点；卡片中的全段韵律轨迹给出能量与音高随时间的走向。图 21 中黄底标记主要模态的最高分证据词，蓝底标记其他模态的最高分证据词，卡片同时给出全段韵律轨迹、语音证据片段与逐块响应。




图 21 附件 4 第 12 条 (转折样本) 解释卡

20 条样本的重新分词序列均与官方词元一致，482 个原词中 478 个获得 CTC 时间区间；该回映与问题一共用同一套对齐实现，词表构建与 CTC 强制对齐直接调用问题一的模块，问题一建立的词元—锚点—时间对应关系由此成为后两问共享的时序基础。新增双任务证据共 120 条，其中 118 条可用记录均完成时间回映并导出音频与关键帧；其余 2 条为第 13 条样本的视觉特征不可用，在分类与强度任务中分别标记 NA。每条记录保存原素材哈希、词元锚点、作用方向、时间区间及真实帧 PTS，构成从模型响应到原素材的可追溯链条。

本模型把情感预测分解为可复核的模态贡献与局部响应，并通过词级时间区间连接到原始素材：Shapley 值度量指定模型与基线下的作用差异，删除实验检验局部证据与预测响应的一致性。两项分析在同一预测器上完成，因此解释结论可直接对应该模型的决策过程。

## 5 模型评价与改进

本文三个模型共享同一套词级时间锚点与掩码定义：问题一完成原始素材到标准化时序特征的转换，问题二在局部缺失条件下给出情感预测，问题三在同一预测器上定位模态与片段两个层级的证据。以下结合已完成的求解结果，从结构优势、适用范围与改进路径三个方面作出评价。

## 5.1 模型的优点

**时间表示统一，缺失状态可分辨。**文本子词、声学帧与视频帧通过同一组原词区间  $A_{iu}$  对齐，交叠时长  $\ell_{ij}^m(A)$  把三路不同的采样粒度统一为归一化池化权重  $\omega_{ij}^m(A)$ ，内容掩码  $P_{ik}$  与观测掩码  $O_{ik}^m$  分别记录接口位置与观测状态，缺失位置始终以缺失状态参与建模。附件 1 的 100 条样本全部形成输出，1932 个原词中 1920 个生成时间区间，生成率 99.38%，已生成区间在起点非负、长度为正、终点落在音轨有效时长之内与起点随词序单调四项约束上均无违例，词界落在声学停顿附近的比例约为随机位置的两倍；未生成的 12 个原词均为数字与标点等难以稳定对齐的符号，其失败记录被保留而非赋予人为时间。逐词记录经 PTS 回映到原视频，为问题二的掩码定义与问题三的证据定位提供同一套时间接口。

**缺失处理与任务学习一体化。**三态变量  $s_{ik}^m$  区分结构位、可观测位与缺失位，补全表示由样本内有效候选按代价加权得到，经可靠度门控  $\rho_{ik}^m$  与自身上下文融合，候选不足时回退到上下文表示而不伪造观测；教师-学生蒸馏把教师的分类分布与强度输出作为软监督，与真实标签、重建和可靠度损失联合优化。附件 3 全部 30 条样本完成预测，105 种连续局部缺失条件下平均 Macro-F1 为 0.6066、MAE 为 0.6492，在十类模型中均为最优；目标区间比例由 5% 增至 40% 时 F1 累计下降 0.0240、MAE 上升 0.0340，句首与句中缺口的平均 F1 相差 0.0090，退化随缺失程度加深但幅度有限，分类与强度两个任务在缺失条件下的排序保持一致。

**预测与解释共用同一模型。**模态 Shapley 值  $\phi_i^m$  与局部删除响应  $\Delta_i^m(E)$  都在同一预测器上计算，模态贡献之和等于联盟价值，效率性残差不超过  $8.9 \times 10^{-16}$ ；局部证据以 2 锚点块删除给出有符号响应，分类与强度分别确定主要模态与关键片段。两部分把“哪一模态起作用”与“哪一片段起作用”分开回答，再借助词级区间回映到原始文本、语音时段与视频帧。96 条验证子集上高分片段删除相对随机删除的 AOPC 差为 0.1068，95% 区间 [0.0887, 0.1259] 不含零；冻结测试子集上分类与强度的删除优势分别为 0.1318 和 0.2132。附件 4 的 20 条样本输出中性 7 条、负向 7 条、正向 6 条，118 条可用证据均完成时间与媒体回映。

**评价协议统一，过程可复算。**三个问题共用同一掩码定义与缺失模拟协议，测试集比较在相同训练划分、相同遮挡课程、相同冻结文本编码与相同标准化统计量下完成，配对 bootstrap 按来源视频分组并作 Holm 校正；逐样本的特征张量、词级时间、帧级记录与事件日志一并写盘，参数、耗时与输入哈希汇总于运行日志，环境信息在程序启动时自动记录。单种子学生训练耗时约 40 至 80 s，三个种子的完整训练、缺失干预与附件推理在单卡上可以整体复跑。

## 5.2 模型的不足

词级时间区间由 CTC 强制对齐自动估计，其精度由停顿位置核验、区间结构约束与相对时序一致性共同评价：邻近停顿的词界中 39.2% 落在停顿 50 ms 内，起点一侧高于终点一侧，连读与弱读处的边界位置仍有不确定性；数字、缩写与标点等符号的读法不稳定，在词表中缺少稳定的声学对应，边界处容易产生偏移。定长接口  $K = 50$  对词元数超过 50 的样本只保留前部内容进入判别模型，截断点之后的词元继续保留时间与特征记录，但不参与该样本的预测与解释。

分类误差集中在情感强度较弱的样本上。测试集 273 条分类错误中有 213 条涉及中性类，占 78.0%。逆频率类别加权均衡了训练目标中三类样本的贡献，使中性类召回率由 0.4891 升至 0.5978，但权重只调整各类别在目标函数中的相对比重，无法增加样本本身的有效证据；中性表达与弱情感表达在文本与韵律上的区分线索有限，模型在这类样本上的判别仍不稳定。

解释结论对解释基线与片段粒度具有依赖性。验证子集上 B1 与 B3 的主模态一致率为 87.50%，但  $\kappa$  降至  $-0.0231$ ，B1 下的 10 条非文本主导样本在 B3 下全部转为文本，少数非文本归因会随基线取法改变；局部删除以 2 锚点块为最小单位，块长变化会影响局部排序，两种基线下的绝对贡献排序 Spearman 相关分别为 0.812 和 0.625。当前解释刻画的是模型在指定基线与片段粒度下的行为，尚缺少人工归因作为对照基准。

训练与评价基于附件 2 的官方划分，语料为英文短视频，录制条件、话题分布与说话风格相对集中。语种、领域或采集条件发生变化时，文本分布、韵律统计与视觉帧质量会同时改变，标准化统计量、类别权重与门控参数都需要在新数据上重新估计，模型的跨域表现需要在目标域数据上单独确认。

### 5.3 模型的改进方向

词级对齐可从锚定与读法两端改进。把声学位落交界纳入解码目标，例如在路径搜索中引入词界与停顿区间的对齐代价、对停顿与清辅音设定分段锚定规则，使边界在连读与弱读处更稳定；对数字、缩写与符号建立读法归一化规则与词典约束，改善特殊符号的区间生成；对超长样本采用滑动窗口或分段编码，使截断点之后的词元以完整形式进入判别与解释流程。

局部缺失条件下的判别可扩展有效证据的来源。在样本内候选之外引入跨样本检索与生成式补全，扩大缺口的候选池；按缺口长度自适应调整补全温度  $\tau$  与可靠度温度  $\tau_\rho$ ，使门控在长缺口下更依赖上下文回退；配合类别校准与决策阈值调整改善弱情感样本的区分。组件作用可用受控消融分离：分别关闭分类与强度蒸馏、关闭补全、关闭可靠度监督以及分别关闭同模态与跨模态候选，在相同评估掩码与相同训练种子下比较，区分各部分的独立贡献与集成收益。

解释的稳健性可通过基线与粒度层面的聚合提升。在多种基线与多种片段粒度下分别求解贡献与响应，按排序融合给出综合证据并报告一致性区间；把分类与强度两个任务的证据并置，识别同时支持两类判别的片段；建立人工标注的归因协议，用于考察解释的定位精度与跨样本迁移性。

模型结构不依赖特定数据集，词级锚点、三态掩码与双任务解释流程可按新任务的特征维度、缺失模式与标签分布重新配置，用于课堂录音、客服对话与访谈等带转写文本的音视频情感分析场景。工程实现上，附件 1 的特征提取耗时 9.72 min，其中视觉分支占 85.6%，批量化人脸检测与更轻量的关键点模型可进一步压缩处理时间，为在线场景中按片段增量推理留出空间。

## 参考文献

- [1] Baltrusaitis T, Ahuja C, Morency L P. Multimodal machine learning: A survey and taxonomy[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(2): 423–443.
- [2] Zadeh A, Liang P P, Poria S, Cambria E, Morency L P. Multimodal language analysis in the wild: CMU-MOSEI dataset and interpretable dynamic fusion graph[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (ACL), 2018: 2236–2246.
- [3] Zadeh A, Chen M, Poria S, Cambria E, Morency L P. Tensor fusion network for multimodal sentiment analysis[C]. Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2017: 1103–1114.

- [4] Tsai Y H H, Bai S, Liang P P, Kolter J Z, Morency L P, Salakhutdinov R. Multimodal transformer for unaligned multimodal language sequences[C]. Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL), 2019: 6558–6569.
- [5] Devlin J, Chang M W, Lee K, Toutanova K. BERT: Pre-training of deep bidirectional transformers for language understanding[C]. Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT), 2019: 4171–4186.
- [6] Baevski A, Zhou Y, Mohamed A, Auli M. wav2vec 2.0: A framework for self-supervised learning of speech representations[C]. Advances in Neural Information Processing Systems (NeurIPS), 2020: 12449–12460.
- [7] Graves A, Fernandez S, Gomez F, Schmidhuber J. Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks[C]. Proceedings of the 23rd International Conference on Machine Learning (ICML), 2006: 369–376.
- [8] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[EB/OL]. arXiv:1503.02531, 2015.
- [9] Sun L, Lian Z, Liu B, Tao J. Efficient multimodal transformer with dual-level feature restoration for robust multimodal sentiment analysis[J]. IEEE Transactions on Affective Computing, 2024, 15(1): 309–325.
- [10] Liu Z, Shen Y, Lakshminarasimhan V B, Liang P P, Zadeh A, Morency L P. Efficient low-rank multimodal fusion with modality-specific factors[C]. Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics, 2018: 2247–2256.
- [11] Shapley L S. A value for n-person games[M]//Kuhn H W, Tucker A W. Contributions to the Theory of Games II. Princeton: Princeton University Press, 1953: 307–317.
- [12] Ribeiro M T, Singh S, Guestrin C. "Why should I trust you?": Explaining the predictions of any classifier[C]. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD), 2016: 1135–1144.
- [13] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]. Advances in Neural Information Processing Systems (NeurIPS), 2017: 4765–4774.

## 附录 A 问题一自生成特征文件的存储组织

表 21 所列张量、逐样本记录、帧级支撑与逐词明细构成问题一的全量特征文件，随附件提交；运行环境、关键参数、逐阶段耗时与输入哈希由程序在运行时自动记录，复现记录一并随支撑材料提交。特征张量、词级时间与帧级记录以样本键关联：读取时由样本键定位逐样本记录，再按内容掩码  $P$  与父词索引  $U$  将接口位置还原到词级区间。存储格式、组织结构与读取方式见表 21。

表 21 自生成特征文件的存储组织与读取方式

| 文件                                                     | 内容与读取方式                                                                           |
|--------------------------------------------------------|-----------------------------------------------------------------------------------|
| E1_features.pkl                                        | 全部 100 条样本的 $X^t/X^a/X^v$ 、掩码与质量分量的汇总字典，含版本号与样本数；按样本键索引，用于全量读取与跨样本统计              |
| per_sample/                                            | 逐样本记录，含特征矩阵、内容掩码 $P$ 、父词索引 $U$ 、观测掩码 $O^a/O^v$ 、词级记录与元数据；文件名由样本键转换得到，是逐样本核对与追溯的入口 |
| frames/                                                | 帧级支撑，含音频帧特征与起止区间、视频帧 PTS 与有效标记；与逐样本记录按同一键关联，是帧级时间与覆盖的来源                           |
| E1_alignment_detail.csv                                | 1932 条逐词明细，含区间 $[a, b)$ 、路径置信度与覆盖、扰动及质量分量；用于定位单个词的时间与质量                           |
| E1_manifest.csv                                        | 样本级清单，含文本与媒体统计、模态覆盖、逐阶段耗时与输入哈希；用于覆盖统计与结果核验                                        |
| audit_anchor.json                                      | 边界位置核验记录，含邻近停顿的 1125 个词界、734 个随机对照的偏差分布与起止点分组统计；用于核对词界与声学停顿的对应关系                  |
| env_run_start.json、<br>run_events.log、<br>run_log.json | 运行环境快照（Python 与各库版本、解码器与推理设备）、事件日志（启动、跳过、失败与汇总）与参数汇总（工具、关键参数、耗时与输入哈希）；用于复现核对      |

## 附录 B 问题二结果文件与交付说明

附件 3 的完整预测按原始样本顺序导出为 pred\_附件 3.csv，逐条给出预测极性、连续强度、三类概率、内容锚点数与三模态缺失计数，并附强度预测的种子间标准差；三类概率的排序、极性判决与强度符号可直接由该文件复核。

附件 2 上的评价结果与核验记录同步保留：metrics.csv 保存十类模型在基础输入与 105 种连续缺失条件下的逐条件、逐种子分类与回归指标；paired\_comparison.csv 保存相对九类基线的配对 bootstrap 区间与 Holm 校正结果；mask\_audit.json 逐条件记录内容位、人工缺口与观测删除的核验值；protocol.json 保存训练与评价协议参数及 21 个检查点的 SHA-256 哈希；checks.json 保存划分、掩码与推理设备的一致性检查结果。上述文件与模型权重、逐种子训练日志随支撑材料一并提交。

## 附录 C 问题二专项模型核心代码

问题二局部缺失情感预测专项模型（TSRF-D）的完整实现与训练脚本随支撑材料提交（问题二实现目录）。以下按三态投影、门控补全和联合损失节选核心代码，与正文式 (39) 及相应结构对应；节选保留源文件中的循环与省略位置，便于与支撑材料逐行核对。

```
# q2_model.py: tri-state projection (content / observed / missing)
def _states(self, P, O):
```

```

s = torch.where(P, torch.full_like(P, 2, dtype=torch.long),
                torch.zeros_like(P, dtype=torch.long))
s = torch.where(P & O, torch.ones_like(s), s)
return s

def _project(self, X, P, O, true_target=False):
    z = {}
    for mi, m in enumerate(MODS):
        st = torch.ones_like(P, dtype=torch.long) if true_target else self._states(P,
O[m])
        base = self.e_mod[mi] + self.e_pos[: P.shape[1]]
        zz = self.proj[m](X[m]) + (self.e_state[st] if self.cfg.use_state_emb else
0.0) + base
        z[m] = zz if true_target else zz * P[..., None]
    return z

```

```

# q2_model.py: gated completion with distance, position and continuity prior
def _complete(self, z, P, O):
    cfg = self.cfg
    B, K = P.shape
    dev = P.device
    d = cfg.d
    known = {m: (P & O[m]) for m in MODS}
    run = {m: _run_length(known[m]) for m in MODS}
    cand_mask = torch.stack([known[m] for m in MODS], dim=1) # (B,3,K)
    cmat = cand_mask[:, None].expand(B, 3, 3, K).reshape(B, 3, 3 * K)
    n_cand = cmat.sum(dim=-1)
    empty = (n_cand == 0)
    key = torch.stack([self.k_proj(z[m]) for m in MODS], dim=1)
    val = torch.stack([self.v_proj(z[m]) for m in MODS], dim=1)
    kmat = key.reshape(B, 3 * K, d)
    vmat = val.reshape(B, 3 * K, d)
    q_base = self.e_pos[:K][None, None, :, :] + self.e_state[2][None, None, None, :]
    q = self.q_proj(q_base.expand(B, 3, K, d) + self.e_mod[None, :, None, :])
    qf = q.reshape(B, 3 * K, d)
    d2 = (qf.pow(2).sum(-1)[:, :, None] + kmat.pow(2).sum(-1)[:, None, :]
          - 2.0 * torch.bmm(qf, kmat.transpose(1, 2))) / d
    d2 = d2.clamp(min=0.0).reshape(B, 3, K, 3 * K)
    cost = d2 + cfg.lam_t * self.dt[None, None, :, :]
    cost = cost + (1.0 - cmat.float())[:, :, None, :] * 1e4
    if cfg.use_u_score:
        u = torch.stack([torch.sigmoid(cfg.alpha0 + cfg.alpha1 * known[m].float()
+ cfg.alpha2 * (run[m] / cfg.run_scale).clamp
(0.0, 1.0))
                        for m in MODS], dim=1)
    else:
        u = torch.ones(B, 3, K, device=dev)
        cost = cost + cfg.lam_q * (1.0 - u.reshape(B, 3 * K))[:, None, None, :]
        cost = torch.where(empty[:, :, None, None], torch.zeros_like(cost), cost)
        pi = torch.softmax(-cost / cfg.temperature, dim=-1) * cmat.float()[:, :, None, :]
        pi = pi / pi.sum(-1, keepdim=True).clamp(min=1e-6)
        pi = torch.where(empty[:, :, None, None], torch.zeros_like(pi), pi)
        z_hat = torch.bmm(pi.reshape(B, 3 * K, 3 * K), vmat).reshape(B, 3, K, d)
        cost_rho = torch.where(cmat.bool()[:, :, None, :],
                              torch.clamp(cost, max=1e3),
                              torch.full_like(cost, 1e4))
        cbar = (pi * cost_rho).sum(-1)
        cvar = (pi * (cost_rho - cbar[..., None]).pow(2)).sum(-1)
        cmin = cost_rho.min(-1).values
        nsrc = (n_cand.float() / (3.0 * K))[:, :, None].expand(B, 3, K)
        aratio = torch.stack([known[m].float().sum(-1) / P.float().sum(-1).clamp(min=1)
                              for m in MODS], dim=1)[..., None].expand(B, 3, K)

```

```

gin = torch.stack([cbar, cvar, cmin, nsrc, aratio], -1) # (B,3,K,5)
if cfg.use_target_mod_gate:
    gin = torch.cat([gin, self.e_mod[None, :, None, :].expand(B, 3, K, -1)], -1)
rho = torch.sigmoid(self.g_rho(gin)).squeeze(-1)
rho = torch.where(empty[:, :, None], torch.zeros_like(rho), rho)
return z_hat, rho, dict(n_cand=n_cand, run=run)

```

```

# q2_train.py: compute_loss (excerpt; num/cnt averaging kept from source)
l_cls = F.cross_entropy(logits, y, weight=batch["class_w"])
l_reg = F.huber_loss(r_hat, r, delta=1.0)
p = torch.softmax(logits, dim=-1)
l_cons = ((p[:, 2] - p[:, 0]) - torch.tanh(r_hat / 3.0)).pow(2).mean()
# ...
if cfg["use_rec"] and rec:
    num, cnt = 0.0, 0
    for m, d in rec.items():
        tgt = x_true[m][batch["hard"][m]]
        num = num + F.smooth_l1_loss(d["pred"], tgt, beta=1.0, reduction="mean")
        cnt += 1
    if cnt:
        l_rec = num / cnt
# ...
if cfg["use_kd_cls"] and batch.get("t_logits") is not None:
    T = float(cfg.get("T_kd", 2.0))
    tlog = batch["t_logits"].detach()
    pT = torch.softmax(tlog / T, dim=-1)
    logq = torch.log_softmax(logits / T, dim=-1)
    l_dc = F.kl_div(logq, pT, reduction="batchmean") * (T * T)
if cfg["use_kd_reg"] and batch.get("t_reg") is not None:
    l_dr = F.huber_loss(r_hat, batch["t_reg"].detach(), delta=1.0)
l = (l_cls + cfg["lam_r"] * l_reg + cfg["lam_c"] * l_cons
    + cfg["lam_dc"] * l_dc + cfg["lam_dr"] * l_dr
    + cfg["lam_rec"] * l_rec + cfg["lam_rel"] * l_rel)

```

## 附录 D 问题三结果文件与交付说明

附件 4 的预测、证据与逐块响应统一存放于交付目录优化实验/输出。pred\_附件 4.csv 保存全量预测及分类、强度双任务的有符号贡献；evidence\_dual\_task.csv 按样本、模态与任务保存局部证据，共 120 行，逐条给出证据块的锚点位置、证据词、有符号响应、作用方向、CTC 时间区间、关键帧索引与 PTS、媒体文件及原视频哈希，其中 118 行完成时间回映，2 行为第 13 条样本视觉分支不可用时的标记；a4\_local\_all.json 保存全部逐块删除响应，可用于复核证据排序与作用方向。

解释卡按统一模板生成，保留有符号最高分片段、逐块响应、证据词时间与关键帧，涵盖跨模态分歧、视觉主模态与缺模态降级三类样本；逐样本的跨模态一致性记录见 cards\_summary.csv，20 张卡片与该表一并随支撑材料提交。

## 附录 E 问题三专项模型核心代码

问题三子集感知可解释预测专项模型的完整实现随支撑材料提交（问题三实现目录）。以下按联盟采样、目标函数、精确 Shapley、逐块删除与忠实性评价节选核心代码。

```

# q3_train.py: coalition sampling for C0 (0.70 full set, 0.30 uniform over 7 subsets)
def sample_bits(self, n, rng):
    if self.variant["sampling"] == 'full':

```

```

        return np.full(n, 7)
    if self.variant['sampling'] == 'uniform':
        bits = np.full(n, 7)
        ch = rng.random(n) < .3
        bits[ch] = rng.integers(0, 7, int(ch.sum()))
        return bits
    return rng.choice(8, n, p=WEIGHTS)

# q3_train.py: subset-aware objective (CE + Huber + direction consistency, weight 0.2)
loss = (F.cross_entropy(z['logits'], y[blk], weight=cw)
        + F.huber_loss(z['r_hat'], r[blk])
        + BASE['cons'] * ((pr[:, 2] - pr[:, 0]) - torch.tanh(z['r_hat'] / 3)).square()
        .mean())

```

```

# q3_explain.py: exact Shapley values for three players
def shapley(values):
    values = np.asarray(values, dtype='float64')
    out = np.zeros((len(values), 3), dtype='float64')
    for j in range(3):
        for s in range(8):
            if s & (1 << j):
                continue
            k = s.bit_count()
            w = math.factorial(k) * math.factorial(2 - k) / 6
            out[:, j] += w * (values[:, s | (1 << j)] - values[:, s])
    return out

# q3_explain.py: enumerate the 8 coalitions (B1 baseline) and verify efficiency
for s in range(8):
    X = {m: d['X'][m].copy() for m in Q.MODS}
    O = {m: d['O'][m].copy() for m in Q.MODS}
    for j, m in enumerate(Q.MODS):
        if not s & (1 << j):
            X[m][:] = 0
            O[m][:] = False
    p, r = Q.predict(ms, X, d['P'], O, per_seed=True)
    probs.append(p)
    regs.append(r)
# ...
value = np.stack([logodds(p[:, s], ref) for s in range(8)], 1)
phi = shapley(value)
residual = np.abs(phi.sum(1) - (value[:, 7] - value[:, 0]))
assert residual.max() < 1e-8

```

```

# q3_explain.py: block-wise deletion, AOPC and sufficiency (excerpt)
def blocks_of(d, i):
    pos = np.flatnonzero(d['P'][i])
    return [pos[j:j + 2].tolist() for j in range(0, len(pos), 2)], pos

orders = {'top': np.argsort(-scores[i], kind='stable'),
          'low': np.argsort(scores[i], kind='stable')}
orders.update({f'random{k}': rng.permutation(len(bb)) for k in range(3)})
for kind, order in orders.items():
    for f in fractions:
        nb = min(len(bb), max(1, int(np.ceil(f * len(bb)))))
        kk = sorted(k for j in order[:nb] for k in bb[j])
        requests.append((i, m, kk))
    if kind == 'top':
        other = np.setdiff1d(pos, kk).tolist()
        requests.append((i, m, other))
        keys.append((i, 'sufficiency', f))

```

```
# ...
boot = diffs[rng.integers(0, len(diffs), (2000, len(diffs)))].mean(1)
summary = dict(curves=curves, fractions=fractions, n=len(diffs),
               aopc_top_minus_random=float(diffs.mean()),
               ci95=np.quantile(boot, [.025, .975]).tolist())
```